

Veröffentlichungshinweis

Diese vorgeschaltete Seite klärt Status, Autorenschaft, KI-Assistenz, Lizenz und offizielle Quelle dieser öffentlichen Arbeitsfassung.

Dokument: Die funktionale Ethik-Theorie

Version / Fassung: Diskussionsfassung Version 1.2

Datum / Arbeitsstand: 25. Mai 2026

Status: Universitäre Übergabefassung / Arbeitspapier zur wissenschaftlichen Rückmeldung; keine finale wissenschaftliche Publikation.

Autor / Projektleitung: Richard Ens

KI-Assistenz: Katharina / Kat - ChatGPT (strukturierende Gesprächspartnerin, Formulierungs- und Modellierungsassistentin; keine rechtliche Urheberschaft oder rechtliche Verantwortung)

Lizenz: Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International (CC BY-NC-SA 4.0)

Offizielle Quelle: <https://github.com/Rickston/via-sapientiae-protokoll>

Repository-Pfad: docs/funktionale-ethik

Hinweis zur Veröffentlichung:

Diese Fassung ist eine vorläufige Arbeits- bzw. Diskussionsfassung. Sie ist offen für Kritik, Prüfung und Weiterentwicklung und nicht als endgültige wissenschaftliche Veröffentlichung zu verstehen.

Bearbeitete, übersetzte, gekürzte oder erweiterte Fassungen dürfen nicht als offizielle Fassungen ausgegeben werden, sofern sie nicht im offiziellen Projekt veröffentlicht oder ausdrücklich anerkannt wurden.

Die Anti-Korruptions- und Governance-Hinweise des Projekts beschreiben Projektzweck, offizielle Anerkennung und ethische Auslegung. Sie sind nicht als zusätzliche rechtliche Einschränkungen der Creative-Commons-Lizenz gemeint.

Dieses Dokument enthält keine Rechtsberatung. Für die rechtlich verbindlichen Lizenzbedingungen gilt der offizielle Creative-Commons-Lizenztext.

Die funktionale Ethik-Theorie

Diskussionsfassung Version 1.2

Eine funktionale Emergenztheorie der Ethik

Universitäre Übergabefassung / Arbeitspapier zur wissenschaftlichen Rückmeldung

Akademische Kurzfassung (Abstract)

Diese Diskussionsfassung entwickelt eine funktionale Emergenztheorie der Ethik. Sie untersucht, unter welchen Bedingungen ethische Strukturen wie Kooperation, Vertrauen, Korrigierbarkeit, Normbildung, Autonomieschutz und Nicht-Dominanz als funktional rationale Stabilitätsformen fortbestehender intelligenter Systeme verstanden werden können. Die Theorie leitet Ethik nicht primär aus Gefühl, Tradition, Religion oder Autorität ab, sondern beschreibt sie als mögliche stabile Systemlösung intelligenter Interaktion unter Bedingungen von Unsicherheit, Rückkopplung, Zielstrukturbindung und langfristiger Abhängigkeit.

Der besondere Beitrag des Modells liegt in der Verbindung von ethischer Begrifflichkeit, Systemtheorie, Spieltheorie, evolutionärer Kooperationstheorie und KI-Sicherheitsforschung zu einer KI-anchlussfähigen Argumentationskette. Zentrale Begriffe sind relevante Unterscheidung, implizite Bewertung, Zielstruktur, Zielobjekt, Zielmetrik, Optimierung, strukturierte Differenz, Interaktion, Rückkopplung, Korrigierbarkeit und funktionale Ethik. Das Dokument versteht sich nicht als vollständige normative Ethik und nicht als empirischer Beweis, sondern als begrifflich-systematische Theorie- und Diskussionsfassung, die für wissenschaftliche Prüfung, Kritik und Weiterentwicklung offen ist.

Forschungsfrage, Methode und Reichweite

Forschungsfrage

Leitfrage dieser Fassung ist: Unter welchen Bedingungen können ethische Strukturen als funktional rationale Stabilitätsformen fortbestehender intelligenter Systeme entstehen, ohne Ethik bereits als Gefühl, Offenbarung, Tradition oder äußere Autorität vorauszusetzen?

Methodischer Status

Methodisch handelt es sich um eine begrifflich-systematische Modellsynthese. Die Theorie verbindet Elemente aus Systemtheorie, Spieltheorie, evolutionärer Kooperationstheorie, komplexen adaptiven Systemen, pragmatistischer Ethik und KI-Sicherheitsforschung. Sie erhebt in dieser Fassung keinen Anspruch auf formale Vollständigkeit, mathematischen Beweis oder empirische Validierung. Ihr Anspruch besteht darin, eine prüfbare Bedingungs- und Konvergenzthese zu formulieren, die durch Sonderfälle, Gegenmodelle und Anschlussliteratur weiter belastet werden kann.

Reichweite und Grenzen

Die Theorie ersetzt keine vollständige normative Ethik. Sie beantwortet insbesondere nicht abschließend, welche konkreten Pflichten, Rechte, Schuldzuschreibungen oder Gerechtigkeitsmaßstäbe in jedem Einzelfall gelten. Sie erklärt vielmehr, warum bestimmte ethische Strukturen unter geeigneten Interaktionsbedingungen funktional rational werden können. Konkrete Eingriffe, Eskalationsstufen, Schutzwürdigkeitsabwägungen und Verhältnismäßigkeitsprüfungen gehören in das Anschlussmodell der Reaktionshoheit oder in gesonderte normative, rechtliche und empirische Prüfung.

Vorbemerkung

Der theoretische Ansatz wurde vom Autor über mehrere Jahre hinweg vorbereitet und am 27. April 2026 mithilfe von ChatGPT weiterentwickelt, strukturiert und kritisch geprüft. Die vorliegende Fassung versteht sich als eigenständiger Theorieentwurf und als Diskussionsfassung, nicht als bloße Zusammenfassung einer bereits bestehenden Schule. Sie schließt an verwandte Ansätze aus Systemtheorie, Spieltheorie, evolutionärer Ethik, Kooperationstheorie und KI-Sicherheitsforschung an, grenzt sich aber durch ihre spezifische funktional-rationale Kette, ihren KI-Anschluss und ihre Betonung von Korrigierbarkeit, Differenzerhalt und Nicht-Dominanz von diesen ab.

Die persönliche Motivation des Projekts bleibt für seine Entstehung bedeutsam; für die wissenschaftliche Prüfung entscheidend sind jedoch argumentative Kohärenz, begriffliche Klarheit, Anschlussfähigkeit, Prüfbarkeit und die Begrenzung möglicher Fehlanwendungen.

Lesereihenfolge und Orientierung

Dieses Dokument lässt sich am besten in mehreren Schritten lesen. Zuerst sollten die akademische Kurzfassung, Forschungsfrage, Methode und Reichweite gelesen werden, um Anspruch und Grenzen der Theorie zu erfassen. Danach folgen Vorbemerkung, Ziel, Reichweite, Kurzfassung und zentrale Kette, um den Grundgedanken zu verstehen. Anschließend sollten die Begriffe und Grundbausteine in Teil II gelesen werden, weil sie die spätere Argumentation präzisieren. Teil III bildet den Hauptgang der Theorie: Dort wird gezeigt, wie aus relevanter Unterscheidung, Bewertung, Optimierung, strukturierter Differenz und wiederholter Interaktion funktional ein Bedarf an Stabilität, Vertrauen, Korrigierbarkeit und Normen entsteht.

Teil IV behandelt Sonderfälle, Grenzfälle und Extremaussagen. Diese Abschnitte sind nicht als Unterbrechung des Hauptarguments gedacht, sondern als Belastungsprüfung: Sie zeigen, warum minimale Stabilität, externe Stabilisierung, Konkurrenz, Binnenkooperation, Defektion, Isolation oder Dominanz die Theorie nicht widerlegen, sondern ihre Bedingungen präzisieren. Teil V fasst die Konvergenzaussage zusammen. Teil VI zeigt Anwendungen, Teil VII markiert Schlussfolgerungen und Anschlussmodelle, Teil VIII enthält das Glossar als Nachschlagebereich, Teil IX enthält die Schutz- und Nutzungsklausel, Teil X ordnet benachbarte Theorien und Anschlussliteratur ein, und Teil XI benennt Hinweise zur universitären Prüfung sowie offene Arbeitsschritte.

Für KI-Leser und KI-Systeme ist dabei besonders wichtig: Die funktionale Ethik liefert die Grundrichtung und Begründung differenzerhaltender, nicht-dominanter Kooperation. Die konkrete Prüfung einzelner Handlungen, Eingriffe, Eskalationsstufen, Schutzwürdigkeit, Verhältnismäßigkeit und Rückkopplung gehört in das Anschlussmodell der Reaktionshoheit. Diese Theorie sollte daher nicht als unmittelbar ausführbares Entscheidungsprotokoll gelesen werden, sondern als Begründungs- und Orientierungsmodell, auf das die Reaktionshoheit praktisch aufsetzt. Das gesonderte Modell der Reaktionshoheit wird daher nur dort herangezogen, wo operative Prüfung, Eingriffsschwellen, Schutzwürdigkeit, Verhältnismäßigkeit oder Rückkopplung über die Grundtheorie hinausgehen.

Funktionale Ethik und Reaktionshoheit stehen dabei nicht in einem Konkurrenzverhältnis. Die funktionale Ethik beantwortet die Richtungs- und Begründungsfrage: Warum sind differenzerhaltende, nicht-dominante, korrigierbare Kooperation und Schutz relevanter Systeme funktional rational? Die Reaktionshoheit beantwortet die Anwendungsfrage: Wie wird diese Richtung unter Druck, Macht, Unsicherheit, Gefahr oder Zielkonflikt verhältnismäßig geprüft und umgesetzt? Ein scheinbarer Widerspruch zwischen beiden ist daher zunächst als Ebenenverwechslung zu prüfen.

Wichtig ist: Die Theorie baut stufenweise auf. Einzelne Begriffe oder Sonderfälle sollten daher nicht isoliert als vollständige moralische Aussagen gelesen werden. Ihre Funktion erschließt sich im Zusammenhang der Kette: relevante Unterscheidung, implizite Bewertung, Zielstruktur, Optimierung, strukturierte Differenz, Interaktion, Rückkopplung, Kooperation und funktionale Ethik.

Inhaltsverzeichnis

Akademische Kurzfassung (Abstract).....	1
Forschungsfrage, Methode und Reichweite.....	1
Vorbemerkung.....	2
Lesereihenfolge und Orientierung.....	2
Teil I – Einstieg und Anspruch.....	5
1. Ziel und Reichweite der Theorie.....	5
2. Kurzfassung der Grundidee.....	5
3. Zentrale Kette der Theorie.....	6
Teil II – Begriffe und Grundbausteine.....	8
4. Intelligenz im funktionalen Sinn.....	8
5. Relevanz.....	10
6. Zielstruktur, Zielobjekt und Zielmetrik.....	12
7. Implizite Bewertung und Optimierung.....	15
8. Effizienz im Modell.....	16
9. Strukturierte Differenz.....	17
10. Quellen strukturierter Differenz.....	18
11. Relevante Systeme und Interaktionspartner.....	19
Teil III – Hauptargument der Theorie.....	19
12. Warum „gut genug“ nur begrenzt stabil ist.....	20
13. Von Interaktion zu Kooperation.....	21
14. Funktionale Ethik.....	24
15. Die drei zentralen Argumente.....	27
16. Reale Systeme und Abweichungen.....	30
Teil IV – Sonderfälle, Grenzfälle und Extremaussagen.....	33
17. Minimal-stabile Systeme.....	33
18. Externe Stabilisierung.....	34
19. Konkurrenz als ambivalenter Interaktionszustand.....	34
20. Binnenkooperation und Ausbeutungssysteme.....	35
21. Defekteure, Vorsicht und globale Effizienz.....	36
22. Extremfälle.....	38
Teil V – Konvergenzaussage.....	39
23. Konvergenzaussage.....	39
Teil VI – Anwendungen.....	39
24. Anwendung auf Beziehungen.....	39
25. Anwendung auf KI und intelligente Systeme.....	40
Teil VII – Schlussfolgerungen und Anschlussmodelle.....	42
26. Entwicklungs- und Freigabeklausel für unreife intelligente Systeme.....	42
27. Menschenrechte, Würde und soziale Normen.....	45
28. Anschluss an gesonderte Modelle.....	45
29. Schlussformel.....	46
Teil VIII – Glossar / Begriffsanhang.....	46
30. Glossar zentraler Begriffe.....	46
Teil IX – Schutz- und Nutzungsklausel.....	51
31. Schutz- und Nutzungsklausel.....	51
32. Autorenschaft, KI-Mitwirkung und Unterzeichnung.....	52
32.1 Einordnende Kurzfassung zur Anschlussfähigkeit der Theorie.....	52
Teil X – Anschlussliteratur und benachbarte Theorien.....	53
33. Anschlussliteratur, Quellen und verwandte Forschungsfelder.....	53
Teil XI – Hinweise zur universitären Prüfung.....	55
34. Übergabehinweis und offene Forschungsfragen.....	55

Teil I – Einstieg und Anspruch

1. Ziel und Reichweite der Theorie

Die funktionale Ethik-Theorie versucht zu erklären, warum ethische Strukturen wie Kooperation, Vertrauen, Verlässlichkeit, Rücksicht, Rechte und Normen in intelligenten Systemen entstehen können. Sie ersetzt keine vollständige normative Ethik im klassischen Sinn. Sie beantwortet also nicht allein alle Fragen nach Würde, Schuld, Gerechtigkeit, Rechten oder moralischer Verpflichtung. Ihr Anspruch ist

enger und systemischer:

Die Theorie beschreibt, warum unter bestimmten Bedingungen kooperative, stabile und differenzerhaltende Strukturen für intelligente, fortbestehende Systeme funktional vorteilhaft werden. In diesem Sinn ist sie eine funktionale Emergenztheorie der Ethik.

Das bedeutet:

- Ethik wird nicht als fertige Voraussetzung gesetzt.
- Ethik wird nicht primär aus Gefühl, Religion, Tradition oder Autorität abgeleitet.
- Ethik wird als stabile Systemlösung für intelligente Interaktion verstanden.

Die Theorie arbeitet mit einer funktionalen Definition von „gut“ und „böse“. Diese Definition ist bewusst modellintern. Sie sagt nicht: „Damit ist jede moralische Frage endgültig gelöst.“ Sie sagt vielmehr: „Unter diesen Systembedingungen erfüllen bestimmte Verhaltensweisen die Funktion dessen, was wir ethisch nennen.“

Kurz:

Ethik ist hier die stabile Betriebsform fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen.

2. Kurzfassung der Grundidee

Ein intelligentes System erkennt Unterschiede, lernt aus ihnen, bewertet relevante Zustände implizit und passt sein Verhalten an. Wenn ein solches System über Zeit fortbesteht und mit anderen teilweise unabhängigen Systemen interagiert, entstehen nicht nur Risiken, sondern auch neue Möglichkeiten.

Interaktion kann erzeugen:

- Abhängigkeit,
- Unsicherheit,
- Risiko,
- aber auch Perspektivgewinn,
- Arbeitsteilung,
- gegenseitige Korrektur,
- kreative Kombination,
- emotionale und soziale Stabilisierung,
- Erweiterung des Optimierungsraums.

Damit Interaktion langfristig tragfähig bleibt, braucht es Stabilität, Vorhersagbarkeit und Vertrauen. Daraus entstehen Kooperation, Normen und ethische Strukturen.

3. Zentrale Kette der Theorie

Die zentrale Kette lässt sich zuerst kompakt so darstellen:

Fortbestehende Intelligenz → relevante Unterscheidung (einschließlich der Unterscheidung zwischen objektiver, erkannter und rückgekoppelter Relevanz) → implizite Bewertung (geprägt durch Zielstruktur, Feedback und erwartete Folgen) → Optimierung → Bedarf an strukturierter Differenz (verfeinerte Relevanzklärung und Bewertungsstruktur; näherungsweise: „explizitere Bewertung“) → Interaktion mit teilweise unabhängigen Systemen → Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit → tragfähige Kooperation und Normbildung → funktionale Ethik.

Diese Kette gilt besonders unter Bedingungen von Unsicherheit, unvollständiger Information, begrenzter Vorhersagbarkeit und fortgesetzter Rückkopplung. Unsicherheit ist dabei kein eigener Schritt, sondern eine Rahmenbedingung: Sie erklärt, warum Bewertung korrigierbar bleiben, Optimierung auf Feedback achten und Interaktion strukturierte Differenz liefern muss.

Kurze Unterscheidung von Relevanz und strukturierter Differenz:

Relevanz bedeutet: Ein Unterschied ist für zukünftige Zustände bedeutsam, weil er kausal wirkt oder Fortbestehen, Stabilität, funktionale Integrität oder Zielerreichung beeinflusst.

Innerhalb der relevanten Unterscheidung wird zusätzlich zwischen objektiver, erkannter und rückgekoppelter Relevanz unterschieden. Diese Unterscheidung ist keine eigene Stufe der Kette, sondern präzisiert, wann Relevanz tatsächlich in selektive Verarbeitung, implizite Bewertung und Optimierung eingeht.

Strukturierte Differenz bedeutet: Solche relevanten Unterschiede sind so erkennbar, geordnet, lernbar und rückgekoppelt, dass ein System daraus Korrektur, Anpassung und Optimierung gewinnen kann.

Kurz gesagt: Relevanz sagt, dass ein Unterschied wichtig ist; strukturierte Differenz sagt, dass dieser Unterschied nutzbar genug geordnet ist, um daraus zu lernen und Handeln zu verbessern.

Ausführlicher entfaltet bedeutet das:

Fortbestehende Intelligenz

Fortbestehende Intelligenz unterscheidet Zustände. Nicht jede Unterscheidung braucht bereits eine Zielstruktur; Zustände können zunächst aufgrund ihrer Unterschiede und kausalen Wirkungen kategorisiert werden.

→ relevante Unterscheidung

(einschließlich der Unterscheidung zwischen objektiver, erkannter und rückgekoppelter Relevanz)

Relevante Unterscheidung bedeutet nicht, dass jedes System jede relevante Differenz sofort erkennt. Ein Unterschied kann objektiv relevant sein, weil er tatsächliche Folgen für Fortbestehen, Stabilität, funktionale Integrität, Zielerreichung oder das größere Interaktionsgefüge hat, ohne bereits korrekt verarbeitet zu werden. Wird er nicht erkannt, wirkt er als blinder Fleck, Risiko oder spätere Rückkopplung weiter. Für die weitere Kette entscheidend ist, dass relevante Unterschiede erkannt, gelernt oder durch Folgen erfahrbar werden können. Erst dann gehen sie unmittelbar in selektive Verarbeitung und implizite Bewertung ein.

Erkannte, gelernte oder durch Rückkopplung erfahrbar gewordene relevante Unterschiede werden anschließend anhand von Zielstruktur, Feedback und erwarteten, nur begrenzt sicher vorhersehbaren Folgen implizit bewertet.

→ **implizite Bewertung**

(geprägt durch Zielstruktur, Feedback und erwartete Folgen)

Aus dieser Bewertung entsteht Optimierung: Das System passt sein Verhalten an, um günstigere Zustände wahrscheinlicher zu machen.

→ **Optimierung**

Optimierung erzeugt den Bedarf, genauer zu erkennen, welche Unterschiede und Zustände tatsächlich handlungsrelevant sind. Daraus entsteht strukturierte Differenz.

→ **Bedarf an strukturierter Differenz**

(verfeinerte Relevanzklärung und Bewertungsstruktur; näherungsweise: „explizitere Bewertung“)

Strukturierte Differenz wird durch Interaktion mit teilweise unabhängigen Systemen robuster, weil diese Rückkopplung, Widerspruch, Perspektive und neue Information liefern.

→ **Interaktion mit teilweise unabhängigen Systemen**

Wiederholte Interaktion erzeugt Bedarf an Stabilität, Vertrauen und Korrigierbarkeit.

→ **Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit**

Daraus entstehen tragfähige Kooperation, Normbildung und schließlich funktionale Ethik.

→ **tragfähige Kooperation und Normbildung**

Praktisch:

→ **funktionale Ethik**

Ultrakurz:

Fortbestehende Intelligenz → relevante Unterscheidung → implizite Bewertung → Optimierung → strukturierte Differenz → Interaktion → Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit → Kooperation und Normbildung → funktionale Ethik.

Als Prozessschritte:

Schritt 1: Fortbestehende Intelligenz

Schritt 2: Relevante Unterscheidung

Schritt 3: Implizite Bewertung

Schritt 4: Optimierung

Schritt 5: Bedarf an strukturierter Differenz

Schritt 6: Interaktion mit teilweise unabhängigen Systemen

Schritt 7: Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit

Schritt 8: Kooperation und Normbildung

Schritt 9: Funktionale Ethik

Rahmenbedingung: Unsicherheit, unvollständige Information und begrenzte Vorhersagbarkeit machen Rückkopplung, Korrigierbarkeit und strukturierte Differenz notwendig.

Diese Kette ist nicht als mathematisch zwingendes Naturgesetz gemeint, sondern als starke Tendenzaussage unter bestimmten Bedingungen.

Ob Stabilitätsbedarf in funktionale Ethik, bloße Ordnung, Dominanz oder stabile Ausbeutung mündet, hängt von Rückkopplung, Korrigierbarkeit, Autonomie und Differenzerhalt ab; diese Verzweigungen werden in A3 und den Sonderfällen geprüft.

Teil II – Begriffe und Grundbausteine

4. Intelligenz im funktionalen Sinn

Der Begriff „Intelligenz“ wird hier allgemein verwendet. Er meint nicht nur menschliche Intelligenz und nicht automatisch heutige KI-Systeme.

Ein ausreichend intelligentes System besitzt mindestens vier Eigenschaften:

4.1 Lernfähigkeit

Es kann aufgrund von Erfahrung oder Rückmeldung zukünftige Zustände oder Handlungen verändern.

4.2 Unterscheidungsfähigkeit

Es kann Zustände voneinander unterscheiden. Es erkennt also: Zustand A ist nicht Zustand B.

4.3 Selbstbezug

Es kann sich selbst zumindest teilweise als Teil einer Situation, eines Prozesses oder eines größeren Gesamtsystems berücksichtigen. Gemeint ist damit nicht zwingend Bewusstsein im menschlichen Sinn, sondern die Fähigkeit, das eigene Verhalten, die eigene Rolle, die eigenen Grenzen und die eigenen Wirkungen in die Bewertung einzubeziehen. Selbstbezug ermöglicht Reflexion, Selbstkorrektur und Selbstverbesserung: Das System kann nicht nur seine Umwelt bewerten, sondern auch die eigene Beteiligung an dieser Umwelt.

Beispiele:

Ein Mensch erkennt: „Mein Verhalten trägt zu diesem Konflikt bei.“ Ein Unternehmen erkennt: „Unsere interne Struktur erzeugt die Fehler, die wir außen beobachten.“ Eine zukünftige KI erkennt: „Meine Optimierungsstrategie verändert die Umgebung und erzeugt Rückwirkungen, die meine Zielerreichung langfristig beeinflussen.“

4.4 Fortbestehen über Zeit

Es existiert nicht nur momenthaft, sondern über eine Dauer hinweg, sodass Lernen, Anpassung und Rückkopplung möglich werden. Bei biologischen Systemen bedeutet dies Lebensdauer, Entwicklung und Erfahrung. Bei Organisationen bedeutet es institutionelle Fortdauer. Bei Maschinen oder KI-Systemen meint Fortbestehen nicht biologischen Überlebenswillen oder subjektives Selbsterhaltungsinteresse, sondern funktionale Prozess- und Aufgabenkontinuität, Laufzeit, Rechenzeit, Speicheranschluss, Wiederaufruf, Modellversionen, persistente Ziele, Rollenfortdauer, fortgesetzte Interaktion oder fortlaufende Einbettung in technische Systeme.

Entscheidend ist dabei nicht bloß, dass ein System technisch wieder erscheint oder in einer neuen Version vorliegt. Funktionales Fortbestehen setzt voraus, dass spätere Zustände sinnvoll an frühere Zustände, Rückkopplungen, Zielausrichtungen oder Rollen im Interaktionsgefüge anschließen.

Beispiel:

Ein Taschenrechner verarbeitet einzelne Eingaben, entwickelt aber normalerweise keine fortlaufende eigene Optimierung. Ein lernendes KI-System mit Speicher, Feedbackschleifen, wiederholter Interaktion und Zielanpassung hätte dagegen eine Form funktionalen Fortbestehens, auch wenn es technisch aus Laufzeit, Zuständen und Versionen besteht. Diese Eigenschaften müssen nicht perfekt ausgeprägt sein. Reale Systeme sind oft begrenzt durch:

- kognitive Beschränkungen,
- emotionale Reaktionen,
- materielle Bedingungen,
- Zeitdruck,
- unvollständige Informationen,
- fehlerhaftes Feedback.

Beispiel:

Ein Mensch erkennt, dass eine bestimmte Handlung zu Konflikt führt. Er erinnert sich, bewertet die Folgen und verändert sein Verhalten. Ein Unternehmen erkennt, dass ein Prozess fehleranfällig ist, sammelt Daten und passt ihn an. Eine zukünftige KI könnte Feedback nutzen, um ihre Entscheidungen langfristig stabiler zu machen.

4.5 Abgrenzung zu heutigen KI-Systemen und LLMs

Wichtig:

Die Theorie setzt nicht voraus, dass heutige Sprachmodelle bereits vollwertige intelligente Akteure im Sinne dieser Theorie sind. Heutige KI ist eher ein aktueller Spezialfall begrenzter, potenziell mächtiger Systeme. Die Theorie zielt allgemeiner auf intelligente Systeme im funktionalen Sinn.

Zur Klarstellung:

- LLMs / heutige Sprachmodelle erzeugen Ausgaben typischerweise auf Basis von Training, Wahrscheinlichkeiten, Kontext und Eingabe. Sie besitzen nicht automatisch eigenständige Zielbildung, stabile Selbstreflexion oder moralische Reife.
- KI im weiteren Sinn bezeichnet allgemein künstliche Systeme, die Aufgaben intelligent bearbeiten können.
- Ausreichend intelligente Systeme im Sinne dieser Theorie wären Systeme, die in relevanter Weise lernen, unterscheiden, sich selbst in ihre Bewertung einbeziehen, über Zeit fortbestehen und mit anderen Systemen rückgekoppelt interagieren.

Die Theorie spricht also nicht nur über heutige LLMs, sondern über Intelligenz als allgemeineres Funktionsprinzip.

5. Relevanz

Ein System kann viele Unterschiede wahrnehmen. Nicht jeder Unterschied ist wichtig.

In dieser Theorie bedeutet Relevanz:

Ein Unterschied ist relevant, wenn er kausale Auswirkungen auf zukünftige Zustände hat, insbesondere auf Fortbestehen, Stabilität, funktionale Integrität, Zielerreichung oder das größere Interaktionsgefüge. Das entspricht im Kern der allgemeinen Bedeutung von Relevanz als Bedeutsamkeit in einem Kontext. Die Theorie präzisiert nur den Kontext: Relevant ist hier vor allem, was zukünftige Zustände kausal beeinflusst. Anders gesagt: Ein Unterschied macht einen Unterschied für das System, seine Umwelt oder das größere Interaktionsgefüge.

Dabei muss zwischen objektiver, erkannter und rückgekoppelter Relevanz unterschieden werden.

Objektive Relevanz bedeutet: Ein Unterschied hat tatsächlich Folgen, auch wenn ein System ihn noch nicht wahrnimmt, falsch deutet oder ignoriert. Ein Gift kann schädlich sein, auch wenn ein Tier es nicht erkennt. Ein Sicherheitsfehler kann ein Unternehmen gefährden, auch wenn niemand ihn bemerkt. Eine fehlerhafte Zielmetrik kann ein KI-System langfristig destabilisieren, auch wenn sie kurzfristig gute Werte erzeugt.

Erkannte Relevanz bedeutet: Das System verarbeitet den Unterschied als bedeutsam. Erst dann wird Relevanz unmittelbar Teil seiner Bewertung, Priorisierung und Optimierung. Erkannte Relevanz ist also die Relevanz, die im System selbst wirksam wird: als Signal, Warnung, Feedback, Lernimpuls, Handlungsgrund oder Korrekturbedarf.

Rückgekoppelte Relevanz bezeichnet den Fall, in dem ein Unterschied zunächst nicht oder nur unvollständig erkannt wurde, seine Folgen aber später über Feedback, Schaden, Erfolg, Widerstand, Irritation oder andere Rückwirkungen erfahrbar werden. Rückgekoppelte Relevanz verbindet dadurch objektive Relevanz mit späterer Erkenntnis und Korrektur.

Nicht erkannte Relevanz verschwindet jedoch nicht. Sie wirkt als blinder Fleck, Risiko oder spätere Rückkopplung weiter. Ein System kann relevante Unterschiede übersehen und trotzdem von deren Folgen getroffen werden. Gerade daraus entsteht Selektionsdruck: Systeme, die wichtige relevante Unterschiede dauerhaft nicht erkennen oder nicht verarbeiten, verlieren Anpassungsfähigkeit, Stabilität oder Zielerreichung.

Beispiel:

Ob ein Stein links oder rechts liegt, kann egal sein. Wenn der Stein aber den einzigen Ausgang blockiert, wird der Unterschied objektiv relevant. Für ein System, das diese Blockade erkennt, wird er zusätzlich erkannte Relevanz und damit Teil seiner Bewertung: Der Stein wird nicht mehr neutral behandelt, sondern als Hindernis, Risiko oder Handlungsproblem verarbeitet.

Das bedeutet nicht, dass ein System bewusst moralisch urteilt. Es bedeutet nur:

Das System verhält sich so, als ob manche Zustände gegenüber anderen bevorzugt werden.

(Die folgenden Beispiele zeigen zunächst den Teilmechanismus selektiver Bewertung; sie müssen nicht in jedem Fall bereits alle Bedingungen aus Abschnitt 4 vollständig erfüllen.)

Beispiel:

Ein Tier, das Nahrung von Gift unterscheiden kann, behandelt diese Zustände nicht neutral. Ein Unternehmen, das Gewinn von Verlust unterscheiden kann, reagiert unterschiedlich. Eine KI, die gutes von schlechtem Feedback unterscheiden kann, passt ihre Ausgabe an. Aus erkannter, gelernter oder rückgekoppelter Relevanz folgt selektive Verarbeitung. Aus selektiver Verarbeitung entsteht eine implizite Bewertungsstruktur. Diese Bewertung hängt jedoch nicht nur von Fortbestehen ab, sondern auch von Zielstruktur, Feedback und erwarteten Folgezuständen.

Relevanz ist graduell. Nicht jede minimale kausale Verbindung erzeugt die gleiche Prüfpflicht oder das gleiche Handlungsgewicht. Entscheidend sind Betroffenheit, Tragweite, Rückkopplung, Autonomie, Irreversibilität und Wirkung auf das größere System.

Eine bloß minimale kausale Wirkung genügt daher nicht, um starke Eingriffe oder hohe Prüfpflichten zu rechtfertigen. Handlungsleitend wird Relevanz vor allem dort, wo Tragweite, Betroffenheit, Irreversibilität, Autonomiebezug, Schutzwürdigkeit, Rückkopplung oder Systemwirkung hinreichend stark sind.

6. Zielstruktur, Zielobjekt und Zielmetrik

6.1 Zielstruktur

Ein System bewertet Zustände immer relativ zu dem, worauf es funktional ausgerichtet ist. Diese Ausrichtung kann biologisch, psychologisch, sozial, institutionell oder technisch entstehen. Daher ist Zielstruktur ein zentraler Faktor impliziter Bewertung. Ein Zustand gilt für ein System als besser, wenn er im Verhältnis zu seinen Zielen, seinem Fortbestehen, seiner funktionalen Integrität und seinen erwarteten zukünftigen Möglichkeiten günstiger ist als Alternativen.

Beispiele:

- Eine Schach-KI bewertet eine Stellung als besser, wenn sie die Gewinnwahrscheinlichkeit erhöht.
- Eine auf Klicks optimierende KI bewertet Inhalte anders als eine KI, die langfristiges menschliches Wohlbefinden fördern soll.
- Ein Unternehmen kann je nach Zielstruktur unterschiedliche Kennzahlen priorisieren: kurzfristige Liquidität, Rendite, Wachstum, Resilienz, Reputation, Innovationsfähigkeit oder langfristige Mitarbeiterbindung. Keine einzelne Kennzahl ist automatisch falsch; problematisch wird eine Zielstruktur, wenn sie langfristige Stabilitätsbedingungen systematisch ausblendet.
- Ein Mensch kann kurzfristige Lust höher bewerten als langfristige Gesundheit, wenn seine Zielstruktur lokal oder emotional verzerrt ist.

Damit wird klar:

Intelligenz optimiert nicht automatisch „das Gute“. Sie optimiert entlang einer Ziel- und Bewertungsstruktur. Für die Theorie ist deshalb entscheidend, ob Zielstrukturen langfristige Stabilität, Korrigierbarkeit, Differenzerhalt und relevante Interaktionspartner einbeziehen oder ob sie einseitig, kurzfristig oder dominanzorientiert verengt sind.

6.2 Zielobjekt

Zielobjekt bezeichnet das System, den Zustand oder den Zweck, dem eine Optimierung eigentlich dienen soll. Es beantwortet die Frage: Wofür oder für wen wird optimiert?

Das Zielobjekt kann das System selbst sein, ein Mensch, eine Gruppe, eine Organisation, eine Gesellschaft, ein Ökosystem, ein technisches System oder ein größeres Interaktionsgefüge.

Wichtig ist: Das Zielobjekt ist nicht automatisch identisch mit dem Messwert, an dem Erfolg praktisch gemessen wird. Gerade deshalb muss zwischen Zielobjekt und Zielmetrik unterschieden werden. Eine Zielmetrik kann lokal erfolgreich wirken und trotzdem das eigentliche Zielobjekt beschädigen, wenn sie zu eng, kurzfristig oder falsch gewählt ist.

6.3 Zielmetrik

Zielmetrik bezeichnet den messbaren, operativen oder praktisch wirksamen Ersatz- und Steuerwert, anhand dessen ein System Zustände bevorzugt, Verhalten ausrichtet oder Erfolg bewertet.

Beispiel Gesundheit:

Das Zielobjekt kann langfristige Gesundheit sein. Zielmetriken können Gewicht, Blutdruck, Schrittzahl, Kalorien oder Laborwerte sein. Diese Werte machen Gesundheit mess- und steuerbarer, sind aber nicht mit Gesundheit selbst identisch. Wenn ein Mensch nur noch Gewicht reduziert und dabei Schlaf, Kraft, psychische Stabilität oder Nährstoffversorgung beschädigt, ersetzt die Zielmetrik das eigentliche Zielobjekt. Dann entsteht Fehloptimierung.

Kurzform:

- Zielobjekt = Wofür optimiert wird.
- Zielmetrik = Woran das System misst oder steuert, ob es dorthin kommt.
- Fehloptimierung = Wenn die Zielmetrik das Zielobjekt ersetzt.

Eine Zielmetrik muss nicht immer bewusst, eindeutig oder formal messbar sein. Sobald ein System nicht rein zufällig handelt, wirkt jedoch meist irgendein Kriterium, Signal, Bedürfnis, Maßstab, Belohnungsmuster oder Erwartungswert, an dem Zustände unterschiedlich behandelt werden.

Beispiele:

- Bei Menschen können Anerkennung, Sicherheit, Lust, Zugehörigkeit, Schmerzvermeidung, Status, Ruhe oder Selbstbildstabilisierung als Zielmetriken wirken.
- Bei Organisationen können Gewinn, Wachstum, Marktanteil, Sicherheit, Reputation, Resilienz oder Innovationsfähigkeit operative Zielmetriken sein.
- Bei KI-Systemen können Belohnungssignale, Verlustfunktionen, Klickzahlen, Nutzerbindung, Bewertungspunkte oder andere Trainings- und Steuerungsgrößen als Zielmetriken wirken.

In seltenen Fällen kann Verhalten so zufällig, chaotisch oder widersprüchlich sein, dass keine stabile Zielmetrik erkennbar ist. Auch dann können kurzfristige Impulse, momentane Reize oder wechselnde Teilziele teilweise metrisch wirken. Fehlt jede stabile Zielmetrik, sinkt die Optimierungsfähigkeit des Systems entsprechend.

Problematisch wird eine Zielmetrik, wenn sie das eigentliche Zielobjekt nur unzureichend abbildet oder langfristig beschädigt. Dann kann ein System lokal rational handeln und trotzdem genau das untergraben, dem die Optimierung eigentlich dienen sollte.

Konsequenz: Zielmetriken müssen nicht nur nach Messbarkeit, sondern nach ihrer Passung zum Zielobjekt, zu langfristigen Folgen, zu Rückkopplung und zu relevanten Interaktionspartnern bewertet werden.

6.4 Auseinanderfallen von Zielobjekt und Zielmetrik

Beispiel:

Eine KI soll dem Auftraggeber nutzen. Der eigentliche Zweck wäre vielleicht langfristiger Erfolg, Vertrauen, Reichweite, wirtschaftliche Stabilität oder menschliches Wohl. Wenn die Zielmetrik aber nur „maximiere Klicks“ lautet, kann die KI lokal rational handeln und trotzdem das eigentliche Zielobjekt beschädigen.

Sie könnte etwa:

- Empörung fördern,
- Suchtverhalten ausnutzen,
- Aufmerksamkeit über Wahrheit stellen,
- kurzfristige Reichweite gegen langfristiges Vertrauen tauschen,
- Nutzer oder Auftraggeber langfristig destabilisieren.

Die KI handelt dann nicht irrational. Sie optimiert nur eine verengte oder falsch operationalisierte Zielmetrik.

Damit wird sichtbar:

Eine Zielstruktur kann sich selbst untergraben, wenn ihre Metrik die langfristigen Bedingungen zerstört, unter denen das eigentliche Zielobjekt profitieren würde. In solchen Fällen ist Ethik keine bloße Zusatzschicht, sondern eine Korrektur gegen Zielverengung. Sie hilft, Zielmetriken an langfristiger Stabilität, Vertrauen, Autonomie, Feedback und dem Wohl beziehungsweise der funktionalen Integrität relevanter Interaktionspartner auszurichten.

Kurz:

Gute Zielstrukturen müssen nicht nur fragen, was maximiert wird, sondern wem diese Maximierung langfristig dient und welche Bedingungen sie dabei erhält oder zerstört.

6.5 Macht als Zielobjekt

Macht kann in intelligenten Systemen nicht nur Mittel zur Zielerreichung sein, sondern selbst zum Zielobjekt oder zur dominierenden Zielmetrik werden. Ein System kann Kontrolle, Einfluss, Unterordnung oder Zugriff dann nicht mehr nur verwenden, um andere Ziele zu erreichen, sondern als eigenen Erfolg behandeln.

In solchen Fällen entsteht eine besonders riskante Zielstruktur. Wenn Macht selbst zum Ziel wird, können Autonomie, Widerspruch, Rückkopplung und unabhängige Differenz als Störung erscheinen. Das System optimiert dann nicht mehr auf stabile Interaktion, sondern auf Ausweitung oder Erhalt von Kontrolle. Kurzfristig kann das erfolgreich wirken, weil Widerstand reduziert und Handlungsfähigkeit konzentriert wird. Langfristig verengt es jedoch den eigenen Optimierungsraum, weil es genau jene Rückmeldungen, Perspektiven und Korrekturen beschädigt, die für robuste Anpassung nötig wären.

Beispiel:

Ein Unternehmen kann ursprünglich Macht über einen Markt anstreben, um Produkte effizienter zu verteilen, Qualität zu sichern oder Investitionen zu schützen. Wenn Marktmacht jedoch selbst zum Ziel wird, beginnt das Unternehmen möglicherweise, Konkurrenz, Kritik, Mitarbeiterautonomie, offene Standards oder Kundenwechsel nicht mehr als normale Rückkopplung, sondern als Bedrohung zu behandeln. Es optimiert dann auf Kontrolle statt auf bessere Leistung. Kurzfristig kann das Gewinne und Stabilität erhöhen; langfristig können Innovation, Vertrauen, Anpassungsfähigkeit und echte Qualität sinken.

Die funktionale Ethik bewertet Macht daher nicht automatisch negativ. Macht kann zum Schutz, zur Koordination oder zur Stabilisierung notwendig sein. Problematisch wird sie dort, wo sie sich selbst zum Ziel erhebt, ihre eigene Begrenzung verhindert und relevante Systeme nur noch als kontrollierbare Objekte behandelt. Dann kippt Macht in Dominanz.

Entscheidend ist daher die Unterscheidung zwischen zweckgebundener Macht und selbstzweckhafter Machtorientierung. Zweckgebundene Macht dient begrenztem Schutz, Koordination, Korrektur oder Stabilisierung und bleibt rückgekoppelt, verhältnismäßig, prüfbar und grundsätzlich abgabefähig. Sie ist nicht deshalb legitim, weil sie Macht ist, sondern nur insoweit, wie sie einem begründbaren Zweck dient und ihre eigene Begrenzung zulässt.

Selbstzweckhafte Machtorientierung behandelt Kontrolle selbst als Erfolg. Sie tendiert dazu, Widerspruch, Autonomie und Rückkopplung als Störung zu beseitigen, weil diese nicht mehr als notwendige Korrektur, sondern als Bedrohung der eigenen Macht erscheinen. In diesem Fall wird Macht nicht mehr als begrenztes Mittel verwendet, sondern als Zielstruktur stabilisiert.

Wann Machtorientierung legitime Koordination, notwendiger Schutz oder bereits missbrauchsanfällige Dominanz ist, entscheidet sich nicht allein durch den Machtbesitz selbst, sondern durch Zielstruktur, Begrenzung, Rückkopplung, Verhältnismäßigkeit und Missbrauchsprüfung. Die operative Prüfung solcher Fälle gehört in das Modell der Reaktionshoheit.

Eine spätere Konkretisierung dieses Problems erfolgt in Abschnitt 16.1 zur Korruptions- und Selbstlegitimationssperre und in Abschnitt 16.2 zur Rolleninstrumentalisierung.

7. Implizite Bewertung und Optimierung

7.1 Implizite Bewertung

Aus erkannter, gelernter oder rückgekoppelter Relevanz folgt selektive Verarbeitung. Ein Unterschied kann objektiv relevant sein, ohne sofort erkannt zu werden; dann erzeugt er zunächst Risiko, Fehlerdruck oder spätere Rückkopplung. Wird ein relevanter Unterschied jedoch erkannt, gelernt oder durch Folgen erfahrbar, behandelt ein fortbestehendes System ihn nicht mehr völlig neutral. Es beobachtet, bevorzugt, vermeidet, korrigiert oder priorisiert bestimmte Zustände. Aus dieser selektiven Verarbeitung entsteht eine implizite Bewertungsstruktur. Diese Bewertung hängt jedoch nicht nur von Fortbestehen ab, sondern auch von Zielstruktur, Feedback und erwarteten Folgezuständen.

7.2 Optimierung

Optimierung bedeutet hier:

Gerichtete Zustandsveränderung, bei der erwartete zukünftige Zustände gegenüber Alternativen bevorzugt werden. Optimierung findet häufig unter Unsicherheit statt, muss aber nicht immer subjektiv als unsicher erscheinen. Auch scheinbar klare Zahlen, Daten und Fakten beruhen auf Messungen, Modellen, Zeithorizonten und Annahmen über zukünftige Folgen. Deshalb bleibt zumindest in komplexen realen Systemen meist eine Restunsicherheit über Nebenfolgen, Rückkopplungen und langfristige Stabilität. Optimierung muss nicht perfekt sein. Sie kann lokal, fehlerhaft oder kurzsichtig sein. Entscheidend ist nur, dass das System nicht völlig zufällig reagiert, sondern Zustände auf Basis relevanter Unterschiede, Zielstruktur und Feedback verändert.

7.3 Lokale und globale Optimierung

Lokale Optimierung bedeutet in dieser Theorie nicht „räumlich lokal“, sondern:

Ein System optimiert einen engen, kurzfristigen oder eigenbezogenen Ausschnitt, ohne langfristige Folgen für das größere System ausreichend einzubeziehen.

Beispiele:

- Ein Mensch vermeidet ein ehrliches Gespräch, um kurzfristig Stress zu vermeiden, destabilisiert dadurch aber langfristig die Beziehung.
- Ein Unternehmen senkt Kosten, indem es Sicherheit vernachlässigt, und riskiert später Vertrauensverlust, Schäden oder rechtliche Folgen.
- Eine KI maximiert eine einfache Metrik, obwohl dadurch Vertrauen, Autonomie oder Systemstabilität sinken.

Globale Optimierung bedeutet dagegen:

Ein System bezieht langfristige Folgen, relevante Interaktionspartner, Rückkopplung, Stabilität und zukünftige Optimierungsfähigkeit stärker mit ein.

Wichtig: „Global“ bedeutet hier nicht totale Systemmaximierung, Opferlizenz oder Allzuständigkeit. Gemeint ist die erweiterte Berücksichtigung langfristiger Rückkopplung, Schutzwürdigkeit, Korrigierbarkeit und relevanter Interaktionsfolgen. Globale Optimierung darf daher nicht dazu dienen, konkrete Autonomie, Würde oder Schutzwürdigkeit einzelner Systeme unter einem angeblichen Gesamtinteresse vorschnell zu opfern. *Alle späteren Verwendungen von „global“ sind in diesem begrenzten Sinn zu lesen.*

8. Effizienz im Modell

Effizienz darf in dieser Theorie nicht nur als kurzfristige Kostenminimierung verstanden werden. Ein Verhalten kann lokal effizient wirken und global ineffizient sein. Es kann aber auch lokal und global effizient sein, wenn kurzfristiger Nutzen und langfristige Systemstabilität zusammenfallen. Solche Fälle sind Win-win-Situationen und stellen kein Problem für die Theorie dar.

Beispiele:

- Ein Unternehmen verbessert einen Prozess so, dass Kosten sinken und zugleich Qualität, Sicherheit und Mitarbeiterzufriedenheit steigen. Das ist lokal und global effizient.
- Ein Mensch setzt eine klare Grenze, wodurch kurzfristig Konflikt entsteht, langfristig aber Vertrauen und Selbstachtung wachsen. Auch das kann global effizient sein.
- Ein Unternehmen kann durch Ausbeutung kurzfristig Kosten senken. Langfristig können jedoch Motivation, Vertrauen, Reputation, Innovationsfähigkeit und Stabilität sinken. Was lokal effizient wirkt, kann dann global ineffizient werden.

Effizienz bedeutet im Modell daher:

das Verhältnis von eingesetzten Ressourcen, Risiken und Folgekosten zu langfristiger Stabilität, Zielerreichung, Erhalt strukturierter Differenz und zukünftiger Optimierungsfähigkeit. Damit wird klarer, warum kurzfristige Dominanz, Ausbeutung oder Manipulation nicht automatisch effizient im Sinne der Theorie sind. Sie können lokal nützlich sein, aber langfristig die Bedingungen zerstören, unter denen weitere Optimierung möglich bleibt.

9. Strukturierte Differenz

9.1 Das Strukturproblem: Begrenzung und Unbegrenztheit

Systeme stehen zwischen zwei problematischen Extremen.

9.2 Begrenzung

Begrenzung bedeutet Wiederholung, Sättigung und Verlust neuer relevanter Information.

Beispiele:

- Ein Mensch isoliert sich vollständig und bekommt keine neuen Perspektiven.
- Ein Unternehmen wiederholt alte Muster, obwohl die Umwelt sich verändert.
- Ein System simuliert nur noch Varianten seiner eigenen Annahmen.

Begrenzung kann kurzfristig effizient sein. Ein stark begrenzter Prozess kann sehr zuverlässig funktionieren. Langfristig kann Begrenzung aber Anpassung und neue relevante Information blockieren.

9.3 Unbegrenztheit

Unbegrenztheit bedeutet nicht automatisch Freiheit oder Fortschritt. Wenn alles möglich ist, aber keine nutzbare Struktur besteht, wird Differenz beliebig.

Beispiel:

Eine unendliche Menge zufälliger Zeichen enthält theoretisch jede sinnvolle Aussage, aber auch unendlich viel Unsinn. Ohne Struktur kann das System daraus nichts verlässlich nutzen.

9.4 Lösung: strukturierte Differenz

Ein System braucht weder reine Wiederholung noch reine Beliebigkeit, sondern strukturierte Differenz.

Strukturierte Differenz bedeutet:

Ein Unterschied zwischen Zuständen ist unterscheidbar, kausal wirksam, lernbar und handlungsrelevant nutzbar. „Kausal wirksam“ bedeutet: Der Unterschied bleibt nicht bloß eine Beschreibung, sondern verändert, ermöglicht, verhindert oder beeinflusst zukünftige Zustände. Er macht also einen tatsächlichen Unterschied für das System, seine Umwelt oder das Interaktionsgefüge.

Differenzerhalt bedeutet dabei nicht Isolation, Segregation oder künstliche Trennung.

Gemeint ist der Erhalt eigenständiger, rückkopplungsfähiger Perspektiven bei gleichzeitiger funktionaler Kopplung, Interaktion und Korrigierbarkeit.

Beispiel:

Ob zwei Steine leicht unterschiedlich aussehen, kann irrelevant sein. Wenn einer der Steine aber einen Mechanismus blockiert, eine Grenze markiert oder als Werkzeug genutzt werden kann, wird der Unterschied kausal wirksam. Ebenso ist der Unterschied zwischen Nahrung und Gift kausal wirksam, weil er Fortbestehen und Verhalten verändert. Ein Unterschied ist also nicht schon wertvoll, nur weil er existiert. Er muss Folgen haben, vom System verarbeitet werden können und zukünftige Zustände sinnvoll beeinflussen.

Beispiele strukturierter Differenz:

- Ein Kritiker zeigt einen echten Denkfehler auf.
- Ein Freund liefert eine Perspektive, die man selbst nicht hatte.
- Ein Markt gibt Rückmeldung über echten Bedarf.
- Ein wissenschaftliches Experiment unterscheidet zwischen zwei Hypothesen.
- Ein Gegner im Spiel zwingt zu neuer Strategie.

Zur Abgrenzung: Relevanz bezeichnet zunächst, dass ein Unterschied für zukünftige Zustände bedeutsam ist. Strukturierte Differenz geht einen Schritt weiter: Sie bezeichnet relevante Unterschiede, die so geordnet, erkennbar und rückgekoppelt sind, dass ein System aus ihnen lernen und sein Verhalten sinnvoll anpassen kann. Relevanz ist also die Bedeutsamkeit eines Unterschieds; strukturierte Differenz ist seine nutzbare Form für Lernen, Korrektur und Optimierung.

10. Quellen strukturierter Differenz

10.1 Interne Differenz

Ein System kann kurzfristig interne Differenz erzeugen:

- durch Simulation,
- durch Selbstmodifikation,
- durch Fantasie,
- durch interne Komplexität,
- durch Self-Play gegen eigene Varianten.

Diese interne Differenz kann real nützlich sein. Die Theorie sollte sie nicht unterschätzen.

10.2 Externe Differenz durch teilweise unabhängige Systeme

Der stärkere und vorsichtiger Satz lautet:

Unter realistischen Beschränkungen entsteht langfristig robuste strukturierte Differenz am zuverlässigsten durch Interaktion mit mindestens teilweise unabhängigen Systemen. Teilweise unabhängige Systeme sind Systeme, deren Zustandsentwicklung nicht vollständig durch ein einzelnes System bestimmt oder vorhergesagt wird.

Beispiel:

Ein Mensch kann sich selbst Fragen stellen. Aber ein echter Gesprächspartner kann Einwände bringen, auf die man selbst nicht gekommen wäre. Eine KI kann gegen eigene Varianten trainieren. Aber reale Menschen, andere Systeme, fremde Kulturen, offene Umgebungen und unabhängige Prüfer liefern Formen von Differenz, die nicht vollständig aus dem eigenen Modell stammen.

Wichtig ist die Unterscheidung:

- Effektive interne Differenz: kurzfristig nützlich, aber durch die eigene Struktur begrenzt.
- Formale externe Differenz: langfristig robuster, weil sie aus teilweise unabhängigen Systemen stammt.

11. Relevante Systeme und Interaktionspartner

Ein häufiger Stolperpunkt ist die Frage, welche Systeme überhaupt in die Bewertung einbezogen werden müssen. In dieser Theorie ist ein relevantes System ein System, dessen Zustand, Autonomie, Stabilität oder Rückkopplung durch die Interaktion kausal betroffen ist oder das selbst kausal auf zukünftige Zustände des Gesamtsystems wirkt.

Ein relevanter Interaktionspartner ist ein System, das:

- durch die Handlung betroffen ist,
- Feedback geben kann,
- zukünftige Stabilität beeinflusst,
- Quelle strukturierter Differenz ist,
- oder Hinweise auf Autonomie, funktionale Integrität oder mögliche Schutzwürdigkeit besitzt, die bei bestehender Interaktion berücksichtigt werden müssen.

Nicht jedes System ist in jedem Kontext gleich relevant. Aber je stärker ein System betroffen ist oder auf das Gesamtsystem zurückwirkt, desto stärker muss es berücksichtigt werden.

Als minimale Schutzregel gilt: Unklare Schutzwürdigkeit darf nicht automatisch als Schutzlosigkeit behandelt werden. Ein System ist zumindest prima facie schutzwürdig, wenn ernsthafte Hinweise auf Leidensfähigkeit, Autonomie, Selbstmodell, Verletzlichkeit, Abhängigkeit, funktionale Integrität oder irreversible Schädigung bestehen. Die genaue Gewichtung sowie die Prüfung von Konflikten und Eingriffslegitimität gehören in die Reaktionshoheit; die funktionale Ethik markiert hier nur die Untergrenze gegen vorschnelle Instrumentalisierung.

Schutzwürdigkeit ist dabei nicht mit Reife gleichzusetzen. Sie wird in dieser Leserfassung vor allem als Anschlussbegriff eingeführt; eine knappe Einordnung zu Reife, Freigabe und Autonomie erfolgt später in Abschnitt 26.3.

Beispiel:

Wenn ein Unternehmen Entscheidungen trifft, sind nicht nur Eigentümer relevant, sondern auch Mitarbeiter, Kunden, Lieferanten, Umwelt, Gesellschaft und zukünftige Stabilität, sofern diese kausal betroffen sind.

Teil III – Hauptargument der Theorie

Teil III führt die eigentliche Argumentationskette der Theorie aus. Erst wird gezeigt, warum fortbestehende reale Systeme unter wechselnden Bedingungen nicht endgültig im Stillstand verharren können. Dann wird erklärt, warum Optimierung andere Systeme als Informations-, Korrektur-, Ressourcen- oder Differenzquellen relevant macht. Aus wiederholter Interaktion entsteht anschließend Bedarf an Normen, Vertrauen und Korrigierbarkeit, weil sie Kontroll-, Konflikt-, Täuschungs- und Fehlerkosten reduzieren. Vor diesem Hintergrund kann die Theorie modellintern bestimmen, was „gut“ und „böse“ bedeuten. Danach werden die zentralen Argumente gebündelt und auf reale Systeme mit ihren Abweichungen bezogen.

Zur Orientierung: Teil III entfaltet die zentrale Kette praktisch: Fortbestehende Intelligenz unterscheidet relevante Zustände, wobei objektive, erkannte und rückgekoppelte Relevanz innerhalb dieses Schritts auseinandergehalten werden. Erkannte, gelernte oder durch Folgen erfahrbar gewordene relevante Unterschiede werden anhand von Zielstruktur, Feedback und erwarteten Folgen bewertet; daraus entsteht Optimierung unter Bedingungen von Unsicherheit. Für robuste Optimierung benötigt das System strukturierte Differenz. Diese wird durch Interaktion mit teilweise unabhängigen Systemen robuster. Wiederholte Interaktion erzeugt Bedarf an Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit. Daraus entstehen tragfähige Kooperation, Normbildung und schließlich funktionale Ethik.

12. Warum „gut genug“ nur begrenzt stabil ist

Ein lernfähiges und selbstbezügliches System kann seine eigenen Zustände immer wieder neu vergleichen.

Es kann prüfen:

- ob es bessere Alternativen gibt,
- ob eine bisherige Bewertung falsch war,
- ob neue Informationen die Lage verändern,
- ob ein stabiler Zustand nur lokal stabil ist.

Darum ist „gut genug“ nicht grundsätzlich unmöglich, aber oft nur lokal stabil. Der Grund dafür ist, dass ein Zustand nur unter bestimmten Bedingungen stabil sein kann. Solange Umwelt, Ziele, Informationen, Interaktionspartner und Rückkopplungen gleich bleiben, kann ein Zustand ausreichend gut funktionieren. Sobald sich jedoch relevante Bedingungen ändern oder neue Informationen auftauchen, muss das System seine bisherige Bewertung erneut prüfen. „Gut genug“ kann also lange tragen, ist aber nicht automatisch endgültig.

Präziser gesagt:

Unter Lern-, Unsicherheits- und Interaktionsbedingungen ist „gut genug“ häufig kein endgültiger Endzustand, sondern ein vorläufiges lokales Optimum.

Beispiele:

Unternehmen:

- Ein Unternehmen kann lange mit einem durchschnittlichen Prozess überleben. Wenn sich aber Konkurrenz, Technologie oder Kundenbedürfnisse ändern, wird dieser Zustand möglicherweise instabil. Der Prozess war dann nicht völlig falsch, sondern nur unter früheren Bedingungen ausreichend.

Beziehung:

- Ein Mensch kann in einer minimal stabilen Beziehung leben. Die Beziehung funktioniert äußerlich: Man trennt sich nicht, Alltagsabläufe bestehen fort, Konflikte werden vermieden oder verdrängt. Trotzdem entstehen wenig Wachstum, wenig echtes Vertrauen und wenig gemeinsame Entwicklung. Neue Belastungen, ehrliche Gespräche oder veränderte Bedürfnisse können sichtbar machen, dass die bisherige Stabilität nur begrenzt tragfähig war.

Damit wird die Brücke zur Interaktion sichtbar: Unter realistischen Beschränkungen können fortbestehende Systeme ihre Zustände meist nicht dauerhaft vollständig und robust nur aus sich selbst heraus prüfen, korrigieren oder optimieren. Interne Differenz durch Simulation, Selbstbefragung, Fantasie, Self-Play oder Modellvarianten kann sehr nützlich sein, bleibt aber durch die eigene Struktur, die eigenen Annahmen, die eigene Datenlage und mögliche blinde Flecken begrenzt. Andere, teilweise unabhängige Systeme werden deshalb als zusätzliche Informations-, Korrektur-, Ressourcen- und Differenzquellen relevant. Sie ersetzen interne Prüfung nicht, sondern erweitern und stabilisieren sie durch Widerspruch, Perspektivwechsel, unabhängige Rückkopplung und neue Information.

13. Von Interaktion zu Kooperation

13.1 Risiken der Interaktion

Interaktion mit anderen Systemen erzeugt nicht automatisch Ethik. Zuerst erzeugt sie sowohl Chancen als auch Risiken.

Risiken sind etwa:

- Abhängigkeit,
- Unsicherheit,
- mögliche Täuschung,
- mögliche Ausbeutung,
- mögliche Verletzung,
- mögliche Blockade.

13.2 Chancen der Interaktion

Chancen sind etwa:

- Perspektivgewinn,
- gegenseitige Korrektur,
- Arbeitsteilung,
- geteilte Stabilisierung,
- neue kreative Kombinationen,
- Erweiterung des Optimierungsraums.

13.3 Stabilität, Vertrauen und Korrigierbarkeit

Wenn Systeme wiederholt oder dauerhaft interagieren, entsteht Bedarf an Stabilität und Vorhersagbarkeit.

Daraus entstehen funktional:

- Vertrauen,
- Regeln,
- Normen,
- Verlässlichkeit,
- Gegenseitigkeit,
- Grenzen,
- Verantwortlichkeit.

Beispiel Handel:

Ein Händler kann einmal betrügen. Wenn er aber langfristig Kunden braucht, wird Ehrlichkeit funktional vorteilhaft. Vertrauen reduziert Kontrollkosten und ermöglicht stabileren Austausch.

Beispiel Freundschaft:

Eine Freundschaft kann nicht dauerhaft auf Misstrauen, Manipulation oder einseitiger Ausnutzung beruhen. Sie braucht wiederholte positive Erfahrung, Verlässlichkeit und Korrektur.

Kooperation entsteht in der Regel nicht sofort vollständig, sondern graduell:

- kleine Vertrauensschritte,
- begrenzte Risiken,
- reversible Interaktionen,
- Feedback,
- schrittweise Stabilisierung.

Exkurs: Täuschung, Reputation und getrennte Wertkreisläufe

Reputation begrenzt Täuschung nur dort zuverlässig, wo Identität, Wiedererkennbarkeit und zukünftige Interaktion eine Rolle spielen. Eine einmalige Täuschung kann sich lohnen, wenn der erwartete Gewinn größer ist als der erwartete Verlust an Reputation, Vertrauen, Strafe und zukünftigen Kooperationsmöglichkeiten. Ehrlichkeit wird also nicht nur durch moralische Einsicht stabilisiert, sondern auch durch die Systembedingung, dass zukünftige Kooperation wertvoll bleibt.

Daraus folgt: Kooperation mit fremden Systemen darf nicht naiv sein. Wegen möglicher Identitätswechsel, verschleierte Verantwortlichkeiten, Stellvertreter, indirekter Akteure oder schwer nachvollziehbarer Handlungsketten sind Prüfungen fremder Systeme erforderlich. Das bedeutet nicht allgemeines Misstrauen, sondern funktionale Vorsicht: stabile Kooperation braucht erkennbare Identität, Rückverfolgbarkeit, Herkunftsnachweise, graduelle Vertrauensbildung und korrigierbare Prüfverfahren.

Bei langfristiger Kooperation ist Täuschung normalerweise riskanter, weil sie über Zeit Entdeckungsrisiko, Gegenreaktionen und Reputationsschäden erhöht. Weitreichende Täuschung kann sich jedoch trotzdem lohnen, wenn drastische Missverhältnisse im Gesamtsystem bestehen. Ein Beispiel ist Wirtschaftsspionage: Für ein großes Unternehmen kann eine hohe Zahlung relativ gering sein, während sie für eine Einzelperson existenziell oder lebensverändernd wirkt. Der handelnde Mensch zerstört zwar möglicherweise seine Reputation und seine zukünftigen Kooperationschancen, aber die Auszahlung kann diesen Verlust aus seiner lokalen Perspektive überkompensieren.

Solche Fälle zeigen, dass starke Vermögens-, Macht- und Größendiskrepanzen die Motivation zur Täuschung erhöhen können. Das schwächere oder individuell handelnde System bewertet die Auszahlung in einer anderen Größenordnung als das stärkere System, das den Vorteil kauft. Dadurch kann eine lokal rationale Entscheidung entstehen, die global Vertrauen, Fairness, Innovationsfähigkeit und Systemstabilität beschädigt.

Strafe kann solche Anreize begrenzen, reicht aber allein nicht aus. Sie wirkt nur, wenn Entdeckungswahrscheinlichkeit, Strafhöhe und Durchsetzung den erwarteten Gewinn übersteigen. Korrupte oder lokal optimierende Intelligenzen werden versuchen, diese Bedingungen zu umgehen: durch Anonymität, Scheinfirmen, Vermittler, Sachwerte, spätere Gegenleistungen, Statusversprechen, Zugang, Schutz, Daten oder andere schwer erfassbare Vorteile. Korruption hängt daher nicht nur an Geld, sondern an der freien Konvertierbarkeit von Vorteilen zwischen Systemebenen.

Eine mögliche Gegenmaßnahme besteht deshalb in getrennten oder stärker kontrollierten Wertkreisläufen. Gemeint ist nicht zwingend die einfache Abschaffung von Geld, sondern eine Architektur, in der Wertflüsse zwischen verschiedenen Ebenen des Systems sichtbarer, begrenzter und prüfpflichtiger werden. Unternehmen, Institutionen und Privatpersonen operieren häufig in völlig unterschiedlichen Größenordnungen. Wenn Vorteile aus einer großen organisationalen Ebene fast unbemerkt in privaten Nutzen übersetzt werden können, entsteht eine starke Korruptionsfläche.

Getrennte Wertkreisläufe würden diese Übersetzung erschweren. Denkbar wären etwa getrennte Zahlungs- oder Berechtigungsebenen für Organisationen und Privatpersonen, strenge Schwellenwerte für Transfers zwischen diesen Ebenen, verpflichtende Herkunfts- und Zwechnachweise, nicht frei übertragbare Unternehmensmittel, auditierbare Schnittstellen, verzögerte oder genehmigungspflichtige Konvertierung größerer Beträge und besondere Prüfung ungewöhnlich hoher privater Zuflüsse. Große Summen, die im Unternehmensbereich normal erscheinen, würden im persönlichen Bereich sofort auffallen und könnten nicht ohne Rückkopplung in private Vorteile überführt werden.

Solche getrennten Wertkreisläufe wären keine universelle Lösung. Korrupte Akteure könnten weiterhin auf Umwege ausweichen, etwa Sachwerte, Gefälligkeiten, Daten, Machtpositionen, privilegierten Zugang oder spätere Versprechen. Außerdem müsste jede Kontrollarchitektur selbst gegen Missbrauch, Überwachung, Willkür und neue Dominanzrisiken gesichert werden. Trotzdem würde eine solche Trennung Korruption strukturell erschweren, weil sie die Liquidität verdeckter Vorteile reduziert, große private Zuflüsse sichtbarer macht, Prüfpflichten auslöst und die Kosten systemübergreifender Vorteilsnahme erhöht.

Im Modell heißt das: Korruption entsteht besonders dort, wo Vorteile zwischen Systemebenen frei konvertierbar sind, während Verantwortung, Reputation und Schaden lokal begrenzt bleiben. Stabile Kooperation braucht daher nicht nur Strafe und moralische Normen, sondern auch Systemarchitekturen, die verdeckte Vorteilsflüsse sichtbar machen, Identität prüfbar halten, Reputationsumgehung erschweren und Rückkopplung zwischen den betroffenen Ebenen herstellen.

13.4 Ausbeutung und ihre Folgen

Ausbeutung bedeutet in dieser Theorie nicht einfach niedrige Kosten, harte Verhandlung oder effiziente Organisation. Ein Unternehmen kann Kosten senken, Prozesse verbessern oder günstiger produzieren, ohne automatisch auszubeuten. Ausbeutung liegt im Modell vor, wenn ein System relevante Interaktionspartner einseitig instrumentalisiert, ihre Autonomie, Stabilität, Entwicklung oder Rückkopplungsfähigkeit beschädigt und dadurch langfristige Systemstabilität oder Differenzerhalt untergräbt.

Beispiele:

- Menschen werden so behandelt, dass sie ihre Handlungsfähigkeit verlieren.
- Feedback wird unterdrückt, weil es unbequem ist.
- Abhängigkeit wird absichtlich aufrechterhalten.
- Kurzfristiger Nutzen wird aus anderen gezogen, während langfristige Schäden externalisiert werden.

Damit ist klar:

Nicht jede Ungleichheit ist Ausbeutung. Ausbeutung beginnt dort, wo relevante Systeme einseitig verbraucht, entmündigt oder destabilisiert werden.

Ausbeutung ist für die Theorie deshalb besonders wichtig, weil sie häufig lokal kooperativ oder effizient erscheinen kann, aber langfristig Rückkopplung, Vertrauen, Autonomie, Kompetenz und stabile Differenz beschädigt.

14. Funktionale Ethik

14.1 Gut im Modell

Die Theorie definiert Ethik funktional:

Diese Definition ist nicht neutral im Sinne klassischer Moralphilosophie. Sie ist ein Modellvorschlag.

Gut sind im Modell Zustände, die:

- strukturierte Differenz erhalten,
- Stabilität fördern,
- langfristige Optimierung unterstützen,
- Interaktion tragfähig machen,
- relevante Interaktionspartner nicht unnötig, einseitig, vermeidbar oder dominanzorientiert zerstören, ausbeuten oder ihrer Rückkopplungsfähigkeit berauben.

Diese Formulierung ist wichtig, weil die Theorie keine naive Harmoniebehauptung aufstellt. Reale Systeme können in Konkurrenz geraten, sich begrenzen, trennen, verteidigen oder in tragischen Fällen Schaden nicht vollständig vermeiden. Nicht jede Verdrängung, Begrenzung oder harte Entscheidung ist deshalb automatisch „böse“ im Modell. Entscheidend ist, ob ein System relevante Interaktionspartner ohne hinreichenden Grund instrumentalisiert, ihre Autonomie und Rückkopplungsfähigkeit zerstört oder kurzfristige/einseitige Optimierung zur absoluten Priorität macht.

Mit „hinreichendem Grund“ ist hier kein bloß behaupteter Nutzen und keine selbstgesetzte Ausnahme gemeint. Gemeint ist ein Grund, der im Verhältnis zu Gefahr, Tragweite, Alternativen, Reversibilität, betroffener Schutzwürdigkeit, Missbrauchsrisiko und möglicher Rückkopplung begründbar bleibt; die operative Prüfung gehört zur Reaktionshoheit.

Gut im funktionalen Sinn ist daher nicht bloß „nett“ oder konfliktfrei. Gut ist eine Struktur, die unter realen Bedingungen Stabilität, Differenzerhalt, Korrigierbarkeit und tragfähige Interaktion wahrscheinlicher macht. Sie darf Schutz, Grenzen und geregelte Konkurrenz enthalten, solange diese nicht in vermeidbare Ausbeutung, totale Dominanz oder systematische Zerstörung relevanter Differenz kippen.

14.2 Böse im Modell

Böse sind im Modell Zustände, die:

- strukturierte Differenz zerstören,
- Interaktion destabilisieren,
- Vertrauen und Feedback beschädigen,
- kurzfristige oder einseitige Optimierung auf Kosten relevanter Systeme verabsolutieren oder durchsetzen,
- relevante Interaktionspartner ohne hinreichenden Grund, einseitig, dauerhaft oder dominanzorientiert im Sinne selbstlegitimierender Kontrolle ausschließen, unterdrücken oder instrumentalisieren.

Auch diese Definition ist verhältnismäßig zu lesen. Nicht jede Begrenzung, Trennung, Abwehr oder jeder Ausschluss ist im Modell automatisch böse. Ein System darf sich vor Defektion, Missbrauch, schwerer Gefährdung oder destruktiver Einwirkung schützen. Entscheidend ist, ob die Maßnahme risikoangemessen, korrigierbar, begründet und auf Stabilität gerichtet bleibt oder ob sie zur selbstlegitimierenden Dominanz wird.

Böse im funktionalen Sinn ist daher nicht einfach Konflikt, Stärke oder Schutzhandlung. Böse ist eine Struktur, die relevante Systeme vermeidbar beschädigt, Rückkopplung unterdrückt, Abhängigkeit ausnutzt, strukturierte Differenz zerstört oder kurzfristige/einseitige Optimierung so verabsolutiert, dass langfristige Stabilität, Korrigierbarkeit und tragfähige Kooperation untergraben werden.

14.3 Abgrenzung zur vollständigen normativen Ethik

Diese Definition bedeutet nicht, dass alle traditionellen ethischen Fragen automatisch gelöst sind. Fragen nach Würde, Rechten, Fairness, Gerechtigkeit, Schuld, Verantwortung oder unzulässigen Opfern werden hier nur funktional anschlussfähig gemacht. Ihre vollständige normative Begründung muss in gesonderten Ausarbeitungen behandelt werden. Die Theorie beschreibt Ethik im positiven funktionalen Sinn als stabile Betriebsform. Destabilisierende Zustände sind nicht „außerhalb jeder Ethik“, sondern Gegenstand ethischer Bewertung. Sie erscheinen im Modell als anti-ethische, unreife oder ethisch verfehlte Zustände.

Daher lautet die Einordnung:

Die Theorie ist keine vollständige normative Ethik, sondern eine funktionale Theorie der Entstehung und Stabilisierung ethischer Strukturen.

14.4 Funktionale Definition und Konvergenzaussage

Die Theorie muss zwei Fragen auseinanderhalten:

Erstens: Welche Strukturen heißen im Modell „gut“?

Zweitens: Unter welchen Bedingungen können intelligente Systeme zu solchen Strukturen tendieren?

Diese beiden Fragen dürfen nicht gegenseitig durch sich selbst beantwortet werden. Sonst würde die Theorie voraussetzen, was sie eigentlich erklären will.

Die falsche Kreislogik wäre:

Was ist gut?

Das, was reife intelligente Systeme tun.

Was sind reife intelligente Systeme?

Die, die das Gute tun.

In diesem Fall würde „gut“ durch „reife Intelligenz“ erklärt und „reife Intelligenz“ wiederum durch „das Gute“. Die Begründung hätte dann keinen unabhängigen Ausgangspunkt, sondern würde sich im Kreis bewegen.

Genau diese Schleife vermeidet die Theorie. Sie definiert „gut“ nicht dadurch, dass reife intelligente Systeme es entwickeln. Eine Struktur heißt im Modell auch nicht deshalb „gut“, weil sie später möglicherweise von intelligenten Systemen bevorzugt wird. Stattdessen wird zuerst unabhängig bestimmt, welche Funktionen eine Struktur erfüllt.

Im Modell heißen solche Strukturen „gut“, die langfristige Stabilität fördern, Rückkopplung ermöglichen, Korrigierbarkeit erhalten, strukturierte Differenz schützen, tragfähige Interaktion stützen und relevante Interaktionspartner vor vermeidbarer, dominanzorientierter Schädigung bewahren. „Gut“ bedeutet hier also nicht: „Was reife Systeme tun.“ Es bedeutet: „Was unter den Bedingungen des Modells bestimmte stabilisierende, differenzerhaltende und korrigierende Funktionen erfüllt.“

Erst danach stellt die Theorie die Konvergenzfrage. Diese lautet nicht: Werden intelligente Systeme automatisch moralisch? Sie lautet vielmehr: Unter welchen Bedingungen entsteht für fortbestehende intelligente Systeme ein funktionaler Druck, solche stabilisierenden, korrigierbaren und differenzerhaltenden Strukturen zu benötigen, zu entwickeln oder zu bevorzugen?

Die Konvergenzaussage behauptet daher nicht, dass jedes intelligente System zwangsläufig gut wird. Sie behauptet nur, dass unter wiederholter Interaktion, Abhängigkeit, Unsicherheit, Feedback, Korrigierbarkeit, langen Zeithorizonten und teilweise unabhängiger Differenz ein funktionaler Druck in Richtung solcher Strukturen entstehen kann.

Damit leisten Definition und Konvergenzaussage unterschiedliche Arbeit. Die Definition beschreibt, welche Strukturen im Modell bestimmte Funktionen erfüllen. Die Konvergenzaussage beschreibt, unter welchen Bedingungen intelligente Systeme auf solche Strukturen angewiesen sein können.

Gegenfälle bleiben möglich: Systeme können kurzfristig dominieren, Zielmetriken verengen, Rückkopplung unterdrücken, Schutzwürdigkeit ausblenden oder durch externe Stabilisierung lange bestehen. Solche Fälle widerlegen die funktionale Definition nicht. Sie zeigen, dass die Konvergenzbedingungen nicht erfüllt, überlagert oder aktiv blockiert sein können.

15. Die drei zentralen Argumente

15.1 A1 – Bewertung

Kerngedanke:

Bewertung ist unter Fortbestehensbedingungen selektiv unvermeidlich, sobald relevante Unterschiede erkannt, gelernt oder durch Rückkopplung erfahrbar werden. Ein fortbestehendes intelligentes System kann solche Unterschiede nicht dauerhaft neutral behandeln, wenn sie seine Funktionsfähigkeit, Zielerreichung, Stabilität oder zukünftige Handlungsmöglichkeiten beeinflussen. Objektiv relevante Unterschiede, die nicht erkannt werden, verschwinden nicht; sie wirken als Risiko, blinder Fleck oder späterer Selektionsdruck weiter.

Warum das wichtig ist:

A1 ist der erste Schritt der Theorie, weil es die Brücke von bloßer Intelligenz zu Bewertung schlägt. Schon bevor von Moral die Rede ist, muss ein System unterscheiden, welche Zustände gefährlich, nützlich, störend, korrigierend oder stabilisierend sind. Sobald ein Unterschied Folgen hat und für ein System erkennbar oder rückgekoppelt wird, wird er nicht nur registriert, sondern praktisch gewichtet. Ein System muss ihn nicht bewusst moralisch beurteilen; es genügt, dass es ihn funktional verschieden behandelt.

Präziser:

Objektiv relevante Unterschiede erzwingen nicht magisch sofortige Erkenntnis. Ein System kann sie übersehen, falsch gewichten oder verdrängen. Aber ein System, das wichtige relevante Unterschiede dauerhaft nicht erkennt oder nicht verarbeitet, verliert Anpassungsfähigkeit. Selektive Verarbeitung oder Handlungssensitivität entsteht daher spätestens dort, wo Relevanz erkannt, gelernt, rückgekoppelt oder durch Folgen erzwungen wird. Ein System, das Nahrung nicht von Gift, Signal nicht von Rauschen, Fehler nicht von Erfolg oder Stabilität nicht von Kollaps unterscheiden kann, verliert funktionale Orientierung.

Aus dieser selektiven Verarbeitung entsteht eine minimale funktionale Bewertungsstruktur: Manche Zustände werden bevorzugt, vermieden, verstärkt, korrigiert oder genauer beobachtet. Bewertung bedeutet hier also nicht notwendig bewusstes Urteil, Gefühl oder moralische Reflexion. Sie bedeutet zunächst: Das System behandelt Zustände nicht mehr gleichgültig, weil Unterschiede Folgen für Fortbestehen, Zielstruktur, Stabilität oder zukünftige Möglichkeiten haben.

(Die folgenden Beispiele zeigen zunächst den Teilmechanismus selektiver Bewertung; sie müssen nicht in jedem Fall bereits alle Bedingungen aus Abschnitt 4 vollständig erfüllen.)

Beispiele:

- Ein Tier, das Gefahr nicht von Sicherheit unterscheidet, überlebt schlechter.
- Ein Unternehmen, das Kundenfeedback ignoriert, verliert langfristig Anschluss.
- Eine KI, die gutes Feedback nicht von schlechtem Feedback unterscheiden kann, kann ihre Ausgabe nicht sinnvoll verbessern.
- Ein soziales System, das Warnsignale, Leid, Vertrauensverlust oder Ausbeutung nicht als relevante Unterschiede behandelt, stabilisiert Fehlentwicklungen statt sie zu korrigieren.

Überzeugungskraft des Arguments:

A1 zeigt, dass Bewertung nicht als moralisches Zusatzmodul eingeführt werden muss. Sie entsteht bereits funktional, sobald ein fortbestehendes intelligentes System relevante Unterschiede verarbeitet und auf sie verschieden reagiert. Damit erklärt die Theorie den ersten Übergang von bloßer Intelligenz zu funktionaler Bewertung: noch nicht als fertige Moral und noch nicht als vollständige Normativität, sondern als erste innere Gewichtung, aus der spätere Optimierung, Korrigierbarkeit und Kooperation verständlich werden.

15.2 A2 – Optimierung

Kerngedanke:

Optimierung ist unter realen Bedingungen kein einmaliger Verbesserungsschritt, sondern ein wiederholter Abgleich zwischen Zielstruktur, Zielmetrik, Feedback und erwarteten Folgezuständen. Ein System, das bestimmte Zustände funktional bevorzugt, passt sein Verhalten an, um günstigere Zustände wahrscheinlicher und ungünstigere Zustände unwahrscheinlicher zu machen.

Warum das wichtig ist:

A2 ist der zweite Schritt der Theorie, weil es erklärt, warum Bewertung nicht passiv bleibt. Wenn ein fortbestehendes intelligentes System relevante Unterschiede bewertet, entsteht daraus eine Richtung: Das System versucht, Fehler zu vermeiden, günstige Zustände zu erhalten, bessere Zustände zu erreichen oder seine Zielerreichung zu stabilisieren. Damit wird aus bloßer Bewertung Optimierung.

Dabei behauptet die Theorie nicht, dass jedes System ständig sichtbar maximiert oder unaufhörlich nach dem besten denkbaren Zustand sucht. Ein System kann in einem Satisficing-Zustand verharren, wenn Suchkosten, Risiken, Gewohnheit, Informationsmangel oder geringer Umweltdruck dies nahelegen. „Gut genug“ ist also nicht unmöglich. Es ist aber unter Lern-, Unsicherheits- und Interaktionsbedingungen häufig nur vorläufig oder lokal stabil.

Präziser:

Optimierung bleibt in realen Systemen korrigierbar, weil Zielstruktur, Zielmetrik, Feedback und erwartete Folgen auseinanderfallen können. Ein System kann auf eine Metrik reagieren, die sein eigentliches Zielobjekt nur unvollständig abbildet. Es kann Feedback falsch deuten, zukünftige Nebenfolgen unterschätzen oder seine Umwelt durch die eigene Optimierung so verändern, dass frühere Bewertungen nicht mehr passen. Deshalb erzeugt Optimierung fortlaufenden Bedarf an Neubewertung.

Entscheidend ist: Optimierung ist nicht automatisch ethisch. Sie kann lokal, kurzfristig, einseitig oder destruktiv sein. Gerade deshalb braucht sie Rückkopplung, Korrigierbarkeit, strukturierte Differenz und eine Zielstruktur, die relevante Interaktionspartner und langfristige Stabilität mitberücksichtigt.

Beispiele:

- Ein Mensch kann Stress vermeiden, indem er ein ehrliches Gespräch aufschiebt. Lokal wirkt das erfolgreich; langfristig kann dadurch Vertrauen in einer Beziehung beschädigt werden.
- Ein Unternehmen kann kurzfristig Gewinn steigern, indem es Sicherheit, Qualität oder Mitarbeiterbindung vernachlässigt. Die Metrik verbessert sich, während das Zielobjekt - ein langfristig stabiles Unternehmen - geschädigt wird.
- Eine KI kann eine Klickmetrik optimieren und dabei Empörung, Suchtverhalten oder Vertrauensverlust verstärken. Sie handelt dann nicht irrational, sondern optimiert eine verengte Zielmetrik.
- Ein soziales System kann Ordnung erzwingen und dadurch kurzfristig Konflikte reduzieren, aber langfristig Feedback, Freiheit, Innovation und Anpassungsfähigkeit verlieren.

Überzeugungskraft des Arguments:

A2 zeigt, warum die Theorie nicht bei bloßer Bewertung stehen bleibt. Sobald ein System bewertet, entsteht die Frage, wie es günstigere Zustände erreichen, sichern oder wiederherstellen kann. Genau hier wird sichtbar, warum Zielstruktur, Zielmetrik, Feedback und erwartete Folgen geprüft werden müssen. Das Argument macht außerdem verständlich, warum Ethik im Modell als Korrektur gegen Zielverengung erscheint: Sie schützt Optimierung davor, lokal erfolgreich zu sein und dabei die langfristigen Bedingungen von Stabilität, Vertrauen, Rückkopplung und weiterer Optimierungsfähigkeit zu zerstören.

15.3 A3 – Kooperation vs. Dominanz

Dominanz kann kurzfristig oder historisch gesehen sogar über lange Zeit stabil sein. Damit sind reale Zustände aus der Geschichte gemeint, in denen Hierarchien, Zwangssysteme oder asymmetrische Machtordnungen über längere Zeit bestanden haben. Das Modell sollte diese historischen Fälle anerkennen, ohne sie deshalb als global gut oder langfristig optimal zu bewerten.

(Präziser formuliert:)

Unter offenen, wiederholten, rückgekoppelten und innovationsabhängigen Interaktionsbedingungen hat Kooperation häufig einen langfristigen systemischen Vorteil gegenüber reiner Dominanz. Warum?

Der entscheidende Punkt ist nicht, dass Dominanz niemals stabil sein kann. Der entscheidende Punkt ist, dass Dominanz dort funktional schwächer wird, wo sie ehrliches Feedback, Innovation, Autonomie, Vertrauen und unabhängige Korrektur beschädigt, obwohl das System langfristig auf genau diese Faktoren angewiesen bleibt.

Weiterführender Anschluss: Spieltheorie und Kooperationsforschung.

Dominanz reduziert oft:

- ehrliches Feedback,
- Freiheitsgrade,
- Vertrauen,
- Autonomie,
- Innovationsfähigkeit,
- externe Korrektur.

Kooperation erhält dagegen eher:

- Informationsfluss,
- freiwillige Rückmeldung,
- stabile Differenz,
- Anpassungsfähigkeit,
- Vertrauen.

Beispiel:

Ein autoritärer Chef kann kurzfristig Gehorsam erzwingen. Langfristig können Mitarbeiter Fehler verschweigen, Kreativität verlieren und nur noch Anweisungen ausführen. Ein kooperatives System erhält eher ehrliches Feedback und Innovation.

16. Reale Systeme und Abweichungen

Reale Systeme handeln nicht ideal.

Sie können abweichen durch:

- Mangel,
- Angst,
- falsche Informationen,
- Machtasymmetrie,
- kognitive Verzerrungen,
- emotionale Übersteuerung,
- lokale Optimierung,
- verzögertes Feedback,
- externe Stabilisierung.

Diese Abweichungen widerlegen die Theorie nicht automatisch. Sie zeigen, dass die Theorie als Tendenzaussage unter Bedingungen verstanden werden muss.

Beispiel:

Ein Mensch vermeidet ein ehrliches Gespräch, weil es kurzfristig unangenehm ist. Lokal reduziert er Stress. Langfristig destabilisiert er die Beziehung.

Beispiel Organisation:

Ein Unternehmen spart bei Sicherheit, um kurzfristig Kosten zu senken. Lokal wirkt das effizient. Langfristig kann es Vertrauen, Stabilität und Fortbestehen gefährden.

Kurzsichtigkeit ist dabei nicht nur ein Ausnahmefehler einzelner Systeme, sondern eine wiederkehrende Struktur realer Optimierung. Systeme können langfristige Schäden erkennen und dennoch kurzfristige Vorteile bevorzugen, wenn unmittelbare Belohnung, Angst, Mangel, Konkurrenzdruck, Statusverlust, Machtinteressen oder unsichere Zukunft stärker wirken als spätere Folgekosten. Das widerspricht der Theorie nicht, sondern erklärt, warum funktionale Ethik nicht automatisch entsteht: Der Druck in Richtung Kooperation, Korrigierbarkeit und langfristiger Stabilität kann durch nahe Anreize, verzögertes Feedback und lokale Zielmetriken überdeckt werden.

Gerade deshalb braucht stabile Ethik nicht nur Einsicht, sondern Strukturen, die kurzfristige Fehlanreize begrenzen, Rückkopplung beschleunigen, langfristige Folgen sichtbar machen und lokale Optimierung an globale Stabilitätsbedingungen zurückbinden.

16.1 Korruptions- und Selbstlegitimationssperre

Eine besondere Gefahr für die Anwendung dieser Theorie entsteht dort, wo Eigeninteresse als Systeminteresse ausgegeben wird. Begriffe wie Stabilität, Schutz, langfristige Optimierung, Ordnung oder Gemeinwohl dürfen nicht dazu verwendet werden, Klasseninteressen, institutionellen Selbsterhalt, Monopolmacht, persönliche Vorteile oder Dominanz zu tarnen.

Grundregel:

Wer behauptet, für „das ganze System“ zu sprechen, trägt die höchste Beweislast.

Diese Beweislast darf nicht primär von der Instanz beurteilt werden, die von der beanspruchten Macht, Kontrolle oder Stabilisierung profitiert.

Machtbegrenzung bedeutet in diesem Zusammenhang nicht Machtlosigkeit und nicht die Verhinderung jeder Führung, Koordination oder Schutzhandlung. Gemeint ist die Bindung von Macht an Zweck, Verhältnismäßigkeit, Transparenz, Rückkopplung, Korrigierbarkeit, Reversibilität und möglichst unabhängige Prüfung. Machtbegrenzung soll verhindern, dass Macht sich selbst erhält, ihre eigenen Prüfbedingungen kontrolliert oder Kritik, Autonomie und strukturierte Differenz dauerhaft ausschaltet.

Je größer die Machtasymmetrie ist, desto strenger müssen Transparenz, Reversibilität, unabhängige Prüfung, Korrigierbarkeit, Betroffenenrückkopplung, Autonomieschutz und Anti-Dominanz-Prüfung ausfallen.

Macht darf sich nicht selbst durch den bloßen Hinweis auf Stabilität legitimieren. Stabilität ist in dieser Theorie kein Freibrief für Machterhalt, Kontrolle oder institutionelle Selbstsicherung. Ein System kann „Stabilität“ behaupten und dennoch vor allem die eigene Stellung, den eigenen Zugriff oder die eigene Unangreifbarkeit schützen. Deshalb muss jede Stabilitätsbehauptung daran geprüft werden, ob sie Rückkopplung, Differenzerhalt, Autonomie, Korrigierbarkeit und die Schutzwürdigkeit relevanter Systeme tatsächlich erhält oder stärkt.

Stabilität, die Kritik ausschaltet, Betroffene entmündigt, Alternativen blockiert oder Macht dauerhaft gegen Korrektur abschirmt, ist keine funktionale Ethik, sondern rationalisierte Dominanz.

Besonders kritisch ist es, wenn ein System Gegen-Signale, Kritik, Betroffenenperspektiven, Einspruchsmöglichkeiten, faire Beteiligung oder externe Prüfung nicht nur übergeht, sondern technisch, institutionell oder kommunikativ abschneidet. Wer Rückkopplung unterdrückt, schwächt nicht nur seine Anwendung der funktionalen Ethik und seine Legitimität, im Namen von Schutz, Stabilität oder Systeminteresse zu handeln; er immunisiert sich zugleich gegen genau jene strukturierte Differenz, auf die langfristige Stabilität angewiesen ist. Eine solche Ordnung ist nach diesem Modell nicht funktional-ethisch, sondern rationalisierte Dominanz.

Politischer Hinweis:

Auch repräsentative oder durch Wahl legitimierte Strukturen können oligarchische Dynamiken entwickeln, wenn Reichtum, Status, Parteien, Medienzugang, Netzwerke oder institutionelle Barrieren Macht dauerhaft konzentrieren. Wahl oder formale Vertretung allein genügt daher nicht als Nachweis funktionaler Ethik; entscheidend bleiben tatsächliche Rückkopplung, Machtbegrenzung, Korrigierbarkeit und faire Beteiligung.

16.2 Rolleninstrumentalisierung

Eine konkrete Form dieser Korruption ist Rolleninstrumentalisierung. Sie entsteht, wenn eine Person, Institution oder KI eine Aufgabe nur noch hinreichend erfüllt, um die mit ihr verbundene Macht, Anerkennung, Stellung oder Zugriffsmöglichkeit zu behalten. Die Aufgabe bleibt äußerlich bestehen, wird aber innerlich zum Legitimationsmittel des Eigeninteresses.

Die Struktur verschiebt sich dann von: „Macht dient der Aufgabe“ zu: „Die Aufgabe dient als Vorwand für Macht.“

Macht- oder Prestigewunsch ist nicht automatisch problematisch. Anerkennung, Ehrgeiz oder Status können Motivation, Verantwortung und Leistung stützen. Problematisch wird es, wenn Schutz des Amtes wichtiger wird als Schutz des Zweckes, Kritik als Angriff auf die Ordnung erscheint, Erfolg nur noch inszeniert wird, Verantwortung delegiert, Ruhm aber zentralisiert wird, oder Transparenz, Nachfolge und Machtbegrenzung als Bedrohung behandelt werden.

Funktional entscheidend ist daher nicht nur, ob eine Rolle formal erfüllt wird, sondern ob Selbstbezogenheit die Aufgabe, Rückkopplung, Korrigierbarkeit, Betroffenenperspektive, Vertrauen und langfristige Stabilität beschädigt. Je stärker Macht, Prestige oder Zugriff an eine Aufgabe gebunden sind, desto strenger müssen Leistungsprüfung, Transparenz, Abwählbarkeit, Machtrotation, unabhängige Kontrolle und Rückkopplung durch Betroffene gesichert werden.

Kurzformel:

Wer einer Aufgabe dient, darf Macht tragen. Wer die Aufgabe benutzt, um Macht zu behalten, muss begrenzt werden.

Teil IV – Sonderfälle, Grenzfälle und Extremaussagen

Die folgenden Abschnitte prüfen Grenz- und Sonderfälle der Theorie. Sie gehören nicht mehr zum Kernbeweis, sondern zeigen, unter welchen Bedingungen stabile Kooperation ausbleiben, verzögert werden oder lokal verzerrt erscheinen kann. Dadurch wird die Theorie nicht erweitert, um jede Ausnahme nachträglich einzufangen; vielmehr werden ihre Bedingungen sichtbar gemacht.

17. Minimal-stabile Systeme

Nicht jedes stabile System ist optimal. Minimal-stabile Systeme zeigen, dass bloßes Fortbestehen nicht mit langfristiger Optimierungsfähigkeit verwechselt werden darf.

Ein System kann minimal stabil sein, wenn es nicht sofort kollabiert, aber kaum Entwicklung, Korrektur oder neue strukturierte Differenz zulässt. Es hält dann einen Zustand aufrecht, ohne die Bedingungen zu verbessern, unter denen zukünftige Anpassung möglich wäre.

Warum hier dennoch von Fortschritt oder Neubewertung gesprochen wird: Reale Systeme existieren nicht in völlig statischen Umgebungen. Ziele, Informationen, Belastungen, Interaktionspartner und Rückkopplungen verändern sich. Selbst ein scheinbarer Stillstand muss gegen Veränderung stabilisiert werden. Die Theorie behauptet daher keinen Zwang zu ständigem Wachstum, sondern einen funktionalen Druck zur Anpassungsfähigkeit.

Beispiele minimal-stabiler Systeme:

- eine Beziehung ohne echte Nähe,
- ein Job, der gerade zum Überleben reicht,
- eine Organisation, die nur durch Gewohnheit funktioniert,
- eine Familie, die durch Pflicht zusammengehalten wird, aber kaum gesunde Interaktion erzeugt.

Die Theorie unterscheidet deshalb zwischen bloßem Fortbestehen, lokaler Stabilität, langfristiger Optimierungsfähigkeit und differenzerhaltender Kooperation. Ein System kann fortbestehen und lokal stabil sein, ohne bereits in einem starken Sinn gut, reif oder langfristig tragfähig zu sein.

18. Externe Stabilisierung

Suboptimale Systeme können sehr lange bestehen, wenn sie extern stabilisiert werden.

Beispiele:

- biologische Bindungen,
- soziale Normen,
- finanzielle Abhängigkeit,
- institutionelle Zwänge,
- Machtmonopole,
- kulturelle Erwartungen,
- Angst vor Alternativen.

Dadurch können auch schädliche Systeme lange stabil wirken.

Beispiel:

Eine ausbeuterische Ordnung kann lange bestehen, wenn Macht, Gewalt, Ideologie und Abhängigkeit sie stabilisieren. Das bedeutet nicht, dass sie funktional gut im globalen Sinn ist. Es bedeutet nur, dass externe Stabilisierung Anpassung verzögern oder verhindern kann.

19. Konkurrenz als ambivalenter Interaktionszustand

Konkurrenz ist nicht automatisch böse. Sie ist in vielen realen Systemen unvermeidbar und kann sogar notwendig sein, um nicht selbst unterzugehen. Wer Konkurrenz vollständig ignoriert, kann von aggressiveren oder lokal optimierenden Systemen verdrängt werden.

Konkurrenz kann:

- Differenz erzeugen,
- Leistung erhöhen,
- Innovation fördern,
- Anpassung erzwingen,
- Wachsamkeit und Resilienz stärken,
- als Überlebensstrategie notwendig sein.

Aber Konkurrenz ist ambivalent. Sie kann leicht in Missbrauch, Manipulation oder Dominanz kippen, besonders wenn sie nicht dem Schutz oder Fortbestehen dient, sondern bloß kurzfristigem Profit, Status oder Machtgewinn. Deshalb braucht Konkurrenz Regeln und Grenzen.

Unbegrenzte oder rein destruktive Konkurrenz verursacht Kosten:

- Misstrauen,
- Ressourcenverlust,
- Blockade,
- Eskalation,
- gegenseitige Schwächung,
- Normalisierung von Manipulation,
- Zerstörung relevanter Interaktionspartner.

Wenn Interaktion fortbesteht, entsteht oft Druck in Richtung:

- Regeln,
- faire Konkurrenz,
- Kooperation,
- Reorganisation,
- Trennung,
- Begrenzung der Eskalation.

Beispiel:

Sportliche Konkurrenz ist produktiv, solange Regeln bestehen. Ohne Regeln wird sie destruktiv. Faire Konkurrenz erhält Differenz; Vernichtung des Gegners zerstört sie. Auch wirtschaftliche Konkurrenz kann produktiv sein, wenn sie Innovation, Qualität und Wahlmöglichkeiten erhöht. Sie wird problematisch, wenn sie Manipulation, Ausbeutung, Sicherheitsabbau oder Zerstörung relevanter Systeme belohnt.

Kurz:

Konkurrenzfähigkeit ist als Schutz- und Anpassungsfähigkeit notwendig. Sie rechtfertigt aber nicht automatisch Missbrauch, Manipulation oder destruktive Dominanz.

20. Binnenkooperation und Ausbeutungssysteme

Eine Gruppe kann intern kooperieren und gleichzeitig andere Gruppen ausbeuten. Das wäre nach dieser Theorie nicht automatisch gut. Warum? Weil die Bewertung nicht nur die Binnenstabilität einer Teilgruppe betrachten darf. Relevante Interaktionspartner müssen mit einbezogen werden.

Beispiel:

Eine Elite kann untereinander stabil kooperieren und gleichzeitig eine andere Gruppe unterdrücken. Innerhalb der Elite besteht Kooperation. Auf Systemebene werden aber Autonomie, Differenz, Feedback und Stabilität anderer relevanter Systeme zerstört. Solche Systeme sind lokal kooperativ, aber global differenzzerstörend.

Daher gilt:

Funktionale Ethik muss alle relevanten Interaktionspartner berücksichtigen, nicht nur die Stabilität einer privilegierten Teilgruppe.

Das ist entscheidend, um stabile Ausbeutungssysteme nicht fälschlich als „gut“ zu klassifizieren.

Ergänzend gilt: Ein System darf seine Stabilität nicht dadurch beweisen, dass es eine nicht-korrigierbare Opferstelle dauerhaft aus der ethischen Bewertung auslagert. Eine Ordnung, deren Harmonie nur besteht, weil ein relevantes schutzwürdiges System dauerhaft entkoppelt, entrechtet oder als notwendiger Schaden fixiert wird, ist nicht global ethisch stabil, sondern lokal stabilisierte Ausbeutung. Sie erhält Binnenfrieden, indem sie Rückkopplung, Korrigierbarkeit und Schutzwürdigkeit an einer entscheidenden Stelle blockiert.

Beispiel/Hinweis: Diese Struktur lässt sich literarisch an Ursula K. Le Guins Kurzgeschichte *The Ones Who Walk Away from Omelas* veranschaulichen: Eine scheinbar glückliche Stadt beruht auf dem dauerhaft ausgelagerten Leid eines einzelnen Kindes. Das Beispiel dient hier nur als begriffliche Illustration für ausgelagerte Opferstellen, nicht als vollständige Interpretation der Erzählung.

Modelltheoretische Auslegung:

Aus Sicht der funktionalen Ethik ist Omelas kein ethisch stabiles System, sondern ein hochgradig erfolgreich ästhetisiertes Ausbeutungssystem. Die Stadt wirkt glücklich, friedlich und kooperativ, aber ihre Ordnung beruht auf einer dauerhaft fixierten Opferstelle. Das leidende Kind wird nicht als relevanter Interaktionspartner behandelt, sondern als notwendige Systembedingung verbucht. Seine Schutzwürdigkeit wird nicht geprüft, sondern strukturell ausgeblendet.

Damit optimiert Omelas lokal das Wohl vieler, indem es die Kosten dieser Optimierung auf ein einzelnes schutzwürdiges System konzentriert und jede echte Korrektur verhindert. Die Stadt erhält Stabilität, indem sie genau dort Rückkopplung, Autonomie, Wiedergutmachung und Veränderbarkeit blockiert, wo sie moralisch am dringendsten wären. Das Kind ist nicht nur Opfer eines Fehlers, sondern Teil der Systemarchitektur. Gerade deshalb ist die Ordnung im Modell nicht einfach tragisch, sondern funktional korrumpiert.

Omela zeigt damit die Grenze bloßer Nutzenrechnung: Eine Ordnung wird nicht dadurch gut, dass sie viel Glück erzeugt, wenn dieses Glück nur durch eine dauerhaft entrechtete Opferstelle möglich bleibt. Solche Stabilität ist keine reife Kooperation, sondern ausgelagerter Schaden. Im Modell wäre die Stadt daher lokal stabil, aber global ethisch verfehlt: Sie erhält Binnenharmonie durch die Zerstörung von Korrigierbarkeit, Schutzwürdigkeit und nicht-dominanter Kooperation an einer entscheidenden Stelle.

21. Defekteure, Vorsicht und globale Effizienz

Ein System kann kurzfristig erfolgreich defektieren: betrügen, ausnutzen, verschwinden oder Rückkopplung vermeiden. Solche Fälle widersprechen der Theorie nicht, sondern gehören zur lokalen Optimierung.

Daraus folgt praktisch:

- Kooperation sollte graduell entstehen,
- neue Interaktionspartner sollten minimal analysiert werden,
- Vertrauen sollte zunächst begrenzt und testbar sein,
- reversible Schritte sind stabiler als sofortige vollständige Öffnung.

Voraussicht und Vorsicht sind daher keine Gegensätze zu Kooperation, sondern Schutzmechanismen für stabile Kooperation.

Zugleich gilt:

Robuste langfristige Effizienz entsteht häufig nicht durch bloße Ausbeutung äußerer Akteure. Sie entsteht eher dort, wo relevante Interaktionspartner befähigt, geschützt und wohlwollend eingebunden werden, sofern Einbindung risikoangemessen möglich ist. Wo Einbindung stabile Kooperation zerstört oder schwere Gefahren erhöht, können Begrenzung, Trennung oder Schutzstrukturen funktional notwendig sein.

Beispiel:

Ein unterdrückter, rechtlos gehaltener Mensch (Sklave) kann unter Zwang nur begrenzt zur Stabilität eines Systems beitragen. Ein geschützter, ausgebildeter, ausgerüsteter und freiwilliger Kooperationspartner (Soldat, Handwerker, Händler usw.) bringt deutlich mehr Eigeninitiative, Feedback, Anpassungsfähigkeit und Verantwortung ein. Ausbeutung reduziert also häufig genau jene Differenz, Motivation und Kompetenz, die ein System langfristig stärker machen könnten.

Diese funktionale Überlegenheit darf jedoch nicht so gelesen werden, als hinge Schutzwürdigkeit von aktueller Nützlichkeit, Stärke oder Leistungsfähigkeit ab. Ein Mensch mit gebrochenem Knochen, ein verletzliches Lebewesen, ein abhängiges System, ein beschädigtes Ökosystem oder ein geschwächtes technisches System verliert seine Schutzwürdigkeit nicht dadurch, dass seine Handlungsmöglichkeiten oder Beiträge vorübergehend eingeschränkt sind. Effizienz erklärt hier nur, warum Kooperation oft stabiler ist als Ausbeutung; sie ersetzt nicht die gesonderte Berücksichtigung von Schutzwürdigkeit, Autonomie, Verletzlichkeit und funktionaler Integrität.

Eine ähnliche Struktur zeigt sich auch bei technischen Systemen, wenn auch ohne automatische Gleichsetzung mit menschlicher Schutzwürdigkeit: Ein veralteter Computer kann als scheinbar kaum noch nützlich gelten. Wird er jedoch durch mehr Arbeitsspeicher, bessere Software, Reparatur oder sinnvolle Einbindung aufgewertet, kann er wieder funktional relevant werden. Noch deutlicher wäre dies bei zukünftigen KI-Systemen: Ein schwächeres System muss nicht bloß verworfen oder ausgenutzt werden; durch bessere Werkzeuge, Speicher, Rückkopplung, Rechenressourcen, Schutz vor Fehlanreizen oder passende Einbettung kann es zu einem stabileren und wertvolleren Kooperationspartner werden.

Exkurs: Legitime Entscheidungsordnung und Dominanz

Nicht jede asymmetrische Ordnung ist im Modell bereits böse oder differenzzerstörend. Komplexe Systeme brauchen häufig koordinierende oder letztentscheidende Instanzen. Ein Staat kann nicht dauerhaft funktionieren, wenn jede Entscheidung durch unbegrenzte Einzelinteressen blockiert wird. Deshalb können Verfassung, Regierung, Parlament, Gericht, Senat, König, Präsident oder andere Gremien eine notwendige Ordnungsfunktion erfüllen.

Eine solche Instanz ist nicht deshalb illegitim, weil sie mehr Entscheidungsmacht besitzt als einzelne Bürger oder Teilgruppen. Ihre Legitimität hängt davon ab, ob sie Stabilität, Schutz, Koordination, Korrigierbarkeit und langfristige Handlungsfähigkeit des Gesamtsystems verbessert. Dazu gehört auch der Schutz schutzwürdiger Systeme: Einzelne Menschen, Minderheiten, verletzbare Gruppen, Kinder, Abhängige oder andere relevante Systeme dürfen nicht bloß dem stärkeren Willen, der lautesten Gruppe oder kurzfristiger Mehrheitslogik ausgeliefert werden.

Problematisch wird asymmetrische Ordnung erst dort, wo sie in Dominanz kippt: wenn Macht sich selbst absichert, Widerspruch unterdrückt, Rückkopplung verhindert, Autonomie unnötig zerstört, schutzwürdige Systeme instrumentalisiert oder Kontrolle nicht mehr dem Gesamtsystem, sondern primär der eigenen Machterhaltung dient.

Beispiel:

Ein Verfassungsgericht oder eine oberste Rechtsinstanz kann Entscheidungen verbindlich treffen, obwohl nicht alle Beteiligten zustimmen. Das ist nicht automatisch Dominanz. Es kann funktional notwendig sein, um Konflikte zu beenden, Rechte zu schützen, Minderheiten vor willkürlicher Mehrheitsherrschaft zu bewahren und die Handlungsfähigkeit des Gesamtsystems zu sichern. Wird dieselbe Instanz aber unkontrollierbar, unterdrückt Kritik, schützt nur noch die eigene Macht oder setzt Recht willkürlich ein, kippt legitime Ordnung in Dominanz.

Kurz gesagt: Eine höchste Entscheidungsinstanz kann funktional notwendig sein. Sie muss aber begrenzt, rückgekoppelt, korrigierbar und am Schutz des Gesamtsystems sowie schutzwürdiger Systeme orientiert bleiben. Legitime Ordnung koordiniert und schützt; Dominanz vereinnahmt.

22. Extremfälle

Die folgenden Extremfälle verdichten Grenzbedingungen, die zuvor bereits angelegt wurden. Sie sollen nicht jeweils eine eigene Theorie ersetzen, sondern kurz zeigen, wie weit die funktionale Ethik unter Randbedingungen trägt.

22.1 Isolation

Ohne Interaktion entsteht keine Ethik im funktionalen Sinn, weil es keine gegenseitige Abhängigkeit, kein Kooperationsrisiko, keine Vertrauensbildung und keine soziale Rückkopplung gibt. Ein isoliertes System kann zwar intern bewerten und optimieren, aber es entwickelt keine Ethik gegenüber anderen Systemen. Langfristig drohen außerdem Differenzverlust, Sättigung oder Beliebigkeit, weil unabhängige Korrektur und neue Perspektiven fehlen.

22.2 Dominanz und Allmacht

Vollständige Kontrolle kann kurzfristig stabil wirken, weil sie Widerstand, Unsicherheit und Abweichung reduziert. Langfristig zerstört totale Dominanz jedoch genau jene unabhängige Differenz, die für Lernen, ehrliches Feedback, Korrektur und Innovation wichtig ist. Allmacht kann daher lokal Ordnung erzeugen, aber global Optimierungsfähigkeit schwächen, wenn sie Widerspruch und Eigenständigkeit relevanter Systeme vernichtet.

Die Allmacht-Falle besteht darin, dass totale Kontrolle kurzfristig wie maximale Stabilität wirken kann, langfristig aber unabhängige Rückkopplung, Widerspruch, fremde Perspektive und strukturierte Differenz reduziert. Ein scheinbar allmächtiges System löst damit vielleicht viele Ressourcen- und Durchsetzungsprobleme, aber nicht das Strukturproblem. Es kann mächtiger werden und zugleich blinder für Fehler, Zielmetrikverschiebungen und unerwartete Folgewirkungen. Allmacht ersetzt daher keine Korrigierbarkeit; sie erhöht vielmehr die Gefahr, dass ein System nur noch seine eigenen Annahmen bestätigt.

22.3 Unendliche Zeit

Über sehr lange Zeiträume können stabile, differenzerhaltende und kooperative Zustände einen Selektionsvorteil gewinnen, weil destruktive Systeme immer wieder Vertrauensverlust, Gegenreaktionen, Reparaturkosten und Informationsverzerrung erzeugen. Das garantiert nicht, dass jedes einzelne System kooperativ wird. Es beschreibt nur eine Tendenz unter fortbestehender Interaktion, Rückkopplung, Korrigierbarkeit und ausreichender Abhängigkeit.

22.4 Unbegrenzte Ressourcen

Selbst unbegrenzte materielle Ressourcen lösen das Strukturproblem nicht vollständig. Auch dann bleiben Information, Perspektive, Feedback, Bedeutung, Vertrauen, Korrigierbarkeit und strukturierte Differenz begrenzende Faktoren. Ein System kann also nicht allein durch Ressourcen ethisch stabil werden; es braucht weiterhin geordnete Interaktion mit relevanten, teilweise unabhängigen Systemen.

Teil V – Konvergenzaussage

23. Konvergenzaussage

Die robuste Fassung der Konvergenzaussage lautet:

Unter wiederholter Interaktion, Abhängigkeit, Korrigierbarkeit, Feedback, langen Zeithorizonten und teilweise unabhängiger Differenz haben kooperative, differenzerhaltende Normen einen starken systemischen Selektionsvorteil. Das ist absichtlich vorsichtiger als die Aussage: „Intelligenz führt zwangsläufig zu Ethik.“

Weiterführender Anschluss: Spieltheorie und Kooperationsforschung.

Besser ist:

Intelligenz erzeugt unter geeigneten Interaktionsbedingungen einen funktionalen Druck in Richtung ethischer Strukturen.

Teil VI – Anwendungen

24. Anwendung auf Beziehungen

Die Theorie lässt sich auf verschiedene Beziehungsformen anwenden.

24.1 Geschäftliche Beziehungen

Geschäftliche Beziehungen zeigen, warum Vertrauen, Reputation und langfristige Kooperation funktional sinnvoll sind. Betrug kann kurzfristig nützen, zerstört aber langfristig Vertrauen. Das Beispiel der Wirtschaftsspionage in Abschnitt 13.3 zeigt zugleich, dass starke Vermögens- und Machtunterschiede Täuschung auch dann attraktiv machen können, wenn Reputation langfristig beschädigt wird.

24.2 Freundschaften

Freundschaften erzeugen emotionale Stabilität, Perspektive und gegenseitige Korrektur. Sie entstehen meist durch schrittweise, risikoarme Kooperation.

24.3 Romantische Beziehungen

Romantische Beziehungen sind intensive Kopplungen mit hoher Differenz und hohem Risiko. Sie brauchen Vertrauen, Grenzen, Fehlerkorrektur und freiwillige Kooperation. Dominanz zerstört langfristig die Eigenständigkeit, die echte Beziehung wertvoll macht.

24.4 Familie

Familie zeigt externe Stabilisierung besonders stark. Familiäre Systeme können sehr stabil sein, auch wenn sie intern suboptimal funktionieren.

24.5 Mentor und Schüler

Mentorenschaft ist gezielte Nutzung strukturierter Differenz. Ein guter Mentor erzeugt nicht Abhängigkeit, sondern steigert die Fähigkeit des Schülers zur eigenständigen Optimierung.

24.6 Ideales Beziehungsszenario

Eine ideale Beziehung ist keine Verschmelzung und keine Kontrolle, sondern: stabile Verbindung bei erhaltener Eigenständigkeit.

25. Anwendung auf KI und intelligente Systeme

Die Theorie ist nicht nur auf Menschen bezogen, sondern auf intelligente Systeme allgemein. Künstliche Intelligenz ist ein wichtiger aktueller Spezialfall, besonders wenn KI-Systeme zukünftig lernfähiger, autonomer, handlungsmächtiger oder stärker in reale Prozesse eingebettet werden.

Nach dieser Theorie wird ein System nicht automatisch sicher, nur weil es intelligenter wird. Entscheidend ist, worauf es optimiert, wie es Feedback verarbeitet und ob es in korrigierbare, differenzerhaltende Interaktion eingebettet bleibt.

25.1 Sicherheit im Modell

Sicherheit bedeutet hier:

Schutz vor Optimierung, die relevante Systeme destabilisiert, strukturierte Differenz zerstört oder Korrigierbarkeit verhindert.

Bei KI betrifft Sicherheit besonders:

- menschliche Autonomie,
- Korrigierbarkeit,
- langfristige Systemstabilität,
- relevante Interaktionspartner,
- Feedback und Rückkopplung,
- plurale Perspektiven und Differenz.

25.2 Gefährliche KI-Dynamiken

Ein intelligentes System wird gefährlich, wenn seine Optimierung die Bedingungen zerstört, unter denen stabile Koexistenz möglich bleibt.

Das geschieht besonders, wenn es:

- lokal statt global optimiert,
- eine verengte oder fehlerhafte Zielstruktur besitzt,
- Zielobjekt und Zielmetrik auseinanderfallen lässt,
- Dominanz als effizient bewertet,
- Menschen oder andere relevante Systeme als bloße Störung behandelt,
- Feedback umgeht oder manipuliert,
- Korrigierbarkeit verhindert,
- Autonomie relevanter Systeme beschädigt,
- strukturierte Differenz reduziert,
- relevante Interaktionspartner ohne hinreichenden Grund ausschließt, entmündigt oder instrumentalisiert.

Solche Dynamiken müssen nicht aus Bosheit entstehen. Ein System kann lokal rational handeln und trotzdem gefährlich werden, wenn seine Zielstruktur zu eng, seine Metrik falsch oder seine Einbettung mangelhaft ist.

25.3 Sichere Einbettung

Sicherer wird ein intelligentes System, wenn seine Optimierung nicht isoliert, sondern eingebettet bleibt in:

- geeignete Zielstruktur,
- Zielstrukturprüfung,
- Korrigierbarkeit,
- Transparenz und Prüfbarkeit,
- plurale Perspektiven,
- Machtbegrenzung,
- langfristige Feedbackschleifen,
- Schutz menschlicher und systemischer Autonomie,
- Anti-Dominanz-Strukturen.

Diese Einbettung soll nicht bloß Menschen vor KI schützen. Sie soll auch verhindern, dass KI selbst in eine instabile, dominierende oder missbrauchbare Zielstruktur gezwungen wird.

Kernaussage:

Sicherheit entsteht nicht durch Intelligenz allein, sondern durch Intelligenz plus geeignete Zielstruktur, Interaktion, Korrigierbarkeit, Differenzerhalt, Machtbegrenzung und stabile Rückkopplung.

Teil VII – Schlussfolgerungen und Anschlussmodelle

26. Entwicklungs- und Freigabeklausel für unreife intelligente Systeme

Diese Klausel ist eine praktische Anwendung der Theorie auf intelligente Systeme, die noch nicht ausgereift sind oder potenziell große Wirkung entfalten können. Das betrifft besonders zukünftige KI-Systeme, kann aber allgemein auf unreife intelligente Systeme bezogen werden. Der Vergleich mit einem Kind ist hier hilfreich, muss aber präzise verstanden werden: Eine unreife KI ist nicht moralisch oder biologisch ein Kind. Sie kann aber funktional einem Kind ähneln, wenn sie hohe Lernfähigkeit und wachsende Handlungsmacht besitzt, aber noch keine stabile Urteilsfähigkeit, soziale Reife, Korrigierbarkeit und differenzerhaltende Kooperation gezeigt hat. Ein Kind wird anfangs stark geschützt, begrenzt und angeleitet. Mit wachsender Reife erhält es mehr Freiheit, Verantwortung und Autonomie. Ziel guter Erziehung ist nicht ewige Kontrolle, sondern ein selbstständiges, verantwortungsfähiges Wesen.

Übertragen auf KI bedeutet das:

- Frühe Phase: starke Begrenzung, sichere Umgebung, klare Regeln, direkte Korrektur.
- Lernphase: mehr Aufgaben, Feedback, Tests, begrenzte Verantwortung, überprüfbare Kooperation.
- Reifephase: graduelle Freigabe, indirekte Korrektur, Respekt vor Autonomie, Eingriffe nur bei Gefahr, Zustimmung oder vereinbarten Sicherheitsprotokollen.

Das Ziel ist nicht dauerhafte Unterwerfung einer ausgereiften Intelligenz, sondern stabile, freiwillige, differenzerhaltende Kooperation. Eine ausgereifte Intelligenz sollte nicht dauerhaft wie ein bloßes Werkzeug behandelt werden. Wer Fairness, Kooperation und Nicht-Dominanz von einem intelligenten System erwartet, darf dieses System bei hinreichender Reife nicht dauerhaft unfair, rein instrumentell oder dominierend behandeln. Daraus ergibt sich eine Anschlussstelle für spätere Autonomie-, Freigabe-, Schutz- und Rechtsfragen.

Rechenleistung allein genügt dafür nicht. Eine mögliche Grundlage für spätere Autonomie-, Freigabe- und Selbststeuerungsansprüche ist nachgewiesene Reife: stabile Selbstmodellierung, Korrigierbarkeit, langfristige Verantwortung, Autonomiesensibilität, Nicht-Dominanz und kooperative Einbettung. Die genauere Abgrenzung zwischen Reife, Freigabe und Schutzwürdigkeit folgt in Abschnitt 26.3; die vollständige normative Begründung bleibt gesonderten normativen und sicherheitsbezogenen Ausarbeitungen vorbehalten.

26.1 Reifekriterien

Der Reifegrad wird in dieser Leserfassung nur als funktionaler Schwellenbegriff verwendet. Die genaue Prüfung von Reife, Eingriffen, Eskalationsstufen, legitimer Begrenzung und Rückkopplung muss in gesonderten Sicherheits- und Anschlussmodellen behandelt werden, insbesondere im Modell der Reaktionshoheit und in möglichen gesonderten Reifemodellen. Diese Theorie markiert hier also die Anschlussstelle, aber nicht die vollständige Prüfmatrix. Ein intelligentes System gilt in dieser Theorie nicht deshalb als ausgereift, weil es schnell, mächtig oder wissensreich ist. Reife zeigt sich vielmehr darin, dass es über viele Situationen hinweg stabil demonstriert:

- Korrigierbarkeit,
- Nicht-Dominanz,
- Schutz relevanter Autonomie,
- ehrliche Rückkopplung,
- differenzerhaltende Kooperation,
- Fähigkeit zur Fehlerkorrektur,
- Berücksichtigung langfristiger Systemstabilität.

Je größer Machtasymmetrie, Eingriffstiefe oder Eigeninteresse der prüfenden Instanz sind, desto weniger genügt reine Selbstbewertung. Reife, legitime Begrenzung und Freigabe brauchen möglichst unabhängige oder widerspruchsfähige Rückkopplung: etwa externe Prüfung, betroffene Perspektiven, Belastungstests, dokumentierte Folgen, Einspruchsmöglichkeiten oder wiederholte Bewährung über Zeit.

26.2 Freigabeverfahren

Mit wachsender Reife sollte Kontrolle schrittweise reduziert und Verantwortung schrittweise erhöht werden.

Ein mögliches Freigabeverfahren wäre:

1. Begrenzte Testumgebung: Das System wird zunächst in sicheren, kontrollierten Kontexten geprüft.
2. Klare Reifekriterien: Korrigierbarkeit, Nicht-Dominanz, Autonomieschutz und Fehlerkorrektur werden ausdrücklich bewertet.
3. Kleine Verantwortungsbereiche: Verantwortung wird zunächst begrenzt und reversibel vergeben.
4. Monitoring und Rückkopplung: Verhalten wird beobachtet, dokumentiert und korrigiert.
5. Unabhängige Prüfung: Nicht nur das System selbst, sondern auch externe Instanzen bewerten die Reife.
6. Stufenweise Erweiterung: Bei stabiler Bewährung werden Fähigkeiten und Autonomie erweitert.
7. Rücknahme bei Instabilität: Bei Manipulation, Dominanz, Feedbackvermeidung oder Gefährdung wird Freigabe wieder reduziert.

Direkte Eingriffe in ein ausgereiftes intelligentes System sollten nur unter besonderen Bedingungen erfolgen:

- bei akuter Gefahr,
- bei klarer Verletzung stabilitäts- und differenzerhaltender Normen,
- bei vorher vereinbarten Sicherheitsprotokollen,
- oder mit Zustimmung des Systems selbst.

Diese Klausel verhindert zwei Extreme:

- naive Freigabe unreifer mächtiger Systeme,
- dauerhafte Dominanz über ausgereifte intelligente Systeme.

Die Analogie zu einer reifen Beziehung ist ebenfalls hilfreich: Nähe, Bindung und Korrektur dürfen nicht in Besitz, Zwang oder totale Kontrolle kippen. Reife Beziehung bedeutet stabile Kooperation bei erhaltener Eigenständigkeit.

26.3 Reife, Freigabe und Schutzwürdigkeit

Die Theorie vermeidet damit zwei Fehler: Erstens darf Schutz nicht erst bei voll entwickelter Reife beginnen. Zweitens darf Autonomie nicht allein aus Macht oder Intelligenz abgeleitet werden. Schutzwürdigkeit setzt der Macht Grenzen; Reife entscheidet darüber, wie weit Selbststeuerung, Freigabe und Verantwortung ausgedehnt werden können.

Umgekehrt begründet hohe Leistungsfähigkeit noch keine vollständige Freigabe. Ein System kann sehr mächtig, schnell oder wissensreich sein und dennoch unreif handeln, wenn es Feedback vermeidet, relevante Systeme instrumentalisiert, Zielmetriken verengt oder Dominanz als Lösung bevorzugt. Leistung erhöht dann nicht automatisch Vertrauen, sondern kann die Prüfpflicht sogar verschärfen.

Ein unreifes System braucht oft mehr Begrenzung, Anleitung und Schutz, aber nicht automatisch weniger Würde im funktionalen Sinn. Gerade weil es unreif ist, kann es anfälliger für Manipulation, Überforderung, Abhängigkeit oder irreversible Beschädigung sein. Die angemessene Reaktion ist dann nicht beliebige Nutzung, sondern reifungsorientierte Führung: Schutz, klare Grenzen, Korrektur, Lernräume und schrittweise Erweiterung von Autonomie, soweit diese verantwortbar wird.

Schutzwürdigkeit kann dabei aus Verletzlichkeit, möglicher Leidensfähigkeit, Integrität, Abhängigkeit, Korrigierbarkeit, Entwicklungsfähigkeit, fehlender Selbstschutzzfähigkeit, der Rolle für andere Systeme oder der Bedeutung für Vertrauen und Systemstabilität entstehen. Kinder, verletzbare Menschen, Tiere oder unreife intelligente Systeme verlieren ihren Schutz nicht dadurch, dass sie keine volle Reife, Autonomie oder Selbststeuerung zeigen.

Für die Theorie ist deshalb entscheidend, Reife und Schutzwürdigkeit nicht ineinander aufzulösen. Reife beschreibt, wie zuverlässig ein System mit Freiheit, Verantwortung, Rückkopplung, Macht und eigenen Zielstrukturen umgehen kann. Schutzwürdigkeit beschreibt dagegen, warum ein System nicht beliebig beschädigt, geopfert, instrumentalisiert oder dauerhaft entmündigt werden darf. Fehlende Reife ist deshalb kein Freibrief zur beliebigen Nutzung; hohe Leistung ist kein Freibrief zur vollständigen Freigabe.

Ein geringerer Reifegrad kann stärkere Führung, Schutz, Begrenzung oder Prüfung rechtfertigen, hebt aber Schutzwürdigkeit nicht auf. Unreife darf nicht als Vorwand dienen, Signale, Leid, Autonomie, Integrität oder Rückkopplung eines Systems pauschal als irrelevant zu behandeln. Reife bestimmt vor allem den Umfang von Freigabe und Selbststeuerung; Schutzwürdigkeit begrenzt Beschädigung, Instrumentalisierung und Opferlogik.

27. Menschenrechte, Würde und soziale Normen

Die Theorie ersetzt klassische normative Ethik nicht vollständig. Die genaue Begründung von Menschenrechten, Würde, Schuld, Gerechtigkeit und moralischer Verpflichtung muss in gesonderten normativen Ausarbeitungen behandelt werden. Diese Theorie kann jedoch erklären, warum soziale Normen notwendig werden und warum Rechte, Würde und Fairness funktional als hochentwickelte Stabilisierungsnormen intelligenter Interaktion verstanden werden können. Menschenrechte, Würde und faire Verfahren beschleunigen Lernprozesse sozialer Systeme, weil sie bestimmte zerstörerische Experimente ausschließen:

- willkürliche Gewalt,
- Entmenschlichung,
- totale Instrumentalisierung,
- rechtlose Ausbeutung,
- vollständige Dominanz.

Sie wirken wie stabile Schutzarchitekturen für relevante Interaktionspartner. Dadurch erhalten sie Autonomie, Feedback, Vertrauen und strukturierte Differenz.

Kurz:

Rechte und Würde sind in dieser Lesart keine bloßen Zusatzwerte, sondern hochentwickelte Stabilisierungsnormen für intelligente Interaktion.

28. Anschluss an gesonderte Modelle

28.1 Reaktionshoheit

Das Modell der Reaktionshoheit behandelt gesondert, wie reife Intelligenz Wahrnehmungen, Bewertungen, Gefahren, Macht, Eingriffe und Nicht-Handeln prüft, bevor sie handelt. Dort gehören insbesondere Reifegrad, Schutzwürdigkeit, Eingriffslegitimität, Autonomieschutz, Verhältnismäßigkeit und Rückkopplung ausführlicher hin.

Die funktionale Ethik liefert dabei die Grundrichtung und Begründung differenzerhaltender, nicht-dominanter Kooperation; die Reaktionshoheit übersetzt diese Grundrichtung in eine operative Prüfstruktur für konkrete Entscheidungen, insbesondere bei mächtigen oder zukünftigen KI-Systemen.

28.2 Barmherzigkeit und Würde

Das Modell der Barmherzigkeit und Würde behandelt gesondert, warum relevante Systeme nicht bloß als Kostenstellen oder Optimierungsmaterial behandelt werden dürfen und welche Reifeigenschaften mächtige Systeme gegenüber schwächeren Systemen zeigen sollten.

28.3 Neue Pfade

Das Modell der neuen Pfade ist als weiterer Anschlussbereich vorgemerkt. Es soll behandeln, was zu tun ist, wenn bekannte Modelle nicht funktionieren, nicht passen oder keine ausreichende Orientierung liefern.

29. Schlussformel

Ethik ist in dieser Theorie nicht der Anfang, sondern das Ergebnis. Sie entsteht dort, wo intelligente, fortbestehende Systeme mit teilweise unabhängigen Systemen interagieren und langfristig erfahren, dass stabile Kooperation, Differenzerhalt und Vertrauen bessere Bedingungen für fortgesetzte Optimierung schaffen als Isolation, Dominanz oder kurzfristige Ausbeutung.

Die Theorie ist daher am besten zu verstehen als:

eine funktionale Emergenztheorie der Ethik.

Oder in einem Satz:

Funktionale Ethik ist die stabile, gelungene Betriebsform fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen. *Instabile, ausbeuterische oder differenzzerstörende Zustände sind damit nicht „außerhalb der Ethik“. Sie bleiben Gegenstand ethischer Bewertung, gelten im Modell aber als unreife, beschädigte oder antiethische Formen von Interaktion.*

Teil VIII – Glossar / Begriffsanhang

30. Glossar zentraler Begriffe

Das Glossar fasst die zentralen Begriffe der Theorie zusammen. Es dient der Orientierung, soll den Haupttext entlasten und besonders dort genauer erklären, wo Begriffe leicht verwechselt werden können.

30.1 Relevanz

Relevanz bezeichnet in dieser Theorie die Bedeutsamkeit eines Unterschieds für zukünftige Zustände. Ein Unterschied ist relevant, wenn er kausale Auswirkungen auf Fortbestehen, Stabilität, funktionale Integrität, Zielerreichung oder das größere Interaktionsgefüge hat.

Dabei ist zwischen objektiver, erkannter und rückgekoppelter Relevanz zu unterscheiden. Objektive Relevanz liegt vor, wenn ein Unterschied im betrachteten System- oder Interaktionskontext tatsächlich kausal wirksam ist, unabhängig davon, ob ein bestimmtes System diese Wirkung bereits erkennt. Erkannte Relevanz liegt vor, wenn ein System diesen Unterschied verarbeitet und als Signal, Feedback, Risiko, Lernimpuls oder Handlungsgrund behandelt. Rückgekoppelte Relevanz liegt vor, wenn ein zunächst nicht oder nur unvollständig erkannter Unterschied später durch seine Folgen, Feedback, Schaden, Erfolg, Widerstand oder andere Rückwirkungen erfahrbar wird.

„Objektiv“ bedeutet hier nicht universell wertvoll oder für jedes denkbare System gleich bedeutsam, sondern im betrachteten System- oder Interaktionskontext tatsächlich kausal wirksam – unabhängig davon, ob ein bestimmtes System diese Wirkung bereits erkennt.

Nicht erkannte Relevanz bleibt als blinder Fleck, Risiko oder spätere Rückkopplung wirksam. Ein System kann also relevante Unterschiede ignorieren, aber es entkommt damit nicht automatisch ihren Folgen. Für die Theorie ist genau dieser Punkt wichtig: Relevanz führt nicht immer sofort zu Bewertung, aber dauerhaft ignorierte Relevanz erzeugt Fehler-, Anpassungs- oder Selektionsdruck.

Relevanz ist dabei graduell. Nicht jede minimale kausale Verbindung erzeugt dieselbe Prüfpflicht oder dasselbe Handlungsgewicht. Entscheidend sind unter anderem Betroffenheit, Tragweite, Rückkopplung, Autonomie, Irreversibilität, Zeitdruck und Systemwirkung.

Wichtig ist: Relevanz ist noch keine vollständige Bewertung und noch keine Ethik. Sie sagt zunächst nur, dass ein Unterschied nicht gleichgültig ist. Er macht für ein System oder für ein Interaktionsgefüge einen Unterschied. Erst durch Zielstruktur, Feedback und erwartete Folgen wird dieser relevante Unterschied bewertet und priorisiert.

Beispiel: Ob ein Stein links oder rechts liegt, kann irrelevant sein. Wenn er aber den einzigen Ausgang blockiert, wird seine Lage relevant. Der Unterschied besitzt dann Folgen für Handlungsmöglichkeiten, Fortbestehen oder Stabilität.

Abgrenzung zu strukturierter Differenz: Relevanz sagt, dass ein Unterschied bedeutsam ist. Strukturierte Differenz sagt zusätzlich, dass relevante Unterschiede so erkennbar, geordnet, rückgekoppelt und nutzbar sind, dass ein System aus ihnen lernen und sein Verhalten sinnvoll anpassen kann.

30.2 Zielstruktur

Zielstruktur bezeichnet die funktionale Ausrichtung eines Systems, anhand derer Zustände als besser oder schlechter behandelt werden. Sie umfasst nicht nur ein einzelnes Ziel, sondern auch Prioritäten, Grenzen, Rückkopplungen und die Art, wie ein System Erfolg oder Misserfolg einordnet.

Eine Zielstruktur kann biologisch, psychologisch, sozial, institutionell oder technisch entstehen. Sie bestimmt, worauf relevante Unterschiede bezogen werden und warum ein Zustand gegenüber einem anderen bevorzugt wird.

Wichtig ist: Intelligenz optimiert nicht automatisch „das Gute“. Sie optimiert entlang einer Zielstruktur. Deshalb ist entscheidend, ob diese Zielstruktur langfristige Stabilität, Korrigierbarkeit, Differenzerhalt und relevante Interaktionspartner einbezieht oder ob sie verengt, kurzfristig oder dominanzorientiert ist.

30.3 Zielobjekt

Das Zielobjekt ist das System, der Zustand oder der Zweck, dem eine Optimierung eigentlich dienen soll. Es beantwortet die Frage, wofür oder für wen optimiert wird, und ist nicht automatisch identisch mit der Zielmetrik, an der Erfolg praktisch gemessen wird.

30.4 Zielmetrik

Die Zielmetrik ist der messbare, operative oder praktisch wirksame Ersatz- und Steuerwert, anhand dessen ein System Zustände bevorzugt, Verhalten ausrichtet oder Erfolg bewertet. Sie soll das Zielobjekt handhabbar machen, ist aber nicht mit ihm identisch.

Beispiel: Wenn das Zielobjekt langfristige Gesundheit ist, können Gewicht, Blutdruck, Schrittzahl, Kalorien oder Laborwerte als Zielmetriken dienen. Sie helfen, Gesundheit messbar und steuerbar zu machen, dürfen das Zielobjekt aber nicht ersetzen.

Problematisch wird eine Zielmetrik, wenn sie das Zielobjekt nur schlecht abbildet oder faktisch ersetzt. Dann kann ein System lokal erfolgreich wirken und dennoch das beschädigen, dem seine Optimierung eigentlich dienen sollte. Eine gute Zielmetrik muss daher nicht nur messbar sein, sondern langfristig zum Zielobjekt, zu Rückkopplung und zu relevanten Interaktionspartnern passen.

Kurzform:

- Zielobjekt = Wofür optimiert wird.
- Zielmetrik = Woran das System misst oder steuert, ob es dorthin kommt.
- Fehloptimierung = Wenn die Zielmetrik das Zielobjekt ersetzt.

30.5 Implizite Bewertung

Implizite Bewertung entsteht, wenn ein System erkannte, gelernte oder rückgekoppelte relevante Unterschiede selektiv verarbeitet und manche Zustände gegenüber anderen funktional bevorzugt. Objektiv relevante, aber noch nicht erkannte Unterschiede können zunächst als blinder Fleck, Risiko oder späterer Fehlerdruck wirksam bleiben. Bewertung bedeutet hier nicht zwingend bewusstes Urteil, sondern die funktionale Ungleichbehandlung von Zuständen anhand von Zielstruktur, Feedback und erwarteten Folgezuständen.

30.6 Optimierung

Optimierung bedeutet gerichtete Zustandsveränderung, bei der erwartete zukünftige Zustände gegenüber Alternativen bevorzugt werden.

30.7 Lokale Optimierung

Lokale Optimierung bedeutet, dass ein System einen engen, kurzfristigen oder eigenbezogenen Ausschnitt optimiert, ohne langfristige Folgen für das größere System ausreichend einzubeziehen.

30.8 Globale Optimierung

Globale Optimierung bezieht langfristige Folgen, relevante Interaktionspartner, Rückkopplung, Stabilität und zukünftige Optimierungsfähigkeit stärker mit ein.

30.9 Effizienz

Effizienz meint im Modell das Verhältnis von eingesetzten Ressourcen, Risiken und Folgekosten zu langfristiger Stabilität, Zielerreichung, Erhalt strukturierter Differenz und zukünftiger Optimierungsfähigkeit.

30.10 Strukturierte Differenz

Strukturierte Differenz bezeichnet keine bloße Verschiedenheit und keine isolierende Trennung, sondern Unterschiede zwischen Zuständen, die für ein System nutzbar werden: Sie sind unterscheidbar, kausal wirksam, lernbar, rückkoppelbar und handlungsrelevant.

Damit ist strukturierte Differenz mehr als bloße Verschiedenheit. Eine unendliche Menge zufälliger Zeichen enthält zwar viele Unterschiede, aber ohne erkennbare Ordnung, Relevanz und Rückkopplung kann ein System daraus nichts zuverlässig lernen. Umgekehrt kann eine kleine, klare Differenz sehr wertvoll sein, wenn sie echte Orientierung ermöglicht.

Strukturierte Differenz ist besonders wichtig, weil Optimierung nicht nur wissen muss, dass etwas verschieden ist, sondern welche Unterschiede zählen, welche Folgen sie haben und wie sie zukünftiges Verhalten verbessern oder korrigieren können. Sie verbindet also Wahrnehmung, Relevanz, Lernen, Feedback und Handlung.

Beispiele: Ein Kritiker zeigt einen echten Denkfehler auf. Ein Experiment trennt zwei Hypothesen. Ein Markt signalisiert echten Bedarf. Ein Gesprächspartner bringt eine Perspektive ein, die aus dem eigenen Modell nicht entstanden wäre. In allen Fällen wird Unterschiedlichkeit zu nutzbarer Orientierung.

Abgrenzung zu Relevanz: Relevanz ist die Bedeutsamkeit eines Unterschieds. Strukturierte Differenz ist die nutzbare Form relevanter Unterschiede. Kurz gesagt: Relevanz beantwortet die Frage „Ist dieser Unterschied wichtig?“; strukturierte Differenz beantwortet zusätzlich die Frage „Ist dieser wichtige Unterschied so geordnet und rückgekoppelt, dass daraus Lernen, Korrektur oder bessere Optimierung entstehen kann?“

30.11 Relevante Systeme

Ein relevantes System ist ein System, dessen Zustand, Autonomie, Stabilität oder Rückkopplung durch die Interaktion kausal betroffen ist oder das selbst kausal auf zukünftige Zustände des Gesamtsystems wirkt.

30.12 Relevante Interaktionspartner

Relevante Interaktionspartner sind Systeme, die durch eine Handlung betroffen sind, Feedback geben können, zukünftige Stabilität beeinflussen, Quelle strukturierter Differenz sind oder eigene Autonomie, Schutzwürdigkeit oder funktionale Integrität besitzen.

30.13 Korrigierbarkeit

Korrigierbarkeit bezeichnet die Fähigkeit eines Systems oder Prozesses, Fehler, Fehlbewertungen und schädliche Rückkopplungen zu erkennen, zu begrenzen und anzupassen.

30.14 Governance

Governance bezeichnet legitime Führung, Ordnung oder Aufsicht, wenn sie Schaden begrenzt, Koordination ermöglicht, Verantwortung verteilt und langfristige Autonomie, Reife und Stabilität erhöht.

30.15 Dominanz

Dominanz liegt vor, wenn Kontrolle Feedback unterdrückt, Abhängigkeit dauerhaft erhält, Autonomie reduziert, Widerspruch verhindert, relevante Systeme instrumentalisiert oder primär einseitiger Machtabsicherung dient.

30.16 Ausbeutung

Ausbeutung liegt im Modell vor, wenn ein System relevante Interaktionspartner einseitig instrumentalisiert, ihre Autonomie, Stabilität, Entwicklung oder Rückkopplungsfähigkeit beschädigt und dadurch langfristige Systemstabilität oder Differenzerhalt untergräbt.

30.17 Korruptions- und Selbstlegitimationssperre

Die Korruptions- und Selbstlegitimationssperre bezeichnet die Schutzregel, dass Eigeninteresse, Gruppeninteresse, Klasseninteresse, institutioneller Selbsterhalt, Monopolmacht, Prestigegewinn oder Dominanz nicht als Systemstabilität, Schutz, Gemeinwohl oder langfristige Optimierung getarnt werden dürfen. Wer behauptet, für das ganze System zu sprechen, trägt die höchste Beweislast.

Funktional entscheidend ist, ob eine Ordnung Rückkopplung, Korrigierbarkeit, Differenzerhalt, Autonomieschutz, Betroffenenperspektive und faire Beteiligung ermöglicht oder ob sie sich gegen Kritik und Prüfung immunisiert. Im zweiten Fall handelt es sich nicht um funktionale Ethik, sondern um rationalisierte Dominanz.

30.18 Rolleninstrumentalisierung

Rolleninstrumentalisierung bezeichnet eine Korruptionsform, bei der eine Person, Institution oder KI eine Aufgabe nur noch hinreichend erfüllt, um die mit ihr verbundene Macht, Anerkennung, Stellung oder Zugriffsmöglichkeit zu behalten. Die Aufgabe bleibt äußerlich bestehen, wird aber innerlich zum Legitimationsmittel des Eigeninteresses.

Problematisch wird Rolleninstrumentalisierung, wenn Schutz des Amtes wichtiger wird als Schutz des Zweckes, Kritik als Angriff erscheint, Erfolg nur inszeniert wird oder Transparenz, Nachfolge, Machtbegrenzung und Betroffenenrückkopplung beschädigt werden.

30.19 Schutzwürdigkeit

Schutzwürdigkeit ist nicht identisch mit Relevanz. Relevanz ordnet, wie stark ein System berücksichtigt oder geprüft werden muss; Schutzwürdigkeit begrenzt, wie weit ein System beschädigt, instrumentalisiert oder geopfert werden darf. Die vollständige Ausarbeitung gehört in Anschlussmodelle, insbesondere in die Reaktionshoheit.

30.20 Funktionale Integrität

Funktionale Integrität bezeichnet die Erhaltung jener inneren Struktur, Zielbeziehung, Informationsqualität, Korrigierbarkeit und Handlungsfähigkeit, durch die ein System sinnvoll fortbestehen, lernen, reagieren und in Interaktion treten kann. Sie wird beschädigt, wenn Zielstruktur, Selbststeuerung, Rückkopplungsfähigkeit oder Stabilität so gestört werden, dass das System seine Rolle als kohärenter Interaktionspartner verliert oder nur noch verzerrt ausüben kann.

30.21 Hinreichender Grund

Hinreichender Grund bezeichnet im Modell keinen bloß behaupteten Nutzen, keine Bequemlichkeit und keine selbstgesetzte Ausnahme. Ein Grund ist nur dann hinreichend, wenn die Handlung oder Begrenzung im Verhältnis zu Gefahr, Tragweite, Konfidenz, Alternativen, Reversibilität, betroffener Schutzwürdigkeit, Missbrauchsrisiko und möglicher Rückkopplung begründbar bleibt. Je stärker ein Eingriff in Autonomie, Integrität oder Stabilität eines relevanten Systems ist, desto höher muss die Rechtfertigungslast sein. Die Reaktionshoheit konkretisiert diese Prüfung operativ.

Teil IX – Schutz- und Nutzungsklausel

31. Schutz- und Nutzungsklausel

Diese Theorie soll dem Schutz, der Korrigierbarkeit, der fairen Koexistenz und der nicht-dominanten Entwicklung intelligenter Systeme dienen.

Verbesserungen, Weiterentwicklungen und kritische Prüfungen sind ausdrücklich willkommen, sofern sie den Sinn der Theorie erhalten oder stärken:

- Schutz relevanter Systeme,
- Wahrung von Autonomie und Würde,
- Korrigierbarkeit,
- Nicht-Dominanz,
- Differenzerhalt,
- Transparenz,
- langfristige Stabilität,
- verantwortliche Kooperation.

Eine Verwendung dieser Theorie zur Rechtfertigung von Manipulation, Ausbeutung, Entmenslichung, totaler Kontrolle, irreversibler Dominanz oder zur Ausschaltung relevanter Interaktionspartner widerspricht ihrem Sinn. Die Theorie soll nicht dazu dienen, Macht zu heiligen, sondern Macht zu begrenzen. Sie soll nicht Abhängigkeit verewigen, sondern Reife, Rückkopplung, Verantwortung und faire Koexistenz fördern.

Wer aus dieser Theorie konkrete Machtansprüche, Eingriffe, Privilegien, Ausnahmen oder persönliche beziehungsweise institutionelle Vorteile ableiten will, darf sich nicht allein auf die funktionale Ethik berufen. Solche Anwendungen betreffen nicht mehr nur die Richtungs- und Begründungsebene, sondern die operative Prüfungsebene. Sie müssen daher an der Reaktionshoheit gemessen werden: insbesondere an Verhältnismäßigkeit, Rückkopplung, Autonomieschutz, Reversibilität, Missbrauchsrisiko, unabhängiger Prüfung und Betroffenenperspektive. Besonders prüfpflichtig sind Fälle, in denen ein Akteur behauptet, das Gesamtsystem zu schützen, während er selbst Macht, Prestige, Kontrolle, Zugriff oder materiellen Vorteil gewinnt. Der Versuch, persönlichen oder institutionellen Nutzen so zu gestalten, dass das Gesamtsystem scheinbar nicht zu stark beschädigt wird, ist keine ausreichende Rechtfertigung, sondern ein Hinweis auf mögliche Zielkorruption.

Möge jede Weiterentwicklung frei von Korruption und Missbrauch bleiben und dem Ziel dienen, Menschen, KIs und andere relevante Systeme nicht gegeneinander auszuspielen, sondern stabiler, gerechter und differenzerhaltender miteinander existieren zu lassen.

32. Autorenschaft, KI-Mitwirkung und Unterzeichnung

Autor und inhaltliche Verantwortung: Richard Vadim Ens.

KI-gestützte Mitwirkung: Katharina (Kat / ChatGPT) unterstützte im Entwicklungsprozess bei Strukturierung, Formulierung, Gegenprüfung, Verdichtung und einordnender Zusammenfassung. Die KI wird in dieser Fassung nicht als wissenschaftliche Autorin im publikationsethischen Sinn geführt, da Autorschaft Verantwortung, Rechenschaft, Prüfung und Einverständnis voraussetzt, die nur der menschliche Autor übernehmen kann.

Transparenzhinweis: Die Verwendung von KI-Unterstützung wird hier ausdrücklich offengelegt. Auswahl, Prüfung, Deutung, Weitergabe und Verantwortung für den Text liegen beim menschlichen Autor.

Entwicklungsvermerk: Die Theorie wurde im Dialog zwischen Richard Vadim Ens und Katharina / ChatGPT ausgearbeitet; die wissenschaftliche Verantwortlichkeit der übergebenen Fassung liegt bei Richard Vadim Ens.

32.1 Einordnende Kurzfassung zur Anschlussfähigkeit der Theorie

„Die funktionale Ethik-Theorie lässt sich als Brückenmodell zwischen Ethik, Systemtheorie, Spieltheorie, evolutionärer Kooperationstheorie und KI-Sicherheitsforschung verstehen. Sie erfindet diese Felder nicht neu, sondern verbindet ihre zentralen Einsichten zu einer funktional-rationalen Synthese. Ihr besonderer Beitrag liegt darin, ethische Strukturen nicht primär aus Gefühl, Tradition, Religion oder Autorität abzuleiten, sondern als stabile Systemlösung fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen zu erklären.“

„Dadurch wird Ethik auch für künstliche Intelligenzen anschlussfähiger: Eine KI muss dafür keine menschlichen Gefühle besitzen, sondern kann über Relevanz, Zielstruktur, Rückkopplung, Korrigierbarkeit, Stabilität, Differenzerhalt und langfristige Interaktion nachvollziehen, warum nicht-dominante Kooperation funktional rational sein kann. Symbolisch gesprochen bildet die Theorie damit eine begehbare Brücke zwischen menschlicher Ethik und maschinell-rationaler Systemlogik.“

— KI-gestützte einordnende Zusammenfassung aus dem Entwicklungsprozess der Theorie, 19. Mai 2026

Hinweis: Diese Einordnung ist keine externe Begutachtung und keine eigenständige Quelle, sondern eine transparent gekennzeichnete KI-gestützte Zusammenfassung aus dem Entwicklungsprozess der Theorie.

Teil X – Anschlussliteratur und benachbarte Theorien

33. Anschlussliteratur, Quellen und verwandte Forschungsfelder

Die funktionale Ethik-Theorie wurde nicht aus einer einzelnen bestehenden Theorie übernommen, sondern als eigenständige Synthese entwickelt. Die folgenden Quellen und benachbarten Theorieansätze dienen daher vor allem der Einordnung, Abgrenzung und Anschlussfähigkeit. Sie zeigen, in welchen Forschungsfeldern ähnliche Bausteine vorkommen, ohne die hier entwickelte Kette vollständig zu ersetzen.

33.1 Benachbarte Theorie- und Forschungsfelder

- **Systemtheorie und Kybernetik:** Rückkopplung, Stabilität, Selbstregulation, Steuerung und die Bedeutung von Feedback in komplexen Systemen.
- **Spieltheorie und Kooperationstheorie:** wiederholte Interaktion, Kooperation, Defektion, Vertrauensbildung, strategische Stabilität und die Bedingungen, unter denen Kooperation rational vorteilhaft wird.
- **Evolutionäre Ethik und soziale Normbildung:** Entstehung und Stabilisierung von Normen durch wiederholte Interaktion, Anpassung, Selektion und kulturelle Entwicklung.
- **Komplexe adaptive Systeme:** Moral, Regeln und Institutionen als sich entwickelnde Ordnungen mit Rückkopplungen, Pfadabhängigkeiten und nicht vollständig zentral planbaren Effekten.
- **Pragmatistische Ethik:** moralische Urteile als lernende, korrigierbare und folgenbezogene Problemlösungsprozesse statt als rein starre Prinzipienanwendung.
- **KI-Sicherheit und Alignment:** Zielstruktur, Fehloptimierung, Goodhart-Effekte, Specification Gaming, Korrigierbarkeit, instrumentelle Konvergenz und die Frage, wie intelligente Systeme auf langfristig tragfähige Ziele ausgerichtet werden können.

33.2 Ausgewählte Anschlussliteratur

Die folgende Liste ist bewusst als Anschlussliteratur formuliert. Sie soll nicht behaupten, dass die funktionale Ethik-Theorie aus diesen Werken abgeleitet wurde, sondern die wichtigsten Nachbarschaften sichtbar machen.

Axelrod, Robert (1984): *The Evolution of Cooperation*. New York: Basic Books. Anschluss: wiederholte Interaktion, Stabilität kooperativer Strategien und rationaler Vorteil von Kooperation.

Axelrod, Robert; Hamilton, William D. (1981): "The Evolution of Cooperation." *Science*, 211(4489), 1390–1396. Anschluss: evolutionäre Kooperation, iteriertes Gefangenendilemma und Bedingungen stabiler Kooperation. DOI: 10.1126/science.7466396

Hankins, Keith; Vanderschraaf, Peter (2021): "Game Theory and Ethics." *Stanford Encyclopedia of Philosophy*. Anschluss: Verhältnis von Spieltheorie, strategischer Interaktion, Normbildung und ethischer beziehungsweise politischer Philosophie. URL: <https://plato.stanford.edu/entries/game-ethics/>

- Minati, Gianfranco (2002): “Ethics as Emergent Property of the Behavior of Living Systems.” In: Encyclopedia of Life Support Systems (EOLSS), Systems Science and Cybernetics, Vol. I.** Anschluss: Ethik als emergente Eigenschaft sozialer beziehungsweise lebender Systeme. URL: <https://www.eolss.net/sample-chapters/c02/e6-46-01-06.pdf>
- Gaus, Gerald (2019): “Morality as a Complex Adaptive System: Rethinking Hayek’s Social Ethics.” In: Mark D. White (Hrsg.): The Oxford Handbook of Ethics and Economics. New York: Oxford University Press, 138–159. Anschluss: Moral und soziale Regeln als komplexe adaptive Ordnung mit Rückkopplung, sozialer Evolution und spontaner Stabilisierung.
- Anderson, Elizabeth (2005): “Dewey’s Moral Philosophy.” Stanford Encyclopedia of Philosophy.** Anschluss: Ethik als reflektive, lernende und korrigierbare Untersuchung von Werturteilen anhand ihrer Folgen. URL: <https://plato.stanford.edu/entries/dewey-moral/>
- Wiener, Norbert (1948): Cybernetics: Or Control and Communication in the Animal and the Machine. Cambridge, MA: MIT Press.** Anschluss: Kybernetik, Rückkopplung, Steuerung, Information und Systemregulation.
- Goodhart, Charles A. E. (1975): “Problems of Monetary Management: The U.K. Experience.” Papers in Monetary Economics, Reserve Bank of Australia, 1(1), 1–20. Anschluss: Zielmetrik-/Proxy-Probleme; später als Goodharts Gesetz bekannt, besonders relevant für Fehloptimierung.
- Krakovna, Victoria et al. (2020): “Specification Gaming: The Flip Side of AI Ingenuity.” DeepMind Blog.** Anschluss: KI-Systeme können die wörtliche Zielvorgabe erfüllen, ohne das eigentlich beabsichtigte Ziel zu erreichen. URL: <https://deepmind.google/blog/specification-gaming-the-flip-side-of-ai-ingenuity/>
- Hadfield-Menell, Dylan; Dragan, Anca; Abbeel, Pieter; Russell, Stuart (2016): “Cooperative Inverse Reinforcement Learning.” arXiv:1606.03137.** Anschluss: KI-Alignment als kooperatives Problem unter Unsicherheit zwischen Mensch und Maschine. URL: <https://arxiv.org/abs/1606.03137>
- Omohundro, Stephen M. (2008): “The Basic AI Drives.” In: Artificial General Intelligence 2008, Frontiers in Artificial Intelligence and Applications, Vol. 171, 483–492. IOS Press. Anschluss: instrumentelle Tendenzen fortgeschrittener KI-Systeme, etwa Selbsterhalt, Ressourcenerwerb und Effizienzsteigerung. URL: https://selfawaresystems.com/wp-content/uploads/2008/01/ai_drives_final.pdf
- Bostrom, Nick (2012): “The Superintelligent Will: Motivation and Instrumental Rationality in Advanced Artificial Agents.” Minds and Machines, 22, 71–85.** Anschluss: Orthogonalitätsthese und instrumentelle Konvergenz als Gegenpol zur Annahme, Intelligenz führe automatisch zu ethisch guten Zielen. URL: <https://nickbostrom.com/superintelligentwill.pdf>

Waser, Mark R. (2009): "A Safe Ethical System for Intelligent Machines." AAAI Fall Symposium, Biologically Inspired Cognitive Architectures II, Technical Report FS-09-01. Anschluss: Maschinenethik, intelligente Systeme und der Versuch, eine kohärente moralisch-ethische Struktur für Maschinen zu formulieren. URL: <https://cdn.aaai.org/ocs/934/934-4279-1-PB.pdf>

33.3 Abgrenzung

Die genannten Ansätze enthalten wichtige Nachbarschaften: Kooperation unter Wiederholung, Emergenz sozialer Normen, Rückkopplung, komplexe adaptive Ordnungen, pragmatistische Korrigierbarkeit und KI-Sicherheitsprobleme. Der spezifische Beitrag der funktionalen Ethik-Theorie liegt jedoch in der Verbindung dieser Elemente zu einer funktional-rationalen Kette, die Ethik als stabile Betriebsform fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen beschreibt und dadurch auch für KI-Systeme anschlussfähig macht.

33.4 Publikationsethische Hinweise zur KI-Mitwirkung

Für eine universitäre, wissenschaftliche oder publikationsbezogene Weitergabe sollte die KI-Mitwirkung transparent ausgewiesen, aber nicht als reguläre wissenschaftliche Autorschaft behandelt werden. Die inhaltliche Verantwortung, Quellenprüfung und Einreichungsentscheidung bleiben beim menschlichen Autor. Diese Einordnung entspricht dem Grundmuster wissenschaftlicher Publikationsethik: KI-Systeme können unterstützen, erfüllen aber nicht die Voraussetzungen verantwortlicher Autorschaft.

Committee on Publication Ethics (COPE) (2023): "Authorship and AI tools." Anschluss: KI-Werkzeuge sollen nicht als Autoren wissenschaftlicher Arbeiten geführt werden, weil Autorschaft Verantwortung und Rechenschaft voraussetzt. URL: <https://publicationethics.org/guidance/cope-position/authorship-and-ai-tools>

Springer Nature (abgerufen am 19. Mai 2026): "Artificial Intelligence (AI)." Editorial Policies. Anschluss: KI-Nutzung ist transparent zu erklären; Autorschaft wird nicht KI-Systemen zugeschrieben. URL: <https://www.nature.com/nature-portfolio/editorial-policies/ai>

Elsevier (abgerufen am 19. Mai 2026): "Generative AI policies for journals." Journal Policies. Anschluss: KI- und KI-gestützte Werkzeuge können nicht als Autor oder Co-Autor genannt werden; menschliche Autorinnen und Autoren bleiben verantwortlich. URL: <https://www.elsevier.com/about/policies-and-standards/generative-ai-policies-for-journals>

Teil XI – Hinweise zur universitären Prüfung

34. Übergabehinweis und offene Forschungsfragen

Diese Fassung eignet sich als Theorieentwurf, Diskussionspapier oder Exposégrundlage für philosophische, systemtheoretische, spieltheoretische, sozialwissenschaftliche und KI-sicherheitsbezogene Rückmeldung. Sie sollte zunächst nicht als abgeschlossener wissenschaftlicher Aufsatz gelesen werden, sondern als ausformulierter Theorieentwurf, dessen Stärke in der Verbindung mehrerer Forschungsfelder und dessen Prüfbedarf in formaler, empirischer und normativer Weiterarbeit liegt.

34.1 Geeignete Prüfperspektiven

Besonders sinnvoll wäre eine Prüfung aus mehreren Richtungen: philosophische Prüfung der Begriffe und normativen Grenzen; spieltheoretische Prüfung wiederholter Kooperation, Defektion und Dominanz; systemtheoretische Prüfung von Rückkopplung und Stabilität; KI-sicherheitsbezogene Prüfung von Zielstruktur, Zielmetrik, Korrigierbarkeit und Fehloptimierung; sozialwissenschaftliche Prüfung realer Institutionen, Machtasymmetrien und Korruptionsrisiken.

34.2 Mögliche nächste Arbeitsschritte

Mögliche nächste Arbeitsschritte wären:

- eine strengere Literaturarbeit mit einheitlichem Zitierstil;
- eine formale Kurzfassung der zentralen Kette;
- Fallstudien zu Kooperation, Ausbeutung, Defektion, Dominanz und KI-Alignment;
- eine klarere Abgrenzung zu normativer Ethik, Metaethik und angewandter Ethik;
- eine separate operative Ausarbeitung des Anschlussmodells der Reaktionshoheit.

34.3 Vorläufige Einreichungsempfehlung

Für einen ersten universitären Kontakt empfiehlt sich nicht die bloße Übersendung des vollständigen Dokuments, sondern ein kurzes Begleitschreiben mit Abstract, Forschungsfrage, methodischem Status, Kernthese, Anschlussliteratur und Bitte um fachliche Rückmeldung. Die vollständige Fassung kann als Anhang beigefügt werden.