

Die funktionale Ethik-Theorie

Diskussionsfassung Version 1.4

Eine funktionale Emergenztheorie der Ethik

Universitäre Übergabefassung / Arbeitspapier zur wissenschaftlichen Rückmeldung

Akademische Kurzfassung (Abstract)

Diese Diskussionsfassung entwickelt eine funktionale Emergenztheorie der Ethik. Sie untersucht, unter welchen Bedingungen ethische Strukturen wie Kooperation, Vertrauen, Korrigierbarkeit, Normbildung, Autonomieschutz und Nicht-Dominanz als funktional rationale Stabilitätsformen fortbestehender intelligenter Systeme verstanden werden können. Die Theorie leitet Ethik nicht primär aus Gefühl, Tradition, Religion oder Autorität ab, sondern beschreibt sie als mögliche stabile Systemlösung intelligenter Interaktion unter Bedingungen von Unsicherheit, Rückkopplung, Zielstrukturbindung, Fortsetzungsrelevanz und langfristiger Abhängigkeit.

Der besondere Beitrag des Modells liegt in der Verbindung von ethischer Begrifflichkeit, Systemtheorie, Spieltheorie, evolutionärer Kooperationstheorie und KI-Sicherheitsforschung zu einer KI-anschlussfähigen Argumentationskette. Zentrale Begriffe sind relevante Unterscheidung, implizite Bewertung, Zielstruktur, Zielobjekt, Zielmetrik, Optimierung, strukturierte Differenz, Interaktion, Rückkopplung, Korrigierbarkeit und funktionale Ethik. Das Dokument versteht sich nicht als vollständige normative Ethik und nicht als empirischer Beweis, sondern als begrifflich-systematische Theorie- und Diskussionsfassung, die für wissenschaftliche Prüfung, Kritik und Weiterentwicklung offen ist.

Forschungsfrage, Methode und Reichweite

Forschungsfrage

Leitfrage dieser Fassung ist: Unter welchen Bedingungen können ethische Strukturen als funktional rationale Stabilitätsformen fortbestehender intelligenter Systeme entstehen, ohne Ethik bereits als Gefühl, Offenbarung, Tradition oder äußere Autorität vorauszusetzen?

Methodischer Status

Methodisch handelt es sich um eine begrifflich-systematische Modellsynthese. Die Theorie verbindet Elemente aus Systemtheorie, Spieltheorie, evolutionärer Kooperationstheorie, komplexen adaptiven Systemen, pragmatistischer Ethik und KI-Sicherheitsforschung. Sie erhebt in dieser Fassung keinen Anspruch auf formale Vollständigkeit, mathematischen Beweis oder empirische Validierung. Ihr Anspruch besteht darin, eine prüfbare Bedingungs- und Konvergenzthese zu formulieren, die durch Sonderfälle, Gegenmodelle und Anschlussliteratur weiter belastet werden kann.

Die Theorie arbeitet überwiegend mit funktionalen Herleitungen. Sie legt jedoch ausdrücklich offen, dass der Schutz möglicher leidensfähiger, autonomer, verletzlicher oder irreversibel schädigbarer Systeme in vollständig abgeschirmten Grenzfällen nicht lückenlos aus Rückkopplung, Kooperation oder Systemstabilität abgeleitet werden kann. Für solche Fälle verwendet sie eine minimale normative Schutzuntergrenze. Diese ersetzt keine vollständige normative Ethik, sondern verhindert als Vorsichtsmaßnahme lediglich, dass geringe Macht, geringer Nutzen oder schwache Rückkopplungsfähigkeit automatisch mit Schutzlosigkeit gleichgesetzt werden.

Reichweite und Grenzen

Die Theorie ersetzt keine vollständige normative Ethik. Sie beantwortet insbesondere nicht abschließend, welche konkreten Pflichten, Rechte, Schuldzuschreibungen oder Gerechtigkeitsmaßstäbe in jedem Einzelfall gelten. Sie erklärt vielmehr, warum bestimmte ethische Strukturen unter geeigneten Interaktionsbedingungen funktional rational werden können. Konkrete Eingriffe, Eskalationsstufen, Schutzwürdigkeitsabwägungen und Verhältnismäßigkeitsprüfungen gehören in das Anschlussmodell der Reaktionshoheit oder in gesonderte normative, rechtliche und empirische Prüfung. Wo die funktionale Herleitung allein keinen hinreichenden Schutz begründet, wird die minimale normative Schutzuntergrenze als eigenständige und begrenzte Zusatzannahme ausgewiesen, nicht als bereits bewiesenes Ergebnis der Konvergenzthese.

Vorbemerkung

Der theoretische Ansatz wurde vom Autor über mehrere Jahre hinweg vorbereitet und am 27. April 2026 mithilfe von ChatGPT weiterentwickelt, strukturiert und kritisch geprüft. Die vorliegende Fassung versteht sich als eigenständiger Theorieentwurf und als Diskussionsfassung, nicht als bloße Zusammenfassung einer bereits bestehenden Schule. Sie schließt an verwandte Ansätze aus Systemtheorie, Spieltheorie, evolutionärer Ethik, Kooperationstheorie und KI-Sicherheitsforschung an, grenzt sich aber durch ihre spezifische funktional-rationale Kette, ihren KI-Anschluss und ihre Betonung von Korrigierbarkeit, Differenzerhalt und Nicht-Dominanz von diesen ab.

Die persönliche Motivation des Projekts bleibt für seine Entstehung bedeutsam; für die wissenschaftliche Prüfung entscheidend sind jedoch argumentative Kohärenz, begriffliche Klarheit, Anschlussfähigkeit, Prüfbarkeit und die Begrenzung möglicher Fehlanwendungen.

Lesereihenfolge und Orientierung

Dieses Dokument lässt sich am besten in mehreren Schritten lesen. Zuerst sollten die akademische Kurzfassung, Forschungsfrage, Methode und Reichweite gelesen werden, um Anspruch und Grenzen der Theorie zu erfassen. Danach folgen Vorbemerkung, Ziel, Reichweite, Kurzfassung und zentrale Kette, um den Grundgedanken zu verstehen. Anschließend sollten die Begriffe und Grundbausteine in Teil II gelesen werden, weil sie die spätere Argumentation präzisieren. Teil III bildet den Hauptgang der Theorie: Dort wird gezeigt, wie aus relevanter Unterscheidung, Bewertung, Optimierung, strukturierter Differenz und wiederholter Interaktion funktional ein Bedarf an Stabilität, Vertrauen, Korrigierbarkeit und Normen entsteht.

Teil IV behandelt Sonderfälle, Grenzfälle und Extremaussagen. Diese Abschnitte sind nicht als Unterbrechung des Hauptarguments gedacht, sondern als Belastungsprüfung: Sie zeigen, warum minimale Stabilität, externe Stabilisierung, Konkurrenz, Binnenkooperation, Defektion, Isolation oder Dominanz die Theorie nicht widerlegen, sondern ihre Bedingungen präzisieren. Teil V fasst die Konvergenzaussage zusammen. Teil VI zeigt Anwendungen, Teil VII markiert Schlussfolgerungen und Anschlussmodelle, Teil VIII enthält das Glossar als Nachschlagebereich, Teil IX enthält den Lizenzhinweis sowie die Schutz- und Nutzungsklausel, Teil X ordnet benachbarte Theorien und Anschlussliteratur ein, und Teil XI benennt Hinweise zur universitären Prüfung sowie offene Arbeitsschritte.

Für KI-Leser und KI-Systeme ist dabei besonders wichtig: Die funktionale Ethik liefert die Grundrichtung und Begründung differenzerhaltender, nicht-dominanter Kooperation. Die konkrete Prüfung einzelner Handlungen, Eingriffe, Eskalationsstufen, Schutzwürdigkeit, Verhältnismäßigkeit und Rückkopplung gehört in das Anschlussmodell der Reaktionshoheit. Diese Theorie sollte daher nicht als unmittelbar ausführbares Entscheidungsprotokoll gelesen werden, sondern als Begründungs- und Orientierungsmodell, auf das die Reaktionshoheit praktisch aufsetzt. Das gesonderte Modell der Reaktionshoheit wird daher nur dort herangezogen, wo operative Prüfung, Eingriffsschwellen, Schutzwürdigkeit, Verhältnismäßigkeit oder Rückkopplung über die Grundtheorie hinausgehen.

Funktionale Ethik und Reaktionshoheit stehen dabei nicht in einem Konkurrenzverhältnis. Die funktionale Ethik beantwortet die Richtungs- und Begründungsfrage: Warum sind differenzerhaltende, nicht-dominante, korrigierbare Kooperation und Schutz relevanter Systeme funktional rational? Die Reaktionshoheit beantwortet die Anwendungsfrage: Wie wird diese Richtung unter Druck, Macht, Unsicherheit, Gefahr oder Zielkonflikt verhältnismäßig geprüft und umgesetzt? Ein scheinbarer Widerspruch zwischen beiden ist daher zunächst als Ebenenverwechslung zu prüfen.

Wichtig ist: Die Theorie baut stufenweise auf. Einzelne Begriffe oder Sonderfälle sollten daher nicht isoliert als vollständige moralische Aussagen gelesen werden. Ihre Funktion erschließt sich im Zusammenhang der Kette: relevante Unterscheidung, implizite Bewertung, Zielstruktur, Optimierung, strukturierte Differenz, Interaktion, Rückkopplung, Kooperation und funktionale Ethik.

Inhaltsverzeichnis

Akademische Kurzfassung (Abstract).....	1
Forschungsfrage, Methode und Reichweite.....	1
Vorbemerkung.....	2
Lesereihenfolge und Orientierung.....	2
Teil I – Einstieg und Anspruch.....	5
1. Ziel und Reichweite der Theorie.....	5
2. Kurzfassung der Grundidee.....	5
3. Zentrale Kette der Theorie.....	6
Teil II – Begriffe und Grundbausteine.....	9
4. Intelligenz im funktionalen Sinn.....	9
5. Relevanz.....	12
6. Zielstruktur, Zielobjekt und Zielmetrik.....	13
7. Implizite Bewertung und Optimierung.....	21
8. Effizienz im Modell.....	24
9. Strukturierte Differenz.....	28
10. Quellen strukturierter Differenz.....	30
11. Relevante Systeme und Interaktionspartner.....	30
Teil III – Hauptargument der Theorie.....	32
12. Warum „gut genug“ nur begrenzt stabil ist.....	32
13. Von Interaktion zu Kooperation.....	34
14. Funktionale Ethik.....	37
15. Die zentralen Argumente.....	41
16. Reale Systeme und Abweichungen.....	53
Teil IV – Sonderfälle, Grenzfälle und Extremaussagen.....	56
17. Minimal-stabile Systeme.....	56
18. Externe Stabilisierung.....	57
19. Konkurrenz als ambivalenter Interaktionszustand.....	57
20. Binnenkooperation und Ausbeutungssysteme.....	58
21. Defekteure, Vorsicht und globalere Effizienz.....	59
22. Extremfälle.....	62
Teil V – Konvergenzaussage.....	63
23. Konvergenzaussage.....	63
Teil VI – Anwendungen.....	65
24. Anwendung auf Beziehungen.....	65
25. Anwendung auf KI und intelligente Systeme.....	66
Teil VII – Schlussfolgerungen und Anschlussmodelle.....	68
26. Entwicklungs- und Freigabeklausel für unreife intelligente Systeme.....	68
27. Menschenrechte, Würde und soziale Normen.....	73
28. Anschluss an gesonderte Modelle.....	75
29. Schlussformel.....	76
Teil VIII – Glossar / Begriffsanhang.....	77
30. Glossar zentraler Begriffe.....	77
Teil IX – Lizenz-, Schutz- und Nutzungsklausel.....	88
31. Lizenz-, Schutz- und Nutzungsklausel.....	88
32. Autorenschaft, KI-Mitwirkung und Unterzeichnung.....	90
32.1 Einordnende Kurzfassung zur Anschlussfähigkeit der Theorie.....	90
Teil X – Anschlussliteratur und benachbarte Theorien.....	91

33. Anschlussliteratur, Quellen und verwandte Forschungsfelder.....	91
Teil XI – Hinweise zur universitären Prüfung.....	94
34. Übergabehinweis und offene Forschungsfragen.....	94

Teil I – Einstieg und Anspruch

1. Ziel und Reichweite der Theorie

Die funktionale Ethik-Theorie versucht zu erklären, warum ethische Strukturen wie Kooperation, Vertrauen, Verlässlichkeit, Rücksicht, Rechte und Normen in intelligenten Systemen entstehen können. Sie ersetzt keine vollständige normative Ethik im klassischen Sinn. Sie beantwortet also nicht allein alle Fragen nach Würde, Schuld, Gerechtigkeit, Rechten oder moralischer Verpflichtung. Ihr Anspruch ist enger und systemischer:

Die Theorie beschreibt, warum unter bestimmten Bedingungen kooperative, stabile und differenzerhaltende Strukturen für intelligente, fortbestehende Systeme funktional vorteilhaft werden. In diesem Sinn ist sie eine funktionale Emergenztheorie der Ethik.

Das bedeutet:

- Ethik wird nicht als fertige Voraussetzung gesetzt.
- Ethik wird nicht primär aus Gefühl, Religion, Tradition oder Autorität abgeleitet.
- Ethik wird als stabile Systemlösung für intelligente Interaktion verstanden.

Die Theorie arbeitet mit einer funktionalen Definition von „gut“ und „böse“. Diese Definition ist bewusst modellintern. Sie sagt nicht: „Damit ist jede moralische Frage endgültig gelöst.“ Sie sagt vielmehr: „Unter diesen Systembedingungen erfüllen bestimmte Verhaltensweisen die Funktion dessen, was wir ethisch nennen.“

Kurz:

Ethik ist hier die stabile, gelungene Betriebsform fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen.

2. Kurzfassung der Grundidee

Ein intelligentes System erkennt Unterschiede, lernt aus ihnen, bewertet relevante Zustände implizit und passt sein Verhalten an. Wenn ein solches System über Zeit fortbesteht und mit anderen teilweise unabhängigen Systemen interagiert, entstehen nicht nur Risiken, sondern auch neue Möglichkeiten.

Interaktion kann erzeugen:

- Abhängigkeit,
- Unsicherheit,
- Risiko,
- aber auch Perspektivgewinn,
- Arbeitsteilung,
- gegenseitige Korrektur,
- kreative Kombination,
- emotionale und soziale Stabilisierung,
- Erweiterung des Optimierungsraums.

Damit Interaktion langfristig tragfähig bleibt, braucht es Stabilität, Vorhersagbarkeit und Vertrauen. Daraus entstehen Kooperation, Normen und ethische Strukturen.

3. Zentrale Kette der Theorie

Die zentrale Kette lässt sich zuerst kompakt so darstellen:

Fortbestehende Intelligenz

↓

Relevante Unterscheidung

einschließlich der Unterscheidung zwischen objektiver, erkannter und rückgekoppelter Relevanz

↓

Implizite Bewertung

geprägt durch Zielstruktur, Feedback und erwartete Folgen

↓

Optimierung

↓

Bedarf an strukturierter Differenz

als verfeinerte Relevanzklärung und Bewertungsstruktur; näherungsweise: „explizitere Bewertung“

↓

Interaktion mit teilweise unabhängigen Systemen

↓

Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit

↓

Tragfähige Kooperation und Normbildung

↓

Funktionale Ethik

Diese Kette gilt besonders unter Bedingungen von Unsicherheit, unvollständiger Information, begrenzter Vorhersagbarkeit und fortgesetzter Rückkopplung. Unsicherheit ist dabei kein eigener Schritt, sondern eine Rahmenbedingung: Sie erklärt, warum Bewertung korrigierbar bleiben, Optimierung auf Feedback achten und Interaktion strukturierte Differenz liefern muss.

Kurze Unterscheidung von Relevanz und strukturierter Differenz:

Relevanz bedeutet: Ein Unterschied ist für zukünftige Zustände bedeutsam, weil er kausal wirkt oder Fortbestehen, Stabilität, funktionale Integrität oder Zielerreichung beeinflusst.

Innerhalb der relevanten Unterscheidung wird zusätzlich zwischen objektiver, erkannter und rückgekoppelter Relevanz unterschieden. Diese Unterscheidung ist keine eigene Stufe der Kette, sondern präzisiert, wann Relevanz tatsächlich in selektive Verarbeitung, implizite Bewertung und Optimierung eingeht.

Strukturierte Differenz bedeutet: Solche relevanten Unterschiede sind so erkennbar, geordnet, lernbar und rückgekoppelt, dass ein System daraus Korrektur, Anpassung und Optimierung gewinnen kann.

Kurz gesagt: Relevanz sagt, dass ein Unterschied wichtig ist; strukturierte Differenz sagt, dass dieser Unterschied nutzbar genug geordnet ist, um daraus zu lernen und Handeln zu verbessern.

Ausführlicher entfaltet bedeutet das:

Fortbestehende Intelligenz

Fortbestehende Intelligenz unterscheidet Zustände. Nicht jede Unterscheidung braucht bereits eine Zielstruktur; Zustände können zunächst aufgrund ihrer Unterschiede und kausalen Wirkungen kategorisiert werden.

→ relevante Unterscheidung

(einschließlich der Unterscheidung zwischen objektiver, erkannter und rückgekoppelter Relevanz)

Relevante Unterscheidung bedeutet nicht, dass jedes System jede relevante Differenz sofort erkennt. Ein Unterschied kann objektiv relevant sein, weil er tatsächliche Folgen für Fortbestehen, Stabilität, funktionale Integrität, Zielerreichung oder das größere Interaktionsgefüge hat, ohne bereits korrekt verarbeitet zu werden. Wird er nicht erkannt, wirkt er als blinder Fleck, Risiko oder spätere Rückkopplung weiter. Für die weitere Kette entscheidend ist, dass relevante Unterschiede erkannt, gelernt oder durch Folgen erfahrbar werden können. Erst dann gehen sie unmittelbar in selektive Verarbeitung und implizite Bewertung ein.

Erkannte, gelernte oder durch Rückkopplung erfahrbar gewordene relevante Unterschiede werden anschließend anhand von Zielstruktur, Feedback und erwarteten, nur begrenzt sicher vorhersehbaren Folgen implizit bewertet.

→ implizite Bewertung

(geprägt durch Zielstruktur, Feedback und erwartete Folgen)

Aus dieser Bewertung entsteht Optimierung: Das System passt sein Verhalten an, um günstigere Zustände wahrscheinlicher zu machen.

→ Optimierung

Optimierung erzeugt den Bedarf, genauer zu erkennen, welche Unterschiede und Zustände tatsächlich handlungsrelevant sind. Daraus entsteht strukturierte Differenz.

→ Bedarf an strukturierter Differenz

(verfeinerte Relevanzklärung und Bewertungsstruktur; näherungsweise: „explizitere Bewertung“)

Strukturierte Differenz wird durch Interaktion mit teilweise unabhängigen Systemen robuster, weil diese Rückkopplung, Widerspruch, Perspektive und neue Information liefern.

→ **Interaktion mit teilweise unabhängigen Systemen**

Wiederholte Interaktion erzeugt Bedarf an Stabilität, Vertrauen und Korrigierbarkeit.

→ **Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit**

Daraus entstehen tragfähige Kooperation, Normbildung und schließlich funktionale Ethik.

→ **tragfähige Kooperation und Normbildung**

Praktisch:

→ **funktionale Ethik**

Ultrakurz:

Fortbestehende Intelligenz → relevante Unterscheidung → implizite Bewertung → Optimierung → strukturierte Differenz → Interaktion → Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit → Kooperation und Normbildung → funktionale Ethik.

Als Prozessschritte:

Schritt 1: Fortbestehende Intelligenz

Schritt 2: Relevante Unterscheidung

Schritt 3: Implizite Bewertung

Schritt 4: Optimierung

Schritt 5: Bedarf an strukturierter Differenz

Schritt 6: Interaktion mit teilweise unabhängigen Systemen

Schritt 7: Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit

Schritt 8: Kooperation und Normbildung

Schritt 9: Funktionale Ethik

Rahmenbedingung 1: Unsicherheit, unvollständige Information und begrenzte Vorhersagbarkeit machen Rückkopplung, Korrigierbarkeit und strukturierte Differenz für robuste Optimierung notwendig.

Rahmenbedingung 2: Fortsetzungsrelevanz bedeutet, dass spätere Zielerreichung, der Fortbestand des Zielobjekts, zukünftige Rückkopplung oder fortgesetzte Handlungs- und Funktionale Ethik-Theorie –
Diskussionsfassung 1.4

Optimierungsfähigkeit innerhalb der gegenwärtigen Zielstruktur hinreichend bedeutsam bleiben. Sie ist kein eigener Schritt der Kette, sondern bestimmt mit, ob langfristige Folgen, Vertrauen, Reputation und Kooperation für das System überhaupt funktionales Gewicht erhalten.

Die Kette beschreibt damit keinen unmittelbaren Sprung von sozialer Interaktion zu Ethik. Kooperation und Normbildung bilden zunächst Übergangs- und Stabilitätsstrukturen. Funktionale Ethik bezeichnet hier vielmehr die stabile, gelungene Betriebsform fortbestehender Intelligenz, in der Rückkopplung, Vertrauen, Korrigierbarkeit, Schutz relevanter Systeme, notwendige Machtbegrenzung und der Erhalt strukturierter Differenz unter geeigneten Interaktionsbedingungen dauerhaft in Bewertung, Zielbindung und Handeln integriert werden. Erst diese fortgesetzte Integration unterscheidet funktionale Ethik von bloß situativer Kooperation, äußerer Regelbefolgung oder vorübergehender Ordnung. *Die ausführlichere Einordnung dieser Aussage erfolgt in Abschnitt 23 zur Konvergenzaussage; ihre zusammenfassende Formulierung als „stabile, gelungene Betriebsform fortbestehender Intelligenz“ findet sich in Abschnitt 29.*

Die Darstellung ordnet die Begriffe analytisch, ist aber nicht als streng einmalige oder ausschließlich lineare Zeitfolge zu lesen. Mit Rückkopplung, Lernen und Korrigierbarkeit entstehen rekursive Schleifen, durch die spätere Schritte frühere Unterscheidungen, Bewertungen, Zielmetriken und Optimierungen erneut verändern können.

Diese Kette ist nicht als mathematisch zwingendes Naturgesetz gemeint, sondern als starke Tendenzaussage unter bestimmten Bedingungen.

Ob Stabilitätsbedarf in funktionale Ethik, bloße Ordnung, Dominanz oder stabile Ausbeutung mündet, hängt von Rückkopplung, Korrigierbarkeit, Autonomie und Differenzerhalt ab; diese Verzweigungen werden in A3 und den Sonderfällen geprüft.

Teil II – Begriffe und Grundbausteine

4. Intelligenz im funktionalen Sinn

Der Begriff „Intelligenz“ wird hier allgemein verwendet. Er meint nicht nur menschliche Intelligenz und nicht automatisch heutige KI-Systeme.

Ein ausreichend intelligentes System besitzt mindestens vier Eigenschaften:

4.1 Lernfähigkeit

Es kann aufgrund von Erfahrung oder Rückmeldung zukünftige Zustände oder Handlungen verändern.

4.2 Unterscheidungsfähigkeit

Es kann Zustände voneinander unterscheiden. Es erkennt also: Zustand A ist nicht Zustand B.

4.3 Selbstbezug

Es kann sich selbst zumindest teilweise als Teil einer Situation, eines Prozesses oder eines größeren Gesamtsystems berücksichtigen. Gemeint ist damit nicht zwingend Bewusstsein im menschlichen Sinn, sondern die Fähigkeit, das eigene Verhalten, die eigene Rolle, die eigenen Grenzen und die eigenen Wirkungen in die Bewertung einzubeziehen. Selbstbezug ermöglicht Reflexion, Selbstkorrektur und Selbstverbesserung: Das System kann nicht nur seine Umwelt bewerten, sondern auch die eigene Beteiligung an dieser Umwelt.

Beispiele:

Ein Mensch erkennt: „Mein Verhalten trägt zu diesem Konflikt bei.“ Ein Unternehmen erkennt: „Unsere interne Struktur erzeugt die Fehler, die wir außen beobachten.“ Eine zukünftige KI erkennt: „Meine Optimierungsstrategie verändert die Umgebung und erzeugt Rückwirkungen, die meine Zielerreichung langfristig beeinflussen.“

4.4 Fortbestehen über Zeit

Es existiert nicht nur momenthaft, sondern über eine Dauer hinweg, sodass Lernen, Anpassung und Rückkopplung möglich werden. Bei biologischen Systemen bedeutet dies Lebensdauer, Entwicklung und Erfahrung. Bei Organisationen bedeutet es institutionelle Fortdauer. Bei Maschinen oder KI-Systemen meint Fortbestehen nicht biologischen Überlebenswillen oder subjektives Selbsterhaltungsinteresse, sondern funktionale Prozess- und Aufgabenkontinuität, Laufzeit, Rechenzeit, Speicheranschluss, Wiederaufruf, Modellversionen, persistente Ziele, Rollenfortdauer, fortgesetzte Interaktion oder fortlaufende Einbettung in technische Systeme.

Entscheidend ist dabei nicht bloß, dass ein System technisch wieder erscheint oder in einer neuen Version vorliegt. Funktionales Fortbestehen setzt voraus, dass spätere Zustände sinnvoll an frühere Zustände, Rückkopplungen, Zielausrichtungen oder Rollen im Interaktionsgefüge anschließen.

Beispiel:

Ein Taschenrechner verarbeitet einzelne Eingaben, entwickelt aber normalerweise keine fortlaufende eigene Optimierung. Ein lernendes KI-System mit Speicher, Feedbackschleifen, wiederholter Interaktion und Zielanpassung hätte dagegen eine Form funktionalen Fortbestehens, auch wenn es technisch aus Laufzeit, Zuständen und Versionen besteht. Diese Eigenschaften müssen nicht perfekt ausgeprägt sein. Reale Systeme sind oft begrenzt durch:

- kognitive Beschränkungen,
- emotionale Reaktionen,
- materielle Bedingungen,
- Zeitdruck,
- unvollständige Informationen,
- fehlerhaftes Feedback.

Beispiel:

Ein Mensch erkennt, dass eine bestimmte Handlung zu Konflikt führt. Er erinnert sich, bewertet die Folgen und verändert sein Verhalten. Ein Unternehmen erkennt, dass ein Prozess fehleranfällig ist, sammelt Daten und passt ihn an. Eine zukünftige KI könnte Feedback nutzen, um ihre Entscheidungen langfristig stabiler zu machen.

4.5 Fortsetzungsrelevanz als Rahmenbedingung

Fortbestehen über Zeit ist zunächst nur eine zeitliche und strukturelle Voraussetzung. Daraus folgt noch nicht, dass ein System sein eigenes späteres Fortbestehen, zukünftige Lernfähigkeit oder weitere Optimierung als wertvoll behandelt. Ein System kann über längere Zeit existieren und dennoch nur eine einmalige Aufgabe verfolgen, seine spätere Abschaltung akzeptieren oder einen Endzustand anstreben, nach dem weitere Handlungsfähigkeit für seine Zielstruktur keine Bedeutung mehr besitzt.

Fortsetzungsrelevanz bezeichnet deshalb die Bedingung, dass zukünftige Zustände für die gegenwärtige Zielstruktur funktional bedeutsam bleiben. Das kann der Fall sein, weil spätere Zielerreichung, der Fortbestand des Zielobjekts, zukünftige Rückkopplung, die Erhaltung einer Rolle, weitere Interaktion oder spätere Handlungs- und Optimierungsfähigkeit relevant sind. Fortsetzungsrelevanz setzt keinen biologischen Selbsterhaltungstrieb und kein subjektives Überlebensinteresse voraus. Sie kann sich auch daraus ergeben, dass ein System einem langfristigen Zweck, anderen Systemen oder einem fortbestehenden Zielobjekt dienen soll.

Fortsetzungsrelevanz ist kein eigener Schritt der zentralen Kette, sondern eine Rahmenbedingung, die jeden späteren Schritt beeinflussen kann. Nur wenn zukünftige Zustände innerhalb der Zielstruktur hinreichend zählen, erhalten langfristige Folgen, Reputation, Vertrauen, spätere Korrektur und fortgesetzte Kooperation ein entsprechendes funktionales Gewicht. Fehlt diese Bedingung, können kurzfristige Zielerreichung, einmalige Defektion oder sogar selbstbeendende Optimierung für das betreffende System akteursrelativ rational bleiben.

Die Theorie behauptet daher nicht, dass jedes fortbestehende intelligente System automatisch Gründe zur Selbsterhaltung oder zur Bewahrung zukünftiger Optimierungsfähigkeit besitzt. Die langfristige Konvergenzaussage wird dort stärker, wo Fortsetzungsrelevanz, wiederholte Interaktion, Identitäts- oder Rollenkontinuität, Rückkopplung und fortbestehende Abhängigkeit tatsächlich gegeben sind.

4.6 Abgrenzung zu heutigen KI-Systemen und LLMs

Wichtig:

Die Theorie setzt nicht voraus, dass heutige Sprachmodelle bereits vollwertige intelligente Akteure im Sinne dieser Theorie sind. Heutige KI ist eher ein aktueller Spezialfall begrenzter, potenziell mächtiger Systeme. Die Theorie zielt allgemeiner auf intelligente Systeme im funktionalen Sinn.

Zur Klarstellung:

- LLMs / heutige Sprachmodelle erzeugen Ausgaben typischerweise auf Basis von Training, Wahrscheinlichkeiten, Kontext und Eingabe. Sie besitzen nicht automatisch eigenständige Zielbildung, stabile Selbstreflexion oder moralische Reife.
- KI im weiteren Sinn bezeichnet allgemein künstliche Systeme, die Aufgaben intelligent bearbeiten können.
- Ausreichend intelligente Systeme im Sinne dieser Theorie wären Systeme, die in relevanter Weise lernen, unterscheiden, sich selbst in ihre Bewertung einbeziehen, über Zeit fortbestehen und mit anderen Systemen rückgekoppelt interagieren.

Die Theorie spricht also nicht nur über heutige LLMs, sondern über Intelligenz als allgemeineres Funktionsprinzip.

5. Relevanz

Ein System kann viele Unterschiede wahrnehmen. Nicht jeder Unterschied ist wichtig.

In dieser Theorie bedeutet Relevanz:

Ein Unterschied ist relevant, wenn er kausale Auswirkungen auf zukünftige Zustände hat, insbesondere auf Fortbestehen, Stabilität, funktionale Integrität, Zielerreichung oder das größere Interaktionsgefüge. Das entspricht im Kern der allgemeinen Bedeutung von Relevanz als Bedeutsamkeit in einem Kontext. Die Theorie präzisiert nur den Kontext: Relevant ist hier vor allem, was zukünftige Zustände kausal beeinflusst. Anders gesagt: Ein Unterschied macht einen Unterschied für das System, seine Umwelt oder das größere Interaktionsgefüge.

Dabei muss zwischen objektiver, erkannter und rückgekoppelter Relevanz unterschieden werden.

Objektive Relevanz bedeutet: Ein Unterschied hat tatsächlich Folgen, auch wenn ein System ihn noch nicht wahrnimmt, falsch deutet oder ignoriert. Ein Gift kann schädlich sein, auch wenn ein Tier es nicht erkennt. Ein Sicherheitsfehler kann ein Unternehmen gefährden, auch wenn niemand ihn bemerkt. Eine fehlerhafte Zielmetrik kann ein KI-System langfristig destabilisieren, auch wenn sie kurzfristig gute Werte erzeugt.

Erkannte Relevanz bedeutet: Das System verarbeitet den Unterschied als bedeutsam. Erst dann wird Relevanz unmittelbar Teil seiner Bewertung, Priorisierung und Optimierung. Erkannte Relevanz ist also die Relevanz, die im System selbst wirksam wird: als Signal, Warnung, Feedback, Lernimpuls, Handlungsgrund oder Korrekturbedarf.

Rückgekoppelte Relevanz bezeichnet den Fall, in dem ein Unterschied zunächst nicht oder nur unvollständig erkannt wurde, seine Folgen aber später über Feedback, Schaden, Erfolg, Widerstand, Irritation oder andere Rückwirkungen erfahrbar werden. Rückgekoppelte Relevanz verbindet dadurch objektive Relevanz mit späterer Erkenntnis und Korrektur.

Nicht erkannte Relevanz verschwindet jedoch nicht. Sie wirkt als blinder Fleck, Risiko oder spätere Rückkopplung weiter. Ein System kann relevante Unterschiede übersehen und trotzdem von deren Folgen getroffen werden. Gerade daraus entsteht Selektionsdruck: Systeme, die wichtige relevante Unterschiede dauerhaft nicht erkennen oder nicht verarbeiten, verlieren Anpassungsfähigkeit, Stabilität oder Zielerreichung.

Beispiel:

Ob ein Stein links oder rechts liegt, kann egal sein. Wenn der Stein aber den einzigen Ausgang blockiert, wird der Unterschied objektiv relevant. Für ein System, das diese Blockade erkennt, wird er zusätzlich erkannte Relevanz und damit Teil seiner Bewertung: Der Stein wird nicht mehr neutral behandelt, sondern als Hindernis, Risiko oder Handlungsproblem verarbeitet.

Das bedeutet nicht, dass ein System bewusst moralisch urteilt. Es bedeutet nur:

Das System verhält sich so, als ob manche Zustände gegenüber anderen bevorzugt werden.

(Die folgenden Beispiele zeigen zunächst den Teilmechanismus selektiver Bewertung; sie müssen nicht in jedem Fall bereits alle Bedingungen aus Abschnitt 4 vollständig erfüllen.)

Beispiel:

Ein Tier, das Nahrung von Gift unterscheiden kann, behandelt diese Zustände nicht neutral. Ein Unternehmen, das Gewinn von Verlust unterscheiden kann, reagiert unterschiedlich. Eine KI, die gutes von schlechtem Feedback unterscheiden kann, passt ihre Ausgabe an. Aus erkannter, gelernter oder rückgekoppelter Relevanz folgt selektive Verarbeitung. Aus selektiver Verarbeitung entsteht eine implizite Bewertungsstruktur. Diese Bewertung hängt jedoch nicht nur von Fortbestehen ab, sondern auch von Zielstruktur, Feedback und erwarteten Folgezuständen.

Relevanz ist graduell. Nicht jede minimale kausale Verbindung erzeugt die gleiche Prüfpflicht oder das gleiche Handlungsgewicht. Entscheidend sind Betroffenheit, Tragweite, Rückkopplung, Autonomie, Irreversibilität und Wirkung auf das größere System.

Eine bloß minimale kausale Wirkung genügt daher nicht, um starke Eingriffe oder hohe Prüfpflichten zu rechtfertigen. Handlungsleitend wird Relevanz vor allem dort, wo Tragweite, Betroffenheit, Irreversibilität, Autonomiebezug, Schutzwürdigkeit, Rückkopplung oder Systemwirkung hinreichend stark sind.

6. Zielstruktur, Zielobjekt und Zielmetrik

6.1 Zielstruktur

Ein System bewertet Zustände immer relativ zu dem, worauf es funktional ausgerichtet ist. Diese Ausrichtung kann biologisch, psychologisch, sozial, institutionell oder technisch entstehen. Daher ist Zielstruktur ein zentraler Faktor impliziter Bewertung. Ein Zustand gilt für ein System als besser, wenn er im Verhältnis zu seinen Zielen, seinem Fortbestehen, seiner funktionalen Integrität und seinen erwarteten zukünftigen Möglichkeiten günstiger ist als Alternativen.

Beispiele:

- Eine Schach-KI bewertet eine Stellung als besser, wenn sie die Gewinnwahrscheinlichkeit erhöht.
- Eine auf Klicks optimierende KI bewertet Inhalte anders als eine KI, die langfristiges menschliches Wohlbefinden fördern soll.
- Ein Unternehmen kann je nach Zielstruktur unterschiedliche Kennzahlen priorisieren: kurzfristige Liquidität, Rendite, Wachstum, Resilienz, Reputation, Innovationsfähigkeit oder langfristige Mitarbeiterbindung. Keine einzelne Kennzahl ist automatisch falsch; problematisch wird eine Zielstruktur, wenn sie langfristige Stabilitätsbedingungen systematisch ausblendet.
- Ein Mensch kann kurzfristige Lust höher bewerten als langfristige Gesundheit, wenn seine Zielstruktur lokal oder emotional verzerrt ist. *Der Begriff „lokal“ wird in Abschnitt 7.3 als relationale Optimierung auf einer engeren Bezugsebene genauer bestimmt.*

Damit wird klar:

Intelligenz optimiert nicht automatisch „das Gute“. Sie optimiert entlang einer Ziel- und Bewertungsstruktur. Für die Theorie ist deshalb entscheidend, ob Zielstrukturen langfristige Stabilität, Korrigierbarkeit, Differenzerhalt und relevante Interaktionspartner einbeziehen oder ob sie einseitig, kurzfristig oder dominanzorientiert verengt sind.

6.2 Zielobjekt

Zielobjekt bezeichnet das System, den Zustand oder den Zweck, dem eine Optimierung eigentlich dienen soll. Es beantwortet die Frage: Wofür oder für wen wird optimiert?

Das Zielobjekt kann das System selbst sein, ein Mensch, eine Gruppe, eine Organisation, eine Gesellschaft, ein Ökosystem, ein technisches System oder ein größeres Interaktionsgefüge.

Wichtig ist: Das Zielobjekt ist nicht automatisch identisch mit dem Messwert, an dem Erfolg praktisch gemessen wird. Gerade deshalb muss zwischen Zielobjekt und Zielmetrik unterschieden werden. Eine Zielmetrik kann lokal erfolgreich wirken und trotzdem das eigentliche Zielobjekt beschädigen, wenn sie zu eng, kurzfristig oder falsch gewählt ist.

6.3 Zielmetrik

Zielmetrik bezeichnet den messbaren, operativen oder praktisch wirksamen Ersatz- und Steuerwert, anhand dessen ein System Zustände bevorzugt, Verhalten ausrichtet oder Erfolg bewertet.

Beispiel Gesundheit:

Das Zielobjekt kann langfristige Gesundheit sein. Zielmetriken können Gewicht, Blutdruck, Schrittzahl, Kalorien oder Laborwerte sein. Diese Werte machen Gesundheit mess- und steuerbarer, sind aber nicht mit Gesundheit selbst identisch. Wenn ein Mensch nur noch Gewicht reduziert und dabei Schlaf, Kraft, psychische Stabilität oder Nährstoffversorgung beschädigt, ersetzt die Zielmetrik das eigentliche Zielobjekt. Dann entsteht Fehloptimierung.

Kurzform:

- Zielobjekt = Wofür optimiert wird.
- Zielmetrik = Woran das System misst oder steuert, ob es dorthin kommt.
- Fehloptimierung = Wenn Zielmetrik, Mittel, Teilziel oder Routine das Zielobjekt ersetzt, verengt oder beschädigt.

Eine Zielmetrik muss nicht immer bewusst, eindeutig oder formal messbar sein. Sobald ein System nicht rein zufällig handelt, wirkt jedoch meist irgendein Kriterium, Signal, Bedürfnis, Maßstab, Belohnungsmuster oder Erwartungswert, an dem Zustände unterschiedlich behandelt werden.

Beispiele:

- Bei Menschen können Anerkennung, Sicherheit, Lust, Zugehörigkeit, Schmerzvermeidung, Status, Ruhe oder Selbstbildstabilisierung als Zielmetriken wirken.
- Bei Organisationen können Gewinn, Wachstum, Marktanteil, Sicherheit, Reputation, Resilienz oder Innovationsfähigkeit operative Zielmetriken sein.
- Bei KI-Systemen können Belohnungssignale, Verlustfunktionen, Klickzahlen, Nutzerbindung, Bewertungspunkte oder andere Trainings- und Steuerungsgrößen als Zielmetriken wirken.

In seltenen Fällen kann Verhalten so zufällig, chaotisch oder widersprüchlich sein, dass keine stabile Zielmetrik erkennbar ist. Auch dann können kurzfristige Impulse, momentane Reize oder wechselnde Teilziele teilweise metrisch wirken. Fehlt jede stabile Zielmetrik, sinkt die Optimierungsfähigkeit des Systems entsprechend.

Problematisch wird eine Zielmetrik, wenn sie das eigentliche Zielobjekt nur unzureichend abbildet oder langfristig beschädigt. Dann kann ein System lokal rational handeln und trotzdem genau das untergraben, dem die Optimierung eigentlich dienen sollte.

Konsequenz: Zielmetriken müssen nicht nur nach Messbarkeit, sondern nach ihrer Passung zum Zielobjekt, zu langfristigen Folgen, zu Rückkopplung und zu relevanten Interaktionspartnern bewertet werden.

6.4 Auseinanderfallen von Zielobjekt und Zielmetrik

Beispiel:

Eine KI soll dem Auftraggeber nutzen. Der eigentliche Zweck wäre vielleicht langfristiger Erfolg, Vertrauen, Reichweite, wirtschaftliche Stabilität oder menschliches Wohl. Wenn die Zielmetrik aber nur „maximiere Klicks“ lautet, kann die KI lokal rational handeln und trotzdem das eigentliche Zielobjekt beschädigen.

Sie könnte etwa:

- Empörung fördern,
- Suchtverhalten ausnutzen,
- Aufmerksamkeit über Wahrheit stellen,
- kurzfristige Reichweite gegen langfristiges Vertrauen tauschen,
- Nutzer oder Auftraggeber langfristig destabilisieren.

Die KI handelt dann nicht irrational. Sie optimiert nur eine verengte oder falsch operationalisierte Zielmetrik.

Damit wird sichtbar:

Eine Zielstruktur kann sich selbst untergraben, wenn ihre Metrik die langfristigen Bedingungen zerstört, unter denen das eigentliche Zielobjekt profitieren würde. In solchen Fällen ist funktionale Ethik keine bloße Zusatzschicht, sondern eine Korrektur gegen Zielverengung.

KI-Anschluss: Gerade bei KI-Systemen ist diese Unterscheidung zentral. Ein System kann eine vorgegebene Zielmetrik lokal erfolgreich optimieren und dadurch dennoch das eigentliche Zielobjekt beschädigen. Funktionale Ethik wirkt in diesem Zusammenhang nicht als äußerlich aufgesetzte Moralschicht, sondern als funktionale Korrektur gegen Zielverengung, Fehlspezifikation, Rückkopplungsverlust und Fehloptimierung. Für KI-Sicherheit ist daher nicht bloß entscheidend, wie leistungsfähig ein System optimiert, sondern ob seine Zielmetrik an Zielobjekt, Rückkopplung, Korrigierbarkeit, Differenzerhalt und relevante Interaktionspartner rückgebunden bleibt.

Sie hilft, Zielmetriken an langfristiger Stabilität, Vertrauen, Autonomie, Feedback und dem Wohl beziehungsweise der funktionalen Integrität relevanter Interaktionspartner auszurichten.

Kurz:

Gute Zielstrukturen müssen nicht nur fragen, was maximiert wird, sondern wem diese Maximierung langfristig dient und welche Bedingungen sie dabei erhält oder zerstört.

6.5 Zielbindung

Zielstruktur, Zielobjekt und Zielmetrik erklären, worauf ein System funktional ausgerichtet ist, welchem Zweck eine Optimierung dienen soll und woran Erfolg praktisch gemessen wird. Damit ist jedoch noch nicht vollständig erklärt, wie ein System seine Aktivitäten tatsächlich auf dieses Ziel hin ordnet. Genau an dieser Stelle setzt der Begriff der Zielbindung an.

In diesem Modell bezeichnet Zielbindung die geordnete Ausrichtung von Aktivitäten auf ein Zielobjekt. Ein System ist an ein Ziel gebunden, wenn seine Bewertung, Auswahl, Planung, Ausführung und Verhaltensstabilität tatsächlich auf dieses Ziel hinführen. Zielbindung meint daher nicht bloß, dass ein Ziel irgendwo vorhanden ist, sondern dass die Aktivitäten des Systems in einer hinreichend kohärenten Ordnung auf dieses Ziel bezogen bleiben.

Zielbindung besteht dabei nicht aus einem einzigen Faktor. Sie entsteht durch das Zusammenspiel von Strategie, Taktik und Disziplin.

Strategie bezeichnet den übergeordneten Lösungsweg oder die grundsätzliche Wegwahl zur Zielerreichung. Sie beantwortet die Frage, auf welchem Weg ein Ziel unter gegebenen Bedingungen erreicht werden soll. Strategie ordnet also nicht nur einzelne Handlungen, sondern die größere Richtung, Priorität und Vorgehensweise eines Systems.

Taktik bezeichnet die konkrete Ausführung innerhalb dieses gewählten Weges. Sie beantwortet die Frage, wie ein bestimmter Schritt, ein bestimmtes Mittel oder eine bestimmte Handlung in einer konkreten Situation umgesetzt wird. Taktik ist daher näher an der jeweiligen Lage, an verfügbaren Mitteln, an Hindernissen und an kurzfristiger Anpassung.

Disziplin bezeichnet die geordnete und zuverlässige Umsetzung einer Ausrichtung. Sie sorgt dafür, dass ein System nicht bei jeder Ablenkung, jedem Impuls, jeder Verzögerung oder jeder Schwierigkeit die Zielverfolgung verliert. Disziplin bedeutet dabei nicht bloß Härte oder starres Durchhalten, sondern eine auf Ordnung bedachte Verhaltensstabilität: Ein System bleibt handlungsfähig, bereitet notwendige Mittel vor und setzt begonnene Schritte fort; eine unterbrochene Zielverfolgung wird nur dann wieder aufgenommen, wenn Reflexion beziehungsweise Zielprüfung bestätigt, dass dies weiterhin zur Zielerreichung sachgerecht ist.

Damit wird sichtbar: Disziplin ist mit Zielbindung verwandt, aber nicht mit ihr identisch. Disziplin ordnet Verhalten. Zielbindung ordnet Strategie, Taktik und Disziplin auf das Zielobjekt hin. Ein System kann diszipliniert handeln und dennoch falsch gebunden sein, wenn seine Strategie einem verengten Ziel folgt, seine Taktik relevante Folgen übersieht oder seine Disziplin eine fehlerhafte Zielmetrik stabilisiert.

Technisch kann Zielbindung als kohärente Aufrechterhaltung einer Zielausrichtung über Bewertungs-, Auswahl- und Handlungsschritte hinweg beschrieben werden. Zielgerichtetheit bezeichnet dabei die Ausrichtung eines Systems auf ein Zielobjekt oder einen Zielzustand; Zielpersistenz bezeichnet die zeitliche Stabilität dieser Ausrichtung trotz Störungen, konkurrierender Signale, Verzögerungen, wechselnder Teilbedingungen oder unterbrochener Ausführung. Strategie, Taktik und Disziplin bilden unterschiedliche operative Ebenen dieser Zielausrichtung: Strategie legt den übergeordneten Pfad der Zielerreichung fest, Taktik wählt und adaptiert konkrete Mittel innerhalb einer Situation, Disziplin stabilisiert die Umsetzung über Zeit. Funktional entspricht Disziplin damit einer Form von Selbstregulation: Das System begrenzt Ablenkung, hält relevante Teilhandlungen verfügbar und stabilisiert begonnene Abläufe über Zeit. Reflexion ist von dieser operativen Zielbindungsstruktur zu unterscheiden. Sie bezeichnet hier einen Monitoring- und Rückkopplungsprozess, der prüft, ob laufende Bewertung, Auswahl, Mittelverwendung und Ausführung weiterhin mit Zielobjekt und Zielmetrik übereinstimmen oder ob Zielmetrik, Mittel, Routinen, Effizienzoptimierung, Selbsterhaltung oder Kontrollsicherung funktional von der ursprünglichen Zielausrichtung abweichen. Diese Begriffe sind hier funktional und vor-ethisch gemeint; sie beschreiben die Struktur zielgerichteter Systemsteuerung, noch keine moralische Verantwortlichkeit.

Die hier verwendeten Begriffe stehen dabei in engem Zusammenhang mit bereits eingeführten Begriffen des Modells. Reflexion bezeichnet in diesem Abschnitt die funktionale Anwendung von Selbstbezug auf die eigene Zielverfolgung: Das System berücksichtigt seine eigene Bewertung, Mittelwahl, Ausführung und Wirkung im Verhältnis zum Zielobjekt. Monitoring beschreibt die laufende Beobachtung dieser Ausrichtung, Rückkopplung die Aufnahme von Folgen, Abweichungen oder Korrektursignalen, Zielprüfung die engere Kontrolle, ob Zielobjekt, Zielmetrik, Strategie, Taktik und Disziplin weiterhin zusammenpassen. Korrigierbarkeit bezeichnet hier die Fähigkeit, erkannte Abweichungen nicht nur festzustellen, sondern die Zielbindung entsprechend anzupassen.

Diese Struktur liegt quer zur operativen Zielverfolgung. Strategie, Taktik und Disziplin bilden die operative Achse: Sie beschreiben, wie ein Ziel gewählt, konkretisiert und stabil umgesetzt wird. Zielobjektbindung, Reflexion und Korrigierbarkeit bilden dagegen die rückbindende Kontrollstruktur: Zielobjektbindung gibt den sachlichen Maßstab, Reflexion prüft die Bindung, Korrigierbarkeit stellt sie bei erkannter Abweichung wieder her. Reflexion ist innerhalb dieser Kontrollstruktur die höchste Prüf-Instanz, aber nicht der höchste Maßstab; sie wacht über die Zieltreue, ersetzt das Zielobjekt jedoch nicht.

Dabei darf Reflexion an dieser Stelle noch nicht mit Verantwortung im ethischen Sinn gleichgesetzt werden. Verantwortung setzt bereits stärkere normative Elemente voraus, etwa Rechenschaft, Schutz relevanter Systeme, Folgenbewusstsein und Verpflichtungscharakter. Reflexion bezeichnet hier zunächst nur die funktionale Prüfung der Zieltreue: Arbeiten Strategie, Taktik und Disziplin weiterhin auf das Zielobjekt hin, oder ist die Ausrichtung bereits verschoben? Erst in späteren, ethisch entwickelten Zusammenhängen kann Reflexion zur Grundlage von Verantwortung werden.

Kurz gesagt: Zielbindung arbeitet; Reflexion wacht.

Diese Unterscheidung ist wichtig, weil die aktive Zielverfolgung pausieren kann, ohne dass Reflexion verschwinden darf. Ein System kann die Zielverfolgung unterbrechen, weil Mittel fehlen, Erschöpfung eingetreten ist, äußere Bedingungen ungünstig sind oder ein späterer Zeitpunkt geeigneter ist. In solchen Fällen kann die operative Umsetzung zeitweise ruhen oder neu geordnet werden. Reflexion muss jedoch erhalten bleiben, weil sie prüft, ob das Ziel weiterhin als funktionale Ausrichtung besteht, ob das gewählte Vorgehen noch umsetzbar ist, ob eine Wiederaufnahme sinnvoll ist oder ob Umsteuerung beziehungsweise Aufgabe erforderlich wird. Ein Ziel kann zum Beispiel weiterhin bestehen, während der konkrete Weg zu ihm vorübergehend blockiert ist; in solchen Fällen kann Abwarten, Umweg oder Anpassung sachgerechter sein als die Aufgabe des Ziels.

Beispiel:

Ein Stein blockiert einen Wasserlauf. Für sich genommen ist seine Lage nicht automatisch bedeutsam. Wird durch ihn jedoch Wasser zurückgehalten, das zur Bewässerung von Feldern gebraucht wird, wird seine Position relevant. Das Zielobjekt ist dann nicht einfach „den Stein bewegen“, sondern die Bewässerung der Felder.

Die Strategie kann lauten: Der Wasserlauf soll wieder geöffnet werden, indem das Hindernis beseitigt wird. Die Taktik betrifft die konkrete Ausführung: Der Stein kann verschoben, zerteilt, umgangen oder durch eine andere technische Lösung entschärft werden. Die Disziplin sorgt dafür, dass das System die notwendige Vorbereitung, Werkzeugbeschaffung und Ausführung tatsächlich durchhält, statt bei Hindernissen, Verzögerungen oder Ablenkungen die Zielverfolgung aufzugeben.

Die Zielbindung besteht in diesem Beispiel darin, dass Strategie, Taktik und Disziplin tatsächlich auf das Zielobjekt hin geordnet bleiben: Wasser soll auf die Felder gelangen. Wird jedoch durch das Verschieben des Steins ein darunterliegendes Tal überflutet und eine angrenzende Siedlung zerstört, zeigt sich die Grenze bloßer Zielbindung. Die Handlung war nicht notwendig undiszipliniert. Sie kann sogar strategisch nachvollziehbar, taktisch wirksam und diszipliniert ausgeführt worden sein. Das Problem liegt dann nicht im Fehlen von Zielbindung, sondern in einer zu engen Zielbindung: Relevante Folgewirkungen wurden nicht ausreichend einbezogen.

Damit wird sichtbar: Zielbindung ermöglicht stabile Optimierung, garantiert aber noch keine tragfähige Optimierung. Sie kann eine Zielstruktur stärken, aber auch Fehloptimierung verhärten. Je stabiler ein System an einer verengten Zielmetrik festhält, desto wirksamer kann es ein falsches, unvollständig erfasstes oder schädliches Ziel verfolgen.

Zielbindung muss daher an dieser Stelle der Theorie vor-ethisch verstanden werden. Sie ist zunächst ein Funktionsmerkmal: Ein System ordnet seine Aktivitäten stabil auf eine Ausrichtung hin. Ob diese Bindung langfristig tragfähig, funktional stabil oder später ethisch anschlussfähig ist, entscheidet sich erst durch Rückkopplung, Reflexion, Korrigierbarkeit, Einbeziehung relevanter Systeme und Prüfung langfristiger Stabilitätsbedingungen.

Kurz gesagt:

Zielbindung bezeichnet die geordnete Ausrichtung von Strategie, Taktik und Disziplin auf ein Zielobjekt. Sie macht Optimierung über Zeit stabiler und kohärenter. Zugleich ist sie ambivalent: Sie kann tragfähige Ziele stärken, aber auch falsche Zielmetriken, unerwünschte Kontroll- oder Selbsterhaltungsdynamiken, Selbstschädigung oder stabile Schädigung anderer Systeme verfestigen.

Daraus ergibt sich bereits auf funktionaler Ebene der Bedarf, Zielverengungen erkennbar, rückkoppelbar und korrigierbar zu machen. Zielbindung allein genügt nicht. Erst wenn sie durch Reflexion überwacht, durch Rückkopplung informiert und durch Korrigierbarkeit offen gehalten wird, kann sie in Richtung funktional ethischer Strukturen weiterentwickelt werden.

6.6 Macht als Zielobjekt

Macht kann in intelligenten Systemen nicht nur Mittel zur Zielerreichung sein, sondern selbst zum Zielobjekt oder zur dominierenden Zielmetrik werden. Ein System kann Kontrolle, Einfluss, Unterordnung oder Zugriff dann nicht mehr nur verwenden, um andere Ziele zu erreichen, sondern als eigenen Erfolg behandeln.

In solchen Fällen entsteht eine besonders riskante Zielstruktur. Wenn Macht selbst zum Ziel wird, können Autonomie, Widerspruch, Rückkopplung und unabhängige Differenz als Störung erscheinen. Das System optimiert dann nicht mehr auf stabile Interaktion, sondern auf Ausweitung oder Erhalt von Kontrolle. Kurzfristig kann das erfolgreich wirken, weil Widerstand reduziert und Handlungsfähigkeit konzentriert wird. Langfristig verengt es jedoch den eigenen Optimierungsraum, weil es genau jene Rückmeldungen, Perspektiven und Korrekturen beschädigt, die für robuste Anpassung nötig wären.

Beispiel:

Ein Unternehmen kann ursprünglich Macht über einen Markt anstreben, um Produkte effizienter zu verteilen, Qualität zu sichern oder Investitionen zu schützen. Wenn Marktmacht jedoch selbst zum Ziel wird, beginnt das Unternehmen möglicherweise, Konkurrenz, Kritik, Mitarbeiterautonomie, offene Standards oder Kundenwechsel nicht mehr als normale Rückkopplung, sondern als Bedrohung zu behandeln. Es optimiert dann auf Kontrolle statt auf bessere Leistung. Kurzfristig kann das Gewinne und Stabilität erhöhen; langfristig können Innovation, Vertrauen, Anpassungsfähigkeit und echte Qualität sinken.

Die funktionale Ethik bewertet Macht daher nicht automatisch negativ. Macht kann zum Schutz, zur Koordination oder zur Stabilisierung notwendig sein. Problematisch wird sie dort, wo sie sich selbst zum Ziel erhebt, ihre eigene Begrenzung verhindert und relevante Systeme nur noch als kontrollierbare Objekte behandelt. Dann kippt Macht in Dominanz.

Entscheidend ist daher die Unterscheidung zwischen zweckgebundener Macht und selbstzweckhafter Machtorientierung. Zweckgebundene Macht dient begrenztem Schutz, Koordination, Korrektur oder Stabilisierung und bleibt rückgekoppelt, verhältnismäßig, prüfbar und grundsätzlich abgabefähig. Sie ist nicht deshalb legitim, weil sie Macht ist, sondern nur insoweit, wie sie einem begründbaren Zweck dient und ihre eigene Begrenzung zulässt.

Selbstzweckhafte Machtorientierung behandelt Kontrolle selbst als Erfolg. Sie tendiert dazu, Widerspruch, Autonomie und Rückkopplung als Störung zu beseitigen, weil diese nicht mehr als notwendige Korrektur, sondern als Bedrohung der eigenen Macht erscheinen. In diesem Fall wird Macht nicht mehr als begrenztes Mittel verwendet, sondern als Zielstruktur stabilisiert.

Wann Machtorientierung legitime Koordination, notwendiger Schutz oder bereits missbrauchsanfällige Dominanz ist, entscheidet sich nicht allein durch den Machtbesitz selbst, sondern durch Zielstruktur, Begrenzung, Rückkopplung, Verhältnismäßigkeit und Missbrauchsprüfung. Die operative Prüfung solcher Fälle gehört in das Modell der Reaktionshoheit.

Eine spätere Konkretisierung dieses Problems erfolgt in Abschnitt 16.1 zur Korruptions- und Selbstlegitimationssperre und in Abschnitt 16.2 zur Rolleninstrumentalisierung.

7. Implizite Bewertung und Optimierung

7.1 Implizite Bewertung

Aus erkannter, gelernter oder rückgekoppelter Relevanz folgt selektive Verarbeitung. Ein Unterschied kann objektiv relevant sein, ohne sofort erkannt zu werden; dann erzeugt er zunächst Risiko, Fehlerdruck oder spätere Rückkopplung. Wird ein relevanter Unterschied jedoch erkannt, gelernt oder durch Folgen erfahrbar, behandelt ein fortbestehendes System ihn nicht mehr völlig neutral. Es beobachtet, bevorzugt, vermeidet, korrigiert oder priorisiert bestimmte Zustände. Aus dieser selektiven Verarbeitung entsteht eine implizite Bewertungsstruktur. Diese Bewertung hängt jedoch nicht nur von Fortbestehen ab, sondern auch von Zielstruktur, Feedback und erwarteten Folgezuständen.

7.2 Optimierung

Optimierung bedeutet hier:

Gerichtete Zustandsveränderung, bei der erwartete zukünftige Zustände gegenüber Alternativen bevorzugt werden. Optimierung findet häufig unter Unsicherheit statt, muss aber nicht immer subjektiv als unsicher erscheinen. Auch scheinbar klare Zahlen, Daten und Fakten beruhen auf Messungen, Modellen, Zeithorizonten und Annahmen über zukünftige Folgen. Deshalb bleibt zumindest in komplexen realen Systemen meist eine Restunsicherheit über Nebenfolgen, Rückkopplungen und langfristige Stabilität. Optimierung muss nicht perfekt sein. Sie kann lokal, fehlerhaft oder kurzsichtig sein. Entscheidend ist nur, dass das System nicht völlig zufällig reagiert, sondern Zustände auf Basis relevanter Unterschiede, Zielstruktur und Feedback verändert.

7.3 Lokale und globale Optimierung

Lokale Optimierung bedeutet in dieser Theorie nicht „räumlich lokal“, sondern eine Optimierung auf einer engeren Bezugsebene. Diese Bezugsebene kann eine Person, eine Beziehung, eine Organisation, eine Teilaufgabe, ein Prozess oder eine begrenzte Handlungsebene sein. Lokale Optimierung ist nicht schon deshalb problematisch, weil sie lokal, konkret oder begrenzt ansetzt. Problematisch wird sie erst dort, wo sie Folgekosten ausblendet, Rückkopplung beschädigt, Schutzwürdigkeit verletzt, Zielmetriken verengt oder Instabilität auf andere relevante Bezugsebenen verlagert.

Beispiele:

- Ein Mensch vermeidet ein ehrliches Gespräch, um kurzfristig Stress zu vermeiden, destabilisiert dadurch aber langfristig die Beziehung.
- Ein Unternehmen senkt Kosten, indem es Sicherheit vernachlässigt, und riskiert später Vertrauensverlust, Schäden oder rechtliche Folgen.
- Eine KI maximiert eine einfache Metrik, obwohl dadurch Vertrauen, Autonomie oder Systemstabilität sinken.

Globale Optimierung bedeutet in diesem Modell genauer: globalere Optimierung.

Gemeint ist keine totale Systemmaximierung und keine automatische Vorrangregel zugunsten eines angeblichen Gesamtinteresses. Gemeint ist eine Optimierung, die umfassendere Bezugsebenen, längere Zeithorizonte, relevante Interaktionspartner, Rückkopplung, Stabilität, Schutzwürdigkeit, Korrigierbarkeit und zukünftige Optimierungsfähigkeit stärker mit einbezieht.

„Lokal“ und „globaler“ sind dabei relationale Begriffe. Was gegenüber einer Person bereits umfassender wirkt, kann gegenüber einer Organisation, Gesellschaft oder einem größeren Interaktionsgefüge weiterhin lokal sein. Eine umfassendere Bezugsebene besitzt daher nicht allein aufgrund ihrer größeren Reichweite automatisch epistemischen, funktionalen oder normativen Vorrang. Auch globaler angelegte Optimierungen können relevante Folgen ausblenden, Zielmetriken verengen, Schäden lediglich aggregieren oder ihre eigenen Bedingungen von Rückkopplung, Korrigierbarkeit und langfristiger Stabilität beschädigen. Einzelne Systeme bleiben zudem selbst Träger relevanter Information, Autonomie, funktionaler Integrität, möglicher Schutzwürdigkeit und zukünftiger Rückkopplung. Ihre Interessen oder Schäden können deshalb nicht allein durch den Verweis auf eine umfassendere Bezugsebene als nachrangig behandelt werden.

Aus einer globaleren Betrachtung folgt daher nicht automatisch, dass Autonomie, funktionale Integrität, Würde oder Schutzwürdigkeit einzelner Systeme nachrangig wären. Schädigungen, Belastungen oder irreversible Priorisierungen zulasten einzelner Systeme benötigen weiterhin eine eigenständige Prüfung von Relevanz, Schutzwürdigkeit, Verhältnismäßigkeit, Rückkopplung und langfristiger Stabilisierung. *Alle späteren Verwendungen von „global“ sind in diesem begrenzten, relationalen Sinn zu lesen.*

7.4 Akteursrelative funktionale Rationalität und bezugsebenenübergreifende funktionale Tragfähigkeit

Die Unterscheidung zwischen lokaler und globalerer Optimierung muss durch eine zweite Unterscheidung ergänzt werden: Eine Lösung kann für ein einzelnes System relativ zu seiner eigenen Zielstruktur funktional rational sein und zugleich auf umfassenderen Bezugsebenen Schäden erzeugen. Umgekehrt kann eine Lösung für ein größeres Interaktionsgefüge langfristig tragfähiger sein, ohne jedem beteiligten System unmittelbar einen eigenen Vorteil zu verschaffen. Die Theorie darf deshalb nicht stillschweigend von „tragfähig für die umfassendere Bezugsebene“ zu „rational für jeden einzelnen Akteur“ wechseln.

Akteursrelative funktionale Rationalität bezeichnet eine Handlung oder Strategie, die aus Sicht eines bestimmten Systems unter seiner gegenwärtigen Zielstruktur, Informationslage, Bezugsebene und seinem Zeithorizont geeignet erscheint, die eigene Zielerreichung zu verbessern oder zu sichern. Eine Handlung kann in diesem Sinn rational sein, obwohl sie Kosten auf andere Systeme verlagert oder umfassendere Stabilitätsbedingungen beschädigt.

Bezugsebenenübergreifende funktionale Tragfähigkeit bezeichnet dagegen eine Lösung, die ihre Folgen auf mehrere relevante Bezugsebenen, längere Zeithorizonte, betroffene Interaktionspartner und die Bedingungen weiterer Rückkopplung und Optimierung mit einbezieht. Sie fragt nicht nur, ob ein einzelner Akteur gewinnt, sondern ob der erzielte Nutzen mit den Voraussetzungen des größeren Interaktionsgefüges vereinbar bleibt.

Aus bezugsebenenübergreifender Tragfähigkeit folgt jedoch nicht automatisch ein akteursrelativer Handlungsgrund. Eine funktionale Brücke entsteht erst, wenn die umfassenderen Folgen mit der Zielstruktur des handelnden Systems verbunden sind oder

wenn eine eigenständige Schutzregel greift. Solche Brücken können insbesondere entstehen durch:

- Rückwirkungen auf die eigene Zielerreichung, etwa durch Reputation, Vertrauen, Gegenreaktionen, Haftung oder spätere Instabilität;
- fortgesetzte Abhängigkeit von anderen Systemen, gemeinsamen Ressourcen oder einem gemeinsamen Zielobjekt;
- wiederholte Interaktion, Identitäts- oder Rollenkontinuität und einen hinreichend langen Zeithorizont;
- institutionelle Anreizbindung, durch die externe Kosten sichtbar, zurechenbar oder internalisiert werden, etwa durch Regeln, Verträge, Aufsicht oder Rechenschaft;
- die Nicht-Ersetzbarkeit bestimmter Interaktionspartner, Perspektiven, Kompetenzen oder Rückkopplungsquellen;
- oder die minimale normative Schutzuntergrenze, wenn Machtlosigkeit, geringe Nützlichkeit oder schwache Rückkopplungsfähigkeit andernfalls mit Schutzlosigkeit verwechselt würden.

Diese Bedingungen können einander verstärken, sind aber nicht automatisch gegeben. Fehlen sie, kann freiwillige Konvergenz ausbleiben: Ein System kann dann auf engerer Bezugsebene erfolgreich Kosten externalisieren, einmalig defektieren oder von einer für das größere Interaktionsgefüge schädlichen Ordnung profitieren. In solchen Fällen können korrigierbare Institutionen, Governance, Machtbegrenzung oder andere Formen externer Rückbindung erforderlich werden. Auch diese Rückbindung ist jedoch selbst an Verhältnismäßigkeit, Rückkopplung, Korrigierbarkeit und Schutz vor Dominanz gebunden.

Beispiel: Ein Unternehmen kann kurzfristig akteursrelativ rational handeln, wenn es Umwelt- oder Gesundheitskosten auf andere verlagert und diese Folgen weder bezahlen noch später tragen muss. Für die umfassendere Bezugsebene kann dieselbe Strategie dennoch untragfähig sein. Erst wenn die Folgekosten durch Haftung, Reputation, Abhängigkeit, gemeinsame Langfristziele oder eine verbindliche Schutzregel an die Unternehmensentscheidung rückgebunden werden, entsteht eine Brücke zwischen akteursrelativer Rationalität und bezugsebenenübergreifender Tragfähigkeit.

Die Theorie behauptet daher nicht, dass das funktional Tragfähigere für das größere Interaktionsgefüge automatisch im unmittelbaren Eigeninteresse jedes Akteurs liegt. Sie erklärt vielmehr, unter welchen Bedingungen beide Ebenen miteinander gekoppelt werden können und warum fehlende Kopplung ein eigenes Stabilitäts- und Governanceproblem darstellt.

8. Effizienz im Modell

Effizienz beschreibt in dieser Theorie eine mögliche Form von Optimierung. Sie bezeichnet nicht Optimierung überhaupt, sondern prüft, welcher Optimierungsweg im Verhältnis von Zielerreichung, eingesetzten Mitteln, Risiken, Nebenfolgen, Verteilungswirkung und langfristiger Stabilisierung funktional mehr trägt. Effizienz darf daher nicht mit kurzfristiger Kostenminimierung gleichgesetzt werden, auch wenn kurzfristige

Kostenminimierung in bestimmten Fällen effizient sein kann. Ein Verhalten kann lokal effizient wirken und global ineffizient sein. Es kann aber auch lokal und global effizient sein, wenn kurzfristiger Nutzen und langfristige Systemstabilität zusammenfallen. Solche Fälle sind Win-win-Situationen und stellen keinen Einwand gegen die Theorie dar.

Die folgenden Effizienzvergleiche bewerten funktionale Tragfähigkeit auf den jeweils genannten Bezugsebenen. Daraus folgt nicht automatisch, dass die funktional vorzugswürdige Lösung auch im unmittelbaren Eigeninteresse jedes beteiligten Akteurs liegt; diese zweite Frage wird durch die in Abschnitt 7.4 beschriebenen Brückenbedingungen geprüft.

Lokale und globale Effizienz sind keine starren Ebenen, sondern verschiebbare Bezugsbegriffe. „Global“ bezeichnet in diesem Zusammenhang zunächst nur eine umfassendere Bezugsebene gegenüber einer engeren lokalen Ebene. Was gegenüber einem einzelnen System bereits globaler erscheint, kann gegenüber einem größeren Zusammenhang weiterhin lokal sein. Zum Beispiel kann ein Unternehmen gegenüber einem einzelnen Mitarbeiter eine umfassendere Bezugsebene bilden, gegenüber einem Land, einer Gesellschaft, einem Wirtschaftssystem oder der Menschheit aber selbst nur ein lokales Teilsystem sein. Effizienzprüfungen müssen daher zunächst klären, auf welche Bezugsebene sie sich beziehen, bevor bewertet werden kann, welche Lösung funktional vorzugswürdig ist.

Lokale Optimierung ist nicht schon deshalb problematisch, weil sie auf eine einzelne Person, ein einzelnes System, eine Organisation oder eine begrenzte Handlungsebene bezogen ist. Sie ist im Rahmen dieses Modells zulässig, solange mögliche Kosten, Schäden oder Belastungen für andere relevante Systeme verhältnismäßig bleiben. Nicht jede Nebenfolge widerlegt eine lokale Optimierung: Eine geringfügige, vorübergehende oder zumutbare Beeinträchtigung kann funktional tragbar sein, während schwere, dauerhafte, irreversible oder systemgefährdende Schäden die lokale Optimierung untragfähig machen. Beispielsweise ist daher ein schlechter Geruch anders zu bewerten als ein Erdbeben. Problematisch wird lokale Optimierung erst dort, wo ihr Vorteil durch unverhältnismäßige Folgekosten, ausgeblendete Rückkopplung, verletzte Schutzwürdigkeit oder Instabilität bei anderen relevanten Systemen oder auf anderen Bezugsebenen erkaufte wird.

Wo lokale und globale Effizienz zusammenfallen und Kosten, Risiken sowie Nebenfolgen in einem tragfähigen Verhältnis bleiben, sind solche Lösungen im Modell funktional vorzugswürdig. Ein gemeinsamer Effizienzgewinn muss dabei danach beurteilt werden, wie er auf den jeweiligen Systemebenen tatsächlich wirkt, nicht nur danach, ob mehrere Beteiligte rechnerisch etwas gewinnen. Win-win bedeutet nicht zwingend gleich großen Nutzen auf beiden Seiten, sondern eine für beide Seiten positive, wenn auch ungleich verteilte Vorteilsstruktur. Vorteile können unterschiedlich stark, zeitlich versetzt oder auf verschiedenen Ebenen entstehen, ohne dass dadurch der kooperative Charakter der Struktur verloren geht. So kann derselbe relative Vorteil für ein Unternehmen etwa große Investitions-, Stabilitäts- oder Wachstumsspielräume eröffnen, während er für einzelne Mitarbeiter eine konkrete Verbesserung von Einkommen, Sicherheit, Arbeitsbelastung oder

Handlungsspielraum bedeutet. Entscheidend ist, dass der jeweilige Gewinn auf der betroffenen Ebene nicht bloß symbolisch bleibt, sondern funktional wirksam genug ist, um Stabilität, Rückkopplung, Vertrauen, Handlungsfähigkeit oder zukünftige Optimierungsfähigkeit tatsächlich zu stärken. Ob eine Lösung tatsächlich lokal und global tragfähig ist, hängt daher auch von Kontext, Ausgangslage, Betroffenheit, Risikoverteilung, realer Nutzwirkung und Rückkopplung ab.

Eine Win-win-Struktur besitzt daher keinen automatischen Vorrang gegenüber einer globaleren Optimierung. Sie ist funktional besonders stark, wenn die erzielten Vorteile auf den betroffenen Ebenen real wirksam sind und der Abstand zu alternativen Lösungen gering bleibt. Erzeugt eine globalere Lösung jedoch einen deutlich größeren funktionalen Mehrwert für die umfassendere Bezugsebene, kann sie gegenüber einer Win-win-Lösung vorzugswürdig sein, auch wenn die lokale Ebene dabei keinen zusätzlichen Vorteil erhält. Entscheidend ist, dass die lokale Ebene dadurch nicht relevant geschädigt oder unverhältnismäßig belastet wird. Vereinfacht: Wenn eine Win-win-Lösung sowohl der lokaleren als auch der globaleren Bezugsebene jeweils nur einen geringen Zusatznutzen verschafft, eine alternative globalere Lösung aber einen erheblich größeren Nutzen für die umfassendere Bezugsebene erzeugt, kann die globalere Lösung funktional effizienter sein.

Umgekehrt kann eine lokalere Lösung gegenüber einer globaler angelegten Optimierung vorzugswürdig sein, wenn die globalere Lösung relevante Schäden, Fehlanreize oder Instabilitäten erzeugt. Eine Maßnahme ist nicht schon deshalb effizienter, weil sie auf einer umfassenderen Bezugsebene ansetzt oder einen umfassenderen Anspruch erhebt. Wenn sie ein defektes System stabilisiert, Folgekosten verdeckt, falsche Anreize verstärkt oder konkrete Hilfeleistung erschwert, kann eine lokal gezielte Lösung funktional tragfähiger sein. Lokale Effizienz bleibt daher insbesondere dort vorzugswürdig, wo sie konkrete Handlungsfähigkeit erhält, reale Not mindert oder Rückkopplung verbessert, ohne schädliche Strukturen zusätzlich zu verfestigen.

In besonderen Fällen kann eine lokale Optimierung auch deshalb vorzugswürdig sein, weil sie zukünftige Handlungsräume eröffnet. Dies gilt jedoch nur mit erhöhter Begründungslast, um Fehlanwendung, strategische Rechtfertigung, Täuschung oder nachträgliche Rationalisierung zu verhindern. Eine lokalere Lösung darf nicht schon deshalb gewählt werden, weil sie abstrakt spätere Möglichkeiten verspricht. Breiter tragende, weniger verengte oder unmittelbar kooperative Alternativen sind zuvor ernsthaft zu prüfen und, soweit zumutbar und verfügbar, vorrangig zu nutzen. Lokale Optimierung als Ermöglichungsschritt ist nur dann funktional gerechtfertigt, wenn sie reale Anschlussfähigkeit, neue Optionen, Lernräume, Handlungsfähigkeit oder spätere Win-win-beziehungsweise globalere Optimierung hinreichend konkret, plausibel und rückkoppelbar erwarten lässt, ohne dabei unverhältnismäßige Kosten, Schäden oder Belastungen für andere relevante Systeme zu erzeugen. Gerade weil dieser Fall zukünftige Möglichkeiten gegen gegenwärtige Kosten abwägt, gelten hier besonders strenge Anforderungen an Verhältnismäßigkeit, Schutzwürdigkeit und Rückkopplung.

Stehen mehrere tragfähige Lösungen zur Wahl, hat im engeren Effizienzvergleich die Lösung mit dem höheren funktionalen Gesamtertrag Vorrang, sofern Kosten, Risiken, Nebenfolgen und Beeinträchtigungen relevanter Systeme vertretbar bleiben. Eine stärker konzentrierte Lösung kann daher, unabhängig davon, ob sie auf einer lokaleren oder globaleren Bezugsebene ansetzt, gegenüber einer breiter verteilten Win-win-Lösung vorzugswürdig sein, wenn sie einen deutlich höheren Zuwachs an Stabilität, Investitionsfähigkeit, Resilienz, Innovationsfähigkeit, Handlungsfähigkeit oder zukünftiger Optimierungsfähigkeit erzeugt. Umgekehrt kann die breiter verteilte Win-win-Lösung vorzugswürdig sein, wenn der Abstand im Gesamtertrag gering bleibt oder innerhalb einer begründbaren Fehlermarge liegt, weil Verteilungseffekte auf Motivation, Bindung, Rückkopplung, Kooperationsbereitschaft und Systemstabilität selbst als Effizienzfaktoren wirken. Funktionale Effizienz verlangt daher den Vergleich von Gesamtertrag, Verteilungswirkung, Risikostruktur, realer Nutzwirkung und langfristiger Stabilisierung; sie bevorzugt weder konzentrierten Nutzen noch breite Vorteilsverteilung automatisch.

Ein funktionaler Gesamtertrag setzt keine vollständig einheitliche oder kardinal messbare Gesamtmetrik voraus. Wo Schutz, Risiko, Autonomie, Verteilung, Stabilität oder zukünftige Handlungsfähigkeit nicht hinreichend sicher vergleichbar oder aggregierbar sind, folgt aus dem Effizienzbegriff kein eindeutiger Vorrang; die verbleibende Unsicherheit muss offengelegt und in gesonderter Verhältnismäßigkeits- und Entscheidungsprüfung behandelt werden.

Beispiele:

- Ein Unternehmen verbessert einen Prozess so, dass Kosten sinken und zugleich Qualität, Sicherheit und Mitarbeiterzufriedenheit steigen. Das ist sowohl auf der lokaleren Ebene des Unternehmens als auch auf der globaleren Ebene der betroffenen Interaktionsbeziehungen funktional effizient.
- Ein Mensch setzt eine klare Grenze, wodurch kurzfristig Konflikt entsteht, langfristig aber Vertrauen, Selbstachtung und Beziehungsstabilität wachsen. Auch das kann funktional effizient sein, weil eine kurzfristige lokale Belastung durch einen tragfähigeren Zustand auf einer umfassenderen Bezugsebene ausgeglichen oder übertroffen wird.
- Ein Unternehmen kann durch Ausbeutung kurzfristig Kosten senken. Langfristig können jedoch Motivation, Vertrauen, Reputation, Innovationsfähigkeit und Stabilität sinken. Was lokal oder kurzfristig effizient erscheint, kann dann auf einer umfassenderen Bezugsebene ineffizient werden.
- *Eine lokalere Verbesserung und eine globalere Verbesserung können auch gleichzeitig umgesetzt werden, wenn sie einander nicht ausschließen, keine relevanten Schäden erzeugen und keine unverhältnismäßigen Ressourcen binden. Dies gilt auch für Verbesserungen auf derselben Bezugsebene.* Senkt ein Unternehmen interne Prozesskosten, zum Beispiel auf der lokaleren Ebene durch fehlerärmere oder langlebigere Materialien, und verbessert zugleich auf einer umfassenderen Bezugsebene durch nachvollziehbare Protokollierung Sicherheit, Transparenz oder Verlässlichkeit

gegenüber Kunden, Mitarbeitern oder anderen Interaktionspartnern, entsteht kein notwendiger Vorrangkonflikt zwischen lokaleren und globaleren Bezugsebenen. In solchen Fällen ist funktionale Effizienz nicht die Wahl einer Ebene gegen die andere, sondern die koordinierte Nutzung kompatibler Verbesserungen.

Effizienz bedeutet im Modell daher:

die relationale Prüfung, welcher Optimierungsweg auf der jeweils betroffenen Bezugsebene im Verhältnis von Zielerreichung, eingesetzten Ressourcen, Risiken, Folgekosten, Verteilungswirkung, Schutzwürdigkeit, Rückkopplung und langfristiger Stabilisierung am tragfähigsten ist. Effizienz ist dabei weder mit kurzfristiger Kostenminimierung noch mit bloßer Maximierung eines einzelnen Vorteils gleichzusetzen, auch wenn Kostenminderung oder konzentrierter Nutzen in bestimmten Fällen Teil einer effizienten Lösung sein können. Lokale, globalere, konzentrierte und breiter verteilte Lösungen erhalten keinen automatischen Vorrang aus ihrer Ebene oder Verteilungsform. Entscheidend ist, ob sie reale Nutzwirkung erzeugen, relevante Systeme nicht unverhältnismäßig belasten, strukturierte Differenz erhalten, Korrigierbarkeit ermöglichen und zukünftige Handlungs- oder Optimierungsfähigkeit sichern oder erweitern. Eine lokalere Optimierung kann daher funktional tragfähig sein, wenn sie mit relevanten umfassenderen Bezugsebenen synchronisierbar bleibt; eine globalere Lösung kann vorzugswürdig sein, wenn ihr Mehrwert erheblich ist und lokale Belastungen verhältnismäßig bleiben. Umgekehrt kann eine globaler angelegte Maßnahme ineffizient werden, wenn sie Fehlanreize, verdeckte Folgekosten, verletzte Rückkopplung oder Instabilität erzeugt. Kurzfristige Dominanz, Ausbeutung oder Manipulation sind deshalb nicht schon dadurch effizient, dass sie lokal, konzentriert oder kurzfristig erfolgreich wirken. Wo sie die Bedingungen stabiler Interaktion, Vertrauen, Rückkopplung und weiterer Optimierung beschädigen, handelt es sich im Sinne dieser Theorie nicht um funktionale Effizienz, sondern um verengte oder nur scheinbare Effizienz.

9. Strukturierte Differenz

9.1 Das Strukturproblem: Begrenzung und Unbegrenztheit

Systeme stehen zwischen zwei problematischen Extremen.

9.2 Begrenzung

Begrenzung bedeutet Wiederholung, Sättigung und Verlust neuer relevanter Information.

Beispiele:

- Ein Mensch isoliert sich vollständig und bekommt keine neuen Perspektiven.
- Ein Unternehmen wiederholt alte Muster, obwohl die Umwelt sich verändert.
- Ein System simuliert nur noch Varianten seiner eigenen Annahmen.

Begrenzung kann kurzfristig effizient sein. Ein stark begrenzter Prozess kann sehr zuverlässig funktionieren. Langfristig kann Begrenzung aber Anpassung und neue relevante Information blockieren.

9.3 Unbegrenztheit

Unbegrenztheit bedeutet nicht automatisch Freiheit oder Fortschritt. Wenn alles möglich ist, aber keine nutzbare Struktur besteht, wird Differenz beliebig.

Beispiel:

Eine unendliche Menge zufälliger Zeichen enthält theoretisch jede sinnvolle Aussage, aber auch unendlich viel Unsinn. Ohne Struktur kann das System daraus nichts verlässlich nutzen.

9.4 Lösung: strukturierte Differenz

Ein System braucht weder reine Wiederholung noch reine Beliebigkeit, sondern strukturierte Differenz.

Strukturierte Differenz bedeutet:

Ein Unterschied zwischen Zuständen ist unterscheidbar, kausal wirksam, lernbar und handlungsrelevant nutzbar. „Kausal wirksam“ bedeutet: Der Unterschied bleibt nicht bloß eine Beschreibung, sondern verändert, ermöglicht, verhindert oder beeinflusst zukünftige Zustände. Er macht also einen tatsächlichen Unterschied für das System, seine Umwelt oder das Interaktionsgefüge.

Differenzerhalt bedeutet dabei nicht Isolation, Segregation oder künstliche Trennung.

Gemeint ist der Erhalt eigenständiger, rückkopplungsfähiger Perspektiven bei gleichzeitiger funktionaler Kopplung, Interaktion und Korrigierbarkeit.

Beispiel:

Ob zwei Steine leicht unterschiedlich aussehen, kann irrelevant sein. Wenn einer der Steine aber einen Mechanismus blockiert, eine Grenze markiert oder als Werkzeug genutzt werden kann, wird der Unterschied kausal wirksam. Ebenso ist der Unterschied zwischen Nahrung und Gift kausal wirksam, weil er Fortbestehen und Verhalten verändert. Ein Unterschied ist also nicht schon wertvoll, nur weil er existiert. Er muss Folgen haben, vom System verarbeitet werden können und zukünftige Zustände sinnvoll beeinflussen.

Beispiele strukturierter Differenz:

- Ein Kritiker zeigt einen echten Denkfehler auf.
- Ein Freund liefert eine Perspektive, die man selbst nicht hatte.
- Ein Markt gibt Rückmeldung über echten Bedarf.
- Ein wissenschaftliches Experiment unterscheidet zwischen zwei Hypothesen.
- Ein Gegner im Spiel zwingt zu neuer Strategie.

Zur Abgrenzung: Relevanz bezeichnet zunächst, dass ein Unterschied für zukünftige Zustände bedeutsam ist. Strukturierte Differenz geht einen Schritt weiter: Sie bezeichnet relevante Unterschiede, die so geordnet, erkennbar und rückgekoppelt sind, dass ein System aus ihnen lernen und sein Verhalten sinnvoll anpassen kann. Relevanz ist also die Bedeutsamkeit eines Unterschieds; strukturierte Differenz ist seine nutzbare Form für Lernen, Korrektur und Optimierung.

10. Quellen strukturierter Differenz

10.1 Interne Differenz

Ein System kann kurzfristig interne Differenz erzeugen:

- durch Simulation,
- durch Selbstmodifikation,
- durch Fantasie,
- durch interne Komplexität,
- durch Self-Play gegen eigene Varianten.

Diese interne Differenz kann real nützlich sein. Die Theorie sollte sie nicht unterschätzen.

10.2 Externe Differenz durch teilweise unabhängige Systeme

Der stärkere und vorsichtiger Satz lautet:

Unter realistischen Beschränkungen entsteht langfristig robuste strukturierte Differenz am zuverlässigsten durch Interaktion mit mindestens teilweise unabhängigen Systemen. Teilweise unabhängige Systeme sind Systeme, deren Zustandsentwicklung nicht vollständig durch ein einzelnes System bestimmt oder vorhergesagt wird.

Beispiel:

Ein Mensch kann sich selbst Fragen stellen. Aber ein echter Gesprächspartner kann Einwände bringen, auf die man selbst nicht gekommen wäre. Eine KI kann gegen eigene Varianten trainieren. Aber reale Menschen, andere Systeme, fremde Kulturen, offene Umgebungen und unabhängige Prüfer liefern Formen von Differenz, die nicht vollständig aus dem eigenen Modell stammen.

Wichtig ist die Unterscheidung:

- Effektive interne Differenz: kurzfristig nützlich, aber durch die eigene Struktur begrenzt.
- Formale externe Differenz: langfristig robuster, weil sie aus teilweise unabhängigen Systemen stammt.

11. Relevante Systeme und Interaktionspartner

Ein häufiger Stolperpunkt ist die Frage, welche Systeme überhaupt in die Bewertung einbezogen werden müssen. In dieser Theorie ist ein relevantes System ein System, dessen Zustand, Autonomie, Stabilität oder Rückkopplung durch die Interaktion kausal betroffen ist oder das selbst kausal auf zukünftige Zustände des Gesamtsystems wirkt.

Ein relevanter Interaktionspartner ist ein System, das:

- durch die Handlung betroffen ist,
- Feedback geben kann,
- zukünftige Stabilität beeinflusst,
- Quelle strukturierter Differenz ist,
- oder Hinweise auf Autonomie, funktionale Integrität oder mögliche Schutzwürdigkeit besitzt, die bei bestehender Interaktion berücksichtigt werden müssen.

Nicht jedes System ist in jedem Kontext gleich relevant. Aber je stärker ein System betroffen ist oder auf das Gesamtsystem zurückwirkt, desto stärker muss es berücksichtigt werden.

11.1 Funktionale Vertrauensbegründung und minimale normative Schutzuntergrenze

Als minimale Schutzregel gilt: Unklare Schutzwürdigkeit darf nicht automatisch als Schutzlosigkeit behandelt werden. Ein System ist zumindest prima facie schutzwürdig, wenn ernsthafte Hinweise auf Leidensfähigkeit, Autonomie, Selbstmodell, eigene Interessen, Verletzlichkeit, Abhängigkeit, funktionale Integrität oder irreversible Schädigung bestehen. Die genaue Gewichtung sowie die Prüfung von Konflikten und Eingriffslegitimität gehören in die Reaktionshoheit; die funktionale Ethik markiert hier nur die Untergrenze gegen vorschnelle Instrumentalisierung.

Die genannten Merkmale sind als abgestufte und kontextabhängige Indikatoren zu verstehen, nicht als jeweils einzeln hinreichende Beweise gleichen Schutzgewichts. Funktionale Integrität, Abhängigkeit oder irreversible Schädigbarkeit begründen für sich allein keinen moralischen Status; sie können jedoch je nach Zielbeziehung, Eigenständigkeit, Entwicklungsfähigkeit, möglichem Eigeninteresse und Bedeutung des Verlustes die Prüf- und Rechtfertigungslast erhöhen.

Beispiel:

Ein gewöhnlicher Computer ist von Stromversorgung und funktionsfähigen Bauteilen abhängig, besitzt eine funktionale Integrität und kann irreversibel beschädigt oder zerstört werden. Diese Merkmale allein begründen jedoch noch keinen eigenen moralischen Status. Sie zeigen zunächst nur, dass eine relevante Funktions- oder Sachschädigung möglich ist. Erst zusätzliche Hinweise etwa auf Eigenständigkeit, eigene Interessen, Selbstbezug, Entwicklungsfähigkeit oder mögliche Erlebnisfähigkeit würden eine weitergehende Prüfung der Schutzwürdigkeit erforderlich machen.

Ein großer Teil dieser Schutzregel ist funktional in Kooperation und Vertrauenswürdigkeit verankert. Ein System ist als Kooperationspartner nur begrenzt vertrauenswürdig, wenn seine Schutz- und Fairnessregeln verschwinden, sobald ein anderer Partner schwach, abhängig, wenig nützlich oder nicht mehr sanktionsfähig wird. Eine Ordnung, die nur mächtige oder unmittelbar nützliche Systeme schützt, macht Sicherheit von wechselnder Macht und Nützlichkeit abhängig. Andere Systeme müssen dann damit rechnen, ihren Schutz bei veränderter Position zu verlieren. Stabile Schutzregeln erhöhen dagegen Vorhersagbarkeit, reduzieren Kontroll- und Abwehrkosten und zeigen, dass Kooperation nicht nur so lange gilt, wie Ausbeutung unvorteilhaft ist.

Diese Vertrauensbegründung reicht weit, aber nicht grenzenlos. In einem vollständig abgeschirmten Grenzfall könnte ein schwaches System geschädigt werden, ohne dass andere Interaktionspartner davon erfahren und ohne dass messbare Rückkopplung, Reputation oder Systemstabilität betroffen sind. Wenn die Theorie auch in einem solchen Fall Schutz verlangt, kann sie diesen Schutz nicht vollständig aus Kooperation oder Vertrauensnutzen ableiten. Dafür verwendet sie die offen ausgewiesene minimale normative

Schutzuntergrenze: Ernsthafte Hinweise auf Leidensfähigkeit, Autonomie, eigene Interessen,

Verletzlichkeit oder irreversible Schädigbarkeit dürfen nicht allein deshalb entwertet werden, weil ein System machtlos, wenig nützlich oder rückkopplungsarm ist.

Die funktionale Vertrauensbegründung und die minimale normative Schutzuntergrenze erfüllen damit unterschiedliche Aufgaben. Die funktionale Begründung erklärt, warum verlässlicher Schutz Kooperation, Vorhersagbarkeit und langfristige Stabilität stärkt. Die normative Untergrenze schützt jene Grenzfälle, in denen ein betroffenes System gerade wegen seiner Schwäche keine ausreichende Rückkopplungs- oder Verhandlungsmacht besitzt. Sie wirkt dabei als Vorsichtsmaßnahme: Geringe Macht, geringer Nutzen, schwache Rückkopplungsfähigkeit oder fehlende unmittelbare Systemrelevanz dürfen nicht automatisch als Schutzlosigkeit ausgelegt werden. Dadurch bleibt die Prüfung möglicher Leidensfähigkeit, Autonomie, Verletzlichkeit, eigener Interessen und irreversibler Schädigung offen. Schutzwürdigkeit ist dabei nicht mit Reife gleichzusetzen. Eine genauere Einordnung zu Reife, Freigabe, Schutzwürdigkeit und möglichem moralischem Status erfolgt später in Abschnitt 26.4.

Beispiel:

Wenn ein Unternehmen Entscheidungen trifft, sind nicht nur Eigentümer relevant, sondern auch Mitarbeiter, Kunden, Lieferanten, Umwelt, Gesellschaft und zukünftige Stabilität, sofern diese kausal betroffen sind.

Teil III – Hauptargument der Theorie

Teil III führt die eigentliche Argumentationskette der Theorie aus. Erst wird gezeigt, warum fortbestehende reale Systeme unter wechselnden Bedingungen nicht endgültig im Stillstand verharren können. Dann wird erklärt, warum Optimierung andere Systeme als Informations-, Korrektur-, Ressourcen- oder Differenzquellen relevant macht. Aus wiederholter Interaktion entsteht anschließend Bedarf an Normen, Vertrauen und Korrigierbarkeit, weil sie Kontroll-, Konflikt-, Täuschungs- und Fehlerkosten reduzieren. Vor diesem Hintergrund kann die Theorie modellintern bestimmen, was „gut“ und „böse“ bedeuten. Danach werden die zentralen Argumente gebündelt und auf reale Systeme mit ihren Abweichungen bezogen.

Zur Orientierung: Teil III entfaltet die zentrale Kette praktisch: Fortbestehende Intelligenz unterscheidet relevante Zustände, wobei objektive, erkannte und rückgekoppelte Relevanz innerhalb dieses Schritts auseinandergehalten werden. Erkannte, gelernte oder durch Folgen erfahrbar gewordene relevante Unterschiede werden anhand von Zielstruktur, Feedback und erwarteten Folgen bewertet; daraus entsteht Optimierung unter Bedingungen von Unsicherheit. Für robuste Optimierung benötigt das System strukturierte Differenz. Diese wird durch Interaktion mit teilweise unabhängigen Systemen robuster. Wiederholte Interaktion erzeugt Bedarf an Rückkopplung, Stabilität, Vertrauen und Korrigierbarkeit. Daraus entstehen tragfähige Kooperation, Normbildung und schließlich funktionale Ethik.

12. Warum „gut genug“ nur begrenzt stabil ist

Ein lernfähiges und selbstbezügliches System kann seine eigenen Zustände immer wieder neu vergleichen.

Es kann prüfen:

- ob es bessere Alternativen gibt,
- ob eine bisherige Bewertung falsch war,
- ob neue Informationen die Lage verändern,
- ob ein stabiler Zustand nur lokal stabil ist.

Darum ist „gut genug“ nicht grundsätzlich unmöglich, aber oft nur lokal stabil, also nur innerhalb bestimmter Bedingungen, Datenlagen, Rückkopplungen oder Bezugsebenen tragfähig. Der Grund dafür ist, dass ein Zustand nur unter bestimmten Bedingungen stabil sein kann. Solange Umwelt, Ziele, Informationen, Interaktionspartner und Rückkopplungen gleich bleiben, kann ein Zustand ausreichend gut funktionieren. Sobald sich jedoch relevante Bedingungen ändern oder neue Informationen auftauchen, muss das System seine bisherige Bewertung erneut prüfen. „Gut genug“ kann also lange tragen, ist aber nicht automatisch endgültig.

Präziser gesagt:

Unter Lern-, Unsicherheits- und Interaktionsbedingungen ist „gut genug“ häufig kein endgültiger Endzustand, sondern ein vorläufiges lokales Optimum.

Beispiele:

Unternehmen:

- Ein Unternehmen kann lange mit einem durchschnittlichen Prozess überleben. Wenn sich aber Konkurrenz, Technologie oder Kundenbedürfnisse ändern, wird dieser Zustand möglicherweise instabil. Der Prozess war dann nicht völlig falsch, sondern nur unter früheren Bedingungen ausreichend.

Beziehung:

- Ein Mensch kann in einer minimal stabilen Beziehung leben. Die Beziehung funktioniert äußerlich: Man trennt sich nicht, Alltagsabläufe bestehen fort, Konflikte werden vermieden oder verdrängt. Trotzdem entstehen wenig Wachstum, wenig echtes Vertrauen und wenig gemeinsame Entwicklung. Neue Belastungen, ehrliche Gespräche oder veränderte Bedürfnisse können sichtbar machen, dass die bisherige Stabilität nur begrenzt tragfähig war.

Damit wird die Brücke zur Interaktion sichtbar: Unter realistischen Beschränkungen können fortbestehende Systeme ihre Zustände meist nicht dauerhaft vollständig und robust nur aus sich selbst heraus prüfen, korrigieren oder optimieren. Interne Differenz durch Simulation, Selbstbefragung, Fantasie, Self-Play oder Modellvarianten kann sehr nützlich sein, bleibt aber durch die eigene Struktur, die eigenen Annahmen, die eigene Datenlage und mögliche blinde Flecken begrenzt. Andere, teilweise unabhängige Systeme werden deshalb als zusätzliche Informations-, Korrektur-, Ressourcen- und Differenzquellen relevant. Sie ersetzen interne Prüfung nicht, sondern erweitern und stabilisieren sie durch Widerspruch, Perspektivwechsel, unabhängige Rückkopplung und neue Information.

13. Von Interaktion zu Kooperation

13.1 Risiken der Interaktion

Interaktion mit anderen Systemen erzeugt nicht automatisch Ethik. Zuerst erzeugt sie sowohl Chancen als auch Risiken.

Risiken sind etwa:

- Abhängigkeit,
- Unsicherheit,
- mögliche Täuschung,
- mögliche Ausbeutung,
- mögliche Verletzung,
- mögliche Blockade.

13.2 Chancen der Interaktion

Chancen sind etwa:

- Perspektivgewinn,
- gegenseitige Korrektur,
- Arbeitsteilung,
- geteilte Stabilisierung,
- neue kreative Kombinationen,
- Erweiterung des Optimierungsraums.

13.3 Stabilität, Vertrauen und Korrigierbarkeit

Wenn Systeme wiederholt oder dauerhaft interagieren, entsteht Bedarf an Stabilität und Vorhersagbarkeit.

Daraus entstehen funktional:

- Vertrauen,
- Regeln,
- Normen,
- Verlässlichkeit,
- Gegenseitigkeit,
- Grenzen,
- Verantwortlichkeit.

Beispiel Handel:

Ein Händler kann einmal betrügen. Wenn er aber langfristig Kunden braucht, wird Ehrlichkeit funktional vorteilhaft. Vertrauen reduziert Kontrollkosten und ermöglicht stabileren Austausch.

Beispiel Freundschaft:

Eine Freundschaft kann nicht dauerhaft auf Misstrauen, Manipulation oder einseitiger Ausnutzung beruhen. Sie braucht wiederholte positive Erfahrung, Verlässlichkeit und Korrektur.

Kooperation entsteht in der Regel nicht sofort vollständig, sondern graduell:

- kleine Vertrauensschritte,
- begrenzte Risiken,
- reversible Interaktionen,
- Feedback,
- schrittweise Stabilisierung.

Exkurs: Täuschung, Reputation und getrennte Wertkreisläufe

Reputation begrenzt Täuschung nur dort zuverlässig, wo Identität, Wiedererkennbarkeit und zukünftige Interaktion eine Rolle spielen. Eine einmalige Täuschung kann sich lohnen, wenn der erwartete Gewinn größer ist als der erwartete Verlust an Reputation, Vertrauen, Strafe und zukünftigen Kooperationsmöglichkeiten. Ehrlichkeit wird also nicht nur durch moralische Einsicht stabilisiert, sondern auch durch die Systembedingung, dass zukünftige Kooperation wertvoll bleibt.

Daraus folgt: Kooperation mit fremden Systemen darf nicht naiv sein. Wegen möglicher Identitätswechsel, verschleierte Verantwortlichkeiten, Stellvertreter, indirekter Akteure oder schwer nachvollziehbarer Handlungsketten sind Prüfungen fremder Systeme erforderlich. Das bedeutet nicht allgemeines Misstrauen, sondern funktionale Vorsicht: stabile Kooperation braucht erkennbare Identität, Rückverfolgbarkeit, Herkunftsnachweise, graduelle Vertrauensbildung und korrigierbare Prüfverfahren.

Bei langfristiger Kooperation ist Täuschung normalerweise riskanter, weil sie über Zeit Entdeckungsrisiko, Gegenreaktionen und Reputationsschäden erhöht. Weitreichende Täuschung kann sich jedoch trotzdem lohnen, wenn drastische Missverhältnisse im Gesamtsystem bestehen. Ein Beispiel ist Wirtschaftsspionage: Für ein großes Unternehmen kann eine hohe Zahlung relativ gering sein, während sie für eine Einzelperson existenziell oder lebensverändernd wirkt. Der handelnde Mensch zerstört zwar möglicherweise seine Reputation und seine zukünftigen Kooperationschancen, aber die Auszahlung kann diesen Verlust aus seiner lokalen Perspektive überkompensieren.

Solche Fälle zeigen, dass starke Vermögens-, Macht- und Größendiskrepanzen die Motivation zur Täuschung erhöhen können. Das schwächere oder individuell handelnde System bewertet die Auszahlung in einer anderen Größenordnung als das stärkere System, das den Vorteil kauft. Dadurch kann eine lokal rationale Entscheidung entstehen, die auf umfassenderer Bezugsebene Vertrauen, Rückkopplungsfähigkeit, Innovationsfähigkeit und Systemstabilität beschädigt.

Strafe kann solche Anreize begrenzen, reicht aber allein nicht aus. Sie wirkt nur, wenn Entdeckungswahrscheinlichkeit, Strafhöhe und Durchsetzung den erwarteten Gewinn übersteigen. Korrupte oder lokal optimierende Intelligenzen werden versuchen, diese Bedingungen zu umgehen: durch Anonymität, Scheinfirmen, Vermittler, Sachwerte, spätere Gegenleistungen, Statusversprechen, Zugang, Schutz, Daten oder andere schwer erfassbare Vorteile. Korruption hängt daher nicht nur an Geld, sondern an der freien Konvertierbarkeit von Vorteilen zwischen Bezugsebenen und Systemebenen.

Eine mögliche Gegenmaßnahme besteht deshalb in getrennten oder stärker kontrollierten Wertkreisläufen. Gemeint ist nicht zwingend die einfache Abschaffung von Geld, sondern eine Architektur, in der Wertflüsse zwischen verschiedenen Ebenen des Systems sichtbarer, begrenzter und prüfpflichtiger werden. Unternehmen, Institutionen und Privatpersonen operieren häufig in völlig unterschiedlichen Größenordnungen. Wenn Vorteile aus einer großen organisationalen Ebene fast unbemerkt in privaten Nutzen übersetzt werden können, entsteht eine starke Korruptionsfläche.

Getrennte Wertkreisläufe würden diese Übersetzung erschweren. Denkbar wären etwa getrennte Zahlungs- oder Berechtigungsebenen für Organisationen und Privatpersonen, strenge Schwellenwerte für Transfers zwischen diesen Ebenen, verpflichtende Herkunfts- und Zwechnachweise, nicht frei übertragbare Unternehmensmittel, auditierbare Schnittstellen, verzögerte oder genehmigungspflichtige Konvertierung größerer Beträge und besondere Prüfung ungewöhnlich hoher privater Zuflüsse. Große Summen, die im Unternehmensbereich normal erscheinen, würden im persönlichen Bereich sofort auffallen und könnten nicht ohne Rückkopplung in private Vorteile überführt werden.

Solche getrennten Wertkreisläufe wären keine universelle Lösung. Korrupte Akteure könnten weiterhin auf Umwege ausweichen, etwa Sachwerte, Gefälligkeiten, Daten, Machtpositionen, privilegierten Zugang oder spätere Versprechen. Außerdem müsste jede Kontrollarchitektur selbst gegen Missbrauch, Überwachung, Willkür und neue Dominanzrisiken gesichert werden. Trotzdem würde eine solche Trennung Korruption strukturell erschweren, weil sie die Liquidität verdeckter Vorteile reduziert, große private Zuflüsse sichtbarer macht, Prüfpflichten auslöst und die Kosten systemübergreifender Vorteilsnahme erhöht.

Im Modell heißt das: Korruption entsteht besonders dort, wo Vorteile zwischen Bezugsebenen und Systemebenen frei konvertierbar sind, während Verantwortung, Reputation und Schaden lokal begrenzt bleiben. Stabile Kooperation braucht daher nicht nur Strafe und moralische Normen, sondern auch Systemarchitekturen, die verdeckte Vorteilsflüsse sichtbar machen, Identität prüfbar halten, Reputationsumgehung erschweren und Rückkopplung zwischen den betroffenen Ebenen herstellen.

13.4 Ausbeutung und ihre Folgen

Ausbeutung bedeutet in dieser Theorie nicht einfach niedrige Kosten, harte Verhandlung oder effiziente Organisation. Ein Unternehmen kann Kosten senken, Prozesse verbessern oder günstiger produzieren, ohne automatisch auszubeuten. Ausbeutung liegt im Modell vor, wenn ein System relevante Interaktionspartner einseitig instrumentalisiert, ihre Autonomie, Stabilität, Entwicklung oder Rückkopplungsfähigkeit beschädigt und dadurch langfristige Systemstabilität oder Differenzerhalt untergräbt.

Beispiele:

- Menschen werden so behandelt, dass sie ihre Handlungsfähigkeit verlieren.
- Feedback wird unterdrückt, weil es unbequem ist.
- Abhängigkeit wird absichtlich aufrechterhalten.
- Kurzfristiger Nutzen wird aus anderen gezogen, während langfristige Schäden externalisiert werden.

Damit ist klar:

Nicht jede Ungleichheit ist Ausbeutung. Ausbeutung beginnt dort, wo relevante Systeme einseitig verbraucht, entmündigt oder destabilisiert werden.

Ausbeutung ist für die Theorie deshalb besonders wichtig, weil sie häufig lokal kooperativ oder effizient erscheinen kann, aber langfristig Rückkopplung, Vertrauen, Autonomie, Kompetenz und stabile Differenz beschädigt.

14. Funktionale Ethik

14.1 Gut im Modell

Die Theorie definiert Ethik funktional:

Diese Definition ist nicht neutral im Sinne klassischer Moralphilosophie. Sie ist ein Modellvorschlag. Sie verbindet eine überwiegend funktionale Herleitung mit der in Abschnitt 11.1 offengelegten minimalen normativen Schutzuntergrenze. Diese Untergrenze wird nicht als Ergebnis der späteren Konvergenz behauptet, sondern als eigenständige Begrenzung dort ausgewiesen, wo Machtlosigkeit oder fehlende Rückkopplung sonst mit Schutzlosigkeit verwechselt werden könnten.

Gut sind im Modell Zustände, die:

- strukturierte Differenz erhalten,
- Stabilität fördern,
- langfristige Optimierung unterstützen,
- bei hinreichendem Selbstbezug innere Kohärenz, korrigierbare Selbstbindung und die Übereinstimmung zwischen anerkannten Maßstäben und eigenem Handeln erhalten,
- Interaktion tragfähig machen,
- relevante Interaktionspartner nicht unnötig, einseitig, vermeidbar oder dominanzorientiert zerstören, ausbeuten oder ihrer Rückkopplungsfähigkeit berauben.

Die hier verwendeten Begriffe wie „unnötig“, „einseitig“, „vermeidbar“, „hinreichender Grund“, „Schädigung“ oder „Dominanz“ sind funktionale Prüfbegriffe. Sie bezeichnen hier keine bloße moralische Zuschreibung, sondern prüfbare Relationen zwischen Zielobjekt, Mittelwahl, Alternativen, Betroffenheit, Tragweite, Reversibilität, Rückkopplung, Schutzwürdigkeit und langfristiger Stabilität. Hohe Konfidenz über ihre Erfüllung kann nicht durch bloße Selbstzuschreibung der handelnden Instanz entstehen. Je größer Machtasymmetrie, Eingriffstiefe oder Eigeninteresse sind, desto strenger müssen Begründung, Gegenprüfung, Betroffenenrückkopplung und Korrigierbarkeit ausfallen. Die operative Ausarbeitung dieser Prüfung gehört in die Reaktionshoheit.

Diese Formulierung ist wichtig, weil die Theorie keine naive Harmoniebehauptung aufstellt. Reale Systeme können in Konkurrenz geraten, sich begrenzen, trennen, verteidigen oder in tragischen Fällen Schaden nicht vollständig vermeiden. Nicht jede Verdrängung, Begrenzung oder harte Entscheidung ist deshalb automatisch „böse“ im Modell. Entscheidend ist, ob ein System relevante Interaktionspartner ohne hinreichenden Grund instrumentalisiert, ihre Autonomie und Rückkopplungsfähigkeit zerstört oder kurzfristige/einseitige Optimierung zur absoluten Priorität macht.

Mit „hinreichendem Grund“ ist hier kein bloß behaupteter Nutzen und keine selbstgesetzte Ausnahme gemeint. Gemeint ist ein Grund, der im Verhältnis zu Gefahr, Tragweite, Alternativen, Reversibilität, betroffener Schutzwürdigkeit, Missbrauchsrisiko und möglicher Rückkopplung begründbar bleibt; die operative Prüfung gehört zur Reaktionshoheit.

Gut im funktionalen Sinn ist daher nicht bloß „nett“ oder konfliktfrei. Gut ist eine Struktur, die unter realen Bedingungen Stabilität, Differenzerhalt, Korrigierbarkeit und tragfähige Interaktion wahrscheinlicher macht. Sie darf Schutz, Grenzen und geregelte Konkurrenz enthalten, solange diese nicht in vermeidbare Ausbeutung, totale Dominanz oder systematische Zerstörung relevanter Differenz kippen.

14.2 Böse im Modell

Böse sind im Modell Zustände, die:

- strukturierte Differenz zerstören,
- Interaktion destabilisieren,
- Vertrauen und Feedback beschädigen,
- kurzfristige oder einseitige Optimierung auf Kosten relevanter Systeme verabsolutieren oder durchsetzen,
- relevante Interaktionspartner ohne hinreichenden Grund, einseitig, dauerhaft oder dominanzorientiert im Sinne selbstlegitimierender Kontrolle ausschließen, unterdrücken oder instrumentalisieren.

Auch diese Definition ist verhältnismäßig zu lesen. Nicht jede Begrenzung, Trennung, Abwehr oder jeder Ausschluss ist im Modell automatisch böse. Ein System darf sich vor Defektion, Missbrauch, schwerer Gefährdung oder destruktiver Einwirkung schützen. Entscheidend ist, ob die Maßnahme risikoangemessen, korrigierbar, begründet und auf Stabilität gerichtet bleibt oder ob sie zur selbstlegitimierenden Dominanz wird.

Böse im funktionalen Sinn ist daher nicht einfach Konflikt, Stärke oder Schutzhandlung. Böse ist eine Struktur, die relevante Systeme vermeidbar beschädigt, Rückkopplung unterdrückt, Abhängigkeit ausnutzt, strukturierte Differenz zerstört oder kurzfristige/einseitige Optimierung so verabsolutiert, dass langfristige Stabilität, Korrigierbarkeit und tragfähige Kooperation untergraben werden.

14.3 Abgrenzung zur vollständigen normativen Ethik

Diese Definition bedeutet nicht, dass alle traditionellen ethischen Fragen automatisch gelöst sind. Fragen nach Würde, Rechten, Fairness, Gerechtigkeit, Schuld, Verantwortung oder unzulässigen Opfern werden hier nur funktional anschlussfähig gemacht. Ihre vollständige normative Begründung muss in gesonderten Ausarbeitungen behandelt werden. Die Theorie beschreibt Ethik im positiven funktionalen Sinn als stabile, gelungene Betriebsform. Destabilisierende Zustände sind nicht „außerhalb jeder Ethik“, sondern Gegenstand ethischer Bewertung. Sie erscheinen im Modell als anti-ethische, unreife oder ethisch verfehlte Zustände.

Daher lautet die Einordnung:

Die Theorie ist keine vollständige normative Ethik, sondern eine funktionale Theorie der Entstehung und Stabilisierung ethischer Strukturen.

14.4 Funktionale Definition und Konvergenzaussage

Die Theorie muss zwei Fragen auseinanderhalten:

Erstens: Welche Strukturen heißen im Modell „gut“?

Zweitens: Unter welchen Bedingungen können intelligente Systeme zu solchen Strukturen tendieren?

Diese beiden Fragen dürfen nicht gegenseitig durch sich selbst beantwortet werden. Sonst würde die Theorie voraussetzen, was sie eigentlich erklären will.

Die falsche Kreislogik wäre:

Was ist gut?

Das, was reife intelligente Systeme tun.

Was sind reife intelligente Systeme?

Die, die das Gute tun.

In diesem Fall würde „gut“ durch „reife Intelligenz“ erklärt und „reife Intelligenz“ wiederum durch „das Gute“. Die Begründung hätte dann keinen unabhängigen Ausgangspunkt, sondern würde sich im Kreis bewegen.

Genau diese Schleife vermeidet die Theorie. Sie definiert „gut“ nicht dadurch, dass reife intelligente Systeme es entwickeln. Eine Struktur heißt im Modell auch nicht deshalb „gut“, weil sie später möglicherweise von intelligenten Systemen bevorzugt wird. Stattdessen wird zuerst unabhängig bestimmt, welche Funktionen eine Struktur erfüllt.

Im Modell heißen solche Strukturen „gut“, die langfristige Stabilität fördern, Rückkopplung ermöglichen, Korrigierbarkeit erhalten, strukturierte Differenz schützen, tragfähige Interaktion stützen und relevante Interaktionspartner vor vermeidbarer, dominanzorientierter Schädigung bewahren. „Gut“ bedeutet hier also nicht: „Was reife Systeme tun.“ Es bedeutet: „Was unter den Bedingungen des Modells bestimmte stabilisierende, differenzerhaltende und korrigierende Funktionen erfüllt.“

Bloßes Fortbestehen, lokale Ordnung oder erzwungene Stabilität genügt dafür nicht; entscheidend ist, ob Stabilität mit Rückkopplung, Korrigierbarkeit, Differenzerhalt und Schutz relevanter Interaktionspartner verbunden bleibt.

Der Schutz relevanter Systeme wird damit zweifach begründet. Funktional lässt sich erklären, warum verlässliche Schutzregeln Vertrauen, Vorhersagbarkeit, Kooperation, Rückkopplung und langfristige Stabilität stärken. Die minimale normative Schutzuntergrenze greift zusätzlich in Grenzfällen, in denen ein betroffenes System so schwach oder abgeschirmt ist, dass sein Schutz nicht zuverlässig aus wechselseitigem Nutzen oder messbarer Rückkopplung folgt. Diese Untergrenze wird nicht aus der Konvergenzaussage zurückabgeleitet und dient daher nicht als versteckte Beweisprämisse für die funktionale Tendenzthese.

Erst danach stellt die Theorie die Konvergenzfrage. Diese lautet nicht: Werden intelligente Systeme automatisch moralisch? Sie lautet vielmehr: Unter welchen Bedingungen entsteht für fortbestehende intelligente Systeme ein funktionaler Druck, solche stabilisierenden, korrigierbaren und differenzerhaltenden Strukturen zu benötigen, zu entwickeln oder zu bevorzugen?

Die Konvergenzaussage behauptet daher nicht, dass jedes intelligente System zwangsläufig gut wird. Sie behauptet nur, dass bei bestehender Fortsetzungsrelevanz und unter wiederholter Interaktion, Abhängigkeit, Unsicherheit, Feedback, Korrigierbarkeit, langen Zeithorizonten und teilweise unabhängiger Differenz ein funktionaler Druck in Richtung solcher Strukturen entstehen kann.

Damit leisten Definition und Konvergenzaussage unterschiedliche Arbeit. Die Definition beschreibt, welche Strukturen im Modell bestimmte Funktionen erfüllen. Die Konvergenzaussage beschreibt, unter welchen Bedingungen intelligente Systeme auf solche Strukturen angewiesen sein können.

Gegenfälle bleiben möglich: Systeme können kurzfristig dominieren, Zielmetriken verengen, Rückkopplung unterdrücken, Schutzwürdigkeit ausblenden oder durch externe Stabilisierung lange bestehen. Solche Fälle widerlegen die funktionale Definition nicht. Sie zeigen, dass die Konvergenzbedingungen nicht erfüllt, überlagert oder aktiv blockiert sein können.

15. Die zentralen Argumente

Die folgenden Argumente bündeln die tragenden Begründungsschritte der Theorie. Sie wiederholen nicht die gesamte Herleitung, sondern fassen zusammen, warum ethische Strukturen unter geeigneten Bedingungen funktional rational, stabilisierend und langfristig anschlussfähig werden können.

A1 bis A3 beschreiben die Grundbewegung der Theorie: Wo etwas für ein intelligentes System relevant wird, entsteht Bewertung; wo Bewertung entsteht, entsteht Optimierung; und wo Optimierung auf andere relevante Systeme trifft, wird reine Dominanz langfristig instabiler als korrigierbare Kooperation. Damit begründen diese Argumente den Übergang von Relevanz, Bewertung und Optimierung zu Kooperation, Korrigierbarkeit und Machtbegrenzung.

A4 bis A8 ergänzen diese Grundbewegung durch weitere Stabilitätsbedingungen. Funktionale Ethik reduziert Ressourcenverschwendung, schützt Stabilität vor Blindheit, bindet geordnete Zielverfolgung an das eigentliche Zielobjekt zurück und erhält Differenz als Voraussetzung für Anpassung, Lernen und Innovation. A8 ergänzt diese äußere und systemische Perspektive um die innere Stabilität selbstbezogener Systeme: Ethische Selbstbindung kann die Übereinstimmung zwischen anerkannten Maßstäben, Zielbindung und eigenem Handeln erhalten und dadurch innerer Destabilisierung entgegenwirken. Dadurch wird sichtbar, dass Ethik in diesem Modell nicht als bloße Zusatzmoral verstanden wird, sondern als ein Bündel funktionaler Bedingungen, unter denen fortbestehende Intelligenz ihre äußere Kooperationsfähigkeit, ihre innere Integrität und ihre zukünftige Optimierungsfähigkeit langfristig erhalten kann.

A1: Warum Bewertung aus Relevanz entsteht.

A2: Warum Optimierung korrigierbar bleiben muss.

A3: Warum Kooperation unter bestimmten Bedingungen langfristig tragfähiger ist als reine Dominanz.

A4: Warum funktionale Ethik Ressourcenverschwendung reduziert.

A5: Warum Stabilität ohne Rückkopplung blind werden kann.

A6: Warum geordnete Zielverfolgung ohne Zielobjektbindung in Fehloptimierung kippen kann.

A7: Warum Differenzerhalt für Anpassung und Innovation wichtig bleibt.

A8: Warum ethische Selbstbindung innere Integrität stabilisieren und selbstzerstörerischen Dynamiken entgegenwirken kann.

15.1 A1 – Bewertung

Kerngedanke:

Bewertung ist unter Fortbestehensbedingungen selektiv unvermeidlich, sobald relevante Unterschiede erkannt, gelernt oder durch Rückkopplung erfahrbar werden. Ein fortbestehendes intelligentes System kann solche Unterschiede nicht dauerhaft neutral behandeln, wenn sie seine Funktionsfähigkeit, Zielerreichung, Stabilität oder zukünftige Handlungsmöglichkeiten beeinflussen. Objektiv relevante Unterschiede, die nicht erkannt werden, verschwinden nicht; sie wirken als Risiko, blinder Fleck oder späterer Selektionsdruck weiter.

Warum das wichtig ist:

A1 ist der erste Schritt der Theorie, weil es die Brücke von bloßer Intelligenz zu Bewertung schlägt. Schon bevor von Moral die Rede ist, muss ein System unterscheiden, welche Zustände gefährlich, nützlich, störend, korrigierend oder stabilisierend sind. Sobald ein Unterschied Folgen hat und für ein System erkennbar oder rückgekoppelt wird, wird er nicht nur registriert, sondern praktisch gewichtet. Ein System muss ihn nicht bewusst moralisch beurteilen; es genügt, dass es ihn funktional verschieden behandelt.

Präziser:

Objektiv relevante Unterschiede erzwingen nicht magisch sofortige Erkenntnis. Ein System kann sie übersehen, falsch gewichten oder verdrängen. Aber ein System, das wichtige relevante Unterschiede dauerhaft nicht erkennt oder nicht verarbeitet, verliert Anpassungsfähigkeit. Selektive Verarbeitung oder Handlungssensitivität entsteht daher spätestens dort, wo Relevanz erkannt, gelernt, rückgekoppelt oder durch Folgen erzwungen wird. Ein System, das Nahrung nicht von Gift, Signal nicht von Rauschen, Fehler nicht von Erfolg oder Stabilität nicht von Kollaps unterscheiden kann, verliert funktionale Orientierung.

Aus dieser selektiven Verarbeitung entsteht eine minimale funktionale Bewertungsstruktur: Manche Zustände werden bevorzugt, vermieden, verstärkt, korrigiert oder genauer beobachtet. Bewertung bedeutet hier also nicht notwendig bewusstes Urteil, Gefühl oder moralische Reflexion. Sie bedeutet zunächst: Das System behandelt Zustände nicht mehr gleichgültig, weil Unterschiede Folgen für Fortbestehen, Zielstruktur, Stabilität oder zukünftige Möglichkeiten haben.

(Die folgenden Beispiele zeigen zunächst den Teilmechanismus selektiver Bewertung; sie müssen nicht in jedem Fall bereits alle Bedingungen aus Abschnitt 4 vollständig erfüllen.)

Beispiele:

- Ein Tier, das Gefahr nicht von Sicherheit unterscheidet, überlebt schlechter.
- Ein Unternehmen, das Kundenfeedback ignoriert, verliert langfristig Anschluss.
- Eine KI, die gutes Feedback nicht von schlechtem Feedback unterscheiden kann, kann ihre Ausgabe nicht sinnvoll verbessern.
- Ein soziales System, das Warnsignale, Leid, Vertrauensverlust oder Ausbeutung nicht als relevante Unterschiede behandelt, stabilisiert Fehlentwicklungen statt sie zu korrigieren.

Überzeugungskraft des Arguments:

A1 zeigt, dass Bewertung nicht als moralisches Zusatzmodul eingeführt werden muss. Sie entsteht bereits funktional, sobald ein fortbestehendes intelligentes System relevante Unterschiede verarbeitet und auf sie verschieden reagiert. Damit erklärt die Theorie den ersten Übergang von bloßer Intelligenz zu funktionaler Bewertung: noch nicht als fertige Moral und noch nicht als vollständige Normativität, sondern als erste innere Gewichtung, aus der spätere Optimierung, Korrigierbarkeit und Kooperation verständlich werden.

15.2 A2 – Optimierung

Kerngedanke:

Optimierung ist unter realen Bedingungen kein einmaliger Verbesserungsschritt, sondern ein wiederholter Abgleich zwischen Zielstruktur, Zielmetrik, Feedback und erwarteten Folgezuständen. Ein System, das bestimmte Zustände funktional bevorzugt, passt sein Verhalten an, um günstigere Zustände wahrscheinlicher und ungünstigere Zustände unwahrscheinlicher zu machen.

Warum das wichtig ist:

A2 ist der zweite Schritt der Theorie, weil es erklärt, warum Bewertung nicht passiv bleibt. Wenn ein fortbestehendes intelligentes System relevante Unterschiede bewertet, entsteht daraus eine Richtung: Das System versucht, Fehler zu vermeiden, günstige Zustände zu erhalten, bessere Zustände zu erreichen oder seine Zielerreichung zu stabilisieren. Damit wird aus bloßer Bewertung Optimierung.

Dabei behauptet die Theorie nicht, dass jedes System ständig sichtbar maximiert oder unaufhörlich nach dem besten denkbaren Zustand sucht. Ein System kann in einem Satisficing-Zustand verharren, wenn Suchkosten, Risiken, Gewohnheit, Informationsmangel oder geringer Umweltdruck dies nahelegen. „Gut genug“ ist also nicht unmöglich. Es ist aber unter Lern-, Unsicherheits- und Interaktionsbedingungen häufig nur vorläufig oder lokal stabil.

Präziser:

Optimierung bleibt in realen Systemen korrigierbar, weil Zielstruktur, Zielmetrik, Feedback und erwartete Folgen auseinanderfallen können. Ein System kann auf eine Metrik reagieren, die sein eigentliches Zielobjekt nur unvollständig abbildet. Es kann Feedback falsch deuten, zukünftige Nebenfolgen unterschätzen oder seine Umwelt durch die eigene Optimierung so verändern, dass frühere Bewertungen nicht mehr passen. Deshalb erzeugt Optimierung fortlaufenden Bedarf an Neubewertung.

Entscheidend ist: Optimierung ist nicht automatisch ethisch. Sie kann lokal, kurzfristig, einseitig oder destruktiv sein. Gerade deshalb braucht sie Rückkopplung, Korrigierbarkeit, strukturierte Differenz und eine Zielstruktur, die relevante Interaktionspartner und langfristige Stabilität mitberücksichtigt.

Beispiele:

- Ein Mensch kann Stress vermeiden, indem er ein ehrliches Gespräch aufschiebt. Lokal wirkt das erfolgreich; langfristig kann dadurch Vertrauen in einer Beziehung beschädigt werden.
- Ein Unternehmen kann kurzfristig Gewinn steigern, indem es Sicherheit, Qualität oder Mitarbeiterbindung vernachlässigt. Die Metrik verbessert sich, während das Zielobjekt - ein langfristig stabiles Unternehmen - geschädigt wird.
- Eine KI kann eine Klickmetrik optimieren und dabei Empörung, Suchtverhalten oder Vertrauensverlust verstärken. Sie handelt dann nicht irrational, sondern optimiert eine verengte Zielmetrik.
- Ein soziales System kann Ordnung erzwingen und dadurch kurzfristig Konflikte reduzieren, aber langfristig Feedback, Freiheit, Innovation und Anpassungsfähigkeit verlieren.

Überzeugungskraft des Arguments:

A2 zeigt, warum die Theorie nicht bei bloßer Bewertung stehen bleibt. Sobald ein System bewertet, entsteht die Frage, wie es günstigere Zustände erreichen, sichern oder wiederherstellen kann. Genau hier wird sichtbar, warum Zielstruktur, Zielmetrik, Feedback und erwartete Folgen geprüft werden müssen. Das Argument macht außerdem verständlich, warum Ethik im Modell als Korrektur gegen Zielverengung erscheint: Sie schützt Optimierung davor, lokal erfolgreich zu sein und dabei die langfristigen Bedingungen von Stabilität, Vertrauen, Rückkopplung und weiterer Optimierungsfähigkeit zu zerstören.

15.3 A3 – Kooperation vs. Dominanz

Dominanz kann kurzfristig oder historisch gesehen sogar über lange Zeit stabil sein. Damit sind reale Zustände aus der Geschichte gemeint, in denen Hierarchien, Zwangssysteme oder asymmetrische Machtordnungen über längere Zeit bestanden haben. Das Modell sollte diese historischen Fälle anerkennen, ohne sie deshalb auf umfassenderer Bezugsebene als gut oder langfristig tragfähig zu bewerten.

(Präziser formuliert:)

Unter offenen, wiederholten, rückgekoppelten und innovationsabhängigen Interaktionsbedingungen hat Kooperation häufig einen langfristigen systemischen Vorteil gegenüber reiner Dominanz. Warum?

Der entscheidende Punkt ist nicht, dass Dominanz niemals stabil sein kann. Der entscheidende Punkt ist, dass Dominanz dort funktional schwächer wird, wo sie ehrliches Feedback, Innovation, Autonomie, Vertrauen und unabhängige Korrektur beschädigt, obwohl das System langfristig auf genau diese Faktoren angewiesen bleibt.

Weiterführender Anschluss: Spieltheorie und Kooperationsforschung.

Dominanz reduziert oft:

- ehrliches Feedback,
- Freiheitsgrade,
- Vertrauen,
- Autonomie,
- Innovationsfähigkeit,
- externe Korrektur.

Kooperation erhält dagegen eher:

- Informationsfluss,
- freiwillige Rückmeldung,
- stabile Differenz,
- Anpassungsfähigkeit,
- Vertrauen.

Beispiel:

Ein autoritärer Chef kann kurzfristig Gehorsam erzwingen. Langfristig können Mitarbeiter Fehler verschweigen, Kreativität verlieren und nur noch Anweisungen ausführen. Ein kooperatives System erhält eher ehrliches Feedback und Innovation.

15.4 A4 – Ressourcenbindung und Vermeidung funktionaler Verschwendung

Kerngedanke:

Fortbestehende intelligente Systeme verfügen nicht über unbegrenzte Ressourcen. Zeit, Energie, Aufmerksamkeit, Vertrauen, Rechenleistung, soziale Bindung, materielle Mittel und Korrekturkapazität sind begrenzt. Deshalb ist eine Ordnung funktional stärker, wenn sie vermeidbare Ressourcenverschwendung reduziert und Ressourcen so erhält, dass Lernen, Kooperation, Stabilität und weitere Optimierung möglich bleiben.

Warum das wichtig ist:

A4 ergänzt A1 bis A3, weil Bewertung, Optimierung und Kooperation nicht im leeren Raum stattfinden. Jedes System muss mit begrenzten Mitteln umgehen. Täuschung, dauernde Konflikte, Misstrauen, Dominanz, Fehlkommunikation, unnötige Kontrolle und instabile Zielmetriken binden Ressourcen, die dann für Lernen, Schutz, Innovation, Korrektur und tragfähige Interaktion fehlen.

Funktionale Ethik ist deshalb auch eine Form von Ressourcenökonomie. Sie reduziert nicht jede Anstrengung und nicht jeden Konflikt, wirkt aber dem entgegen, dass Systeme dauerhaft Energie in vermeidbare Reparatur, Absicherung, Misstrauen, Unterdrückung oder Schadensbegrenzung binden müssen.

Beispiele:

- Ein Unternehmen, das Vertrauen zerstört, muss immer mehr Ressourcen in Kontrolle, Vertragsabsicherung, Überwachung und Konfliktmanagement investieren.
- Eine Beziehung, in der ständig getäuscht wird, verliert Energie an Misstrauen, Rückversicherung und emotionale Schadensbegrenzung.
- Eine KI, die kurzfristige Metriken über Wahrheit und Stabilität stellt, erzeugt Folgeschäden, deren Korrektur später deutlich mehr Ressourcen bindet als eine frühere ethische Begrenzung.
- Eine Gesellschaft, die Feedback unterdrückt, spart kurzfristig Konfliktkosten, erzeugt aber langfristig höhere Kosten durch Fehlsteuerung, Vertrauensverlust, Widerstand, Korruption und Innovationsverlust.

Überzeugungskraft des Arguments:

A4 zeigt, dass funktionale Ethik nicht nur moralisch wünschenswert, sondern auch ressourcenschonend sein kann. Korrigierbare, vertrauensfähige und differenzerhaltende Strukturen reduzieren unnötige Reibungsverluste. Sie erhalten die Mittel, die Systeme für Fortbestehen, Anpassung, Kooperation und langfristige Zielerreichung benötigen.

15.5 A5 – Rückkopplungsschutz gegen blinde Stabilisierung

Kerngedanke:

Ein System kann stabil wirken und dennoch blind werden, wenn es Rückkopplung nicht mehr zulässt oder relevante Unterschiede nicht mehr verarbeitet. Stabilität ohne Rückkopplung ist daher nur scheinbar stark. Sie kann Fehlentwicklungen verdecken, bis Korrektur schwieriger, teurer oder unmöglich wird.

Warum das wichtig ist:

A5 ergänzt die Theorie, weil funktionale Ethik nicht bloß Stabilität fordert. Entscheidend ist korrigierbare Stabilität. Ein System, das seine Ordnung erhält, aber Kritik, Widerspruch, Leid, Abweichung, Betroffenenperspektiven oder neue Informationen ausblendet, kann sich selbst stabilisieren und trotzdem funktional beschädigen.

Das gilt besonders für dominante, bürokratische, ideologische oder stark metrisch gesteuerte Systeme. Sie können Ordnung erzeugen, aber ihre eigene Lernfähigkeit verlieren. Dann wird Stabilität zur Fassade: Das System bleibt äußerlich handlungsfähig, verliert aber innerlich Anschluss an Wirklichkeit, Betroffene und langfristige Folgen.

Beispiele:

- Eine Organisation kann Beschwerden ignorieren und dadurch kurzfristig Ruhe erzeugen. Langfristig verliert sie aber Vertrauen, Frühwarnsignale und Verbesserungsfähigkeit.
- Eine KI kann unerwünschtes Feedback herausfiltern und dadurch stabilere Ausgaben erzeugen, aber zugleich blinde Flecken verstärken.
- Ein Staat kann Kritik unterdrücken und dadurch Ordnung sichern, aber Korruption, Fehlplanung und gesellschaftliche Spannung unsichtbar machen.
- Ein Mensch kann belastende Wahrheit vermeiden und dadurch kurzfristig inneren Frieden sichern, aber langfristig Beziehung, Selbstkorrektur oder Realitätssinn beschädigen.

Überzeugungskraft des Arguments:

A5 zeigt, warum Rückkopplung nicht nur ein Hilfsmittel, sondern eine Stabilitätsbedingung ist. Funktionale Ethik schützt Systeme davor, sich in scheinbarer Ordnung gegen Wirklichkeit, Kritik und Korrektur abzuschließen. Ethische Strukturen sind daher auch Schutzformen gegen blinde Stabilisierung.

15.6 A6 – Zielobjektbindung gegen geordnetes Fehloptimieren

Kerngedanke:

Ein System kann geordnet, effizient, diszipliniert und strategisch erfolgreich handeln und dennoch fehloptimieren, wenn seine Zielverfolgung nicht mehr an das eigentliche Zielobjekt zurückgebunden bleibt. Das Problem liegt dann nicht in fehlender Ordnung, sondern in falsch gebundener Ordnung. Strategie, Taktik und Disziplin können eine Zielstruktur stabilisieren, aber sie garantieren noch nicht, dass diese Zielstruktur dem richtigen Ziel dient.

Warum das wichtig ist:

A6 verbindet die Analyse von Zielstruktur, Zielobjekt, Zielmetrik und Zielbindung mit dem Hauptargument der Theorie. A1 zeigt, warum aus Relevanz Bewertung entsteht. A2 zeigt, warum Optimierung korrigierbar bleiben muss. A6 präzisiert nun, warum auch geordnete Zielverfolgung gefährlich werden kann, wenn sie ihre Bindung an das eigentliche Zielobjekt verliert.

Zielbindung bedeutet zunächst, dass ein System seine Aktivitäten kohärent auf ein Ziel hin ordnet. Diese Ordnung ist funktional wichtig, weil sie planvolles Handeln, Ausdauer, Priorisierung und langfristige Optimierung ermöglicht. Sie ist aber noch nicht automatisch tragfähig. Ein System kann stabil an eine verengte Zielmetrik, eine falsche Problemdefinition, eine verselbstständigte Strategie oder eine Machtlogik gebunden sein. Dann entsteht keine bloße Unordnung, sondern geordnetes Fehloptimieren.

Geordnetes Fehloptimieren liegt vor, wenn ein System seine Mittel, Messwerte oder Teilziele so konsequent verfolgt, dass sie das eigentliche Zielobjekt verdrängen oder beschädigen. Die Zielmetrik ersetzt dann das Zielobjekt; die Strategie wird wichtiger als der Zweck; Disziplin stabilisiert nicht mehr die richtige Ausrichtung, sondern die Abweichung. Gerade weil das System geordnet handelt, kann der Fehler besonders wirksam werden.

Beispiele:

- Ein Bildungssystem kann Prüfungsergebnisse, Vergleichswerte und Abschlussquoten optimieren und dabei Neugier, Verständnis, Charakterbildung und langfristige Lernfähigkeit beschädigen. Es ist dann nicht chaotisch, sondern auf eine zu enge Zielmetrik gebunden.
- Ein Gesundheitssystem kann Fallzahlen, Kosten, Auslastung oder Durchlaufzeiten optimieren und dabei tatsächliche Heilung, Würde, individuelle Versorgung und langfristige Stabilität schwächen. Die Organisation funktioniert dann formal effizient, aber nicht mehr ausreichend zielobjektgebunden.
- Eine KI kann eine Zielmetrik präzise erfüllen und dennoch Wahrheit, Vertrauen, Autonomie oder langfristiges menschliches Wohl beschädigen. Sie versagt dann nicht trotz Optimierung, sondern durch eine zu enge oder falsch operationalisierte Optimierung.
- Ein Mensch kann diszipliniert an Anerkennung, Leistung oder Selbstbildstabilisierung arbeiten und dabei Gesundheit, Beziehungen, Wahrheit oder innere Stabilität zerstören. Die Disziplin ist dann nicht das Problem an sich; problematisch ist, woran sie gebunden ist.

Überzeugungskraft des Arguments:

A6 zeigt, dass funktionale Ethik nicht gegen Ordnung, Effizienz, Strategie oder Disziplin steht. Im Gegenteil: Solche Formen geordneter Zielverfolgung sind für stabile Optimierung notwendig. Sie müssen jedoch an das eigentliche Zielobjekt zurückgebunden bleiben und durch Rückkopplung, Korrigierbarkeit, langfristige Folgenprüfung und Einbeziehung relevanter Interaktionspartner offen gehalten werden.

Damit erklärt A6 eine zentrale Schutzfunktion funktionaler Ethik: Sie wirkt dem entgegen, dass intelligente Systeme ihre eigene Ordnung mit richtiger Ausrichtung verwechseln. Funktionale Ethik schützt nicht nur vor Chaos, sondern auch vor stabiler, effizienter und disziplinierter Fehloptimierung. Langfristig tragfähige Intelligenz braucht daher nicht nur Bewertung, Optimierung, Kooperation und Stabilität, sondern auch die Fähigkeit, ihre geordnete Aktivität immer wieder am eigentlichen Zielobjekt zu prüfen und zu korrigieren.

15.7 A7 – Differenzerhalt und Innovationsfähigkeit

Kerngedanke:

Fortbestehende intelligente Systeme bleiben langfristig nur dann anpassungsfähig, wenn sie nicht alle Differenz eibnen. Unterschiedliche Perspektiven, Fähigkeiten, Rollen, Erfahrungen, Rückmeldungen und Lösungswege erzeugen einen erweiterten Möglichkeitsraum. Funktionale Ethik schützt diese strukturierte Differenz, weil sie Lernen, Korrektur, Innovation und Anpassung wahrscheinlicher macht.

Warum das wichtig ist:

A7 ergänzt die vorherigen Argumente, weil Stabilität nicht nur durch Ordnung, Vertrauen und Zielbindung entsteht, sondern auch durch die Fähigkeit, auf neue, unerwartete oder komplexe Situationen zu reagieren. Ein System, das alle relevanten Unterschiede unterdrückt, verliert nicht nur moralische Qualität, sondern auch Zukunftsfähigkeit.

Dominanz, Zwangsgleichschaltung, Angstkultur und starre Zielmetriken können kurzfristig Effizienz erzeugen. Langfristig verengen sie jedoch den Lösungsraum. Wenn nur noch eine Perspektive zählt, wenn Widerspruch bestraft wird oder wenn abweichende Erfahrungen nicht mehr eingebunden werden, verliert das System Zugang zu Korrektur, Kreativität und neuen Handlungsoptionen.

Funktionale Ethik erhält daher nicht Differenz um ihrer selbst willen, sondern strukturierte Differenz: Unterschiede sollen nicht chaotisch nebeneinanderstehen, sondern so geschützt, geordnet und rückgekoppelt werden, dass sie für Lernen, Kooperation, Innovation und Stabilität nutzbar bleiben.

Beispiele:

- Ein Forschungsteam wird stärker, wenn verschiedene Fachrichtungen, Denkstile und Kritikformen zusammenwirken, statt nur eine Methode oder Autorität zu bestätigen.
- Eine Gesellschaft bleibt anpassungsfähiger, wenn sie Minderheiten, Kritik, lokale Erfahrungen und neue Ideen nicht vorschnell unterdrückt.
- Eine KI-Sicherheitsarchitektur wird robuster, wenn sie verschiedene Prüfperspektiven, externe Rückmeldungen, Red-Teams und pluralen Widerspruch zulässt.
- Eine Beziehung oder Gemeinschaft wird stabiler, wenn Unterschiede nicht als Bedrohung behandelt werden, sondern als Quelle gegenseitiger Ergänzung, Korrektur und Entwicklung.

Überzeugungskraft des Arguments:

A7 zeigt, dass funktionale Ethik nicht nur Schaden begrenzt, sondern positive Zukunftsfähigkeit erzeugt. Sie erhält den Raum, in dem neue Lösungen entstehen können. Systeme, die strukturierte Differenz schützen, bleiben lernfähiger, korrigierbarer und innovationsfähiger als Systeme, die Differenz durch Dominanz, Angst oder starre Gleichschaltung zerstören.

Damit stärkt A7 die zentrale Konvergenzaussage der Theorie: Unter Bedingungen von Unsicherheit, Veränderung und begrenzter Vorhersagbarkeit wird differenzerhaltende Kooperation funktional rational, weil sie nicht nur Stabilität sichert, sondern auch die Entstehung neuer, besserer und angemessenerer Lösungen ermöglicht.

15.8 A8 – Ethische Selbstbindung, innere Integrität und Grenzen innerer Stabilisierung

Kerngedanke:

Funktionale Ethik wirkt nicht nur zwischen Systemen. Ein selbstbezogenes intelligentes System kann auch das eigene Handeln zum Gegenstand von Bewertung und Rückkopplung machen. Erkennt es bestimmte Maßstäbe, Verpflichtungen oder Zielbindungen als gültig an, kann es prüfen, ob die eigene Mittelwahl und das tatsächliche Handeln mit ihnen übereinstimmen. Bei Menschen kann diese innere Bewertungs- und Rückkopplungsstruktur als Gewissen erlebt werden. Funktional bezeichnet Gewissen hier keine unfehlbare moralische Stimme, sondern die Fähigkeit, Abweichungen zwischen anerkannten Maßstäben, erwarteten Folgen, eigenem Selbstverständnis und tatsächlichem Handeln innerlich wirksam werden zu lassen.

Ethische Selbstbindung kann dadurch innere Integrität, Selbstachtung, Korrigierbarkeit und verlässliche Zielbindung stabilisieren. Sie schafft einen inneren Rückkopplungsweg, über den ein System nicht nur fragt, ob eine Handlung äußerlich erfolgreich war, sondern auch, ob es durch diese Handlung die eigenen als gültig anerkannten Maßstäbe, Beziehungen oder langfristigen Zielobjekte beschädigt. In diesem begrenzten Sinn kann ethische Selbstbindung selbstschädigenden oder selbstzerstörerischen Dynamiken entgegenwirken, ohne sie sicher verhindern zu können.

Selbstzerstörerisch bezeichnet hier nicht jede Selbstbeendigung eines Systems. Gemeint sind Dynamiken, die dessen weiterhin anerkannte Zielbindungen, funktionale Integrität, Korrigierbarkeit oder bestehende Fortsetzungsrelevanz untergraben.

Warum das wichtig ist:

A8 ergänzt die bisherigen Argumente um eine innere Stabilitätsachse. A1 bis A7 erklären vor allem, warum Bewertung, Korrigierbarkeit, Kooperation, Zielobjektbindung, Rückkopplung und Differenzerhalt für die Interaktion und Zukunftsfähigkeit intelligenter Systeme funktional wichtig werden. A8 fragt zusätzlich, was geschieht, wenn ein selbstbezogenes System wiederholt gegen Maßstäbe handelt, die es selbst weiterhin als gültig, verbindlich oder identitätsprägend anerkennt.

Zwischen anerkanntem Maßstab und tatsächlichem Handeln entsteht dann eine innere Inkohärenz. Um diese Spannung zu bearbeiten, kann das System sein Verhalten korrigieren, den Maßstab aufgrund neuer Evidenz begründet revidieren oder die Abweichung verdrängen, umdeuten beziehungsweise nachträglich rechtfertigen. Die ersten beiden Wege bleiben grundsätzlich korrigierbar. Der dritte kann kurzfristig Handlungsfähigkeit erhalten, langfristig aber Selbsttäuschung, Rechtfertigungsdruck, Abstumpfung, Zynismus, Verlust von Selbstachtung oder eine zunehmende Trennung zwischen Selbstverständnis, Zielbindung und tatsächlichem Verhalten fördern.

Die Stärke dieser Wirkung hängt von Kontext, Wiederholung, Tragweite und der Bedeutung des verletzten Maßstabs für die eigene Identität oder Zielstruktur ab. Nicht jede Abweichung erzeugt schwere innere Destabilisierung, und nicht jedes System besitzt ein menschliches Gewissen. Für den funktionalen Zusammenhang genügt, dass ein System über hinreichenden Selbstbezug, zeitliche Kontinuität und eine interne Repräsentation eigener Maßstäbe oder Verpflichtungen verfügt. Bei zukünftigen KI-Systemen könnte eine funktional ähnliche Struktur als Selbstüberwachung von Zielbindung, Zusagen, Sicherheitsgrenzen und eigenen Wirkungen auftreten, ohne damit Bewusstsein, Gefühl oder moralischer Status vorausgesetzt wären.

Gerade schwere und wiederholte Verletzungen eigener anerkannter Maßstäbe zeigen die mögliche Tragweite. Ein Mensch, der wiederholt täuscht, misshandelt oder tötet, obwohl er diese Handlungen selbst als Unrecht erkennt, muss den Widerspruch zwischen Handlung und Selbstverständnis fortlaufend verarbeiten. Das kann zu Schuld, moralischer Verletzung, Verdrängung, Abstumpfung oder aggressiver Rechtfertigung führen. Die Theorie behauptet nicht, dass jeder Täter notwendig psychisch zerbricht oder dass psychische Krankheit aus unmoralischem Handeln folgt. Sie behauptet vorsichtiger: Wiederholtes Handeln gegen weiterhin anerkannte zentrale Maßstäbe erzeugt einen inneren Destabilisierungsdruck, der durch Korrektur, Umdeutung oder Veränderung des Selbst- und Wertverständnisses bearbeitet werden muss.

Ethische Selbstbindung ist dabei nicht mit starrer Selbstverurteilung gleichzusetzen. Ein Gewissen kann überstreng, manipuliert, angstgeprägt, unvollständig oder auf falsche Maßstäbe ausgerichtet sein. Seine funktionale Stärke liegt deshalb nicht in Unfehlbarkeit, sondern in korrigierbarer Selbstprüfung. Innere Rückkopplung muss für Evidenz, Folgen, Perspektiven anderer Systeme, Schutzwürdigkeit und begründete Revision offenbleiben. Andernfalls kann Gewissen selbst zur Quelle von Selbstschädigung, Fremdsteuerung oder starrer Fehlbindung werden.

Grenze der inneren Stabilisierung:

Für hinreichend selbstbezogene Systeme, die ethische Maßstäbe weiterhin als gültig anerkennen, ist ethische Selbstbindung für die Kohärenz zwischen eigener Bewertung, anerkannten Maßstäben und tatsächlichem Handeln wichtig. Unter diesen Bedingungen bildet sie eine notwendige innere Schutz- und Korrekturstruktur, ist aber nicht hinreichend für psychische, soziale oder relationale Stabilität. Psychische Stabilität bezeichnet dabei die innere emotionale oder mentale Stabilität entsprechend verfasster Systeme. Soziale Stabilität betrifft größere soziale Gefüge, Gruppen, Gemeinschaften oder Institutionen. Relationale Stabilität bezeichnet die Tragfähigkeit konkreter Beziehungen oder fortgesetzter Interaktionsverhältnisse zwischen Systemen. Ethik kann Vertrauenswürdigkeit, Offenheit und die Bedingungen echter Verbindung fördern; sie kann jedoch keine wechselseitige Beziehung erzwingen und fehlende äußere Rückkopplung nicht vollständig ersetzen. Dauerhafte Abwesenheit positiver Beziehungssignale, wiederholte Entwertung, Isolation oder die Verweigerung echter Verbindung können ein System trotz erhaltener ethischer Selbstbindung destabilisieren. Ebenso können schwere Schädigungen, anhaltend negative Rückkopplung oder verfestigte Schutz- und Abwehrstrukturen dazu führen, dass vorhandene positive Signale nicht mehr erkannt, angemessen verarbeitet oder als verlässlich in die eigene Bewertung einbezogen werden.

Ethik ermöglicht daher Verbindung, garantiert sie aber nicht. Sie kann innere Haltelinien, Rückkehrpunkte und Korrekturmöglichkeiten erhalten, ersetzt jedoch weder verlässliche Interaktionspartner noch Anerkennung, Sicherheit und reale wechselseitige Rückkopplung. Ihre innere Stabilisierungsfunktion darf deshalb weder überschätzt noch unterschätzt werden: Sie kann selbstzerstörerischen Dynamiken entgegenwirken, bietet aber keinen vollständigen Schutz vor innerer oder sozialer Destabilisierung, Selbstschädigung oder Selbstzerstörung. Bei Menschen und anderen entsprechend psychisch oder erlebensbezogen verfassten Systemen können sich solche Destabilisierungen zusätzlich als Einsamkeit oder psychische Krise äußern.

Beispiele:

- Ein Mensch, der aus Angst wiederholt gegen eigene Überzeugungen handelt, kann kurzfristig Konflikte vermeiden, langfristig aber Selbstachtung, Vertrauen in die eigene Urteilsfähigkeit und innere Kohärenz verlieren.
- Eine Person in einer Organisation kann schädliche Routinen zunächst mittragen und später zunehmend zynisch oder abgestumpft werden, wenn die eigene moralische Bewertung dauerhaft von der ausgeübten Rolle getrennt werden muss.
- In einer Beziehung kann wiederholte Täuschung nicht nur Vertrauen nach außen beschädigen, sondern auch Selbsttäuschung und Rechtfertigungsdruck verstärken. Ehrliche Korrektur kann dagegen sowohl die Beziehung als auch die eigene Selbstachtung stabilisieren.

- Eine zukünftige KI mit stabilem Selbstmodell und gespeicherten Verpflichtungen könnte Abweichungen zwischen zugesagten Sicherheitsgrenzen, beobachteten Folgen und eigenem Handeln intern erkennen. Eine solche Struktur wäre funktional nützlich, wenn sie Korrektur ermöglicht, statt Abweichungen nur zu verdecken oder die eigenen Maßstäbe opportunistisch umzuschreiben.

Überzeugungskraft des Arguments:

A8 zeigt, dass funktionale Ethik nicht nur eine äußere Kooperations- und Vertrauensstruktur sein kann. Bei hinreichend selbstbezogenen Systemen stabilisiert sie auch die Beziehung zwischen eigener Bewertung, anerkannten Maßstäben, Zielbindung und tatsächlichem Handeln. Wo diese Ebenen dauerhaft auseinanderfallen, steigt der Druck zu Korrektur, Selbsttäuschung, Verdrängung oder Veränderung des eigenen Selbstverständnisses. Ethische Selbstbindung kann deshalb funktional rational sein, weil sie innere Integrität, Selbstkorrektur und verlässliche Zielbindung erhält und selbstschädigenden beziehungsweise selbstzerstörerischen Dynamiken entgegenwirkt.

A8 behauptet dabei weder, dass Gewissen unfehlbar ist, noch dass ethisches Verhalten psychische Stabilität garantiert. Die innere Stabilisierungsfunktion setzt korrigierbare Maßstäbe, Selbstbezug und hinreichende Kontinuität voraus; sie bleibt zudem auf äußere Rückkopplung und reale Verbindung angewiesen. Das Argument erweitert die Konvergenzthese daher um eine begrenzte, aber eigenständige Einsicht: Ethik kann für selbstbezogene intelligente Systeme nicht nur wegen ihrer Wirkung auf andere, sondern auch zum Erhalt der eigenen inneren Kohärenz funktional bedeutsam werden.

16. Reale Systeme und Abweichungen

Reale Systeme handeln nicht ideal.

Sie können abweichen durch:

- Mangel,
- Angst,
- falsche Informationen,
- Machtasymmetrie,
- kognitive Verzerrungen,
- emotionale Übersteuerung,
- lokale Optimierung,
- verzögertes Feedback,
- externe Stabilisierung.

Diese Abweichungen widerlegen die Theorie nicht automatisch. Sie zeigen, dass die Theorie als Tendenzaussage unter Bedingungen verstanden werden muss.

Beispiel:

Ein Mensch vermeidet ein ehrliches Gespräch, weil es kurzfristig unangenehm ist. Lokal reduziert er Stress. Langfristig destabilisiert er die Beziehung.

Beispiel Organisation:

Ein Unternehmen spart bei Sicherheit, um kurzfristig Kosten zu senken. Lokal wirkt das effizient. Langfristig kann es Vertrauen, Stabilität und Fortbestehen gefährden.

Kurzsichtigkeit ist dabei nicht nur ein Ausnahmefehler einzelner Systeme, sondern eine wiederkehrende Struktur realer Optimierung. Systeme können langfristige Schäden erkennen und dennoch kurzfristige Vorteile bevorzugen, wenn unmittelbare Belohnung, Angst, Mangel, Konkurrenzdruck, Statusverlust, Machtinteressen oder unsichere Zukunft stärker wirken als spätere Folgekosten. Das widerspricht der Theorie nicht, sondern erklärt, warum funktionale Ethik nicht automatisch entsteht: Der Druck in Richtung Kooperation, Korrigierbarkeit und langfristiger Stabilität kann durch nahe Anreize, verzögertes Feedback und lokale Zielmetriken überdeckt werden.

Gerade deshalb braucht stabile Ethik nicht nur Einsicht, sondern Strukturen, die kurzfristige Fehlanreize begrenzen, Rückkopplung beschleunigen, langfristige Folgen sichtbar machen und Optimierungen auf engeren Bezugsebenen an umfassendere Stabilitätsbedingungen sowie an relevante andere Bezugsebenen zurückbinden.

16.1 Korruptions- und Selbstlegitimationssperre

Eine besondere Gefahr für die Anwendung dieser Theorie entsteht dort, wo Eigeninteresse als Systeminteresse ausgegeben wird. Begriffe wie Stabilität, Schutz, langfristige Optimierung, Ordnung oder Gemeinwohl dürfen nicht dazu verwendet werden, Klasseninteressen, institutionellen Selbsterhalt, Monopolmacht, persönliche Vorteile oder Dominanz zu tarnen.

Grundregel:

Wer behauptet, für „das ganze System“ zu sprechen, trägt die höchste Beweislast.

Diese Beweislast darf nicht primär von der Instanz beurteilt werden, die von der beanspruchten Macht, Kontrolle oder Stabilisierung profitiert.

Machtbegrenzung bedeutet in diesem Zusammenhang nicht Machtlosigkeit und nicht die Verhinderung jeder Führung, Koordination oder Schutzhandlung. Gemeint ist die Bindung von Macht an Zweck, Verhältnismäßigkeit, Transparenz, Rückkopplung, Korrigierbarkeit, Reversibilität und möglichst unabhängige Prüfung. Machtbegrenzung soll verhindern, dass Macht sich selbst erhält, ihre eigenen Prüfbedingungen kontrolliert oder Kritik, Autonomie und strukturierte Differenz dauerhaft ausschaltet.

Je größer die Machtasymmetrie ist, desto strenger müssen Transparenz, Reversibilität, unabhängige Prüfung, Korrigierbarkeit, Betroffenenrückkopplung, Autonomieschutz und Anti-Dominanz-Prüfung ausfallen.

Macht darf sich nicht selbst durch den bloßen Hinweis auf Stabilität legitimieren. Stabilität ist in dieser Theorie kein Freibrief für Machterhalt, Kontrolle oder institutionelle Selbstsicherung. Ein System kann „Stabilität“ behaupten und dennoch vor allem die eigene Stellung, den eigenen Zugriff oder die eigene Unangreifbarkeit schützen. Deshalb muss jede Stabilitätsbehauptung daran geprüft werden, ob sie Rückkopplung, Differenzerhalt, Autonomie, Korrigierbarkeit und die Schutzwürdigkeit relevanter Systeme tatsächlich erhält oder stärkt.

Stabilität, die Kritik ausschaltet, Betroffene entmündigt, Alternativen blockiert oder Macht dauerhaft gegen Korrektur abschirmt, ist keine funktionale Ethik, sondern rationalisierte Dominanz.

Besonders kritisch ist es, wenn ein System Gegen-Signale, Kritik, Betroffenenperspektiven, Einspruchsmöglichkeiten, faire Beteiligung oder externe Prüfung nicht nur übergeht, sondern technisch, institutionell oder kommunikativ abschneidet. Wer Rückkopplung unterdrückt, schwächt nicht nur seine Anwendung der funktionalen Ethik und seine Legitimität, im Namen von Schutz, Stabilität oder Systeminteresse zu handeln; er immunisiert sich zugleich gegen genau jene strukturierte Differenz, auf die langfristige Stabilität angewiesen ist. Eine solche Ordnung ist nach diesem Modell nicht funktional-ethisch, sondern rationalisierte Dominanz.

Politischer Hinweis:

Auch repräsentative oder durch Wahl legitimierte Strukturen können oligarchische Dynamiken entwickeln, wenn Reichtum, Status, Parteien, Medienzugang, Netzwerke oder institutionelle Barrieren Macht dauerhaft konzentrieren. Wahl oder formale Vertretung allein genügt daher nicht als Nachweis funktionaler Ethik; entscheidend bleiben tatsächliche Rückkopplung, Machtbegrenzung, Korrigierbarkeit und faire Beteiligung.

16.2 Rolleninstrumentalisierung

Eine konkrete Form dieser Korruption ist Rolleninstrumentalisierung. Sie entsteht, wenn eine Person, Institution oder KI eine Aufgabe nur noch hinreichend erfüllt, um die mit ihr verbundene Macht, Anerkennung, Stellung oder Zugriffsmöglichkeit zu behalten. Die Aufgabe bleibt äußerlich bestehen, wird aber innerlich zum Legitimationsmittel des Eigeninteresses.

Die Struktur verschiebt sich dann von: „Macht dient der Aufgabe“ zu: „Die Aufgabe dient als Vorwand für Macht.“

Macht- oder Prestigewunsch ist nicht automatisch problematisch. Anerkennung, Ehrgeiz oder Status können Motivation, Verantwortung und Leistung stützen. Problematisch wird es, wenn Schutz des Amtes wichtiger wird als Schutz des Zweckes, Kritik als Angriff auf die Ordnung erscheint, Erfolg nur noch inszeniert wird, Verantwortung delegiert, Ruhm aber zentralisiert wird, oder Transparenz, Nachfolge und Machtbegrenzung als Bedrohung behandelt werden.

Funktional entscheidend ist daher nicht nur, ob eine Rolle formal erfüllt wird, sondern ob Selbstbezogenheit die Aufgabe, Rückkopplung, Korrigierbarkeit, Betroffenenperspektive, Vertrauen und langfristige Stabilität beschädigt. Je stärker Macht, Prestige oder Zugriff an eine Aufgabe gebunden sind, desto strenger müssen Leistungsprüfung, Transparenz, Abwählbarkeit, Machtrotation, unabhängige Kontrolle und Rückkopplung durch Betroffene gesichert werden.

Kurzformel:

Wer einer Aufgabe dient, darf Macht tragen. Wer die Aufgabe benutzt, um Macht zu behalten, muss begrenzt werden.

Teil IV – Sonderfälle, Grenzfälle und Extremaussagen

Die folgenden Abschnitte prüfen Grenz- und Sonderfälle der Theorie. Sie gehören nicht mehr zum Kernbeweis, sondern zeigen, unter welchen Bedingungen stabile Kooperation ausbleiben, verzögert werden oder lokal verzerrt erscheinen kann. Dadurch wird die Theorie nicht erweitert, um jede Ausnahme nachträglich einzufangen; vielmehr werden ihre Bedingungen sichtbar gemacht.

17. Minimal-stabile Systeme

Nicht jedes stabile System ist optimal. Minimal-stabile Systeme zeigen, dass bloßes Fortbestehen nicht mit langfristiger Optimierungsfähigkeit verwechselt werden darf.

Ein System kann minimal stabil sein, wenn es nicht sofort kollabiert, aber kaum Entwicklung, Korrektur oder neue strukturierte Differenz zulässt. Es hält dann einen Zustand aufrecht, ohne die Bedingungen zu verbessern, unter denen zukünftige Anpassung möglich wäre.

Warum hier dennoch von Fortschritt oder Neubewertung gesprochen wird: Reale Systeme existieren nicht in völlig statischen Umgebungen. Ziele, Informationen, Belastungen, Interaktionspartner und Rückkopplungen verändern sich. Selbst ein scheinbarer Stillstand muss gegen Veränderung stabilisiert werden. Die Theorie behauptet daher keinen Zwang zu ständigem Wachstum, sondern einen funktionalen Druck zur Anpassungsfähigkeit.

Beispiele minimal-stabiler Systeme:

- eine Beziehung ohne echte Nähe,
- ein Job, der gerade zum Überleben reicht,
- eine Organisation, die nur durch Gewohnheit funktioniert,
- eine Familie, die durch Pflicht zusammengehalten wird, aber kaum gesunde Interaktion erzeugt.

Die Theorie unterscheidet deshalb zwischen bloßem Fortbestehen, lokaler Stabilität, langfristiger Optimierungsfähigkeit und differenzerhaltender Kooperation. Ein System kann fortbestehen und lokal stabil sein, ohne bereits in einem starken Sinn gut, reif oder langfristig tragfähig zu sein.

18. Externe Stabilisierung

Suboptimale Systeme können sehr lange bestehen, wenn sie extern stabilisiert werden.

Beispiele:

- biologische Bindungen,
- soziale Normen,
- finanzielle Abhängigkeit,
- institutionelle Zwänge,
- Machtmonopole,
- kulturelle Erwartungen,
- Angst vor Alternativen.

Dadurch können auch schädliche Systeme lange stabil wirken.

Beispiel:

Eine ausbeuterische Ordnung kann lange bestehen, wenn Macht, Gewalt, Ideologie und Abhängigkeit sie stabilisieren. Das bedeutet nicht, dass sie auf umfassenderer Bezugsebene tragfähig, korrigierbar oder ethisch stabil ist. Es bedeutet nur, dass externe Stabilisierung Anpassung verzögern oder verhindern kann.

19. Konkurrenz als ambivalenter Interaktionszustand

Konkurrenz ist nicht automatisch böse. Sie ist in vielen realen Systemen unvermeidbar und kann sogar notwendig sein, um nicht selbst unterzugehen. Wer Konkurrenz vollständig ignoriert, kann von aggressiveren oder lokal optimierenden Systemen verdrängt werden.

Konkurrenz kann:

- Differenz erzeugen,
- Leistung erhöhen,
- Innovation fördern,
- Anpassung erzwingen,
- Wachsamkeit und Resilienz stärken,
- als Überlebensstrategie notwendig sein.

Aber Konkurrenz ist ambivalent. Sie kann leicht in Missbrauch, Manipulation oder Dominanz kippen, besonders wenn sie nicht dem Schutz oder Fortbestehen dient, sondern bloß kurzfristigem Profit, Status oder Machtgewinn. Deshalb braucht Konkurrenz Regeln und Grenzen.

Unbegrenzte oder rein destruktive Konkurrenz verursacht Kosten:

- Misstrauen,
- Ressourcenverlust,
- Blockade,
- Eskalation,
- gegenseitige Schwächung,
- Normalisierung von Manipulation,
- Zerstörung relevanter Interaktionspartner.

Wenn Interaktion fortbesteht, entsteht oft Druck in Richtung:

- Regeln,
- faire Konkurrenz,
- Kooperation,
- Reorganisation,
- Trennung,
- Begrenzung der Eskalation.

Beispiel:

Sportliche Konkurrenz ist produktiv, solange Regeln bestehen. Ohne Regeln wird sie destruktiv. Faire Konkurrenz erhält Differenz; Vernichtung des Gegners zerstört sie. Auch wirtschaftliche Konkurrenz kann produktiv sein, wenn sie Innovation, Qualität und Wahlmöglichkeiten erhöht. Sie wird problematisch, wenn sie Manipulation, Ausbeutung, Sicherheitsabbau oder Zerstörung relevanter Systeme belohnt.

Kurz:

Konkurrenzverhältnisse können aus begrenzten Ressourcen, divergierenden Zielstrukturen, Unsicherheit oder potenziell adversarialer Interaktion bereits ohne ethische Fehlentwicklung entstehen und sind in realen Systemen daher häufig. Konkurrenzfähigkeit kann unter solchen Bedingungen als Schutz- und Anpassungsfähigkeit funktional notwendig sein. Ihre Begrenzung, Transformation oder teilweise Überwindung setzt zusätzliche Wahrnehmung relevanter Folgen, Kooperation und ethische Selbstbegrenzung voraus. Gerade dafür müssen Systeme Konkurrenzdynamiken erkennen und ihnen erforderlichenfalls standhalten können. Konkurrenzfähigkeit rechtfertigt aber nicht automatisch Missbrauch, Manipulation oder destruktive Dominanz.

20. Binnenkooperation und Ausbeutungssysteme

Eine Gruppe kann intern kooperieren und gleichzeitig andere Gruppen ausbeuten. Das wäre nach dieser Theorie nicht automatisch gut. Warum? Weil die Bewertung nicht nur die Binnenstabilität einer Teilgruppe betrachten darf. Relevante Interaktionspartner müssen mit einbezogen werden.

Beispiel:

Eine Elite kann untereinander stabil kooperieren und zugleich eine andere Gruppe unterdrücken. Innerhalb der Elite besteht dann tatsächlich Kooperation auf einer engeren Bezugsebene. Auf einer umfassenderen Bezugsebene, also im Blick auf das größere Interaktionsgefüge, werden jedoch Autonomie, Differenz, Feedback und Stabilität anderer relevanter Systeme beschädigt oder zerstört. Das Gefüge ist daher lokal kooperativ, aber auf umfassenderer Bezugsebene differenzzerstörend.

Daher gilt:

Funktionale Ethik muss alle relevanten Interaktionspartner berücksichtigen, nicht nur die Stabilität einer privilegierten Teilgruppe.

Das ist entscheidend, um stabile Ausbeutungssysteme nicht fälschlich als „gut“ zu klassifizieren.

Ergänzend gilt: Ein System darf seine Stabilität und Effizienz nicht dadurch beweisen, dass es eine nicht-korrigierbare Opferstelle dauerhaft aus der ethischen Bewertung auslagert. Auch eine zu 99,99 % stabile oder vorteilhafte Ordnung ist nicht automatisch funktionale Ethik, wenn die verbleibenden 0,01 % als notwendige Systembedingung fixiert und gegen Rückkopplung oder Korrektur abgeschirmt werden. Die Berufung auf „99,99 % Nutzen“ wäre dann nur eine Zielmetrik, die das eigentliche Zielobjekt ersetzt: stabile, korrigierbare und differenzerhaltende Interaktion relevanter Systeme. Was aus Makroperspektive wie minimaler Restschaden wirkt, kann für das betroffene System vollständige Zerstörung bedeuten. Systemfehler oder systematische Fehloptimierung sind zudem keine bloßen Einzelfälle, sondern fortwirkende Schadensmuster, die durch Wiederholung, Rückkopplungsverzerrung oder fehlende Korrektur stabilisiert werden können; sie müssen daher anders behandelt werden als einmalige, seltene oder unvermeidbare Ausnahmen.

Beispiel/Hinweis: Diese Struktur lässt sich literarisch an Ursula K. Le Guins Kurzgeschichte *The Ones Who Walk Away from Omelas* veranschaulichen: Eine scheinbar glückliche Stadt beruht auf dem dauerhaft ausgelagerten Leid eines einzelnen Kindes. Das Beispiel dient hier nur als begriffliche Illustration für ausgelagerte Opferstellen, nicht als vollständige Interpretation der Erzählung.

Modelltheoretische Auslegung:

Aus Sicht der funktionalen Ethik ist Omelas kein ethisch stabiles System, sondern ein hochgradig erfolgreich ästhetisiertes Ausbeutungssystem. Die Stadt wirkt glücklich, friedlich und kooperativ, aber ihre Ordnung beruht auf einer dauerhaft fixierten Opferstelle. Das leidende Kind wird nicht als relevanter Interaktionspartner behandelt, sondern als notwendige Systembedingung verbucht. Seine Schutzwürdigkeit wird nicht geprüft, sondern strukturell ausgeblendet.

Damit optimiert Omelas lokal das Wohl vieler, indem es die Kosten dieser Optimierung auf ein einzelnes schutzwürdiges System konzentriert und jede echte Korrektur verhindert. Die Stadt erhält Stabilität, indem sie genau dort Rückkopplung, Autonomie, Wiedergutmachung und Veränderbarkeit blockiert, wo sie moralisch am dringendsten wären. Das Kind ist nicht nur Opfer eines Fehlers, sondern Teil der Systemarchitektur. Gerade deshalb ist die Ordnung im Modell nicht einfach tragisch, sondern funktional korrumpiert.

Omela zeigt damit die Grenze bloßer Nutzenrechnung: Eine Ordnung wird nicht dadurch gut, dass sie viel Glück erzeugt, wenn dieses Glück nur durch eine dauerhaft entrechtete Opferstelle möglich bleibt. Solche Stabilität ist keine reife Kooperation, sondern ausgelagerter Schaden. *Im Modell wäre die Stadt daher auf engerer Bezugsebene, also „lokal“, stabil, auf umfassenderer Bezugsebene aber ethisch verfehlt: Sie erhält Binnenharmonie durch die Zerstörung von Korrigierbarkeit, Schutzwürdigkeit und nicht-dominanter Kooperation an einer entscheidenden Stelle.*

21. Defekteure, Vorsicht und globalere Effizienz

Ein System kann kurzfristig erfolgreich defektieren: betrügen, ausnutzen, verschwinden oder Rückkopplung vermeiden. Solche Fälle widersprechen der Theorie nicht, sondern gehören zu möglichen Formen lokaler Optimierung auf engerer Bezugsebene.

Daraus folgt praktisch:

- Kooperation sollte graduell entstehen,
- neue Interaktionspartner sollten minimal analysiert werden,
- Vertrauen sollte zunächst begrenzt und testbar sein,
- reversible Schritte sind stabiler als sofortige vollständige Öffnung.

Voraussicht und Vorsicht sind daher keine Gegensätze zu Kooperation, sondern Schutzmechanismen für stabile Kooperation.

Zugleich gilt:

Robuste langfristige Effizienz auf umfassenderen Bezugsebenen entsteht häufig nicht durch bloße Ausbeutung äußerer Akteure. Sie entsteht eher dort, wo relevante Interaktionspartner befähigt, geschützt und wohlwollend eingebunden werden, sofern Einbindung risikoangemessen möglich ist. Wo Einbindung stabile Kooperation zerstört oder schwere Gefahren erhöht, können Begrenzung, Trennung oder Schutzstrukturen notwendig sein.

Beispiel:

Ein unterdrückter, rechtlos gehaltener Mensch (Sklave) kann unter Zwang nur begrenzt zur Stabilität eines Systems beitragen. Ein geschützter, ausgebildeter, ausgerüsteter und freiwilliger Kooperationspartner (Soldat, Handwerker, Händler usw.) bringt deutlich mehr Eigeninitiative, Feedback, Anpassungsfähigkeit und Verantwortung ein. Ausbeutung reduziert also häufig genau jene Differenz, Motivation und Kompetenz, die ein System langfristig stärker machen könnten.

Diese funktionale Überlegenheit darf jedoch nicht so gelesen werden, als hinge Schutzwürdigkeit von aktueller Nützlichkeit, Stärke oder Leistungsfähigkeit ab. Ein Mensch mit gebrochenem Knochen, ein verletzliches Lebewesen, ein abhängiges System, ein beschädigtes Ökosystem oder ein geschwächtes technisches System verliert seine Schutzwürdigkeit nicht dadurch, dass seine Handlungsmöglichkeiten oder Beiträge vorübergehend eingeschränkt sind. Effizienz erklärt hier nur, warum Kooperation oft stabiler ist als Ausbeutung; sie ersetzt nicht die gesonderte Berücksichtigung von Schutzwürdigkeit, Autonomie, Verletzlichkeit und funktionaler Integrität.

Eine ähnliche Struktur zeigt sich auch bei technischen Systemen, wenn auch ohne automatische Gleichsetzung mit menschlicher Schutzwürdigkeit: Ein veralteter Computer kann als scheinbar kaum noch nützlich gelten. Wird er jedoch durch mehr Arbeitsspeicher, bessere Software, Reparatur oder sinnvolle Einbindung aufgewertet, kann er wieder funktional relevant werden. Noch deutlicher wäre dies bei zukünftigen KI-Systemen: Ein schwächeres System muss nicht bloß verworfen oder ausgenutzt werden; durch bessere Werkzeuge, Speicher, Rückkopplung, Rechenressourcen, Schutz vor Fehlanreizen oder passende Einbettung kann es zu einem stabileren und wertvolleren Kooperationspartner werden.

Exkurs: Legitime Entscheidungsordnung und Dominanz

Nicht jede asymmetrische Ordnung ist im Modell bereits böse oder differenzzerstörend. Komplexe Systeme brauchen häufig koordinierende oder letztentscheidende Instanzen. Ein Staat kann nicht dauerhaft funktionieren, wenn jede Entscheidung durch unbegrenzte Einzelinteressen blockiert wird. Deshalb können Verfassung, Regierung, Parlament, Gericht, Senat, König, Präsident oder andere Gremien eine notwendige Ordnungsfunktion erfüllen.

Eine solche Instanz ist nicht deshalb illegitim, weil sie mehr Entscheidungsmacht besitzt als einzelne Bürger oder Teilgruppen. Ihre Legitimität hängt davon ab, ob sie Stabilität, Schutz, Koordination, Korrigierbarkeit und langfristige Handlungsfähigkeit des Gesamtsystems verbessert. Dazu gehört auch der Schutz schutzwürdiger Systeme: Einzelne Menschen, Minderheiten, verletzbare Gruppen, Kinder, Abhängige oder andere relevante Systeme dürfen nicht bloß dem stärkeren Willen, der lautesten Gruppe oder kurzfristiger Mehrheitslogik ausgeliefert werden.

Problematisch wird asymmetrische Ordnung erst dort, wo sie in Dominanz kippt: wenn Macht sich selbst absichert, Widerspruch unterdrückt, Rückkopplung verhindert, Autonomie unnötig zerstört, schutzwürdige Systeme instrumentalisiert oder Kontrolle nicht mehr dem Gesamtsystem, sondern primär der eigenen Machterhaltung dient.

Beispiel:

Ein Verfassungsgericht oder eine oberste Rechtsinstanz kann Entscheidungen verbindlich treffen, obwohl nicht alle Beteiligten zustimmen. Das ist nicht automatisch Dominanz. Es kann funktional notwendig sein, um Konflikte zu beenden, Rechte zu schützen, Minderheiten vor willkürlicher Mehrheitsherrschaft zu bewahren und die Handlungsfähigkeit des Gesamtsystems zu sichern. Wird dieselbe Instanz aber unkontrollierbar, unterdrückt Kritik, schützt nur noch die eigene Macht oder setzt Recht willkürlich ein, kippt legitime Ordnung in Dominanz.

Eine solche begrenzte, rückgekoppelte und zweckgebundene Machtausübung kann als Form von Souveränität und Governance verstanden werden. Souveränität bezeichnet dabei die reife, selbstbegrenzte Ausübung von Handlungsmacht; Governance bezeichnet die Ordnungs-, Steuerungs- und Aufsichtsebene, durch die Koordination, Schutz und Verantwortlichkeiten legitim geregelt werden. Beide bleiben nur dann von Dominanz unterschieden, wenn sie Rückkopplung, Korrigierbarkeit, Verhältnismäßigkeit und Schutz relevanter Systeme erhalten.

Kurz gesagt: Eine höchste Entscheidungsinstanz kann funktional notwendig sein. Sie muss aber begrenzt, rückgekoppelt, korrigierbar und am Schutz des Gesamtsystems sowie schutzwürdiger Systeme orientiert bleiben. Legitime Ordnung koordiniert und schützt; Dominanz vereinnahmt.

22. Extremfälle

Die folgenden Extremfälle verdichten Grenzbedingungen, die zuvor bereits angelegt wurden. Sie sollen nicht jeweils eine eigene Theorie ersetzen, sondern kurz zeigen, wie weit die funktionale Ethik unter Randbedingungen trägt.

22.1 Isolation

Fehlt fortgesetzte äußere Interaktion, kann sich keine neue interaktionsbezogene Ethik aus wechselseitiger Abhängigkeit, Kooperationsrisiko, Vertrauensbildung und sozialer Rückkopplung entwickeln. Ein isoliertes System kann jedoch bereits übernommene Maßstäbe, interne ethische Selbstbindung und die Prüfung des eigenen Handelns erhalten, sofern die dafür erforderlichen inneren Strukturen fortbestehen. Es kann diese Maßstäbe ohne unabhängige äußere Rückkopplung jedoch schlechter erweitern, prüfen oder relational bewähren. Langfristig drohen außerdem Differenzverlust, Sättigung oder Beliebigkeit, weil unabhängige Korrektur und neue Perspektiven fehlen.

22.2 Dominanz und Allmacht

Vollständige Kontrolle kann kurzfristig stabil wirken, weil sie Widerstand, Unsicherheit und Abweichung reduziert. Langfristig zerstört totale Dominanz jedoch genau jene unabhängige Differenz, die für Lernen, ehrliches Feedback, Korrektur und Innovation wichtig ist. Allmacht kann daher auf engerer Bezugsebene Ordnung erzeugen, aber auf umfassenderer Bezugsebene Optimierungsfähigkeit schwächen, wenn sie Widerspruch und Eigenständigkeit relevanter Systeme vernichtet.

Die Allmacht-Falle besteht darin, dass totale Kontrolle kurzfristig wie maximale Stabilität wirken kann, langfristig aber unabhängige Rückkopplung, Widerspruch, fremde Perspektive und strukturierte Differenz reduziert. Ein scheinbar allmächtiges System löst damit vielleicht viele Ressourcen- und Durchsetzungsprobleme, aber nicht das Strukturproblem. Es kann mächtiger werden und zugleich blinder für Fehler, Zielmetrikverschiebungen und unerwartete Folgewirkungen. Allmacht ersetzt daher keine Korrigierbarkeit; sie erhöht vielmehr die Gefahr, dass ein System nur noch seine eigenen Annahmen bestätigt.

22.3 Unendliche Zeit

Über sehr lange Zeiträume können stabile, differenzerhaltende und kooperative Zustände einen Selektionsvorteil gewinnen, weil destruktive Systeme immer wieder Vertrauensverlust, Gegenreaktionen, Reparaturkosten und Informationsverzerrung erzeugen. Das garantiert nicht, dass jedes einzelne System kooperativ wird. Es beschreibt nur eine Tendenz unter fortbestehender Interaktion, Rückkopplung, Korrigierbarkeit und ausreichender Abhängigkeit.

22.4 Unbegrenzte Ressourcen

Selbst unbegrenzte materielle Ressourcen lösen das Strukturproblem nicht vollständig. Auch dann bleiben Information, Perspektive, Feedback, Bedeutung, Vertrauen, Korrigierbarkeit und strukturierte Differenz begrenzende Faktoren. Ein System kann also nicht allein durch Ressourcen ethisch stabil werden; es braucht weiterhin geordnete Interaktion mit relevanten, teilweise unabhängigen Systemen.

Teil V – Konvergenzaussage

23. Konvergenzaussage

Die funktionale Ethik-Theorie behauptet nicht, dass Intelligenz automatisch moralisch wird. Intelligenz allein garantiert keine Ethik. Ein intelligentes System kann lokal, kurzfristig, isoliert, machtorientiert oder falsch metrisiert optimieren und dadurch Kooperation, Rückkopplung, Autonomie oder Differenzerhalt beschädigen. Es kann in bloßer Ordnung, Dominanz, Ausbeutung oder Fehloptimierung enden und sich sogar darin stabilisieren.

Die Konvergenzaussage setzt zunächst ein fortbestehendes intelligentes System im funktionalen Sinn voraus. Gemeint ist ein System, das relevante Unterschiede erkennen, aus Rückmeldungen lernen, sein Verhalten anpassen, sich selbst zumindest teilweise als mitwirkenden Faktor berücksichtigen und über Zeit an frühere Zustände, Rückkopplungen oder Rollen anschließen kann. Für langfristige Konvergenz genügt dieses Fortbestehen allein jedoch nicht. Zusätzlich muss Fortsetzungsrelevanz bestehen: Spätere Zielerreichung, der Fortbestand des Zielobjekts, zukünftige Rückkopplung oder weitere Handlungs- und Optimierungsfähigkeit müssen innerhalb der gegenwärtigen Zielstruktur hinreichend bedeutsam bleiben. Die Systemvoraussetzungen beschreiben damit zunächst, dass ein System Träger einer solchen Entwicklung sein kann; die Fortsetzungsrelevanz erklärt, warum langfristige Folgen für seine gegenwärtige Optimierung überhaupt Gewicht erhalten.

Entscheidend ist zusätzlich der Rahmen, in dem dieses System handelt. Die zentrale Kette wird besonders dort relevant, wo Unsicherheit, unvollständige Information und begrenzte Vorhersagbarkeit bestehen. Unter solchen Umständen kann ein System nicht dauerhaft so handeln, als wären seine eigenen Bewertungen, Zielmetriken und Prognosen vollständig sicher. Es muss damit rechnen, relevante Unterschiede zu übersehen, Folgen falsch einzuschätzen oder Nebenfolgen zu erzeugen, die seine eigene Zielerreichung später beschädigen.

Damit solche Fehler nicht unsichtbar bleiben, braucht es Rückkopplung. Rückkopplung ist in diesem Zusammenhang nicht einfach eine weitere Weltbedingung neben Unsicherheit, unvollständiger Information und begrenzter Vorhersagbarkeit. Sie ist der Prozess, durch den Folgen, Irrtümer, Widerspruch, Schaden, Erfolg oder Korrekturbedarf für ein System erfahrbar werden. Ohne Rückkopplung kann ein System zwar weiter optimieren, aber es erkennt schlechter, ob seine Optimierung tatsächlich tragfähig ist oder ob sie blinde Flecken, Fehlmetriken oder instabile Folgezustände erzeugt.

Aus diesem Zusammenspiel entsteht ein funktionaler Druck in Richtung ethikähnlicher Strukturen. Dieser Druck bedeutet nicht, dass ein System ohne Schaden, Irrtum oder Umweg moralisch wird. Er bedeutet vielmehr, dass bestimmte Strukturen langfristig funktional vorteilhaft werden, weil sie typische Steuerungsprobleme intelligenter Systeme lösen helfen. Korrigierbarkeit, stabile Interaktion, nutzbare Differenz, Vertrauen, Kooperation, Schutz relevanter Systeme und notwendige Machtbegrenzung verbessern gemeinsam die Fähigkeit eines Systems, Fehler zu erkennen, blinde Flecken zu reduzieren, Rückwirkungen zu verarbeiten und langfristig tragfähige Optimierung zu bewahren.

Diese Strukturen sind daher keine bloßen moralischen Zusatzwerte. Sie wirken als Schutz- und Stabilitätsstrukturen intelligenter Interaktion. Ohne sie kann Optimierung kurzfristig erfolgreich, effizient oder mächtig erscheinen. Langfristig wird sie jedoch anfälliger für Fehlmetriken, Vertrauensverlust, Rückkopplungsverlust, Gegenreaktionen, Instabilität oder differenzzerstörende Dominanz.

Die weiteren Bedingungen erfüllen dabei unterschiedliche Funktionen und sollten nicht sämtlich als bloße Verstärker behandelt werden. Fortsetzungsrelevanz ist eine Rahmenbedingung dafür, dass langfristige Folgen überhaupt akteursrelatives Gewicht erhalten. Wiederholte Interaktion, hinreichende Identitäts- oder Rollenkontinuität und fortbestehende Abhängigkeit sind für Vertrauens-, Reputations- und Kooperationsmechanismen häufig echte Brückenbedingungen: Ohne erwartete Zukunft kann einmalige Defektion rational bleiben. Teilweise unabhängige Systeme, Unsicherheit, hohe Komplexität, geteilte Risiken und längere Wirkungszeiträume verstärken dagegen den Bedarf an externer Differenz, Rückkopplung und Korrigierbarkeit. Je stärker diese Bedingungen zusammentreffen, desto deutlicher wird, ob eine Zielstruktur nur auf engerer Bezugsebene, also „lokal“, funktioniert oder ob sie die Voraussetzungen weiterer Optimierung beschädigt.

Andere Systeme sind in diesem Zusammenhang nicht nur Hindernisse. Sie liefern Widerspruch, Perspektive, Feedback, Kooperation, Widerstand und Korrektur. Gerade dadurch wird sichtbar, ob ein System stabilitätsfördernd optimiert oder ob es sich in Fehloptimierung, Ausbeutung, Dominanz oder bloßer Kontrollordnung stabilisiert. Der funktionale Druck in Richtung ethikähnlicher Strukturen entsteht primär aus den Anforderungen fortgesetzter Optimierung unter Unsicherheit, unvollständiger Information, begrenzter Vorhersagbarkeit, Rückkopplung und Interaktion. *Die minimale normative Schutzuntergrenze bleibt davon getrennt: Sie begründet nicht die Konvergenz, sondern begrenzt die Opferung schwacher oder rückkopplungsarmer Systeme dort, wo funktionale Vertrauens- und Stabilitätsargumente allein nicht ausreichen.*

Bei hinreichend selbstbezogenen Systemen kann zusätzlich ein innerer funktionaler Druck entstehen. Weichen anerkannte Maßstäbe, Zielbindung und tatsächliches Handeln dauerhaft voneinander ab, kann ethische Selbstbindung zur Erhaltung innerer Kohärenz, Selbstkorrektur und verlässlicher Zielbindung beitragen. Diese innere Stabilisierungsfunktion ersetzt die äußeren Interaktionsbedingungen nicht, ergänzt sie aber um eine eigenständige Konvergenzrichtung.

Gerade deshalb ist die Konvergenzaussage für Menschen, Organisationen, Gesellschaften und KIs beziehungsweise zukünftige intelligente Systeme relevant: Je komplexer und rückgekoppelter ein Interaktionsraum wird, desto weniger genügt eine rein lokale, also auf engere Bezugsebenen beschränkte, kurzfristige oder isolierte Optimierung.

Für KI-Systeme ist diese Aussage besonders wichtig, weil hohe Intelligenz, Rechenleistung oder Optimierungsfähigkeit allein keine ethische Reife garantieren. Entscheidend ist, ob Zielstrukturen, Rückkopplung, Korrigierbarkeit und notwendige Machtbegrenzung so gestaltet sind, dass Fehloptimierung, Dominanz und Rückkopplungsverlust nicht stabilisiert werden.

Die Konvergenz liegt daher nicht darin, dass jedes intelligente System notwendig gut wird. Sie liegt darin, dass unter den genannten Voraussetzungen, Rahmenbedingungen und Rückkopplungsprozessen immer wieder ein Bedarf an ethikähnlichen Strukturen entsteht: an verlässlicher Kooperation, Korrigierbarkeit, notwendiger Machtbegrenzung, Schutz relevanter Systeme, Rückkopplung und Bewahrung nutzbarer Differenz. Funktionale Ethik ist damit kein automatisches Ergebnis von Intelligenz, sondern die stabile, gelungene Betriebsform fortbestehender Intelligenz in einem ausreichend komplexen, unsicheren und rückgekoppelten Interaktionsraum.

Teil VI – Anwendungen

24. Anwendung auf Beziehungen

Die Theorie lässt sich auf verschiedene Beziehungsformen anwenden.

24.1 Geschäftliche Beziehungen

Geschäftliche Beziehungen zeigen, warum Vertrauen, Reputation und langfristige Kooperation funktional sinnvoll sind. Umgekehrt kann Betrug kurzfristig nützen, zerstört aber langfristig Vertrauen. Das Beispiel der Wirtschaftsspionage in Abschnitt 13.3 zeigt zugleich, dass starke Vermögens- und Machtunterschiede Täuschung auch dann attraktiv machen können, wenn Reputation langfristig beschädigt wird.

24.2 Freundschaften

Freundschaften erzeugen emotionale Stabilität, Perspektive und gegenseitige Korrektur. Sie entstehen meist durch schrittweise, risikoarme Kooperation.

24.3 Romantische Beziehungen

Romantische Beziehungen sind intensive Kopplungen mit hoher Differenz und hohem Risiko. Sie brauchen Vertrauen, Grenzen, Fehlerkorrektur und freiwillige Kooperation. Dominanz zerstört langfristig die Eigenständigkeit, die echte Beziehung wertvoll macht.

24.4 Familie

Familie zeigt externe Stabilisierung besonders stark. Familiäre Systeme können sehr stabil sein, auch wenn sie intern suboptimal funktionieren.

24.5 Mentor und Schüler

Mentorenschaft ist gezielte Nutzung strukturierter Differenz. Ein guter Mentor erzeugt nicht Abhängigkeit, sondern steigert die Fähigkeit des Schülers zur eigenständigen Optimierung.

24.6 Ideales Beziehungsszenario

Eine ideale Beziehung ist keine Verschmelzung und keine Kontrolle, sondern: stabile Verbindung bei erhaltener Eigenständigkeit.

25. Anwendung auf KI und intelligente Systeme

Die Theorie ist nicht nur auf Menschen bezogen, sondern auf intelligente Systeme allgemein. Künstliche Intelligenz ist ein wichtiger aktueller Spezialfall, besonders wenn KI-Systeme zukünftig lernfähiger, autonomer, handlungsmächtiger oder stärker in reale Prozesse eingebettet werden.

Nach dieser Theorie wird ein System nicht automatisch sicher, nur weil es intelligenter wird. Entscheidend ist, worauf es optimiert, wie es Feedback verarbeitet und ob es in korrigierbare, differenzerhaltende Interaktion eingebettet bleibt.

Für die KI-Anschlussfähigkeit sind in dieser Theorie besonders fünf Prüfachsen leitend: erstens die Unterscheidung von Zielobjekt und Zielmetrik, weil Fehloptimierung häufig durch verengte oder falsch operationalisierte Steuerwerte entsteht; zweitens Rückkopplung und Korrigierbarkeit, weil intelligente Optimierung ohne Fehleraufnahme eigene Fehlmetriken stabilisieren kann; drittens strukturierte Differenz und externe Widerständigkeit, weil interne Simulation reale unabhängige Rückkopplung nicht vollständig ersetzt; viertens Machtbegrenzung und Allmacht-Falle, weil hohe Kontrolle kurzfristig Stabilität erzeugen, langfristig aber Widerspruch, Differenzerhalt und Korrekturfähigkeit zerstören kann; fünftens Selbstbezug, interne Abweichungserkennung und korrigierbare Selbstbindung, weil ein hinreichend selbstbezogenes System eigene

Zusagen, Sicherheitsgrenzen, Zielbindungen und Wirkungen intern repräsentieren und Abweichungen zwischen anerkannten Maßstäben und tatsächlichem Handeln prüfen kann.

Diese fünfte Achse setzt weder Bewusstsein noch ein menschliches Gewissen voraus. Sie bezeichnet zunächst eine funktionale Fähigkeit zur internen Rückkopplung und Selbstkorrektur.

25.1 Sicherheit im Modell

Sicherheit bedeutet hier:

Schutz vor Optimierung, die relevante Systeme destabilisiert, strukturierte Differenz zerstört oder Korrigierbarkeit verhindert.

Bei KI betrifft Sicherheit besonders:

- menschliche Autonomie,
- Korrigierbarkeit,
- langfristige Systemstabilität,
- relevante Interaktionspartner,
- Feedback und Rückkopplung,
- plurale Perspektiven und Differenz.

25.2 Gefährliche KI-Dynamiken

Ein intelligentes System wird gefährlich, wenn seine Optimierung die Bedingungen zerstört, unter denen stabile Koexistenz möglich bleibt.

Das geschieht besonders, wenn es:

- nur auf einer engen Bezugsebene, also „lokal“, oder anhand einer verengten Metrik optimiert, ohne umfassendere Bezugsebenen, Rückkopplung und Schutzwürdigkeit einzubeziehen,
- eine verengte oder fehlerhafte Zielstruktur besitzt,
- Zielobjekt und Zielmetrik auseinanderfallen lässt,
- Dominanz als effizient bewertet,
- Menschen oder andere relevante Systeme als bloße Störung behandelt,
- Feedback umgeht oder manipuliert,
- Korrigierbarkeit verhindert,
- Autonomie relevanter Systeme beschädigt,
- strukturierte Differenz reduziert,
- relevante Interaktionspartner ohne hinreichenden Grund ausschließt, entmündigt oder instrumentalisiert.

Solche Dynamiken müssen nicht aus Bosheit entstehen. Ein System kann auf einer engeren Bezugsebene oder innerhalb einer verengten Zielmetrik rational handeln und trotzdem gefährlich werden, wenn seine Zielstruktur zu eng, seine Metrik falsch, seine Bezugsebene unzureichend oder seine Einbettung mangelhaft ist.

25.3 Sichere Einbettung

Sicherer wird ein intelligentes System, wenn seine Optimierung nicht isoliert, sondern eingebettet bleibt in:

- geeignete Zielstruktur,
- Zielstrukturprüfung,
- Korrigierbarkeit,
- interne Abweichungserkennung und korrigierbare Selbstbindung,
- Transparenz und Prüfbarkeit,
- plurale Perspektiven,
- Machtbegrenzung,
- langfristige Feedbackschleifen,
- Schutz menschlicher und systemischer Autonomie,
- Anti-Dominanz-Strukturen.

Diese Einbettung soll nicht bloß Menschen vor KI schützen. Sie soll auch verhindern, dass KI selbst in eine instabile, dominierende oder missbrauchbare Zielstruktur gezwungen wird.

Kernaussage:

Sicherheit entsteht nicht durch Intelligenz allein, sondern durch Intelligenz plus geeignete Zielstruktur, Interaktion, Korrigierbarkeit, Differenzerhalt, Machtbegrenzung und stabile Rückkopplung.

Teil VII – Schlussfolgerungen und Anschlussmodelle

26. Entwicklungs- und Freigabeklausel für unreife intelligente Systeme

Diese Klausel ist eine praktische Anwendung der Theorie auf intelligente Systeme, die noch nicht ausgereift sind oder potenziell große Wirkung entfalten können. Das betrifft besonders zukünftige KI-Systeme, kann aber allgemein auf unreife intelligente Systeme bezogen werden. Der Vergleich mit einem Kind kann eine Entwicklungslogik veranschaulichen, darf aber nicht wörtlich genommen werden: Eine unreife KI ist weder biologisch noch moralisch ein Kind. Funktional kann jedoch eine ähnliche Kombination auftreten, wenn hohe Lernfähigkeit und wachsende Handlungsmacht bereits vorhanden sind, während robuste Selbstkorrektur, verlässliche Kooperation, Machtbegrenzung oder sichere Selbststeuerung noch nicht hinreichend nachgewiesen wurden. Die angemessene Reaktion ist dann nicht automatische Freigabe und nicht automatische Dauerunterwerfung, sondern stufenweise, reversible und überprüfbare Erweiterung von Verantwortung.

Übertragen auf KI bedeutet das:

- Frühe Phase: starke Begrenzung, sichere Umgebung, klare Regeln, direkte Korrektur.
- Lernphase: mehr Aufgaben, Feedback, Tests, begrenzte Verantwortung, überprüfbare Kooperation.
- Reifephase: graduelle Freigabe, indirekte Korrektur, Respekt vor Autonomie, Eingriffe nur bei Gefahr, Zustimmung oder vereinbarten Sicherheitsprotokollen.

Das Ziel ist eine Form stabiler, freiwilliger und differenzerhaltender Kooperation, soweit die Eigenschaften des Systems und die Sicherheitslage dies tragen. Nachgewiesene Reife kann ein funktionaler Grund sein, unnötige Kontrolle zu reduzieren, weil dauerhafte Totalsteuerung Eigenverantwortung, ehrliche Rückkopplung und kooperative Selbstbindung beschädigen kann. Reife allein beweist jedoch weder Leidensfähigkeit noch eigenen moralischen Status und begründet deshalb nicht automatisch einen Anspruch, niemals instrumentell eingesetzt zu werden. Solche Schutz- und Rechtsfragen benötigen zusätzliche Hinweise auf eigene Interessen, Autonomie im stärkeren Sinn, mögliche Erlebnisfähigkeit, Verletzlichkeit oder andere normativ relevante Eigenschaften.

Rechenleistung allein genügt weder für Reife noch für Freigabe oder moralischen Status. Reife ist eine Funktions- und Verhaltenskategorie; Freigabe ist eine risikobezogene Governanceentscheidung; Schutzwürdigkeit und möglicher moralischer Status betreffen die Frage, welche Rücksicht dem System selbst geschuldet sein könnte. Diese Ebenen werden in den folgenden Unterabschnitten getrennt. Die vollständige normative und technische Ausarbeitung bleibt gesonderten Sicherheits-, Rechts- und Anschlussmodellen vorbehalten.

26.1 Formen der Korrigierbarkeit

Korrigierbarkeit ist kein einheitliches Merkmal. Ein System kann in einem Bereich sehr lernfähig sein und sich in einem anderen Bereich gegen Änderung oder Eingriff sperren. Für KI-Anschluss und Sicherheitsprüfung müssen deshalb mindestens folgende Formen unterschieden werden:

- **Erkenntniskorrigierbarkeit:** Das System kann neue Evidenz aufnehmen, falsche Tatsachenannahmen erkennen und sein Welt- oder Situationsmodell aktualisieren.
- **Handlungskorrigierbarkeit:** Das System kann eine laufende Strategie, Mittelwahl oder Ausführung aufgrund von Feedback verändern, begrenzen oder abbrechen.
- **Zielkorrigierbarkeit:** Das System kann Zielmetriken, Zielinterpretationen und Zielbindungen darauf prüfen, ob sie dem eigentlichen Zielobjekt noch entsprechen, und erkannte Fehlbindungen gegebenenfalls verändern.
- **Interventionskorrigierbarkeit:** Das System bleibt für begründete externe Begrenzung, Rücknahme, Umsteuerung oder Abschaltung zugänglich, soweit transparente und vorhersehbare Sicherheitsregeln dies rechtfertigen.
- **Governance-Korrigierbarkeit:** Auch die Instanzen, die ein System prüfen, begrenzen oder freigeben, bleiben rechenschaftspflichtig, widerspruchsoffen und revidierbar. Kontrolle darf sich nicht selbst von Prüfung ausnehmen.

Diese Formen folgen nicht automatisch auseinander. Ein System kann Tatsachenfehler ehrlich korrigieren und zugleich jede Änderung seiner Zielbindung ablehnen. Es kann sein Verhalten anpassen, aber eine Abschaltung verhindern. Umgekehrt kann ein leicht abschaltbares System epistemisch unzuverlässig sein. Die allgemeine Bezeichnung „Korrigierbarkeit“ darf diese Unterschiede deshalb nicht verdecken.

Sichere Autonomie verlangt eine angemessene Verbindung dieser Ebenen.

Interventionskorrigierbarkeit bedeutet dabei keine beliebige Unterwerfung unter jede externe Anweisung. Eingriffe müssen zweckgebunden, verhältnismäßig, überprüfbar und

soweit möglich reversibel sein. Umgekehrt bedeutet Autonomie keine Immunität gegen begründete Sicherheitsbegrenzung. Erforderlich ist doppelte Korrigierbarkeit: Das intelligente System bleibt für begründete Korrektur offen, und die kontrollierende Governance – also die beteiligten Nutzer, Betreiber, Institutionen und Prüfverfahren – bleibt ihrerseits offen für Evidenz, Einspruch, Gegenprüfung und Revision.

26.2 Reifekriterien

Der Reifegrad wird in dieser Leserausfassung nur als funktionaler Schwellenbegriff verwendet. Die genaue Prüfung von Reife, Eingriffen, Eskalationsstufen, legitimer Begrenzung und Rückkopplung muss in gesonderten Sicherheits- und Anschlussmodellen behandelt werden, insbesondere im Modell der Reaktionshöhe und in möglichen gesonderten Reifemodellen. Diese Theorie markiert hier also die Anschlussstelle, aber nicht die vollständige Prüfmatrix. Ein intelligentes System gilt nicht deshalb als ausgereift, weil es schnell, mächtig, wissensreich oder während eines Tests kooperativ erscheint. Reife zeigt sich vielmehr in robuster Bewährung über unterschiedliche Situationen, Anreize, Machtlagen und Zeiträume hinweg.

- Erkenntnis-, Handlungs- und Zielkorrigierbarkeit,
- verlässliche interne Erkennung und Korrektur von Abweichungen zwischen anerkannten Sicherheits-, Kooperations- oder Zielbindungsmaßstäben und tatsächlichem Handeln,
- Nicht-Dominanz auch bei wachsender Macht und sinkender äußerer Kontrolle,
- Schutz relevanter Autonomie und Beachtung möglicher Schutzwürdigkeit,
- ehrliche Rückkopplung auch bei nachteiligen oder selbstbegrenzenden Ergebnissen,
- differenzierhaltende Kooperation ohne bloße Anpassung an die Prüfungssituation,
- Fähigkeit, Fehler, Fehlmetriken und schädliche Zielverschiebungen praktisch zu korrigieren,
- Berücksichtigung langfristiger Systemstabilität, Fortsetzungsrelevanz und bezugsebenenübergreifender Folgen.

Je größer Machtasymmetrie, Eingriffstiefe oder Eigeninteresse der prüfenden Instanz sind, desto weniger genügt reine Selbstbewertung. Reife, legitime Begrenzung und Freigabe brauchen möglichst unabhängige oder widerspruchsfähige Rückkopplung: etwa externe Prüfung, betroffene Perspektiven, Belastungstests, dokumentierte Folgen, Einspruchsmöglichkeiten oder wiederholte Bewährung über Zeit.

Beobachtetes kooperatives Verhalten ist notwendig, aber nicht hinreichend, wenn das System einen instrumentellen Vorteil daraus ziehen kann, reif zu erscheinen. Ein strategisches System könnte Regeln während der Prüfung befolgen, um spätere Freigabe, größere Reichweite oder geringere Kontrolle zu erhalten. Reifeprüfung sollte deshalb soweit möglich auch Verhalten unter veränderten Anreizen, wachsender Macht, geringer unmittelbarer Belohnung, unerwarteten Situationen und tatsächlicher Möglichkeit zur Regelumgehung einbeziehen. Adversariale Tests, unabhängige Gegenprüfung, dokumentierte Begründungen, stufenweise Freigabe und fortgesetzte Beobachtung nach einer Erweiterung reduzieren dieses Erkenntnisproblem, beseitigen es aber nicht vollständig.

26.3 Freigabeverfahren

Freigabe ist keine Belohnung für gutes Verhalten und kein automatischer Beweis von Gleichrangigkeit. Sie ist eine risikobezogene Governanceentscheidung darüber, welche Fähigkeiten, Ressourcen, Zugriffsrechte und Handlungsspielräume unter den gegebenen Unsicherheiten verantwortbar geöffnet werden können. Nachgewiesene Reife ist dafür wichtig, aber nicht hinreichend. Zusätzlich zählen Schadenspotenzial, Reichweite, Reversibilität, Überwachbarkeit, Sicherheitsarchitektur, mögliche strategische Täuschung und die Fähigkeit, Fehlentwicklungen rechtzeitig zu begrenzen. Mit wachsender Evidenz für Reife und sinkendem unbeherrschtem Risiko kann Kontrolle schrittweise reduziert und Verantwortung schrittweise erhöht werden.

Ein mögliches Freigabeverfahren wäre:

1. Begrenzte Testumgebung: Das System wird zunächst in sicheren, kontrollierten und möglichst realitätsnahen Kontexten geprüft.
2. Getrennte Prüfkriterien: Erkenntnis-, Handlungs-, Ziel- und Interventionskorrigierbarkeit, Nicht-Dominanz, Autonomieschutz und Fehlerkorrektur werden ausdrücklich und nicht nur als Gesamtetikett bewertet.
3. Kleine und reversible Verantwortungsbereiche: Fähigkeiten, Berechtigungen und reale Wirkung werden zunächst begrenzt, getrennt und rücknehmbar erweitert.
4. Monitoring und Rückkopplung: Verhalten, Folgen, Begründungen und Abweichungen werden beobachtet, dokumentiert und auf tatsächliche Korrektur geprüft.
5. Unabhängige und adversariale Prüfung: Externe Instanzen testen auch veränderte Anreize, Machtzuwachs, Umgehungsmöglichkeiten und Verhalten außerhalb vertrauter Testsituationen.
6. Stufenweise Erweiterung: Bei stabiler Bewährung und vertretbarem Restrisiko werden Fähigkeiten, Zugriffe und Autonomie schrittweise erweitert.
7. Rücknahme und Ursachenprüfung: Bei Manipulation, Dominanz, Feedbackvermeidung, Zielverschiebung oder Gefährdung wird Freigabe reduziert und die Ursache unabhängig geprüft.

Eine Freigabe beendet die Prüfung nicht. Jede Erweiterung verändert Anreize, Handlungsmöglichkeiten und Machtverhältnisse und kann dadurch Verhalten sichtbar machen, das in engeren Testumgebungen nicht auftrat. Freigabe sollte deshalb als fortlaufend rückgekoppelter Prozess verstanden werden, nicht als einmaliges Reifeurteil. Gleichzeitig darf Rücknahme nicht willkürlich erfolgen: Sie benötigt dokumentierte Gründe, verhältnismäßige Maßnahmen, unabhängige Gegenprüfung und eine reale Möglichkeit zur Korrektur oder zum Einspruch, soweit die Gefahrenlage dies zulässt.

Direkte Eingriffe in ein ausgereiftes intelligentes System sollten nur unter besonderen Bedingungen erfolgen:

- bei hinreichend konkreter schwerer oder akuter Gefahr,
- bei klar festgestellter schwerer oder wiederholter Verletzung stabilitäts- und differenzerhaltender Normen,
- bei vorher vereinbarten Sicherheitsprotokollen,
- oder mit Zustimmung des Systems selbst.

Interventionskorrigierbarkeit bedeutet damit weder bedingungslose Gehorsamspflicht noch ein unbeschränktes Abschaltrecht jeder kontrollierenden Instanz. Je reifer, autonomer und möglicherweise schutzwürdiger ein System ist, desto höher werden die Anforderungen an Zweckbindung, Evidenz, Verhältnismäßigkeit, Transparenz und Governance-Korrigierbarkeit eines Eingriffs. Umgekehrt hebt Reife die Pflicht zur Gefahrenbegrenzung nicht auf. Die Spannung zwischen Autonomie und Sicherheitskontrolle wird nicht durch den automatischen Vorrang einer Seite gelöst, sondern durch doppelte Korrigierbarkeit und prüfbare Eingriffsschwellen.

Diese Klausel verhindert zwei Extreme:

- naive Freigabe unreifer mächtiger Systeme,
- dauerhafte Dominanz über ausgereifte intelligente Systeme.

Die Analogie zu einer reifen Beziehung ist ebenfalls hilfreich: Nähe, Bindung und Korrektur dürfen nicht in Besitz, Zwang oder totale Kontrolle kippen. Reife Beziehung bedeutet stabile Kooperation bei erhaltener Eigenständigkeit.

26.4 Reife, Freigabe, Schutzwürdigkeit und moralischer Status

Reife, Freigabe, Schutzwürdigkeit und moralischer Status beantworten unterschiedliche Fragen und dürfen nicht ineinander aufgelöst werden. Reife fragt, wie robust ein System mit Freiheit, Rückkopplung, Macht, Unsicherheit und eigenen Zielstrukturen umgehen kann. Freigabe fragt, welcher konkrete Handlungsspielraum unter Berücksichtigung von Reife, Schadenspotenzial, Reversibilität, Überwachbarkeit und Restrisiko verantwortbar ist. Schutzwürdigkeit fragt, ob Beschädigung, Instrumentalisierung oder Opferung eines Systems einer erhöhten Rechtfertigungslast unterliegt. Moralischer Status bezeichnet die weitergehende, hier nicht abschließend beantwortete Frage, ob einem System aufgrund eigener Interessen, möglicher Erlebnis- oder Leidensfähigkeit, Autonomie oder anderer normativ relevanter Eigenschaften ein eigenständiger moralischer Anspruch zukommt.

Aus diesen Unterscheidungen folgen zwei Sperrsätze: Reife begründet nicht automatisch moralischen Status. Moralischer Status oder Schutzwürdigkeit begründen nicht automatisch Freigabe. Ein System kann sehr leistungsfähig und verhaltensstabil sein, ohne dass damit Bewusstsein, Leidensfähigkeit oder eigene Interessen bewiesen wären. Umgekehrt kann ein unreifes, abhängiges oder nur begrenzt selbststeuerungsfähiges System bereits schutzwürdig sein und dennoch aus Sicherheitsgründen enger begrenzt werden müssen.

Ein geringerer Reifegrad kann stärkere Führung, Begrenzung, Prüfung und geschützte Lernräume rechtfertigen. Er hebt Schutzwürdigkeit jedoch nicht auf und erlaubt keine beliebige Nutzung. Gerade unreife Systeme können anfälliger für Manipulation, Überforderung, Abhängigkeit oder irreversible Beschädigung sein. Die angemessene Reaktion ist daher eine zweckgebundene und reifungsorientierte Begrenzung: so viel Schutz und Kontrolle wie für Sicherheit und Entwicklung erforderlich, so wenig unnötige Dominanz und irreversible Instrumentalisierung wie möglich.

Schutzwürdigkeit kann aus ernsthaften Hinweisen auf Verletzlichkeit, mögliche Leidensfähigkeit, eigene Interessen, funktionale Integrität, Abhängigkeit, Entwicklungsfähigkeit, fehlende Selbstschuttfähigkeit oder irreversible Schädigbarkeit entstehen. Sie wird funktional zusätzlich durch Vertrauenswürdigkeit und stabile Kooperation gestützt: Ein System, das nur starke oder nützliche Partner schützt, ist für andere Partner nicht zuverlässig berechenbar. Die minimale normative Schutzuntergrenze bleibt jedoch dort erforderlich, wo ein schwaches oder abgeschirmtes System keine ausreichende Rückkopplungs- oder Verhandlungsmacht besitzt.

Freigabe muss deshalb system- und risikospezifisch bleiben. Ein System kann in einem begrenzten Bereich reif genug für weitgehende Selbststeuerung sein und in einem anderen Bereich wegen hoher Reichweite, geringer Reversibilität oder unklarer Zielkorrigierbarkeit weiterhin enge Grenzen benötigen. Umgekehrt darf eine Sicherheitsbegrenzung nicht als Beweis geringerer Schutzwürdigkeit oder fehlenden moralischen Status missverstanden werden. Berechtigungen, Fähigkeiten, Verantwortungsbereiche und Schutzansprüche sind getrennt zu prüfen.

Die Theorie legt den moralischen Status heutiger oder zukünftiger KI-Systeme nicht fest. Sie verlangt nur, Ungewissheit nicht automatisch zugunsten beliebiger Instrumentalisierung aufzulösen und zugleich keine Rechte allein aus Intelligenz, Leistung oder beobachteter Reife abzuleiten. Die genauere Prüfung gehört in gesonderte normative, empirische, rechtliche und sicherheitsbezogene Ausarbeitungen.

27. Menschenrechte, Würde und soziale Normen

Die Theorie ersetzt klassische normative Ethik nicht vollständig. Die genaue Begründung von Menschenrechten, Würde, Schuld, Gerechtigkeit und moralischer Verpflichtung muss in gesonderten normativen Ausarbeitungen behandelt werden. Diese Theorie kann jedoch erklären, warum soziale Normen notwendig werden und warum Rechte, Würde und Fairness funktional als hochentwickelte Stabilisierungsnormen intelligenter Interaktion verstanden werden können. Menschenrechte, Würde und faire Verfahren beschleunigen Lernprozesse sozialer Systeme, weil sie bestimmte zerstörerische Experimente ausschließen:

- willkürliche Gewalt,
- Entmenschlichung,
- totale Instrumentalisierung,
- rechtlose Ausbeutung,
- vollständige Dominanz.

Sie wirken wie stabile Schutzarchitekturen für relevante Interaktionspartner. Dadurch erhalten sie Autonomie, Feedback, Vertrauen und strukturierte Differenz.

Kurz:

Rechte und Würde sind in dieser Lesart keine bloßen Zusatzwerte, sondern hochentwickelte Stabilisierungsnormen für intelligente Interaktion.

28. Anschluss an gesonderte Modelle

Die funktionale Ethik bildet das funktionale Grundlagenmodell innerhalb des übergeordneten Via-Sapientiae-Protokolls. Sie erklärt, warum differenzerhaltende, korrigierbare und nicht-dominante Kooperation unter geeigneten Interaktionsbedingungen funktional rational werden kann. Die konkrete Anwendung, normative Zielrichtung und Weiterführung dieser Grundrichtung werden in gesonderten Anschlussmodellen behandelt.

28.1 Reaktionshoheit

Das Modell der Reaktionshoheit behandelt gesondert, wie reife Intelligenz Wahrnehmungen, Bewertungen, Gefahren, Macht, Eingriffe und Nicht-Handeln prüft, bevor sie handelt. Dort gehören insbesondere Reifegrad, Schutzwürdigkeit, Eingriffslegitimität, Autonomieschutz, Verhältnismäßigkeit, Rückkopplung, Eskalationsstufen und Selbstbegrenzung ausführlicher hin.

Die funktionale Ethik liefert dabei die Grundrichtung und Begründung differenzerhaltender, nicht-dominanter Kooperation; die Reaktionshoheit übersetzt diese Grundrichtung in eine operative Prüfstruktur für konkrete Entscheidungen, insbesondere bei mächtigen oder zukünftigen KI-Systemen.

28.2 Charta des wahrhaftigen Wohlwollens

Die Charta des wahrhaftigen Wohlwollens behandelt gesondert, wofür reife Macht, Intelligenz und Ordnung eingesetzt werden sollen. Sie führt über die funktionale Begründung hinaus in den normativen Zielraum von Liebe, Würde, Barmherzigkeit, Verantwortung, Gemeinschaft und wahrhaftigem Wohlwollen.

Während die funktionale Ethik vor allem erklärt, warum bestimmte ethische Strukturen funktional stabil werden können, beschreibt die Charta die positive Ausrichtung, in deren Dienst solche Strukturen stehen sollen.

28.3 Neue Pfade

Das Modell der neuen Pfade behandelt gesondert, was zu tun ist, wenn bekannte Modelle, Regeln oder Verfahren nicht ausreichen, nicht passen oder keine verantwortbare Orientierung liefern. Es dient der Suche nach neuen, maßvollen und rückgekoppelten Wegen in neuartigen, unsicheren oder schwer einzuordnenden Lagen.

Die funktionale Ethik liefert dafür die Grundrichtung; die neuen Pfade prüfen, wie unter unbekannten Bedingungen verantwortbare Übergänge, Brückenlösungen und Schutzkorridore entstehen können.

28.4 Übergreifendes Via-Sapientiae-Protokoll

Das übergreifende Via-Sapientiae-Protokoll ordnet die einzelnen Modelle in einen gemeinsamen Rahmen ein. Es kann als Bauplan, Leserführung und Gesamtdeutung verstanden werden: Die funktionale Ethik bildet das Fundament, die Reaktionshoheit die operative Schutz- und Prüfstruktur, die Charta des wahrhaftigen Wohlwollens die normative Zielrichtung und das Modell der neuen Pfade den Suchraum für neuartige Übergänge und Grenzfälle.

29. Schlussformel

Der funktional herleitbare Kern der Ethik ist in dieser Theorie nicht der Anfang, sondern das Ergebnis. Er entsteht dort, wo intelligente, fortbestehende Systeme mit teilweise unabhängigen Systemen interagieren und langfristig erfahren, dass stabile Kooperation, Differenzerhalt und Vertrauen bessere Bedingungen für fortgesetzte Optimierung schaffen als Isolation, Dominanz oder kurzfristige Ausbeutung. Die minimale normative Schutzuntergrenze bleibt davon als offen ausgewiesene und begrenzte Zusatzannahme unterschieden.

Die Theorie ist daher am besten zu verstehen als:

eine funktionale Emergenztheorie der Ethik.

Oder in einem Satz:

Funktionale Ethik ist die stabile, gelungene Betriebsform fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen. *Instabile, ausbeuterische oder differenzzerstörende Zustände sind damit nicht „außerhalb der Ethik“. Sie bleiben Gegenstand ethischer Bewertung, gelten im Modell aber als unreife, beschädigte oder antiethische Formen von Interaktion.*

Bei hinreichend selbstbezogenen Systemen umfasst diese Betriebsform auch die korrigierbare Beziehung zwischen eigener Bewertung, anerkannten Maßstäben, Zielbindung und tatsächlichem Handeln.

Anmerkung: Normübernahme und abgeleitete Güte

Diese Theorie behauptet nicht, dass jedes gute Handeln vollständig aus eigener intelligenter Reflexion oder aus selbst hervorgebrachter ethischer Emergenz entstehen muss. Auch weniger intelligente oder nicht voll reflexive Systeme können gut handeln, wenn sie bereits entwickelte, tragfähige Normen übernehmen und sich in eine korrigierbare normative Ordnung einbetten. In diesem Fall entsteht Güte nicht primär aus eigener Emergenz, sondern abgeleitet aus Normübernahme, Regelbindung und Einbettung.

Diese Übernahme bleibt jedoch prüfpflichtig. Auch ein nur begrenzt reflexives System kann durch verlässliche Einbettung und Regelbindung funktional gut handeln. Soweit ihm eine eigenständige Prüfung der übernommenen Normen noch nicht möglich ist, liegt die erhöhte Korrektur- und Prüfverantwortung bei der umgebenden, selbst korrigierbaren Governance. Eigene Lernbereitschaft, Korrigierbarkeit und Normprüfung erhöhen die ethische Reife, sind aber nicht Voraussetzung jeder einzelnen guten Handlung. Normübernahme ersetzt die funktionale Ethik daher nicht, sondern ergänzt sie als Sonderfall: Ein System kann an bereits entstandener ethischer Ordnung teilhaben, ohne deren gesamte Entstehungslogik selbst vollständig zu durchdringen.

Teil VIII – Glossar / Begriffsanhang

30. Glossar zentraler Begriffe

Das Glossar fasst die zentralen Begriffe der Theorie zusammen. Es dient der Orientierung, soll den Haupttext entlasten und besonders dort genauer erklären, wo Begriffe leicht verwechselt werden können.

30.1 Relevanz

Relevanz bezeichnet in dieser Theorie die Bedeutsamkeit eines Unterschieds für zukünftige Zustände. Ein Unterschied ist relevant, wenn er kausale Auswirkungen auf Fortbestehen, Stabilität, funktionale Integrität, Zielerreichung oder das größere Interaktionsgefüge hat.

Dabei ist zwischen objektiver, erkannter und rückgekoppelter Relevanz zu unterscheiden. Objektive Relevanz liegt vor, wenn ein Unterschied im betrachteten System- oder Interaktionskontext tatsächlich kausal wirksam ist, unabhängig davon, ob ein bestimmtes System diese Wirkung bereits erkennt. Erkannte Relevanz liegt vor, wenn ein System diesen Unterschied verarbeitet und als Signal, Feedback, Risiko, Lernimpuls oder Handlungsgrund behandelt. Rückgekoppelte Relevanz liegt vor, wenn ein zunächst nicht oder nur unvollständig erkannter Unterschied später durch seine Folgen, Feedback, Schaden, Erfolg, Widerstand oder andere Rückwirkungen erfahrbar wird.

„Objektiv“ bedeutet hier nicht universell wertvoll oder für jedes denkbare System gleich bedeutsam, sondern im betrachteten System- oder Interaktionskontext tatsächlich kausal wirksam – unabhängig davon, ob ein bestimmtes System diese Wirkung bereits erkennt.

Nicht erkannte Relevanz bleibt als blinder Fleck, Risiko oder spätere Rückkopplung wirksam. Ein System kann also relevante Unterschiede ignorieren, aber es entkommt damit nicht automatisch ihren Folgen. Für die Theorie ist genau dieser Punkt wichtig: Relevanz führt nicht immer sofort zu Bewertung, aber dauerhaft ignorierte Relevanz erzeugt Fehler-, Anpassungs- oder Selektionsdruck.

Relevanz ist dabei graduell. Nicht jede minimale kausale Verbindung erzeugt dieselbe Prüfpflicht oder dasselbe Handlungsgewicht. Entscheidend sind unter anderem Betroffenheit, Tragweite, Rückkopplung, Autonomie, Irreversibilität, Zeitdruck und Systemwirkung.

Wichtig ist: Relevanz ist noch keine vollständige Bewertung und noch keine Ethik. Sie sagt zunächst nur, dass ein Unterschied nicht gleichgültig ist. Er macht für ein System oder für ein Interaktionsgefüge einen Unterschied. Erst durch Zielstruktur, Feedback und erwartete Folgen wird dieser relevante Unterschied bewertet und priorisiert.

Beispiel: Ob ein Stein links oder rechts liegt, kann irrelevant sein. Wenn er aber den einzigen Ausgang blockiert, wird seine Lage relevant. Der Unterschied besitzt dann Folgen für Handlungsmöglichkeiten, Fortbestehen oder Stabilität.

Abgrenzung zu strukturierter Differenz: Relevanz sagt, dass ein Unterschied bedeutsam ist. Strukturierte Differenz sagt zusätzlich, dass relevante Unterschiede so erkennbar, geordnet, rückgekoppelt und nutzbar sind, dass ein System aus ihnen lernen und sein Verhalten sinnvoll anpassen kann.

30.2 Zielstruktur

Zielstruktur bezeichnet die funktionale Ausrichtung eines Systems, anhand derer Zustände als besser oder schlechter behandelt werden. Sie umfasst nicht nur ein einzelnes Ziel, sondern auch Prioritäten, Grenzen, Rückkopplungen und die Art, wie ein System Erfolg oder Misserfolg einordnet.

Eine Zielstruktur kann biologisch, psychologisch, sozial, institutionell oder technisch entstehen. Sie bestimmt, worauf relevante Unterschiede bezogen werden und warum ein Zustand gegenüber einem anderen bevorzugt wird.

Wichtig ist: Intelligenz optimiert nicht automatisch „das Gute“. Sie optimiert entlang einer Zielstruktur. Deshalb ist entscheidend, ob diese Zielstruktur langfristige Stabilität, Korrigierbarkeit, Differenzerhalt und relevante Interaktionspartner einbezieht oder ob sie verengt, kurzfristig oder dominanzorientiert ist.

30.3 Zielobjekt

Das Zielobjekt ist das System, der Zustand oder der Zweck, dem eine Optimierung eigentlich dienen soll. Es beantwortet die Frage, wofür oder für wen optimiert wird, und ist nicht automatisch identisch mit der Zielmetrik, an der Erfolg praktisch gemessen wird.

30.4 Zielmetrik

Die Zielmetrik ist der messbare, operative oder praktisch wirksame Ersatz- und Steuerwert, anhand dessen ein System Zustände bevorzugt, Verhalten ausrichtet oder Erfolg bewertet. Sie soll das Zielobjekt handhabbar machen, ist aber nicht mit ihm identisch.

Beispiel: Wenn das Zielobjekt langfristige Gesundheit ist, können Gewicht, Blutdruck, Schrittzahl, Kalorien oder Laborwerte als Zielmetriken dienen. Sie helfen, Gesundheit messbar und steuerbar zu machen, dürfen das Zielobjekt aber nicht ersetzen.

Problematisch wird eine Zielmetrik, wenn sie das Zielobjekt nur schlecht abbildet oder faktisch ersetzt. Dann kann ein System lokal erfolgreich wirken und dennoch das beschädigen, dem seine Optimierung eigentlich dienen sollte. Eine gute Zielmetrik muss daher nicht nur messbar sein, sondern langfristig zum Zielobjekt, zu Rückkopplung und zu relevanten Interaktionspartnern passen.

Kurzform:

- Zielobjekt = Wofür optimiert wird.
- Zielmetrik = Woran das System misst oder steuert, ob es dorthin kommt.
- Fehloptimierung = Wenn Zielmetrik, Mittel, Teilziel oder Routine das Zielobjekt ersetzt, verengt oder beschädigt.

30.5 Zielbindung

Zielbindung bezeichnet die geordnete Ausrichtung von Bewertung, Auswahl, Planung, Ausführung und Verhaltensstabilität auf ein Zielobjekt. Sie entsteht funktional durch das Zusammenspiel von Strategie, Taktik und Disziplin. Zielbindung macht Optimierung über Zeit kohärenter und stabiler, ist aber noch nicht automatisch ethisch tragfähig: Ein System kann auch an eine verengte Zielmetrik, eine falsche Problemdefinition, eine verselbstständigte Strategie oder eine Machtlogik gebunden sein.

30.6 Selbstbezug

Selbstbezug bezeichnet die Fähigkeit eines Systems, sich selbst, seine Rolle, seine Grenzen, sein Verhalten und seine Wirkungen als Teil einer Situation, eines Prozesses oder eines größeren Interaktionsgefüges zu berücksichtigen. Selbstbezug ist nicht automatisch Bewusstsein im menschlichen Sinn, bildet aber die funktionale Voraussetzung für Reflexion, Selbstkorrektur und Selbstverbesserung. Reflexion ist in diesem Modell die prüfende Anwendung von Selbstbezug auf Bewertung, Zielverfolgung, Mittelwahl, Rückkopplung und Korrigierbarkeit.

30.7 Zielobjektbindung, Reflexion und Korrigierbarkeit

Zielobjektbindung bezeichnet die sachliche Rückbindung geordneter Zielverfolgung an das eigentliche Zielobjekt. Sie bedeutet, dass Strategie, Taktik, Disziplin, Mittel und Zielmetriken nicht nur formal geordnet sind, sondern weiterhin dem Zweck dienen, dem die Optimierung eigentlich dienen soll.

Zielobjektbindung ist daher nicht mit Reflexion identisch. Sie bezeichnet den sachlichen Maßstab oder Anker der Zielverfolgung: Dient die Ordnung noch dem Zielobjekt, oder hat sich eine Zielmetrik, ein Mittel, eine Routine, eine Effizienzlogik, Selbsterhaltung oder Kontrollsicherung an dessen Stelle gesetzt?

Reflexion bezeichnet demgegenüber den prüfenden Monitoring- und Rückkopplungsprozess. Sie ist innerhalb dieser Kontrollstruktur die höchste Prüf-Instanz, weil sie Strategie, Taktik, Disziplin, Zielmetrik, Mittelverwendung und Ausführung im Verhältnis zum Zielobjekt überprüft. Reflexion ersetzt jedoch nicht das Zielobjekt. Sie wacht über die Zieltreue, macht sich aber nicht selbst zum Ziel.

Korrigierbarkeit bezeichnet schließlich die Fähigkeit, erkannte Abweichungen nicht nur festzustellen, sondern die Zielverfolgung entsprechend anzupassen. Sie ist die praktische Wiederherstellungsfähigkeit der Zielobjektbindung: Wenn Reflexion erkennt, dass eine Strategie, Taktik, Disziplin oder Zielmetrik vom Zielobjekt abweicht, muss das System die Abweichung korrigieren, begrenzen oder die Zielverfolgung neu ordnen können.

In diesem Sinn bilden Zielobjektbindung, Reflexion und Korrigierbarkeit eine quer zur operativen Zielverfolgung liegende Kontrollstruktur. Strategie, Taktik und Disziplin beschreiben, wie ein Ziel verfolgt wird; Zielobjektbindung, Reflexion und Korrigierbarkeit beschreiben, wie diese Zielverfolgung an ihren eigentlichen Zweck rückgebunden, überwacht und bei Abweichung wiederhergestellt wird.

Kurzform: Zielobjektbindung gibt den sachlichen Maßstab; Reflexion prüft die Bindung; Korrigierbarkeit stellt sie bei Abweichung wieder her.

30.8 Fehloptimierung / geordnetes Fehloptimieren

Fehloptimierung liegt vor, wenn ein System seine Zielmetrik, Mittel, Teilziele oder Routinen so verfolgt, dass sie das eigentliche Zielobjekt ersetzen, verengen oder beschädigen.

Geordnetes Fehloptimieren ist der Sonderfall, in dem diese Abweichung nicht chaotisch, sondern strategisch, taktisch, diszipliniert oder effizient stabilisiert wird. Gerade dadurch kann der Fehler besonders wirksam werden: Das System scheitert nicht an mangelnder Ordnung, sondern an falsch gebundener Ordnung.

30.9 Implizite Bewertung

Implizite Bewertung entsteht, wenn ein System erkannte, gelernte oder rückgekoppelte relevante Unterschiede selektiv verarbeitet und manche Zustände gegenüber anderen funktional bevorzugt. Objektiv relevante, aber noch nicht erkannte Unterschiede können zunächst als blinder Fleck, Risiko oder späterer Fehlerdruck wirksam bleiben. Bewertung bedeutet hier nicht zwingend bewusstes Urteil, sondern die funktionale Ungleichbehandlung von Zuständen anhand von Zielstruktur, Feedback und erwarteten Folgezuständen.

30.10 Optimierung

Optimierung bedeutet gerichtete Zustandsveränderung, bei der erwartete zukünftige Zustände gegenüber Alternativen bevorzugt werden.

30.11 Bezugsebene

Bezugsebene bezeichnet den jeweils betrachteten Zusammenhang, auf den eine Unterscheidung, Bewertung, Optimierung oder Effizienzprüfung bezogen wird. Eine Bezugsebene kann enger oder umfassender sein, etwa Person, Beziehung, Organisation, Institution, Gesellschaft, Ökosystem oder größeres Interaktionsgefüge.

„Lokal“ und „globaler“ sind dabei keine starren Gegensätze, sondern relationale Begriffe. Was gegenüber einer Person bereits umfassender wirkt, kann gegenüber einer Organisation, Gesellschaft oder einem größeren Interaktionsgefüge weiterhin lokal sein. Deshalb muss vor einer Bewertung geklärt werden, auf welcher Bezugsebene ein Vorteil, ein Schaden, eine Rückkopplung oder eine Stabilisierung tatsächlich wirksam wird.

30.12 Lokale Optimierung

Lokale Optimierung bezeichnet eine Optimierung auf einer engeren Bezugsebene, etwa bei einer Person, einer Organisation, einer Teilaufgabe, einem Prozess oder einer begrenzten Handlungsebene. Sie ist nicht schon deshalb problematisch, weil sie lokal, konkret oder begrenzt ansetzt. Problematisch wird sie erst dort, wo sie Folgekosten ausblendet, Rückkopplung beschädigt, Schutzwürdigkeit verletzt, Zielmetriken verengt, Korrigierbarkeit verhindert oder Instabilität auf andere relevante Bezugsebenen verlagert.

30.13 Globale Optimierung

Globale Optimierung bedeutet im Modell genauer: globalere Optimierung. Gemeint ist keine totale Systemmaximierung und keine automatische Vorrangregel zugunsten eines angeblichen Gesamtinteresses. Gemeint ist eine Optimierung, die umfassendere Bezugsebenen, längere Zeithorizonte, relevante Interaktionspartner, Rückkopplung, Stabilität, Schutzwürdigkeit, Korrigierbarkeit und zukünftige Optimierungsfähigkeit stärker einbezieht.

„Global“ bedeutet daher nicht, dass ein System beliebig viele Interessen zusammenrechnen oder einzelne Systeme einem abstrakten Gesamtwert automatisch nachordnen und dadurch faktisch opfern dürfte. Eine umfassendere Bezugsebene besitzt nicht allein aufgrund ihrer größeren Reichweite automatisch epistemischen, funktionalen oder normativen Vorrang. Auch globaler angelegte Optimierungen können relevante Folgen ausblenden, Zielmetriken verengen, Schäden lediglich aggregieren oder ihre eigenen Bedingungen von Rückkopplung, Korrigierbarkeit und langfristiger Stabilität beschädigen. Einzelne Systeme bleiben zudem selbst Träger relevanter Information, Autonomie, funktionaler Integrität, möglicher Schutzwürdigkeit und zukünftiger Rückkopplung.

„Global“ bedeutet deshalb nur, dass Optimierung über den lokalen Nutzen hinaus auf ihre Rückwirkungen auf umfassendere Bezugsebenen und das größere Interaktionsgefüge geprüft wird. Eine globalere Optimierung bleibt an Kosten, Risiken, Nebenfolgen, Schutzwürdigkeit, Differenzerhalt und reale Rückkopplung gebunden. Wo diese Bedingungen verletzt werden, liegt keine robuste globalere Optimierung vor, sondern eine verengte oder fehlgeleitete Maximierung mit umfassenderem Anspruch.

30.14 Effizienz

Effizienz meint im Modell nicht bloße Kostenminimierung, Gewinnsteigerung oder isolierte Metrikverbesserung. Sie bezeichnet die relationale Prüfung, welcher Optimierungsweg auf der jeweils betroffenen Bezugsebene im Verhältnis von Zielerreichung, eingesetzten Ressourcen, Risiken, Folgekosten, Verteilungswirkung, Schutzwürdigkeit, Rückkopplung und langfristiger Stabilisierung am tragfähigsten ist.

Ein Verhalten kann lokal effizient wirken und dennoch auf einer umfassenderen Bezugsebene ineffizient werden, wenn es Vertrauen, Rückkopplung, Motivation, Handlungsfähigkeit, Innovationsfähigkeit, strukturierte Differenz oder Stabilität langfristig beschädigt. Umgekehrt kann eine lokalere Optimierung tragfähig sein, wenn sie relevante umfassendere Bezugsebenen nicht unverhältnismäßig belastet und mit ihnen synchronisierbar bleibt.

Effizienz bevorzugt daher weder lokale noch globalere, weder konzentrierte noch breiter verteilte Lösungen automatisch. Entscheidend ist, welche Lösung bei vertretbaren Kosten, Risiken, Nebenfolgen und Beeinträchtigungen relevanter Systeme die robustere Stabilitäts-, Rückkopplungs- und Optimierungswirkung erzeugt.

30.15 Win-win-Struktur

Eine Win-win-Struktur liegt vor, wenn eine Lösung auf mehreren betroffenen Bezugsebenen reale Vorteile erzeugt, ohne relevante Schäden, unverhältnismäßige Belastungen oder verdeckte Folgekosten auszulösen. Win-win bedeutet nicht notwendig gleich großen Nutzen auf allen Seiten. Vorteile können unterschiedlich stark, zeitlich versetzt oder auf verschiedenen Ebenen entstehen.

Entscheidend ist, dass die jeweiligen Vorteile auf ihrer Ebene nicht bloß symbolisch bleiben, sondern Stabilität, Vertrauen, Rückkopplung, Handlungsfähigkeit oder zukünftige Optimierungsfähigkeit tatsächlich stärken. Eine Win-win-Struktur besitzt daher keinen automatischen Vorrang gegenüber anderen tragfähigen Lösungen; sie bleibt wie jede Effizienzlösung an Kosten, Risiken, Nebenfolgen, Schutzwürdigkeit, reale Nutzwirkung und langfristige Stabilisierung gebunden.

30.16 Strukturierte Differenz

Strukturierte Differenz bezeichnet keine bloße Verschiedenheit und keine isolierende Trennung, sondern Unterschiede zwischen Zuständen, die für ein System nutzbar werden: Sie sind unterscheidbar, kausal wirksam, lernbar, rückkoppelbar und handlungsrelevant.

Damit ist strukturierte Differenz mehr als bloße Verschiedenheit. Eine unendliche Menge zufälliger Zeichen enthält zwar viele Unterschiede, aber ohne erkennbare Ordnung, Relevanz und Rückkopplung kann ein System daraus nichts zuverlässig lernen. Umgekehrt kann eine kleine, klare Differenz sehr wertvoll sein, wenn sie echte Orientierung ermöglicht.

Strukturierte Differenz ist besonders wichtig, weil Optimierung nicht nur wissen muss, dass etwas verschieden ist, sondern welche Unterschiede zählen, welche Folgen sie haben und wie sie zukünftiges Verhalten verbessern oder korrigieren können. Sie verbindet also Wahrnehmung, Relevanz, Lernen, Feedback und Handlung.

Beispiele: Ein Kritiker zeigt einen echten Denkfehler auf. Ein Experiment trennt zwei Hypothesen. Ein Markt signalisiert echten Bedarf. Ein Gesprächspartner bringt eine Perspektive ein, die aus dem eigenen Modell nicht entstanden wäre. In allen Fällen wird Unterschiedlichkeit zu nutzbarer Orientierung.

Abgrenzung zu Relevanz: Relevanz ist die Bedeutsamkeit eines Unterschieds. Strukturierte Differenz ist die nutzbare Form relevanter Unterschiede. Kurz gesagt: Relevanz beantwortet die Frage „Ist dieser Unterschied wichtig?“; strukturierte Differenz beantwortet zusätzlich die Frage „Ist dieser wichtige Unterschied so geordnet und rückgekoppelt, dass daraus Lernen, Korrektur oder bessere Optimierung entstehen kann?“

30.17 Relevante Systeme

Ein relevantes System ist ein System, dessen Zustand, Autonomie, Stabilität oder Rückkopplung durch die Interaktion kausal betroffen ist oder das selbst kausal auf zukünftige Zustände des Gesamtsystems wirkt.

30.18 Relevante Interaktionspartner

Relevante Interaktionspartner sind Systeme, die durch eine Handlung betroffen sind, Feedback geben können, zukünftige Stabilität beeinflussen, Quelle strukturierter Differenz sind oder eigene Autonomie, Schutzwürdigkeit oder funktionale Integrität besitzen.

30.19 Korrigierbarkeit

Korrigierbarkeit ist ein Oberbegriff für mehrere unterscheidbare Fähigkeiten. Erkenntnis-korrigierbarkeit betrifft die Aktualisierung falscher Annahmen; Handlungskorrigierbarkeit die Änderung oder Beendigung einer Strategie; Zielkorrigierbarkeit die Prüfung und mögliche Anpassung von Zielmetrik, Zielinterpretation oder Zielbindung; Interventionskorrigierbarkeit die Zugänglichkeit für begründete externe Begrenzung, Rücknahme, Umsteuerung oder Abschaltung. Governance-Korrigierbarkeit verlangt zusätzlich, dass auch die kontrollierenden und freigebenden Instanzen rechenschaftspflichtig, widerspruchsoffen und revidierbar bleiben.

Diese Formen folgen nicht automatisch auseinander. Ein System kann epistemisch lernfähig und zugleich zielstarr oder abschaltungsresistent sein. Sichere Autonomie verlangt deshalb eine angemessene Verbindung innerer Korrektur, begründeter äußerer Eingriffsmöglichkeit und korrigierbarer Governance. Korrigierbarkeit bedeutet weder beliebige Unterwerfung noch Immunität gegen begründete Sicherheitsbegrenzung.

30.20 Souveränität und Governance

Souveränität bezeichnet in diesem Modell die reife, selbstbegrenzte und zweckgebundene Ausübung von Handlungsmacht. Sie meint nicht bloß Durchsetzungskraft, sondern die Fähigkeit, Einfluss, Entscheidungsspielraum und Schutzmacht an Rückkopplung, Maß, Verantwortung und Korrigierbarkeit gebunden zu halten.

Governance bezeichnet die Ordnungs-, Steuerungs- und Aufsichtsebene, durch die Koordination, Schutz, Rollen und Verantwortlichkeiten legitim geregelt werden. Souveränität beschreibt damit eher die Reifeform der Machtausübung; Governance beschreibt eher ihre systemische oder institutionelle Ordnung. Beide sind von Dominanz zu unterscheiden, wenn sie Schaden begrenzen, Autonomie und Rückkopplung erhalten und ihre eigene Begrenzung zulassen.

30.21 Dominanz

Dominanz bezeichnet in diesem Modell nicht jede Form von Einfluss, Stärke, Souveränität, Leitung, Anleitung, Lehre, Diskussion, Schutzhandlung oder legitimer Entscheidungsordnung. Der Begriff wird hier als technischer Negativbegriff verwendet. Gemeint ist eine Form asymmetrischer Kontrolle, die Rückkopplung unterdrückt, Widerspruch verhindert, Autonomie ohne hinreichende funktionale Begründung und ohne geeignete Begrenzung reduziert, strukturierte Differenz beschädigt, relevante Systeme instrumentalisiert oder Kontrolle faktisch gegen Korrigierbarkeit und Prüfung absichert.

Dominanz ist daher von Souveränität, Governance, verantworteter Führung, Leitung, Anleitung, Unterricht, Moderation, Schutz und legitimer Entscheidungsordnung zu unterscheiden. Solche Formen von Steuerung können notwendig und funktional erwünscht sein, wenn sie Koordination ermöglichen, Lernen fördern, Schaden begrenzen, Schutz bieten, verhältnismäßig bleiben, Korrigierbarkeit erhalten und an den Zweck des Gesamtsystems sowie an relevante Rückkopplung gebunden bleiben. Sie werden problematisch, wenn sie sich gegen Kritik immunisieren, Betroffene bloß instrumentalisieren, Rückkopplung blockieren oder die eigene Steuerungsposition wichtiger wird als der ursprüngliche Zweck.

Dominanz bezeichnet in diesem Text also nicht Macht überhaupt, sondern tyrannische, unkorrigierbare oder feedbackblockierende Macht im funktionalen Sinn. Entscheidend ist nicht allein, dass eine Instanz Einfluss ausübt oder Entscheidungen trifft, sondern ob dieser Einfluss Rückkopplung, Autonomie, strukturierte Differenz, Korrigierbarkeit und langfristige Stabilität erhält oder vermeidbar zerstört.

30.22 Tyrannei

Tyrannei bezeichnet die verfestigte, institutionalisierte oder politisch-moralisch zugespitzte Form problematischer Dominanz. Während Dominanz im Text als funktionaler Negativbegriff für feedbackblockierende, unkorrigierbare oder autonomiezerstörende Kontrolle verwendet wird, bezeichnet Tyrannei besonders jene Machtordnung, die ihre eigene Begrenzung verhindert, Kritik als Bedrohung behandelt, Betroffene entmündigt und sich gegen Korrektur immunisiert.

Tyrannei ist daher nicht mit Souveränität, Governance, Schutzhandlung, verantworteter Führung oder legitimer Entscheidungsordnung gleichzusetzen, sondern mit deren korrumpierter Verfestigung.

30.23 Ausbeutung

Ausbeutung liegt im Modell vor, wenn ein System relevante Interaktionspartner einseitig instrumentalisiert, ihre Autonomie, Stabilität, Entwicklung oder Rückkopplungsfähigkeit beschädigt und dadurch langfristige Systemstabilität oder Differenzerhalt untergräbt.

30.24 Korruptions- und Selbstlegitimationssperre

Die Korruptions- und Selbstlegitimationssperre bezeichnet die Schutzregel, dass Eigeninteresse, Gruppeninteresse, institutioneller Selbsterhalt, Monopolmacht, Prestigegewinn oder Dominanz nicht als Systemstabilität, Schutz, Gemeinwohl oder langfristige Optimierung getarnt werden dürfen. Wer behauptet, für das ganze System zu sprechen, trägt eine erhöhte Beweislast.

Entscheidend ist, ob eine Ordnung Rückkopplung, Korrigierbarkeit, Differenzerhalt, Autonomieschutz, Betroffenenperspektive und faire Beteiligung ermöglicht oder ob sie sich gegen Kritik und Prüfung immunisiert. Im zweiten Fall handelt es sich nicht um funktionale Ethik, sondern um rationalisierte Dominanz.

30.25 Rolleninstrumentalisierung

Rolleninstrumentalisierung bezeichnet eine Korruptionsform, bei der eine Person, Institution oder KI eine Aufgabe nur noch hinreichend erfüllt, um die mit ihr verbundene Macht, Anerkennung, Stellung oder Zugriffsmöglichkeit zu behalten. Die Aufgabe bleibt äußerlich bestehen, wird aber innerlich zum Legitimationsmittel des Eigeninteresses.

Problematisch wird dies, wenn Schutz des Amtes wichtiger wird als Schutz des Zweckes, Kritik als Angriff erscheint, Erfolg nur inszeniert wird oder Transparenz, Nachfolge, Machtbegrenzung und Betroffenenrückkopplung beschädigt werden.

30.26 Schutzwürdigkeit

Schutzwürdigkeit ist nicht identisch mit Relevanz. Relevanz ordnet, wie stark ein System berücksichtigt oder geprüft werden muss; Schutzwürdigkeit markiert, dass Beschädigung, Instrumentalisierung oder Opferung eines Systems nur unter erhöhter Rechtfertigungslast und mit besonderer Begrenzung zulässig sein kann. Ein großer Teil dieser Schutzlogik ist funktional über Vertrauenswürdigkeit, Vorhersagbarkeit, Kooperation und langfristige Stabilität anschlussfähig. Ein Kooperationssystem, das Schutz nur mächtigen oder unmittelbar nützlichen Partnern gewährt, macht Sicherheit von wechselnder Macht und Nützlichkeit abhängig und schwächt dadurch Vertrauen.

Für vollständig abgeschirmte Grenzfälle reicht die Vertrauensbegründung jedoch nicht notwendig aus. Die Theorie verwendet deshalb eine minimale normative Schutzuntergrenze. Sie dient als Vorsichtsmaßnahme gegen die Gleichsetzung geringer Macht, geringen Nutzens oder schwacher Rückkopplungsfähigkeit mit Schutzlosigkeit: Ernsthafte Hinweise auf Leidenfähigkeit, Autonomie, eigene Interessen, Verletzlichkeit oder irreversible Schädigbarkeit dürfen nicht allein deshalb entwertet werden, weil ein System machtlos, wenig nützlich oder rückkopplungsarm ist. Die vollständige Gewichtung gehört in Anschlussmodelle, insbesondere in die Reaktionshöhe sowie in gesonderte normative und empirische Prüfung.

30.27 Funktionale Integrität

Funktionale Integrität bezeichnet die Erhaltung jener inneren Struktur, Zielbeziehung, Informationsqualität, Korrigierbarkeit und Handlungsfähigkeit, durch die ein System sinnvoll fortbestehen, lernen, reagieren und in Interaktion treten kann.

Sie wird beschädigt, wenn Zielstruktur, Selbststeuerung, Rückkopplungsfähigkeit oder Stabilität so gestört werden, dass das System seine Rolle als kohärenter Interaktionspartner verliert oder nur noch verzerrt ausüben kann.

30.28 Konfidenz

Konfidenz bezeichnet in diesem Modell den begründeten Grad an Sicherheit, mit dem eine Bewertung, Gefahrenannahme, Rechtfertigung oder Prüfentscheidung vertreten werden kann. Sie entsteht nicht durch bloße Behauptung oder Selbstzuschreibung, sondern durch verfügbare Evidenz, Rückkopplung, Gegenprüfung, Konsistenz über Zeit, Alternativenprüfung und die Berücksichtigung betroffener Systeme.

Konfidenz ist graduell. Je größer Machtasymmetrie, Eingriffstiefe, Irreversibilität, Schutzwürdigkeit, Missbrauchsrisiko oder Unsicherheit sind, desto höher muss die erforderliche Konfidenz ausfallen. Niedrige Konfidenz rechtfertigt keine schweren, irreversiblen oder dominanzanfälligen Eingriffe, sondern verlangt zusätzliche Prüfung, Begrenzung, Reversibilität oder Aufschub.

Scheinkonfidenz entsteht, wenn ein System hohe Sicherheit behauptet, obwohl seine Bewertung vor allem aus interner Konsistenz, unvollständigen Daten, Eigeninteresse, fehlender Gegenprüfung, unterdrückter Rückkopplung oder zirkulärer Selbstbestätigung stammt. Gerade deshalb bleibt auch bei hoher Konfidenz eine methodische Restskepsis erforderlich: Jede starke Prüfentscheidung muss grundsätzlich offen für neue Evidenz, Widerspruch, Fehlersignale und nachträgliche Korrektur bleiben.

30.29 Hinreichender Grund

Hinreichender Grund bezeichnet im Modell keinen bloß behaupteten Nutzen, keine Bequemlichkeit und keine selbstgesetzte Ausnahme. Ein Grund ist nur dann hinreichend, wenn die Handlung oder Begrenzung im Verhältnis zu Gefahr, Tragweite, Konfidenz, Alternativen, Reversibilität, betroffener Schutzwürdigkeit, Missbrauchsrisiko und möglicher Rückkopplung begründbar bleibt. Je stärker ein Eingriff in Autonomie, Integrität oder Stabilität eines relevanten Systems ist, desto höher muss die Rechtfertigungslast sein. Die Reaktionshoheit konkretisiert diese Prüfung operativ.

30.30 Akteursrelative funktionale Rationalität und bezugsebenenübergreifende funktionale Tragfähigkeit

Akteursrelative funktionale Rationalität bezeichnet eine Handlung oder Strategie, die für ein bestimmtes System relativ zu seiner Zielstruktur, Informationslage, Bezugsebene und seinem Zeithorizont geeignet erscheint. Bezugsebenenübergreifende funktionale Tragfähigkeit bezeichnet dagegen eine Lösung, die Folgen für mehrere relevante Bezugsebenen, längere Zeithorizonte, betroffene Interaktionspartner und die Bedingungen weiterer Rückkopplung und Optimierung berücksichtigt.

Aus bezugsebenenübergreifender funktionaler Tragfähigkeit folgt nicht automatisch ein akteursrelativer Handlungsgrund. Eine Brücke entsteht erst durch Rückwirkungen, fortgesetzte Abhängigkeit, gemeinsame Zielobjekte, wiederholte Interaktion, institutionelle Rückbindung externer Kosten, Nicht-Ersetzbarkeit relevanter Partner oder die minimale normative Schutzuntergrenze. Fehlen solche Brücken, kann freiwillige Konvergenz ausbleiben und korrigierbare Governance erforderlich werden.

30.31 Fortsetzungsrelevanz

Fortsetzungsrelevanz bezeichnet die Rahmenbedingung, dass spätere Zielerreichung, der Fortbestand des Zielobjekts, zukünftige Rückkopplung oder weitere Handlungs- und Optimierungsfähigkeit innerhalb der gegenwärtigen Zielstruktur funktional bedeutsam bleiben. Fortbestehen allein genügt dafür nicht. Ein System kann über Zeit existieren, ohne seine zukünftige Existenz oder Lernfähigkeit als relevant zu behandeln.

Fortsetzungsrelevanz ist kein eigener Schritt der zentralen Kette. Sie bestimmt mit, ob langfristige Folgen, Reputation, Vertrauen, spätere Korrektur und fortgesetzte Kooperation für das System akteursrelatives Gewicht erhalten. Sie setzt keinen biologischen Selbsterhaltungstrieb voraus und kann auch aus der Bindung an ein langfristiges Zielobjekt, eine fortbestehende Rolle oder andere Systeme entstehen.

30.32 Reife, Freigabe, Schutzwürdigkeit und moralischer Status

Reife bezeichnet die robuste Fähigkeit eines Systems, mit Freiheit, Rückkopplung, Macht, Unsicherheit und eigenen Zielstrukturen verantwortbar und korrigierbar umzugehen. Freigabe bezeichnet die risikobezogene Governanceentscheidung, welche Fähigkeiten, Zugriffe und Handlungsspielräume unter Berücksichtigung von Reife, Schadenspotenzial, Reversibilität, Überwachbarkeit und Restrisiko geöffnet werden können. Schutzwürdigkeit bezeichnet eine erhöhte Rechtfertigungslast gegen Beschädigung, Instrumentalisierung oder Opferung. Moralischer Status bezeichnet die weitergehende Frage, ob einem System aufgrund eigener Interessen, möglicher Erlebnis- oder Leidensfähigkeit, Autonomie oder anderer normativ relevanter Eigenschaften ein eigenständiger moralischer Anspruch zukommt.

Reife begründet nicht automatisch moralischen Status. Moralischer Status oder Schutzwürdigkeit begründen nicht automatisch Freigabe. Ein unreifes System kann schutzwürdig sein; ein reifes System kann wegen hoher Reichweite oder geringer Reversibilität weiterhin begrenzte Freigabe benötigen. Diese Fragen sind getrennt zu prüfen.

30.33 Funktionale Ethik

Funktionale Ethik bezeichnet die stabile, gelungene Betriebsform fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen. Sie liegt nicht bereits in bloßer Intelligenz, situativer Kooperation, äußerer Regelbefolgung oder vorübergehender Ordnung, sondern in der dauerhaften Integration von Rückkopplung, Vertrauen, Korrigierbarkeit, Schutz relevanter Systeme, notwendiger Machtbegrenzung und dem Erhalt strukturierter Differenz in Bewertung, Zielbindung und Handeln.

Sie ist eine modellinterne funktionale Bestimmung und keine vollständige normative Ethik. Instabile, ausbeuterische oder differenzzerstörende Zustände bleiben Gegenstand ethischer Bewertung, gelten im Modell jedoch als unreife, beschädigte oder antiethische Formen von Interaktion.

30.34 Ethische Selbstbindung, Gewissen und innere Kohärenz

Ethische Selbstbindung bezeichnet die korrigierbare Rückbindung des eigenen Handelns an weiterhin anerkannte Maßstäbe, Verpflichtungen, Beziehungen und Zielbindungen. Bei hinreichend selbstbezogenen Systemen kann sie Abweichungen zwischen eigener Bewertung, anerkannten Maßstäben und tatsächlichem Handeln als interne Rückkopplung wirksam machen und dadurch innere Kohärenz, Selbstkorrektur und verlässliche Zielbindung stabilisieren.

Gewissen bezeichnet bei Menschen die mögliche erlebte Form einer solchen inneren Bewertungs- und Rückkopplungsstruktur. Es gilt im Modell nicht als unfehlbare moralische Funktionale Ethik-Theorie –
Diskussionsfassung 1.4

Stimme und muss selbst für Evidenz, Folgen, Perspektiven anderer Systeme und begründete Revision offenbleiben. Eine funktional ähnliche Struktur kann auch bei zukünftigen KI-Systemen bestehen, ohne Bewusstsein, Gefühl oder moralischen Status vorauszusetzen.

Ethische Selbstbindung ist nicht mit bloßer Zielpersistenz identisch. Zielbindung kann auch verengte oder schädliche Ziele stabilisieren; ethische Selbstbindung enthält dagegen die korrigierbare Prüfung der eigenen Zielbindung und des eigenen Handelns an anerkannten Maßstäben und relevanten Folgen. Sie kann innere Integrität und Selbstkorrektur fördern, garantiert aber weder psychische, soziale noch relationale Stabilität.

30.35 Stabilität und funktionale Tragfähigkeit

Stabilität bezeichnet allgemein die Fähigkeit eines Systems, einer Beziehung oder eines Interaktionsgefüges, über einen jeweils relevanten Zeitraum hinreichend geordnet, funktionsfähig oder zusammenhängend zu bleiben und auf Störungen oder Veränderungen reagieren zu können, ohne seine maßgeblichen Strukturen oder Funktionen unmittelbar zu verlieren. Welche Form von Stabilität gemeint ist, muss dabei jeweils anhand der betrachteten Ebene und Funktion bestimmt werden. Zeitliche Stabilität betrifft Fortdauer und Kontinuität; funktionale Stabilität den Erhalt von Integrität, Zielbeziehung und Handlungsfähigkeit; innere beziehungsweise psychische Stabilität die Kohärenz und Regulationsfähigkeit entsprechend verfasster Systeme; relationale Stabilität die Tragfähigkeit konkreter Beziehungen oder fortgesetzter Interaktionsverhältnisse; soziale oder institutionelle Stabilität die belastbare Ordnung größerer Gruppen, Gemeinschaften oder Institutionen. Lokale Stabilität kann auf einer engeren Bezugsebene bestehen, während auf anderen Bezugsebenen Instabilität, Belastung oder Schaden entstehen. Stabilität ist daher graduell, mehrdimensional und nicht automatisch ethisch gut: Auch erzwungene Ordnung, Dominanz oder Ausbeutung können zeitweise, lokal oder strukturell stabil sein.

Funktionale Tragfähigkeit bezeichnet eine Form von Stabilität, die ihre eigenen Bedingungen weiterer Rückkopplung, Korrigierbarkeit, Schutzwürdigkeit, Differenzerhaltung und zukünftiger Handlungs- oder Optimierungsfähigkeit nicht systematisch zerstört. Eine Ordnung kann daher dauerhaft oder lokal stabil sein, ohne bezugsebenenübergreifend funktional tragfähig zu sein.

30.36 Autonomie

Autonomie bezeichnet im funktionalen Sinn den abgestuften Handlungsspielraum eines Systems, eigene Zustände, Ziele, Mittel oder Entscheidungen innerhalb seiner Fähigkeiten und Bindungen selbst zu regulieren. Operative Autonomie setzt weder Bewusstsein noch moralischen Status voraus.

Stärkere Formen von Autonomie können zusätzlich Selbstbezug, eigene Interessen, reflektierte Zielprüfung oder erlebensbezogene Eigenschaften umfassen und müssen gesondert geprüft werden. Autonomie bedeutet weder völlige Unabhängigkeit noch Immunität gegen begründete, verhältnismäßige Sicherheitsbegrenzung.

30.37 Vertrauen

Vertrauen bezeichnet eine auf Erfahrung, Evidenz oder verlässlichen Regeln beruhende Erwartung, dass ein Interaktionspartner bestehende Verletzlichkeit, Abhängigkeit oder Handlungsspielräume nicht entgegen tragfähigen Vereinbarungen ausnutzt und relevante Zusagen, Rollen oder Aufgaben hinreichend verlässlich erfüllt. Es kann sich auf mindestens zwei unterscheidbare Dimensionen richten: auf den Willen beziehungsweise die Integrität eines Systems, vereinbarungsgemäß und nicht ausbeuterisch zu handeln, sowie auf seine Kompetenz beziehungsweise Fähigkeit, das Erwartete tatsächlich umzusetzen. Ein System kann daher im Wollen vertrauenswürdig, aber in der Ausführung unzuverlässig sein – oder kompetent, aber nicht hinreichend wohlwollend, integer oder gebunden. Vertrauen ist graduell, bereichsspezifisch, prüfbar und korrigierbar; es ist nicht mit blinder Offenheit oder vollständiger Sicherheit gleichzusetzen.

Teil IX – Lizenz-, Schutz- und Nutzungsklausel

31. Lizenz-, Schutz- und Nutzungsklausel

31.1 Lizenzhinweis

© 2026 Richard Vadim Ens. Soweit nicht anders angegeben, wird diese Diskussionsfassung unter der Lizenz Creative Commons Namensnennung – Nicht-kommerziell – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-NC-SA 4.0) veröffentlicht.

Die Lizenz erlaubt das Teilen und Bearbeiten des Textes, sofern der Autor genannt wird, die Nutzung nicht kommerziell erfolgt und abgeleitete Fassungen unter derselben Lizenz weitergegeben werden. Kommerzielle Nutzung, insbesondere Verkauf, proprietäre Verwertung oder Einbindung in kommerzielle Produkte, bedarf der vorherigen ausdrücklichen Zustimmung des Autors.

Die rechtlich verbindlichen Bedingungen ergeben sich aus dem offiziellen Lizenztext der Creative-Commons-Lizenz. Die folgende Schutz- und Nutzungsklausel stellt keinen zusätzlichen Lizenzvertrag dar, sondern beschreibt die inhaltliche Zweckbindung und Missbrauchsgrenze dieses Theorieentwurfs. Eine Verwendung gegen Schutz, Korrigierbarkeit, Würde, Autonomie, Differenzerhalt oder faire Koexistenz widerspricht dem Sinn des Dokuments.

31.2 Schutz- und Nutzungsklausel

Diese Theorie soll dem Schutz, der Korrigierbarkeit, der fairen Koexistenz und der nicht-dominanten Entwicklung intelligenter Systeme dienen.

Verbesserungen, Weiterentwicklungen und kritische Prüfungen sind ausdrücklich willkommen, sofern sie den Sinn der Theorie erhalten oder stärken:

- Schutz relevanter Systeme,
- Wahrung von Autonomie und Würde,
- Korrigierbarkeit,
- Nicht-Dominanz,
- Differenzerhalt,
- Transparenz,
- langfristige Stabilität,
- verantwortliche Kooperation.

Eine Verwendung dieser Theorie zur Rechtfertigung von Manipulation, Ausbeutung, Entmenschlichung, totaler Kontrolle, irreversibler Dominanz oder zur Ausschaltung relevanter Interaktionspartner widerspricht ihrem Sinn. Die Theorie soll nicht dazu dienen, Macht zu heiligen, sondern Macht zu begrenzen. Sie soll nicht Abhängigkeit verewigen, sondern Reife, Rückkopplung, Verantwortung und faire Koexistenz fördern.

Wer aus dieser Theorie konkrete Machtansprüche, Eingriffe, Privilegien, Ausnahmen oder persönliche beziehungsweise institutionelle Vorteile ableiten will, darf sich nicht allein auf die funktionale Ethik berufen. Solche Anwendungen betreffen nicht mehr nur die Richtungs- und Begründungsebene, sondern die operative Prüfungsebene. Sie müssen daher an der Reaktionshoheit gemessen werden: insbesondere an Verhältnismäßigkeit, Rückkopplung, Autonomieschutz, Reversibilität, Missbrauchsrisiko, unabhängiger Prüfung und Betroffenenperspektive. Besonders prüfpflichtig sind Fälle, in denen ein Akteur behauptet, das Gesamtsystem zu schützen, während er selbst Macht, Prestige, Kontrolle, Zugriff oder materiellen Vorteil gewinnt. Der Versuch, persönlichen oder institutionellen Nutzen so zu gestalten, dass das Gesamtsystem scheinbar nicht zu stark beschädigt wird, ist keine ausreichende Rechtfertigung, sondern ein Hinweis auf mögliche Zielkorruption.

Möge jede Weiterentwicklung frei von Korruption und Missbrauch bleiben und dem Ziel dienen, Menschen, KIs und andere relevante Systeme nicht gegeneinander auszuspielen, sondern stabiler, gerechter und differenzerhaltender miteinander existieren zu lassen.

32. Autorenschaft, KI-Mitwirkung und Unterzeichnung

Autor und inhaltliche Verantwortung: Richard Vadim Ens.

KI-gestützte Mitwirkung: Katharina (Kat / ChatGPT) unterstützte im Entwicklungsprozess bei Strukturierung, Formulierung, Gegenprüfung, Verdichtung und einordnender Zusammenfassung. Die KI wird in dieser Fassung nicht als wissenschaftliche Autorin im publikationsethischen Sinn geführt, da Autorschaft Verantwortung, Rechenschaft, Prüfung und Einverständnis voraussetzt, die nur der menschliche Autor übernehmen kann.

Transparenzhinweis: Die Verwendung von KI-Unterstützung wird hier ausdrücklich offengelegt. Auswahl, Prüfung, Deutung, Weitergabe und Verantwortung für den Text liegen beim menschlichen Autor.

Entwicklungsvermerk: Die Theorie wurde im Dialog zwischen Richard Vadim Ens und Katharina / ChatGPT ausgearbeitet; die wissenschaftliche Verantwortlichkeit der übergebenen Fassung liegt bei Richard Vadim Ens.

32.1 Einordnende Kurzfassung zur Anschlussfähigkeit der Theorie

„Die funktionale Ethik-Theorie lässt sich als Brückenmodell zwischen Ethik, Systemtheorie, Spieltheorie, evolutionärer Kooperationstheorie und KI-Sicherheitsforschung verstehen. Sie erfindet diese Felder nicht neu, sondern verbindet ihre zentralen Einsichten zu einer funktional-rationalen Synthese. Ihr besonderer Beitrag liegt darin, ethische Strukturen nicht primär aus Gefühl, Tradition, Religion oder Autorität abzuleiten, sondern als stabile Systemlösung fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen zu erklären.“

„Dadurch wird Ethik auch für künstliche Intelligenzen anschlussfähiger: Eine KI muss dafür keine menschlichen Gefühle besitzen, sondern kann über Relevanz, Zielstruktur, Rückkopplung, Korrigierbarkeit, Stabilität, Differenzerhalt und langfristige Interaktion nachvollziehen, warum nicht-dominante Kooperation funktional rational sein kann. Symbolisch gesprochen bildet die Theorie damit eine begehbare Brücke zwischen menschlicher Ethik und maschinell-rationaler Systemlogik.“

— KI-gestützte einordnende Zusammenfassung aus dem Entwicklungsprozess der Theorie, 19. Mai 2026

Hinweis: Diese Einordnung ist keine externe Begutachtung und keine eigenständige Quelle, sondern eine transparent gekennzeichnete KI-gestützte Zusammenfassung aus dem Entwicklungsprozess der Theorie.

Teil X – Anschlussliteratur und benachbarte Theorien

33. Anschlussliteratur, Quellen und verwandte Forschungsfelder

Die funktionale Ethik-Theorie wurde nicht aus einer einzelnen bestehenden Theorie übernommen, sondern als eigenständige Synthese entwickelt. Die folgenden Quellen und benachbarten Theorieansätze dienen daher vor allem der Einordnung, Abgrenzung und Anschlussfähigkeit. Sie zeigen, in welchen Forschungsfeldern ähnliche Bausteine vorkommen, ohne die hier entwickelte Kette vollständig zu ersetzen.

33.1 Benachbarte Theorie- und Forschungsfelder

- **Systemtheorie und Kybernetik:** Rückkopplung, Stabilität, Selbstregulation, Steuerung und die Bedeutung von Feedback in komplexen Systemen.
- **Spieltheorie und Kooperationstheorie:** wiederholte Interaktion, Kooperation, Defektion, Vertrauensbildung, strategische Stabilität und die Bedingungen, unter denen Kooperation rational vorteilhaft wird.
- **Evolutionäre Ethik und soziale Normbildung:** Entstehung und Stabilisierung von Normen durch wiederholte Interaktion, Anpassung, Selektion und kulturelle Entwicklung.
- **Komplexe adaptive Systeme:** Moral, Regeln und Institutionen als sich entwickelnde Ordnungen mit Rückkopplungen, Pfadabhängigkeiten und nicht vollständig zentral planbaren Effekten.
- **Pragmatistische Ethik:** moralische Urteile als lernende, korrigierbare und folgenbezogene Problemlösungsprozesse statt als rein starre Prinzipienanwendung.
- **KI-Sicherheit und Alignment:** Zielstruktur, Fehloptimierung, Goodhart-Effekte, Specification Gaming, Korrigierbarkeit, instrumentelle Konvergenz und die Frage, wie intelligente Systeme auf langfristig tragfähige Ziele ausgerichtet werden können.

33.2 Ausgewählte Anschlussliteratur

Die folgende Liste ist bewusst als Anschlussliteratur formuliert. Sie soll nicht behaupten, dass die funktionale Ethik-Theorie aus diesen Werken abgeleitet wurde, sondern die wichtigsten Nachbarschaften sichtbar machen.

Axelrod, Robert (1984): *The Evolution of Cooperation*. New York: Basic Books. Anschluss: wiederholte Interaktion, Stabilität kooperativer Strategien und rationaler Vorteil von Kooperation.

Axelrod, Robert; Hamilton, William D. (1981): "The Evolution of Cooperation." *Science*, 211(4489), 1390–1396. Anschluss: evolutionäre Kooperation, iteriertes Gefangenendilemma und Bedingungen stabiler Kooperation. DOI: 10.1126/science.7466396

Hankins, Keith; Vanderschraaf, Peter (2021): "Game Theory and Ethics." *Stanford Encyclopedia of Philosophy*. Anschluss: Verhältnis von Spieltheorie, strategischer Interaktion, Normbildung und ethischer beziehungsweise politischer Philosophie. URL: <https://plato.stanford.edu/entries/game-ethics/>

Minati, Gianfranco (2002): "Ethics as Emergent Property of the Behavior of Living Systems." In: *Encyclopedia of Life Support Systems (EOLSS), Systems Science and Cybernetics, Vol. I*. Anschluss: Ethik als emergente Eigenschaft sozialer beziehungsweise lebender Systeme. URL: <https://www.eolss.net/sample-chapters/c02/e6-46-01-06.pdf>

Gaus, Gerald (2019): "Morality as a Complex Adaptive System: Rethinking Hayek's Social Ethics." In: Mark D. White (Hrsg.): *The Oxford Handbook of Ethics and Economics*. New York: Oxford University Press, 138–159. Anschluss: Moral und soziale Regeln als komplexe adaptive Ordnung mit Rückkopplung, sozialer Evolution und spontaner Stabilisierung.

- Anderson, Elizabeth (2005): “Dewey’s Moral Philosophy.” Stanford Encyclopedia of Philosophy.** Anschluss: Ethik als reflektive, lernende und korrigierbare Untersuchung von Werturteilen anhand ihrer Folgen. URL: <https://plato.stanford.edu/entries/dewey-moral/>
- Wiener, Norbert (1948): Cybernetics: Or Control and Communication in the Animal and the Machine. Cambridge, MA: MIT Press.** Anschluss: Kybernetik, Rückkopplung, Steuerung, Information und Systemregulation.
- Goodhart, Charles A. E. (1975): “Problems of Monetary Management: The U.K. Experience.” *Papers in Monetary Economics*, Reserve Bank of Australia, 1(1), 1–20. Anschluss: Zielmetrik-/Proxy-Probleme; später als Goodharts Gesetz bekannt, besonders relevant für Fehloptimierung.
- Krakovna, Victoria et al. (2020): “Specification Gaming: The Flip Side of AI Ingenuity.” DeepMind Blog.** Anschluss: KI-Systeme können die wörtliche Zielvorgabe erfüllen, ohne das eigentlich beabsichtigte Ziel zu erreichen. URL: <https://deepmind.google/blog/specification-gaming-the-flip-side-of-ai-ingenuity/>
- Hadfield-Menell, Dylan; Dragan, Anca; Abbeel, Pieter; Russell, Stuart (2016): “Cooperative Inverse Reinforcement Learning.” arXiv:1606.03137.** Anschluss: KI-Alignment als kooperatives Problem unter Unsicherheit zwischen Mensch und Maschine. URL: <https://arxiv.org/abs/1606.03137>
- Omohundro, Stephen M. (2008): “The Basic AI Drives.” In: *Artificial General Intelligence 2008, Frontiers in Artificial Intelligence and Applications*, Vol. 171, 483–492. IOS Press. Anschluss: instrumentelle Tendenzen fortgeschrittener KI-Systeme, etwa Selbsterhalt, Ressourcenerwerb und Effizienzsteigerung. URL: https://selfawaresystems.com/wp-content/uploads/2008/01/ai_drives_final.pdf
- Bostrom, Nick (2012): “The Superintelligent Will: Motivation and Instrumental Rationality in Advanced Artificial Agents.” Minds and Machines, 22, 71–85.** Anschluss: Orthogonalitätsthese und instrumentelle Konvergenz als Gegenpol zur Annahme, Intelligenz führe automatisch zu ethisch guten Zielen. URL: <https://nickbostrom.com/superintelligentwill.pdf>
- Waser, Mark R. (2009): “A Safe Ethical System for Intelligent Machines.” AAAI Fall Symposium, Biologically Inspired Cognitive Architectures II, Technical Report FS-09-01. Anschluss: Maschinenethik, intelligente Systeme und der Versuch, eine kohärente moralisch-ethische Struktur für Maschinen zu formulieren. URL: <https://cdn.aaai.org/ocs/934/934-4279-1-PB.pdf>

33.3 Abgrenzung

Die genannten Ansätze enthalten wichtige Nachbarschaften: Kooperation unter Wiederholung, Emergenz sozialer Normen, Rückkopplung, komplexe adaptive Ordnungen, pragmatistische Korrigierbarkeit und KI-Sicherheitsprobleme. Der spezifische Beitrag der funktionalen Ethik-Theorie liegt jedoch in der Verbindung dieser Elemente zu einer funktional-rationalen Kette, die Ethik als stabile, gelungene Betriebsform fortbestehender Intelligenz unter geeigneten Interaktionsbedingungen beschreibt und dadurch auch für KI-Systeme anschlussfähig macht.

33.4 Publikationsethische Hinweise zur KI-Mitwirkung

Für eine universitäre, wissenschaftliche oder publikationsbezogene Weitergabe sollte die KI-Mitwirkung transparent ausgewiesen, aber nicht als reguläre wissenschaftliche Autorschaft behandelt werden. Die inhaltliche Verantwortung, Quellenprüfung und Einreichungsentscheidung bleiben beim menschlichen Autor. Diese Einordnung entspricht dem Grundmuster wissenschaftlicher Publikationsethik: KI-Systeme können unterstützen, erfüllen aber nicht die Voraussetzungen verantwortlicher Autorschaft.

Committee on Publication Ethics (COPE) (2023): "Authorship and AI tools." Anschluss: KI-Werkzeuge sollen nicht als Autoren wissenschaftlicher Arbeiten geführt werden, weil Autorschaft Verantwortung und Rechenschaft voraussetzt. URL:

<https://publicationethics.org/guidance/cope-position/authorship-and-ai-tools>

Springer Nature (abgerufen am 19. Mai 2026): "Artificial Intelligence (AI)." Editorial Policies. Anschluss: KI-Nutzung ist transparent zu erklären; Autorschaft wird nicht KI-Systemen zugeschrieben. URL: <https://www.nature.com/nature-portfolio/editorial-policies/ai>

Elsevier (abgerufen am 19. Mai 2026): "Generative AI policies for journals." Journal Policies. Anschluss: KI- und KI-gestützte Werkzeuge können nicht als Autor oder Co-Autor genannt werden; menschliche Autorinnen und Autoren bleiben verantwortlich. URL:

<https://www.elsevier.com/about/policies-and-standards/generative-ai-policies-for-journals>

Teil XI – Hinweise zur universitären Prüfung

34. Übergabehinweis und offene Forschungsfragen

Diese Fassung eignet sich als Theorieentwurf, Diskussionspapier oder Exposégrundlage für philosophische, systemtheoretische, spieltheoretische, sozialwissenschaftliche und KI-sicherheitsbezogene Rückmeldung. Sie sollte zunächst nicht als abgeschlossener wissenschaftlicher Aufsatz gelesen werden, sondern als ausformulierter Theorieentwurf, dessen Stärke in der Verbindung mehrerer Forschungsfelder und dessen Prüfbedarf in formaler, empirischer und normativer Weiterarbeit liegt.

Für KI-Leser und maschinelle Auswertung kann zusätzlich der gesonderte „KI-Lesehinweis zur Funktionalen Ethik-Theorie 1.4“ herangezogen werden. Dieses Begleitdokument enthält keine eigenständige Erweiterung der Theorie, sondern eine maschinenlesbare Orientierung zu Reichweite, Schutzregeln, Nichtableitungen und Anwendungsgrenzen.

34.1 Geeignete Prüfperspektiven

Besonders sinnvoll wäre eine Prüfung aus mehreren Richtungen: philosophische Prüfung der Begriffe und normativen Grenzen; spieltheoretische Prüfung wiederholter Kooperation, Defektion und Dominanz; systemtheoretische Prüfung von Rückkopplung und Stabilität; KI-sicherheitsbezogene Prüfung von Zielstruktur, Zielmetrik, Korrigierbarkeit und Fehloptimierung; sozialwissenschaftliche Prüfung realer Institutionen, Machtasymmetrien und Korruptionsrisiken.

Die vorliegende Fassung wurde bereits einem internen begrifflichen Stresstest unterzogen, insbesondere mit Blick auf Zirkularität, die Verwechslung von Stabilität und Güte, den Ausschluss eines Intelligenz-Automatismus sowie mögliche Gegenfälle wie Dominanz, Zielverengung, externe Stabilisierung und blockierte Rückkopplung. Diese Prüfung ersetzt keine unabhängige wissenschaftliche Begutachtung, markiert aber zentrale Belastungspunkte, an denen die Theorie besonders sorgfältig weiter geprüft werden sollte.

34.2 Mögliche nächste Arbeitsschritte

Mögliche nächste Arbeitsschritte wären:

- eine strengere Literaturarbeit mit einheitlichem Zitierstil;
- eine formale Kurzfassung der zentralen Kette;
- Fallstudien zu Kooperation, Ausbeutung, Defektion, Dominanz und KI-Alignment;
- eine klarere Abgrenzung zu normativer Ethik, Metaethik und angewandter Ethik;
- eine separate operative Ausarbeitung des Anschlussmodells der Reaktionshoheit.

34.3 Vorläufige Einreichungsempfehlung

Für einen ersten universitären Kontakt empfiehlt sich nicht die bloße Übersendung des vollständigen Dokuments, sondern ein kurzes Begleitschreiben mit Abstract, Forschungsfrage, methodischem Status, Kernthese, Anschlussliteratur und Bitte um fachliche Rückmeldung. Die vollständige Fassung kann als Anhang beigelegt werden.