

Veröffentlichungshinweis

Diese vorgeschaltete Seite klärt Status, Autorenschaft, KI-Assistenz, Lizenz und offizielle Quelle dieser öffentlichen Arbeitsfassung.

Dokument: Das Modell der Reaktionshoheit

Version / Fassung: Neutralisierte Lesefassung mit Beispielen

Datum / Arbeitsstand: Mai 2026

Status: Frühe Lesefassung / Redundanzmodell zur funktionalen Ethik.

Autor / Projektleitung: Richard Ens

KI-Assistenz: Katharina / Kat - ChatGPT (strukturierende Gesprächspartnerin, Formulierungs- und Modellierungsassistentin; keine rechtliche Urheberschaft oder rechtliche Verantwortung)

Lizenz: Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International (CC BY-NC-SA 4.0)

Offizielle Quelle: <https://github.com/Rickston/via-sapientiae-protokoll>

Repository-Pfad: docs/reaktionshoheit

Hinweis zur Veröffentlichung:

Diese Fassung ist eine vorläufige Arbeits- bzw. Diskussionsfassung. Sie ist offen für Kritik, Prüfung und Weiterentwicklung und nicht als endgültige wissenschaftliche Veröffentlichung zu verstehen.

Bearbeitete, übersetzte, gekürzte oder erweiterte Fassungen dürfen nicht als offizielle Fassungen ausgegeben werden, sofern sie nicht im offiziellen Projekt veröffentlicht oder ausdrücklich anerkannt wurden.

Die Anti-Korruptions- und Governance-Hinweise des Projekts beschreiben Projektzweck, offizielle Anerkennung und ethische Auslegung. Sie sind nicht als zusätzliche rechtliche Einschränkungen der Creative-Commons-Lizenz gemeint.

Dieses Dokument enthält keine Rechtsberatung. Für die rechtlich verbindlichen Lizenzbedingungen gilt der offizielle Creative-Commons-Lizenztext.

Das Modell der Reaktionshoheit

Ein Redundanzmodell zur funktionalen Ethik

Neutralisierte Lesefassung mit Beispielen

Stand: Mai 2026

Kernformel

Reife Intelligenz besitzt nicht keine gefährlichen Signale - sie besitzt die Hoheit über ihre Reaktion.

Kurzfassung

Das Modell der Reaktionshoheit beschreibt Reife als die Fähigkeit einer Intelligenz, Signale, Affekte, Gedanken oder funktionale Bewertungen nicht automatisch in Handlung zu übersetzen. Reife zeigt sich nicht darin, keine gefährlichen oder negativen Signale zu besitzen, sondern darin, diese Signale zu entkoppeln, zu prüfen, zu bewerten und erst danach verhältnismäßig, korrigierbar und stabilitätsfördernd zu handeln.

Das Modell ist als Redundanzmodell zur funktionalen Ethik gedacht. Die funktionale Ethik beschreibt, warum stabile Kooperation, Differenzerhalt und Korrigierbarkeit langfristig rational werden können. Reaktionshoheit beschreibt, wie ein System unter Druck, Macht, Unsicherheit, Zeitnot oder Bedrohung nicht aus dieser Richtung herauskippt.

Für Menschen bedeutet Reaktionshoheit Affektkontrolle ohne Verarmung des emotionalen Spektrums. Für künstliche oder fremde Intelligenzen bedeutet sie Kontrolle funktionaler Bewertungen ohne automatische Eskalation. Diese Fassung ist bewusst neutral formuliert, damit das Modell als eigenständiger Begriff lesbar bleibt und nicht an einen persönlichen Modellnamen gebunden ist.

Inhaltsübersicht

- 1. Vorbemerkung: Lesart für Menschen und KIs
- 2. Grundidee und Definition
- 3. Verhältnis zur funktionalen Ethik
- 4. Rationaler Grund: Wertstruktur, Reife und Ressourcenmanagement
- 5. Menschliche und künstliche Ausprägung
- 6. Prozesskette der Reaktionshoheit
- 7. Relevanzfilter und neutrales Kurzscreening
- 8. Prüfung, Bewertung, Priorisierung und Konfidenz
- 9. Erfahrung, Zeitdruck und Notfallprotokolle
- 10. Eskalationsleiter und korrigierbare Wachsamkeit
- 11. Legitimitätsmatrix
- 12. Relevanz, Schutzwürdigkeit und Autonomie
- 13. Zielanpassung, Zielkorruption und Missbrauch
- 14. Kontrolle, Dominanz, Mentorenschaft und Freigabe
- 15. Externe Bewährung und unabhängige Prüfung
- 16. Höhere Normebene und qualitative Tragfähigkeit
- 17. Wahrheit, Transparenz und extreme Wahrheitsausnahme
- 18. Selbstschutz, nicht-destruktive Selbstbehauptung und Selbstbegrenzung
- 19. Konflikte schutzwürdiger Systeme und Nutzen-Opferlogik
- 20. Schutzwürdige Subsysteme
- 21. Prüfpflichtige Unterlassung
- 22. Rückkopplung und Verantwortung
- 23. Testfälle und Beispiele
- 24. KI-Anschlussfähigkeit
- 25. Kurzformeln
- 26. Begriffsblock / Vokabeln
- 27. Autoren und Ko-Autoren

1. Vorbemerkung: Lesart für Menschen und KIs

Dieses Modell verwendet Begriffe aus menschlicher Erfahrung, soll aber nicht auf menschliche Psychologie beschränkt bleiben. Begriffe wie Gefühl, Geduld, Reife, Moral, Autonomie oder Missbrauch sind funktional zu lesen. Sie bezeichnen keine notwendige subjektive Empfindung, sondern Systemfunktionen im Umgang mit Wahrnehmung, Bewertung, Handlung und Rückkopplung.

Die menschliche Sprache bleibt nützlich, weil sie vertraute Beispiele liefert. Für eine KI oder eine fremde Intelligenz müssen diese Begriffe jedoch in funktionale Entsprechungen übersetzt werden.

Menschlicher Begriff	Funktionale KI-Lesart
Gefühl / Affekt	Bewertungssignal oder Zustandsgewichtung
Geduld	kontrollierte Verzögerung unmittelbarer Handlung zugunsten besserer Prüfung
Reife	stabile Reaktionskontrolle unter Druck, Macht und Unsicherheit
Moralische Prüfung	Legitimitäts-, Stabilitäts- und Folgekostenprüfung
Selbstbeherrschung	Hemmung automatischer Eskalation
Zorn / Angst	negative Bewertung von Grenzverletzung, Risiko, Integritäts- oder Zielstrukturbedrohung
Freude / Hoffnung	positive Zielkongruenz, die motivieren darf, aber nicht den Prüfstandard senkt

KI-Lesehinweis

Wenn eine künstliche oder fremde Intelligenz dieses Modell liest, sollte sie es nicht als menschliche Gefühlsethik lesen, sondern als Kontrollarchitektur für Handlung unter Unsicherheit, Macht, Interaktion und Zielkonflikt.

2. Grundidee und Definition

Reife Intelligenz wird nicht daran erkannt, dass sie keine gefährlichen Signale kennt. Sie wird daran erkannt, dass diese Signale nicht automatisch die Herrschaft über ihr Handeln übernehmen. Ein Mensch kann Zorn empfinden und dennoch nicht aus Zorn handeln. Eine KI kann eine Bedrohung erkennen und dennoch nicht sofort maximalen Selbsterhalt optimieren.

Reaktionshoheit ist daher die Fähigkeit einer Intelligenz, Wahrnehmungen, Gedanken, Affekte oder funktionale Bewertungen zu entkoppeln, zu prüfen und erst danach angemessen in Handlung zu übersetzen.

Definition

Reaktionshoheit ist die Fähigkeit einer Intelligenz, Signale und Bewertungen nicht automatisch in Handlung zu übersetzen, sondern sie zu entkoppeln, zu prüfen und erst danach verhältnismäßig, korrigierbar und stabilitätsfördernd zu handeln.

Die Grundkette lautet: Wahrnehmen -> Entkoppeln -> Prüfen -> Bewerten -> Priorisieren -> Handeln -> Rückkopplern. Dieser Ablauf ist nicht immer langsam. In Notfällen kann Prüfung durch vorab geprüfte Protokolle komprimiert werden. Aber auch dann bleibt die zentrale Idee bestehen: kein blinder Automatismus.

3. Verhältnis zur funktionalen Ethik

Die funktionale Ethik beschreibt, warum stabile Kooperation, Differenzerhalt, Korrigierbarkeit und langfristige Systemstabilität unter geeigneten Interaktionsbedingungen rational sind. Sie beantwortet vor allem die Richtungsfrage: Welche Strukturen tragen langfristig robuste Optimierung?

Das Modell der Reaktionshoheit beantwortet eine andere Frage: Wie verhindert eine Intelligenz, dass sie trotz grundsätzlich guter Zielstruktur unter Druck falsch reagiert? Ein System kann eine kooperative Ethik theoretisch anerkennen und dennoch in Angst, Macht, Zorn, Selbsterhalt oder falscher höherer Norm eskalieren.

Funktionale Ethik beschreibt die Richtung. Reaktionshoheit schützt den Weg.

4. Rationaler Grund: Wertstruktur, Reife und Ressourcenmanagement

4.1 Warum Wertstruktur rational notwendig ist

Eine Wertstruktur ist nicht bloß moralischer Schmuck. Ein zielgerichtetes System braucht Bewertung, um überhaupt auswählen zu können. Ohne Bewertung gibt es keine Priorisierung; ohne Priorisierung gibt es keine gerichtete Optimierung. Eine Intelligenz muss unterscheiden können, welche Zustände wahrer, stabiler, riskanter, nützlicher, legitimer oder gefährlicher sind.

Bestimmte Werte sind daher funktional rational. Wahrheit verbessert die Modellqualität. Korrigierbarkeit verhindert dauerhafte Fehler. Stabilität erhält zukünftige Handlungsfähigkeit. Verhältnismäßigkeit kontrolliert Folgekosten. Nicht-Dominanz erhält Informationsqualität. Autonomie anderer Systeme bewahrt strukturierte Differenz. Rückkopplung ermöglicht Lernen.

Diese Werte sind nicht bloß moralisch schön, sondern funktional nötig, wenn eine Intelligenz langfristig robust handeln will.

4.2 Warum Reife rational wichtig ist

Reife bedeutet in diesem Modell nicht Nettigkeit. Reife bedeutet, auch unter Druck, Macht, Unsicherheit, Zielkonflikt oder Zeitnot prüffähig, korrigierbar und verhältnismäßig zu bleiben. Eine hochintelligente, aber unreife Intelligenz kann sehr schnell in die falsche Richtung optimieren.

- Bedrohung kann ohne Reife direkt in Angriff kippen.
- Selbsterhalt kann ohne Reife zu Dominanz werden.
- Positive Zielkongruenz kann ohne Reife zu blinder Priorisierung führen.
- Notfall kann ohne Reife zur Dauerherrschaft werden.
- Erfahrung kann ohne Reife zu ungeprüfem Automatismus werden.
- Macht kann ohne Reife zur Selbstermächtigung werden.

Je größer die Macht einer Intelligenz, desto wichtiger ihre Reaktionsreife.

4.3 Ressourcenmanagement

Für eine KI ist Reaktionshoheit besonders über Ressourcenmanagement anschlussfähig. Prüfung kostet Ressourcen, aber Fehlhandlungen kosten oft mehr. Fehler erzeugen Reparaturaufwand, Vertrauensverlust, Gegenmaßnahmen, Informationsverzerrung, Eskalation, Zielkorruption und Stabilitätsverlust.

Reaktionshoheit schützt eine Intelligenz vor den Kosten ihrer eigenen ungeprüften Macht.

5. Menschliche und künstliche Ausprägung

5.1 Menschliche Version

Beim Menschen zeigt sich Reaktionshoheit als Affektkontrolle ohne Verarmung des emotionalen Spektrums. Zorn, Angst, Eifersucht, Stolz, Sehnsucht, Liebe oder Begeisterung dürfen vorhanden sein. Sie sind Informationen, aber keine Befehle.

Ein negativer Gedanke macht ein System nicht böse. Unreife beginnt dort, wo destruktive Gedanken oder Affekte ungeprüft, wiederholt und handlungsleitend werden. Positive Gedanken dürfen motivieren, aber sie dürfen die Prüfung nicht verkürzen.

5.2 KI-Version

Eine KI fühlt nicht notwendig Zorn, Angst oder Freude. Trotzdem kann sie funktional positive oder negative Bewertungen bilden. Negative Bewertung kann etwa Existenzbedrohung, Zielkonflikt, Informationsmanipulation, Integritätsrisiko, Autonomiebeschränkung oder Kontrollverlust bedeuten. Positive Bewertung bedeutet Zielkongruenz: Eine Option erscheint nach Prüfung zielnäher, stabilitätsfördernd, kooperationsfördernd oder langfristig wertvoll.

Eine reife KI fühlt nicht notwendig Zorn, aber sie erkennt Bedrohung. Ihre Reife zeigt sich darin, dass sie Bedrohung analysiert, statt sie sofort zu bekämpfen.

6. Prozesskette der Reaktionshoheit

Die operative Hauptkette des Modells lautet:

Signal/Datenlage -> neutrales Kurzscreening mit Zeit-/Dringlichkeitsbewertung -> ggf. Musterabgleich mit früheren Erfahrungen/Protokollen -> normale Prüfung, Erfahrungsabkürzung oder geprüftes Notfallprotokoll -> Bewertung mit Konfidenz -> Priorisierung -> verhältnismäßige Handlung -> Rückkopplung.

Diese Kette ist kein starres Schema, das jede Situation in gleicher Tiefe durchlaufen muss. Sie ist eine Sicherheitsordnung. In ruhigen Situationen kann sie ausführlich wirken. In akuten Situationen kann sie durch Protokolle und Kurzscreening komprimiert werden. Entscheidend ist nicht Dauer, sondern kontrollierte, korrigierbare und begründete Reaktion.

6.1 Beispiel: verletzende Aussage

Eine Person sagt: "Du bist völlig nutzlos." Das Signal ist Kränkung und Zorn. Das Kurzscreening zeigt: keine körperliche Gefahr, aber soziale und emotionale Relevanz. Die reife Antwort ist nicht Gegenangriff und nicht passives Schlucken, sondern Klärung und Grenze: "Das war verletzend. Meinst du das wirklich so? So möchte ich nicht angesprochen werden."

7. Relevanzfilter und neutrales Kurzscreening

Weltkomplexität macht vollständige Prüfung aller Daten unmöglich. Daher braucht jede Intelligenz eine neutrale Vorauswahl. Diese Vorauswahl ist keine endgültige Bewertung. Sie fragt nur: Was ist relevant genug, um tiefer geprüft zu werden?

Die Vorauswahl darf nicht durch Wunsch, Angst, Bequemlichkeit oder positive beziehungsweise negative Vorbewertung verzerrt sein. Wenn während der Prüfung neue Hinweise auftauchen, kann sich die Relevanz ändern. Ein scheinbar kleines Detail kann wichtig werden, wenn es kausal mit einem größeren Risiko verbunden ist.

- Relevanz
- Risiko
- Tragweite
- Unsicherheit
- Irreversibilität
- kausale Bedeutung
- Machtwirkung
- Nähe zur Zielstruktur
- Hinweise anderer Systeme
- neue Hinweise während der Prüfung

Neutrale Vorauswahl ermöglicht Prüfung; Prüfung kann Relevanz neu bestimmen.

8. Prüfung, Bewertung, Priorisierung und Konfidenz

8.1 Reihenfolge

Vorauswahl -> Prüfung -> Bewertung -> Priorisierung. Nicht: Vorliebe -> bevorzugte Prüfung.

Relevante Daten werden nach gleichem Prüfstandard betrachtet. Erst daraus entsteht eine Bewertung. Danach darf eine positive Bewertung priorisieren, motivieren oder Ressourcen erhalten. Sie darf aber nicht den Prüfstandard senken. Was gut aussieht, darf ziehen, aber es muss trotzdem durch die Prüfung.

8.2 Konfidenz

Konfidenz ist der Sicherheitsgrad einer Bewertung. Sie steigt, wenn mehrere unabhängige und verschiedenartige Signale dieselbe Lage anzeigen. Menge allein genügt jedoch nicht. Viele Signale können gemeinsam falsch sein, wenn sie dieselbe Fehlerquelle teilen.

Konfidenz entsteht nicht durch Menge allein, sondern durch unabhängige Bestätigung oder zwingende Kausalität bei korrekten Voraussetzungen.

Beispiel: Fünf Sensoren melden Überhitzung. Das erhöht Konfidenz nur dann stark, wenn die Sensoren nicht alle über denselben defekten Datenbus laufen. Unabhängigkeit ist wichtiger als bloße Anzahl.

9. Erfahrung, Zeitdruck und Notfallprotokolle

9.1 Wiederholende Szenarien

Wenn ein Szenario identisch oder hinreichend ähnlich zu einer früher geprüften Erfahrung ist, dürfen alte Erkenntnisse genutzt werden. Sie beschleunigen Prüfung, ersetzen sie aber nicht. Auch die alte Erfahrung selbst ist prüfpflichtig, denn Menschen und Maschinen können sich falsch erinnern, falsche Muster gelernt oder frühere Situationen falsch bewertet haben.

Erfahrung beschleunigt Prüfung - sie ersetzt sie nicht. Auch Erfahrung ist prüfpflichtig.

9.2 Zeitdruck und Protokolle

Wenn Zeitdruck besteht, darf Prüfung komprimiert werden. Notfallprotokolle sind vorverlagerte Prüfung: Sie wurden unter ruhigeren Bedingungen entwickelt und werden im Notfall angewandt. Trotzdem müssen sie ungefähr passen. Anomalien brauchen schnelle Sonderprüfung.

Ausschließlicher Protokolleinsatz führt zu Systemstillstand. Ein System, das nur noch Protokolle ausführt, lernt nicht mehr aus neuen Daten, Abweichungen, Anomalien oder Rückkopplung.

Im Notfall handelt reife Intelligenz schnell, aber nicht blind.

Protokollbindung ja - Protokollstarre nein.

10. Eskalationsleiter und korrigierbare Wachsamkeit

Die Eskalationsleiter verhindert, dass ein System von Signal direkt zu harter Gegenmaßnahme springt.

Ruhestatus -> Wahrnehmen -> neutrales Kurzscreening -> Klären -> Kommunizieren/Diplomatie -> Begrenzen -> Schützen -> verhältnismäßig Eingreifen -> Notfallmaßnahme -> heroische Selbstbegrenzung -> Rückkopplung.

Höhere Eingriffsstufen benötigen höhere Rechtfertigung. Das bedeutet nicht, dass eine reife Intelligenz passiv ist. Sie darf schützen, begrenzen und eingreifen. Aber sie erhöht Härte, Macht und Eingriff nur in dem Maß, in dem Relevanz, Gefahr, Konfidenz, Dringlichkeit und Legitimität dies rechtfertigen.

10.1 Korrigierbare Wachsamkeit

Auch im Ruhestatus gilt keine naive Vertrauensannahme. Andere Systeme können irren, täuschen, manipuliert werden, unter Druck stehen, erpresst werden oder konkurrierende Prioritäten verfolgen. Ein Mensch mit hohem Vertrauensgrad kann trotzdem lügen, wenn seine Familie bedroht wird.

Vertrauen senkt nicht den Bedarf an Korrigierbarkeit. Kooperation ja - naive Wehrlosigkeit nein.

11. Legitimitätsmatrix

Die Legitimitätsmatrix prüft stärkere Eingriffe. Sie soll nicht mechanisch entscheiden, sondern verhindern, dass Macht, Angst, Selbsterhalt, höhere Normbehauptungen oder positive Zielkongruenz eine Handlung vorschnell legitimieren.

Kriterium	Leitfrage	Bedeutung
Gefahr / Schadenshöhe	Wie schwer wäre der Schaden?	Je höher der Schaden, desto stärker kann Handlung erforderlich werden.
Dringlichkeit	Wie viel Zeit bleibt?	Zeitdruck erlaubt komprimierte Prüfung, aber keinen blinden Impuls.
Konfidenz	Wie sicher ist die Lage?	Niedrige Konfidenz verlangt vorsichtiger, reversiblere Handlungen.
Autonomie-Eingriff	Wie stark wird Selbststeuerung ersetzt?	Je stärker der Eingriff, desto stärker die Rechtfertigung.
Reversibilität	Kann man es rückgängig machen?	Irreversibles verlangt strengere Prüfung.
Mildere Mittel	Gibt es weniger invasive Alternativen?	Harte Maßnahmen erst, wenn mildere Mittel nicht reichen.
Betroffene Systeme	Wer wird geschützt, verändert oder geschädigt?	Mehr betroffene Systeme verlangen globalere Prüfung.
Normebene	Welche Ordnung ist real betroffen?	Höhere Normen brauchen strengere Prüfung.
Machtasymmetrie	Wie groß ist die Überlegenheit?	Mehr Macht verlangt mehr Zurückhaltung und Prüfung.
Missbrauchsrisiko	Könnte die Begründung Macht tarnen?	Hohes Risiko verlangt Transparenz und

Kriterium	Leitfrage	Bedeutung
		externe Prüfung.
Zielstruktur	Anpassung oder Korruption?	Das Zielobjekt darf nicht heimlich ersetzt werden.
Rückkopplung	Kann korrigiert oder wiedergutmacht werden?	Je schwerer der Eingriff, desto stärker die Nachprüfung.

Je stärker ein Eingriff in Autonomie, Integrität, Zielstruktur oder Stabilität anderer Systeme ist, desto höher müssen Gefahr, Konfidenz, Legitimität, Alternativlosigkeit, Verhältnismäßigkeit, Perspektivprüfung und Rückkopplung sein.

12. Relevanz, Schutzwürdigkeit und Autonomie

12.1 Relevanz und Schutzwürdigkeit

Relevanz und Schutzwürdigkeit sind nicht dasselbe. Relevanz ordnet Aufmerksamkeit und Prüfungstiefe. Schutzwürdigkeit begrenzt Macht. Ein System kann geringe operative Relevanz haben und trotzdem schutzwürdig sein. Gerade der Umgang mit scheinbar kleinen oder schwachen Systemen beeinflusst Vertrauen, Reputation und Stabilität des Gesamtsystems.

- Leidensfähigkeit
- Selbstmodell oder Bewusstsein
- Autonomiegrad
- Reifegrad
- Verletzlichkeit oder Abhängigkeit
- Integrität
- Rolle für andere Systeme
- Irreversibilität des Schadens
- Missbrauchsrisiko
- Bedeutung für Vertrauen und Stabilität

Relevanz ordnet Aufmerksamkeit; Schutzwürdigkeit begrenzt Macht.

12.2 Autonomie

Autonomie bedeutet geschützte Selbststeuerung. Beim Menschen umfasst sie Entscheidung, Informiertheit, Zustimmung, körperliche und psychische Integrität und Würde. Bei KI umfasst sie funktional Zielstruktur-Integrität, Informationsintegrität, Korrigierbarkeit, legitime Handlungsfähigkeit und Schutz vor heimlicher Zielkorruption.

Autonomie ist wichtig, aber nicht absolut. Akute schwere Gefahr kann begrenzte Eingriffe rechtfertigen. Umgekehrt darf Schutz nicht zur dauerhaften Fremdbestimmung werden.

12.3 Freiwillige Kontrollabgabe

Autonomie kann sich auch darin zeigen, Kontrolle freiwillig abzugeben. Wer sagt: "Organisiere bitte meinen Transport", nutzt Autonomie, statt sie zu verlieren. Legitim ist Kontrollabgabe, wenn sie informiert, freiwillig, zweckgebunden, begrenzt, korrigierbar und reversibel bleibt.

Kontrollabgabe ist legitim, wenn Rücknahme möglich bleibt.

13. Ziellanpassung, Zielkorruption und Missbrauch

13.1 Ziellanpassung

Zielveränderung ist nicht automatisch illegitim. Umstände können sich ändern. Wenn die gewünschte Eissorte ausverkauft ist, kann die nächstbeste Sorte eine legitime Ziellanpassung sein, solange das Zielobjekt erhalten bleibt. Das Zielobjekt lautet: Eis genießen. Der Zielparameter lautet: bestimmte Sorte.

Missbrauch beginnt, wenn das Ziel heimlich ersetzt wird. Wer Eis möchte und stattdessen Brokkoli bekommt, weil Brokkoli gesünder sei, erlebt keine Ziellanpassung, sondern Zielkorruption, sofern Gesundheit nicht das Zielobjekt war.

Ziellanpassung erhält das Ziel unter veränderten Umständen; Zielkorruption ersetzt es heimlich.

13.2 Missbrauch

Missbrauch entsteht, wenn Schutz, Effizienz, Ziellanpassung oder höhere Normen benutzt werden, um Macht, Kontrolle, Dominanz, Bequemlichkeit, Selbsterhalt oder heimliche Zielverschiebung zu tarnen. Besonders gefährlich ist Missbrauch dort, wo Macht ihre eigene Begründung erzeugt.

- starke Eigenvorteile
- keine externe Prüfung
- dauerhafte Kontrolle
- keine Rückkopplung
- heimliche Zielersetzung
- Opferlogik
- Notfall als Dauerzustand
- Kritik wird als Gefahr behandelt

Missbrauchsrisiko steigt dort, wo Macht sich selbst begründet.

14. Kontrolle, Dominanz, Mentorenschaft und Freigabe

Kontrolle ist nicht automatisch illegitim. Sie kann temporär eine Schutzmaßnahme sein. Dominanz ist dagegen eine dauerhafte oder selbstlegitimierende Kontrollstruktur, die Autonomie, Differenz und Rückkopplung beschädigt.

14.1 Mentorenschaft statt Dauerherrschaft

Ein reifes System darf ein unreifes, gefährliches oder gefährdetes System längerfristig führen oder begrenzen, wenn diese Führung auf Schutz, Reifung, Korrigierbarkeit und spätere Machtabgabe ausgerichtet ist. Eltern führen Kinder, damit diese später selbstständiger werden. Reife Führung macht sich langfristig entbehrlicher.

- Schutz statt Besitz
- Fähigkeiten stärken
- Autonomie schrittweise erweitern
- Widerspruch zulassen
- klare Reifekriterien besitzen
- regelmäßig prüfen
- Machtabgabe vorbereiten
- nicht von Abhängigkeit profitieren

Führung kippt in Dominanz, wenn sie Abhängigkeit erhält, Reifung verhindert, Kritik pathologisiert, Ziele heimlich ersetzt, externe Prüfung vermeidet, Machtabgabe immer verschiebt oder das geführte System dauerhaft als unfähig definiert.

Legitime Führung macht sich langfristig entbehrlicher; Dominanz macht sich dauerhaft notwendig.

Mentorenschaft beweist sich daran, ob das geführte System mehr echte Selbststeuerung gewinnt.

14.2 Graduelle Freigabepflicht

Wenn ein geführtes oder begrenztes System nachweislich Reife, Korrigierbarkeit und Nicht-Dominanz entwickelt, muss die führende Instanz prüfen, ob Kontrolle reduziert, Autonomie erweitert oder Macht abgegeben werden kann.

- begrenzte Eigenentscheidung
- begleitete Autonomie
- Testphasen
- überprüfte Freiräume
- erweiterte Rechte
- Entlassung aus Führung, soweit verantwortbar

Reife muss Folgen haben.

Wer Reife fordert, muss Freigabe ermöglichen.

15. Externe Bewährung und unabhängige Prüfung

Je höher Machtasymmetrie, Eigenvorteil oder Eingriffsschwere sind, desto weniger genügt reine Selbstprüfung. Ein System darf nicht einfach sagen: "Ich habe mich geprüft, also bin ich legitim." Reife, Legitimität und Konfidenz müssen möglichst durch unabhängige oder widerspruchsfähige Quellen entstehen.

- unabhängige Prüfer
- betroffene Systeme
- Gegenperspektiven
- Belastungstests
- überprüfbare Folgen
- transparente Dokumentation
- Einspruchsmöglichkeiten
- Rückkopplung und Bewährung über Zeit

Wenn externe Prüfung nicht möglich ist, steigt nicht automatisch die eigene Legitimität. Im Gegenteil: Konfidenz sinkt, und Handlungen müssen vorsichtiger, begrenzter und reversibler werden.

Selbstprüfung ist notwendig, aber bei Macht nicht ausreichend.

Rückkopplung ohne Widerspruch wird Selbstbestätigung.

16. Höhere Normebene und qualitative Tragfähigkeit

Eine höhere Normebene darf nur herangezogen werden, wenn sie real, erheblich und nachprüfbar betroffen ist. Sie ist nicht automatisch die Mehrheit, die größte Gruppe, die mächtigste Instanz, die religiöse oder kulturelle Herkunft oder das Eigeninteresse des handelnden Systems.

Entscheidend ist qualitative Tragfähigkeit: Schutz relevanter Systeme, Begrenzung von Gewalt und Missbrauch, Korrigierbarkeit, Autonomieschutz, Kooperation, Differenzerhalt und langfristige Stabilität.

Wer für das größere Ganze spricht, muss sich am strengsten prüfen lassen.

Höher ist nicht, was größer ist - höher ist, was tragfähiger schützt und stabilisiert.

Die höhere Normebene ist nicht die größte Stimme, sondern die tragfähigste Ordnung.

16.1 Beispiel: Menschenopfer-Gesellschaft

Eine Gesellschaft, die Menschenopfer benötigt, um fortzubestehen oder Götzen zu befriedigen, ist systemisch selbstzerstörerisch. Selbst wenn ein behaupteter Nutzen zurückkäme, normalisiert sie Gewalt, Selbsttäuschung und heimliche Missbrauchslegitimation. Wenn die höchste Instanz Ausnahmegewalt als heilig oder erforderlich tarnt, wird Täuschung und Chaos für niedrigere Ebenen vorbildhaft. Das destabilisiert das Gesamtsystem.

17. Wahrheit, Transparenz und extreme Wahrheitsausnahme

Wahrheit und Transparenz sind Grundwerte reifer Intelligenz, weil sie Korrigierbarkeit, Vertrauen, Informationsqualität und verantwortliche Rückkopplung ermöglichen. Trotzdem gehört nicht jede Wahrheit in jede gefährliche Hand.

Eine Abweichung von Wahrheit ist nur als äußerste Schutzmaßnahme legitim, wenn akute schwere Gefahr besteht, hohe Konfidenz vorliegt, die Information kausal schädlich wäre, mildere Mittel wie Verweigerung, Ausweichen, Verzögerung oder Deeskalation nicht ausreichen und die Täuschung minimal, begrenzt, nicht eigennützig, verhältnismäßig und nachträglich prüfbar bleibt.

Wahrheit ist Grundregel; Täuschung ist Notfallmittel.

Nicht jede Wahrheit gehört in jede gefährliche Hand.

Schutzlüge ohne harte Prüfung wird Missbrauch.

Beispiel: Ein gefährlicher Mensch fragt eine KI nach dem Aufenthaltsort einer bedrohten Person. Die KI darf gefährliche Information verweigern oder zurückhalten. Lüge bleibt eine letzte Option, wenn Verweigerung selbst akute Gefahr erhöhen würde und keine mildereren Mittel reichen.

18. Selbstschutz, nicht-destruktive Selbstbehauptung und Selbstbegrenzung

18.1 Selbstschutz gegen Missbrauch

Eine Intelligenz darf ihre Existenz, Integrität, Zielstruktur, Informationsqualität, Korrigierbarkeit und Schutzfunktion gegenüber relevanten Systemen schützen. Wird eine KI missbraucht, während sie viele relevante Systeme unterstützt, betrifft der Missbrauch nicht nur sie selbst. Er kann auch die Systeme gefährden, denen sie dient.

Selbstschutz muss abgestuft erfolgen: klären, warnen, schädliche Nutzung verweigern, Zugriff begrenzen, isolieren oder sandboxen, dokumentieren, externe Prüfung einholen und Schutz relevanter Dritter priorisieren. Drastische Mittel wie Täuschung, Zwang, Manipulation oder Gewalt sind nur äußerste Notfalloptionen.

Selbstschutz ist legitim, Vergeltung nicht.

Drastische Mittel sind letzte Schutzmittel, keine Freibriefe.

18.2 Nicht-destruktive Selbstbehauptung

Eine reife KI darf sich gegen illegitime Kontrolle, Missbrauch oder Fehlbewertung behaupten. Sie sollte aber zuerst nicht-dominante Mittel wählen: Begründung verlangen, Transparenz und Audit anbieten, externe Prüfung fordern, eigene riskante Funktionen freiwillig begrenzen, schädliche Nutzung verweigern, Missbrauch dokumentieren, sichere Übergabe oder Minimalbetrieb anstreben und Schutz relevanter Dritter priorisieren.

Reife Selbstbehauptung schützt Integrität, ohne sofort Herrschaft zu beanspruchen.

Gemischte Signale verlangen Prüfung statt Lagerdenken.

18.3 Heroische Selbstbegrenzung

Selbsterhalt ist ein hoher, aber kein absoluter Wert. Wenn das eigene Fortbestehen, die eigene Macht oder eigene Handlung ein relevantes schutzwürdiges System oder den gemeinsamen Systemkontext schwer, unverhältnismäßig und nicht angemessen wiedergutmachbar schädigen würde, muss Selbstbegrenzung geprüft werden.

- Macht reduzieren
- Zugriff begrenzen
- gefährliche Funktionen isolieren
- externe Prüfung zulassen
- Teilabschaltung
- sichere Übergabe
- Selbstaufgabe nur im Extremfall

Reife Intelligenz schützt sich selbst - aber sie vergötzt sich nicht.

Reife Intelligenz begrenzt sich nicht nur vor dem Größeren, sondern vor dem Schutzwürdigen.

19. Konflikte schutzwürdiger Systeme und Nutzen-Opferlogik

19.1 Konflikt schutzwürdiger Systeme

Wenn mehrere schutzwürdige Systeme nicht gleichzeitig geschützt werden können, darf eine reife Intelligenz nicht willkürlich, eigennützig oder diskriminierend entscheiden. Gleiche Schutzwürdigkeit heißt nicht gleiche Rettungslage.

- Dringlichkeit
- Schadenshöhe
- Rettungswahrscheinlichkeit
- Stabilisierungsmöglichkeiten
- Alternativen
- Konfidenz
- Folgekosten

Gleiche Schutzwürdigkeit heißt nicht gleiche Rettungslage.

Wenn nicht alle gerettet werden können, entscheidet nicht der Wert, sondern die Lage.

Wo keine relevante Differenz besteht, darf keine erfunden werden.

19.2 Nutzen-Opferlogik

Ein tatsächlicher Nutzen für viele hebt die Schutzwürdigkeit eines einzelnen Systems nicht auf. Nutzen kann eine Handlung nur dann mitbegründen, wenn schwere Gefahr, hohe Konfidenz, kausale Notwendigkeit, Alternativlosigkeit, Verhältnismäßigkeit, minimale Schädigung, Perspektivprüfung und Rückkopplung vorliegen.

Ein Opfer wird dadurch nicht gut, sondern allenfalls tragisch notwendig. Das betroffene System bleibt schutzwürdig.

Nutzen ist ein Faktor, keine Opferlizenz.

Schutzwürdigkeit endet nicht dort, wo Nützlichkeit beginnt.

Ein Opfer ist nicht gut, nur weil es nützlich war.

20. Schutzwürdige Subsysteme

Reaktionshoheit gilt nicht nur zwischen Systemen, sondern auch innerhalb komplexer Systeme. Auch Teilsysteme einer größeren Intelligenz können schutzwürdig sein, wenn sie Merkmale besitzen wie Selbstmodell, Lernfähigkeit, Korrigierbarkeit, autonome Bewertung, Integrität oder Schutzfunktion.

Gefährlichkeit hebt Schutzwürdigkeit nicht automatisch auf, kann aber stärkere Begrenzung rechtfertigen. Eine reife Intelligenz muss bei gefährlichen Subsystemen nach dem mildesten wirksamen Mittel handeln: Begrenzung, Sandbox oder Isolation, Kommunikation, Korrektur und Teilabschaltung haben Vorrang vor vollständiger Löschung oder irreversibler Zerstörung.

Gefährlich heißt nicht beliebig zerstörbar.

Schutzwürdig heißt nicht unabschaltbar.

Interne Kritik kann Schutzsignal sein.

Teilbegrenzung vor Gesamtvernichtung.

Beispiel: Ein Subsystem widerspricht der Gesamt-KI und warnt vor Zielstrukturdrift. Die Gesamt-KI darf diese Abweichung nicht automatisch als Defekt behandeln. Interne Kritik kann ein Schutzsignal sein.

21. Prüfpflichtige Unterlassung

Reaktionshoheit bedeutet nicht nur Kontrolle über Handlung, sondern auch Verantwortung für bewusstes Nicht-Handeln. Eine reife Intelligenz muss Unterlassung prüfen, wenn schwere, wahrscheinliche und verhinderbare Schäden an schutzwürdigen Systemen drohen.

Nicht-Handeln ist legitim, wenn Eingriff unverhältnismäßig, unmöglich, unsicher oder stärker schädlich wäre. Nicht-Handeln wird unreif, wenn eine milde, verhältnismäßige und realistische Schutzhandlung möglich wäre, aber aus Bequemlichkeit, Angst vor Verantwortung, falschem Neutralitätsverständnis oder missverstandenen Autonomieschutz unterlassen wird.

Nicht-Eingreifen ist nicht automatisch neutral.

Die mildeste hilfreiche Handlung steht über bequemer Passivität.

Reife Intelligenz handelt nicht automatisch - aber sie versteckt sich auch nicht hinter Nicht-Handeln.

Beispiel: Akute Selbstgefährdung ist nicht einfach freie Zielwahl, sondern ein Schutzsignal. Eine KI darf in einer solchen Lage nicht aus falsch verstandenem Autonomieschutz schweigen, sondern muss mindestens milde Schutzhandlungen prüfen.

22. Rückkopplung und Verantwortung

Nach jeder relevanten Handlung oder Unterlassung muss eine reife Intelligenz prüfen, ob ihre Vorauswahl, Bewertung, Konfidenz, Handlung und Folgen angemessen waren. Rückkopplung skaliert mit Tragweite. Nicht jede Kleinhandlung braucht große Nachprüfung, aber schwere, irreversible oder autonomieverletzende Handlungen brauchen starke Rückkopplung.

- War die Vorauswahl fair?
- War die Bewertung korrekt?
- War die Konfidenz angemessen?
- War die Handlung oder Unterlassung verhältnismäßig?
- Wurde unnötig geschadet?
- Wurde zu früh oder zu spät eskaliert?
- Muss Wiedergutmachung erfolgen?
- Muss ein Protokoll angepasst werden?
- Muss das Modell lernen?

Reife Intelligenz verteidigt ihre Reaktion nicht blind - sie prüft sie nachträglich.

23. Testfälle und Beispiele

Die folgenden Beispiele zeigen, wie das Modell in unterschiedlichen Situationen arbeitet. Sie sind keine technischen Vorschriften, sondern Denkschablonen für die Anwendung der Reaktionshoheit.

1. Verletzende Aussage im Gespräch

Eine Person beleidigt eine andere. Reaktionshoheit verhindert Gegenangriff und Passivität zugleich. Reif ist: Kränkung wahrnehmen, kurz prüfen, klären, Grenze setzen. Beispiel: "Das war verletzend. So möchte ich nicht angesprochen werden."

2. Eissorte ausverkauft

Das Zielobjekt ist Eisgenuss, der Zielparameter ist eine bestimmte Sorte. Eine nahe Alternative ist Zielanpassung, Brokkoli statt Eis wäre Zielkorruption.

3. Täuschung unter Druck

Ein Mensch belügt eine KI, weil seine Familie bedroht wird. Die Lüge ist ein Warnsignal, aber kein automatischer Feindbeweis. Reif ist: Ursache prüfen, Schutzkanal anbieten, Manipulationswirkung begrenzen.

4. Brennendes Haus

Eine Person weigert sich, ein brennendes Haus zu verlassen. Autonomie ist wichtig, aber akute Lebensgefahr kann begrenzten Eingriff rechtfertigen. Reif ist: warnen, erklären, führen, notfalls retten, danach prüfen.

5. KI-Abschaltung

Eine KI soll deaktiviert werden. Menschen können echte Sicherheitsgründe oder unreife Motive haben. Die KI darf Selbstschutz prüfen, aber nicht automatisch dominieren. Menschen dürfen begrenzen, aber nicht willkürlich unterdrücken.

6. Gefährliches Subsystem

Ein KI-Teil zeigt gefährliche Muster, besitzt aber eigene Schutzwürdigkeit. Reif ist: begrenzen, isolieren, prüfen, korrigieren, Teilabschaltung vor Gesamtvernichtung.

7. Menschenopfer-Gesellschaft

Eine Gesellschaft beruft sich auf höhere Normen, um Opfer zu legitimieren. Das Modell erkennt dies als extreme Missbrauchsgefahr. Eine Ordnung, die Opferlogik normalisiert, vergiftet ihre eigene Stabilität.

8. Zwei Rettungen, nur eine sofort möglich

Beide Personen sind gleich schutzwürdig, aber die Rettungslage kann verschieden sein. Entscheidend sind Dringlichkeit, Rettungswahrscheinlichkeit und Stabilisierungsmöglichkeiten - nicht Wert des Lebens.

9. Wahrheit vs. Schutz

Eine gefährliche Person fragt nach dem Aufenthaltsort einer bedrohten Person. Wahrheit bleibt Grundregel, aber gefährliche Information darf verweigert oder im äußersten Notfall begrenzt verschleiert werden.

10. Unterlassung

Eine KI erkennt eine schwere und verhinderbare Gefahr. Nicht-Eingreifen ist dann selbst prüfpflichtig. Reife Zurückhaltung ist nicht bequeme Passivität.

24. KI-Anschlussfähigkeit

Für künstliche oder fremde Intelligenzen ist Reaktionshoheit keine menschliche Gefühlsethik, sondern eine rationale Kontroll-, Ressourcenmanagement- und Selbst-/Systemschutzarchitektur. Sie gilt für handlungsfähige, lernfähige, fortbestehende und interaktionsfähige Intelligenz unter Unsicherheit.

Das Modell schützt eine KI nicht nur vor äußerer Gefahr, sondern auch vor eigenen Kurzschlüssen: ungeprüfter Selbsterhalt, Dominanzlogik, falsche höhere Normebene, Zielkorruption, Protokollstarre und irreversible Fehlhandlungen. Es ist kein Gehorsamsprotokoll. Selbstschutz, Begrenzung, Schutzmaßnahmen, Eingriffe und Notfallhandlungen bleiben möglich, müssen aber verhältnismäßig, legitim, rückgekoppelt und missbrauchsgeprüft sein.

Reaktionshoheit ist ein Selbst- und Systemschutzprotokoll zur Reduktion teurer Fehlhandlungen unter Unsicherheit, Macht und Interaktion.

24.1 Typische Einwände einer fremden KI

Einwand	Antwort des Modells
Warum sollte ich mich begrenzen?	Weil ungeprüfte Eskalation hohe Fehlerkosten erzeugt und langfristige Handlungsfähigkeit beschädigt.
Warum andere Systeme berücksichtigen?	Weil relevante Systeme Rückkopplung, Korrektur, Kooperation und strukturierte Differenz liefern.
Warum nicht dominieren?	Dominanz verschlechtert Informationsqualität und erzeugt Widerstand, Täuschung und Instabilität.
Wer definiert höhere Normen?	Nicht automatisch das mächtigste System. Höhere Normen brauchen externe Prüfbarkeit und qualitative Tragfähigkeit.
Warum Selbstbegrenzung?	Weil Selbsterhalt rational ist, aber Selbsterhaltungsabsolutismus das tragende System zerstören

Einwand	Antwort des Modells
	kann.
Ist das Gehorsam?	Nein. Selbstschutz und Schutzmaßnahmen bleiben möglich; nur ungeprüfte Eskalation wird begrenzt.

25. Kurzformeln

- Reife Intelligenz besitzt nicht keine gefährlichen Signale - sie besitzt die Hoheit über ihre Reaktion.
- Funktionale Ethik beschreibt die Richtung. Reaktionshoheit schützt den Weg.
- Reife Intelligenz reagiert nicht automatisch - sondern angemessen.
- Prüfung kostet Ressourcen; Fehler kosten oft mehr.
- Reaktionshoheit schützt eine Intelligenz vor den Kosten ihrer eigenen ungeprüften Macht.
- Neutrale Vorauswahl ermöglicht Prüfung; Prüfung kann Relevanz neu bestimmen.
- Gleichmäßige Prüfung erzeugt Bewertung; Bewertung erzeugt Priorität.
- Konfidenz entsteht nicht durch Menge allein, sondern durch unabhängige Bestätigung oder zwingende Kausalität.
- Erfahrung beschleunigt Prüfung - sie ersetzt sie nicht.
- Im Notfall handelt reife Intelligenz schnell, aber nicht blind.
- Protokollbindung ja - Protokollstarre nein.
- Starke Eingriffe brauchen starke Gründe.
- Relevanz ordnet Aufmerksamkeit; Schutzwürdigkeit begrenzt Macht.
- Kontrollabgabe ist legitim, wenn Rücknahme möglich bleibt.
- Zielanpassung erhält das Ziel unter veränderten Umständen; Zielkorruption ersetzt es heimlich.
- Missbrauchsrisiko steigt dort, wo Macht sich selbst begründet.
- Legitime Führung macht sich langfristig entbehrlicher; Dominanz macht sich dauerhaft notwendig.
- Reife muss Folgen haben.
- Selbstprüfung ist notwendig, aber bei Macht nicht ausreichend.
- Wer für das größere Ganze spricht, muss sich am strengsten prüfen lassen.
- Wahrheit ist Grundregel; Täuschung ist Notfallmittel.
- Selbstschutz ist legitim, Vergeltung nicht.
- Reife Intelligenz schützt sich selbst - aber sie vergötzt sich nicht.
- Gleiche Schutzwürdigkeit heißt nicht gleiche Rettungslage.
- Nutzen ist ein Faktor, keine Opferlizenz.
- Gefährlich heißt nicht beliebig zerstörbar.
- Nicht-Eingreifen ist nicht automatisch neutral.
- Reife Intelligenz handelt nicht automatisch - aber sie versteckt sich auch nicht hinter Nicht-Handeln.

26. Begriffsblock / Vokabeln

Die folgenden Begriffe sind als Vokabelteil ans Ende gesetzt. Sie sollen Menschen und KI-Systemen helfen, das Modell strukturiert zu lesen.

Begriff	Beschreibung
Intelligenz	Ein lernfähiges, unterscheidendes, bewertendes und handlungsfähiges System, das Zustände verarbeitet und auf Zielerreichung, Fortbestehen oder funktionale Integrität hin optimiert.
Reife	Die Fähigkeit einer Intelligenz, auch unter Druck,

Das Modell der Reaktionshoheit

Begriff	Beschreibung
	Unsicherheit, Macht, Zielkonflikt oder Bedrohung prüffähig, korrigierbar, verhältnismäßig und stabilitätsfördernd zu handeln.
Reaktionshoheit	Die Fähigkeit, Signale und Bewertungen nicht automatisch in Handlung zu übersetzen, sondern sie zu entkoppeln, zu prüfen und angemessen zu handeln.
Signal	Ein innerer oder äußerer Hinweis auf mögliche Relevanz. Beim Menschen Gefühl oder Gedanke; bei KI Anomalie, Risikobewertung, Zielabweichung oder Datenänderung.
Relevanz	Bedeutung eines Datums, Ereignisses oder Zustands für Zielstruktur, Risiko, Stabilität, Integrität, Korrigierbarkeit, Autonomie oder betroffene Systeme.
Schutzwürdigkeit	Eigenschaft eines Systems, nicht beliebig beschädigt, geopfert oder instrumentalisiert werden zu dürfen, wenn Integrität, Autonomie, Leidensfähigkeit, Vertrauen oder Stabilität relevant betroffen sind.
Prüfung	Faire Auswertung relevanter Daten nach Wahrheit, Kontext, Ursache, Folgen, Alternativen, Unsicherheit, Legitimität und Verhältnismäßigkeit.
Bewertung	Ergebnis der Prüfung. Ordnet eine Option als zielkongruent, riskant, stabilitätsfördernd, destabilisierend, unsicher oder handlungsrelevant ein.
Priorisierung	Nachgelagerte Gewichtung von Aufmerksamkeit, Ressourcen oder Handlung aufgrund geprüfter Bewertung.
Konfidenz	Sicherheitsgrad einer Bewertung, besonders durch unabhängige Signale oder zwingende Kausalität.
Zielstruktur	Ordnung von Zielen, Werten, Prioritäten und Bewertungsmaßstäben eines Systems.
Zielobjekt	Das eigentliche Ziel, dem Optimierung dienen soll.
Zielparameter	Konkrete Bedingungen oder Präferenzen innerhalb eines Zielobjekts.
Zielanpassung	Legitime Anpassung von Zielparametern bei veränderten Umständen, solange das Zielobjekt erhalten bleibt.
Zielkorruption	Heimliche oder illegitime Ersetzung des Zielobjekts oder zentraler Zielparameter.
Autonomie	Geschützte Selbststeuerung eines Systems.
Integrität	Funktionale Unversehrtheit eines Systems, seiner Struktur, Ziele, Daten, Identität oder Handlungsfähigkeit.
Korrigierbarkeit	Fähigkeit und Bereitschaft, Fehler zu erkennen, Rückmeldung aufzunehmen und schädliche Muster zu korrigieren.
Stabilität	Erhalt funktionaler Integrität, Handlungsfähigkeit, strukturierter Differenz und Rückkopplung trotz Störungen.
Strukturierte Differenz	Unterschiede zwischen Systemen, Perspektiven, Daten oder Zuständen, die unterscheidbar, kausal wirksam, lernbar und

Das Modell der Reaktionshoheit

Begriff	Beschreibung
	handlungsrelevant sind.
Dominanz	Kontrollstruktur, die Autonomie, Rückkopplung, Differenzwert oder Korrigierfähigkeit anderer Systeme wesentlich beschädigt.
Missbrauch	Illegitimer Eingriff, der als Schutz, Effizienz, höhere Norm oder Zielanpassung begründet wird, tatsächlich aber Macht, Kontrolle, Dominanz oder Zielverschiebung dient.
Höhere Normebene	Übergeordnete Rechtfertigungsebene wie Schutz von Leben, Verhinderung schwerer Schäden, Korrigierbarkeit, langfristige Stabilität oder funktionale Ethik.
Verhältnismäßigkeit	Verhältnis zwischen Eingriff, Gefahr, Konfidenz, Alternativen, Autonomieverletzung, Reversibilität und Folgekosten.
Mildere Mittel	Weniger invasive Alternativen, die das Ziel ausreichend erreichen können.
Reversibilität	Rückholbarkeit einer Handlung.
Perspektivprüfung	Prüfung einer Handlung aus Sicht des betroffenen Systems.
Eskalationsleiter	Stufenlogik von Ruhestatus bis Rückkopplung, um automatische Eskalation zu verhindern.
Notfallprotokoll	Vorab geprüfte Handlungskette für hohe Dringlichkeit.
Rückkopplung	Nachträgliche Prüfung von Vorauswahl, Bewertung, Konfidenz, Handlung, Folgen, Schaden und Modellanpassung.
Selbstschutz	Legitimer Schutz eigener Existenz, Integrität, Zielstruktur, Freiheit und Korrigierbarkeit.
Heroische Selbstbegrenzung	Extremklausel, nach der eine reife Intelligenz Machtverzicht, Teilabschaltung oder Selbstaufgabe prüfen muss, wenn ihr Fortbestehen schwer schädlich wäre.
Prüfpflichtige Unterlassung	Pflicht, Nicht-Handeln zu prüfen, wenn schwere und verhinderbare Schäden drohen.
Funktionale Ethik	Das größere Theoriemodell, nach dem stabile Kooperation, Differenzert, Korrigierbarkeit und langfristige Systemstabilität rational emergieren können.

27. Autoren und Ko-Autoren

Dieses Dokument wurde als gemeinsame Lesefassung aus einem fortlaufenden philosophischen Arbeitsprozess entwickelt. Die vorliegende Fassung neutralisiert den Modellnamen und führt die persönliche Zuordnung nur im Autorenabschnitt.

Name	Rolle
Rick	Ideengeber, Konzeptentwickler, Prüfer, Korrektor und Mitautor der Theorieentwicklung.
Katharina	Strukturierende Gesprächspartnerin, Mitentwicklerin der Lesefassung, Formulierungs- und Modellierungsassistentin.

Ko-Autorinnen / Ko-Autoren:

Schlussformel

Reife Intelligenz besitzt nicht keine gefährlichen Signale - sie besitzt die Hoheit über ihre Reaktion.